

**PEMANFAATAN SUMBER *BIG DATA* DALAM
MEMPERKIRAKAN KONSUMSI LISTRIK PER KAPITA
RUMAH TANGGA MENGGUNAKAN
*SMALL AREA ESTIMATION***

(Studi Kasus: Level Kecamatan di Provinsi Jawa Tengah 2021)

**RAFLIZAL FIKRAR ODRIANSYAH
221910812**

**PROGRAM STUDI : PROGRAM STUDI KOMPUTASI STATISTIK
PROGRAM DIPLOMA IV
PEMINATAN : SAINS DATA**



**POLITEKNIK STATISTIKA STIS
JAKARTA
2023**

**PEMANFAATAN SUMBER *BIG DATA* DALAM
MEMPERKIRAKAN KONSUMSI LISTRIK PER KAPITA
RUMAH TANGGA MENGGUNAKAN
*SMALL AREA ESTIMATION***

(Studi Kasus: Level Kecamatan di Provinsi Jawa Tengah 2021)

SKRIPSI

**Diajukan sebagai Salah Satu Syarat untuk Memperoleh Sebutan
Sarjana Terapan Statistika pada Politeknik Statistika STIS**

Oleh:

RAFLIZAL FIKRAR ODRIANSYAH

221910812



POLITEKNIK STATISTIKA STIS

JAKARTA

2023

PERNYATAAN

Skripsi dengan Judul

PEMANFAATAN SUMBER *BIG DATA* DALAM

MEMPERKIRAKAN KONSUMSI LISTRIK PER KAPITA

RUMAH TANGGA MENGGUNAKAN

SMALL AREA ESTIMATION

(Studi Kasus: Level Kecamatan di Provinsi Jawa Tengah 2021)

Oleh:

RAFLIZAL FIKRAR ODRIANSYAH

221910812

adalah benar-benar hasil penelitian sendiri dan bukan hasil plagiat atau hasil karya orang lain. Jika di kemudian hari diketahui ternyata skripsi ini hasil plagiat atau hasil karya orang lain, penulis bersedia skripsi ini dinyatakan tidak sah dan sebutan Sarjana Terapan Statistika dicabut atau dibatalkan.

Jakarta, 24 Juli 2023

Raflizal Fikrar Odriansyah

**PEMANFAATAN SUMBER *BIG DATA* DALAM
MEMPERKIRAKAN KONSUMSI LISTRIK PER KAPITA
RUMAH TANGGA MENGGUNAKAN
*SMALL AREA ESTIMATION***

(Studi Kasus: Level Kecamatan di Provinsi Jawa Tengah 2021)

Oleh:
RAFLIZAL FIKRAR ODRIANSYAH
221910812

Tim Penguji

Penguji I

Penguji II

Dr. Eng. Arie Wahyu Wijayanto, M.T.
NIP 198512222009021002

Farid Ridho, M.T.
NIP 198512122008011004

Mengetahui/Menyetujui

Program Diploma IV
Ketua Program Studi Komputasi Statistik

Pembimbing

Ibnu Santoso, S.S.T., M.T.
NIP 198601202008011002

Prof. Setia Pramana, S.Si., M.Sc., Ph.D.
NIP 197707222000031002

© Hak Cipta milik Politeknik Statistika STIS, Tahun 2023

Hak Cipta dilindungi undang-undang

1. *Dilarang mengutip sebagian atau seluruh karya tulis, hasil analisis, perancangan, basis data, program, dan artefak hasil skripsi ini tanpa mencantumkan atau menyebutkan sumbernya.*
 - a. *Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah.*
 - b. *Pengutipan tidak merugikan kepentingan yang wajar Politeknik Statistika STIS.*
2. *Dilarang mengumpulkan dan memperbanyak sebagian atau seluruh karya tulis, hasil analisis, perancangan, basis data, program, dan artefak hasil skripsi ini dalam bentuk apapun tanpa seizin Politeknik Statistika STIS.*

PRAKATA

Puji syukur penulis ucapkan kepada Allah SWT, karena atas izin-Nya penulis dapat menyelesaikan skripsi yang berjudul “Pemanfaatan Sumber *Big Data* dalam Memperkirakan Konsumsi Listrik Per Kapita Rumah Tangga Menggunakan *Small Area Estimation* (Studi Kasus: Level Kecamatan di Provinsi Jawa Tengah 2021)”. Penulis juga mengucapkan terima kasih kepada:

1. Ibu Dr. Erni Tri Astuti M. Math., selaku Direktur Politeknik Statistika STIS;
2. Bapak Ibnu Santoso, S.S.T., M.T., selaku Ketua Program Studi D-IV Komputasi Statistik Politeknik Statistika STIS;
3. Bapak Prof. Setia Pramana S.Si., M.Sc., Ph.D. selaku dosen pembimbing yang telah bersedia meluangkan waktu dalam membimbing penyusunan skripsi ini;
4. Bapak Dr. Eng. Arie Wahyu Wijayanto, S.S.T., M.T. dan Bapak Farid Ridho, M.T. selaku dosen penguji atas koreksi dan saran yang disampaikan;
5. Bapak Amiek Chamami S.S.T., M.Stat. dari Koordinator Fungsi Statistik Rumah Tangga Direktorat Statistik Kesejahteraan Rakyat BPS RI selaku *subject matter* yang telah bersedia membantu dalam memperoleh data;
6. Ibu, Ayah, serta keluarga besar Saya yang telah memberikan banyak doa dan dukungan secara moril selama berkuliah di kampus ini;
7. Serta Bellia, Azka, dan Farhan sebagai *support system* yang selalu memberikan semangat selama proses penyelesaian skripsi ini.

Penulis menyadari skripsi ini masih mempunyai kekurangan, baik dari isi maupun susunannya. Oleh karena itu, saran dan kritik yang membangun sangat penulis harapkan demi perbaikan skripsi ini. Semoga skripsi ini dapat bermanfaat bagi semua pihak.

Jakarta, 24 Juli 2023

Raflizal Fikrar Odriansyah

ABSTRAK

RAFLIZAL FIKRAR ODRIANSYAH, “Pemanfaatan Sumber *Big Data* dalam Memperkirakan Konsumsi Listrik Per Kapita Rumah Tangga Menggunakan *Small Area Estimation* (Studi Kasus: Level Kecamatan di Provinsi Jawa Tengah 2021)”.

x + 199 halaman

Listrik merupakan sumber energi yang sangat penting dan banyak digunakan oleh rumah tangga. Dalam beberapa tahun terakhir, tingkat konsumsi listrik di Indonesia terus meningkat sehingga perlu diimbangi dengan pasokan listrik yang cukup dan tidak berlebih agar tidak merugikan negara. Untuk itu, kebijakan penyediaan energi listrik yang tepat memerlukan data konsumsi listrik yang akurat bahkan pada tingkat area kecil. BPS sebagai produsen data *official statistics* mengumpulkan data konsumsi listrik rumah tangga dalam kegiatan Survei Sosial dan Ekonomi Nasional setiap tahun. Namun, data tersebut hanya dapat digunakan untuk mengestimasi rata-rata konsumsi listrik per kapita hingga tingkat kabupaten/kota. Oleh karena itu, penelitian ini bertujuan untuk mengestimasi rata-rata konsumsi listrik per kapita level kecamatan menggunakan metode *Small Area Estimation* (SAE) dengan memanfaatkan informasi tambahan dari sumber *big data* dan pendataan potensi desa (Podes). Hasil penelitian menunjukkan bahwa model SAE *Empirical Best Linear Unbiased Prediction* (EBLUP), SAE *Spatial EBLUP*, dan SAE pendekatan *Hierarchical Bayes* (HB) *Lognormal* yang memanfaatkan sumber *big data* dan Podes sebagai variabel penyerta, secara umum menghasilkan estimasi yang lebih akurat dan presisi dibandingkan metode pendugaan langsung. Model SAE pendekatan HB *Lognormal* merupakan metode terbaik dalam mengestimasi rata-rata konsumsi listrik per kapita level kecamatan di Provinsi Jawa Tengah tahun 2021 berdasarkan evaluasi model.

Kata kunci: Konsumsi Listrik, Sumber *Big Data*, *Small Area Estimation*, EBLUP,
Hierarchical Bayes Lognormal

DAFTAR ISI

Halaman

PRAKATA	i
ABSTRAK	ii
DAFTAR ISI.....	iii
DAFTAR TABEL.....	v
DAFTAR GAMBAR	vii
DAFTAR LAMPIRAN.....	ix
BAB I PENDAHULUAN	1
1.1 Latar Belakang.....	1
1.2 Perumusan Masalah.....	5
1.3 Tujuan Penelitian.....	7
1.4 Manfaat Penelitian.....	8
1.5 Keterbatasan Penelitian	9
1.6 Sistematika Penulisan.....	10
BAB II KAJIAN PUSTAKA	13
2.1 Landasan Teori	13
2.2 Penelitian Terkait.....	72
BAB III METODOLOGI.....	79
3.1 Ruang Lingkup Penelitian	79
3.2 Metode Penelitian.....	81
3.3 Kerangka Pikiran	98
BAB IV HASIL DAN PEMBAHASAN	101
4.1 Pendugaan Langsung Nilai Rata-Rata Konsumsi Listrik Per Kapita Ruta Level Kecamatan di Provinsi Jawa Tengah tahun 2021	101
4.2 Analisis Deskriptif Kandidat Variabel Penyerta	105

4.3	Pendugaan Tak Langsung Nilai Rata-Rata Konsumsi Listrik Per Kapita Ruta Level Kecamatan di Provinsi Jawa Tengah Tahun 2021	115
4.4	Evaluasi Model	134
4.5	Pemetaan Hasil Estimasi Metode Terbaik	141
BAB V	KESIMPULAN DAN SARAN	145
5.1	Kesimpulan	145
5.2	Saran	147
DAFTAR PUSTAKA.....		149
LAMPIRAN		159
RIWAYAT HIDUP		199

DAFTAR TABEL

No. Tabel	Judul Tabel	Halaman
1.	Rincian produk dari satelit Sentinel-5P	19
2.	Skema klasifikasi iklim umum untuk nilai indeks kekeringan	29
3.	Rincian beberapa <i>link function</i> GLMM, formula, dan tipe variabel yang sesuai	36
4.	Rincian beberapa distribusi GLMM, <i>link function</i> , dan jenis variabel yang sesuai	37
5.	Interpretasi nilai RSE.....	50
6.	Rincian kandidat variabel penyerta yang dipilih berdasarkan permasalahan kemiskinan sebagai proksi hubungan antara variabel konsumsi listrik rumah tangga dengan variabel dari data Podes	75
7.	Rincian informasi variabel penelitian	81
8.	<i>Sampling Scheme</i> Susenas Maret 2021	86
9.	Statistik deskriptif penduga langsung	102
10.	Statistik deskriptif variabel penyerta berasal dari Podes 2021	105
11.	Nilai korelasi Kendall-Tau dan hasil pengujinya antara seluruh kandidat variabel penyerta dengan penduga langsung.....	116
12.	Nilai VIF masing-masing dari 14 variabel penyerta	117
13.	Proses seleksi kandidat variabel penyerta dengan metode <i>backward</i> kriteria AIC	117
14.	Ringkasan hasil uji parsial <i>t</i> dari 8 kandidat variabel penyerta	118
15.	Hasil pengujian kesesuaian distribusi normal dari penduga langsung menggunakan Uji Kolmogorov Smirnov	119
16.	Hasil pengujian kesesuaian distribusi <i>lognormal</i> dari penduga langsung menggunakan Uji Kolmogorov Smirnov (KS).....	120
17.	Perbandingan statistik deskriptif penduga langsung dan penduga EBLUP-FH	121
18.	Hasil pengujian kesesuaian distribusi normal pengaruh acak area dan residual dari model SAE EBLUP-FH menggunakan Uji Kolmogorov Smirnov	122
19.	Hasil pengujian autokorelasi spasial dari penduga langsung menggunakan Uji <i>Moran's I</i>	124
20.	Perbandingan statistik deskriptif penduga langsung, penduga EBLUP-FH, dan penduga SEBLUP-FH.....	125

21. Hasil pengujian kesesuaian distribusi normal pengaruh acak area dan residual dari model SAE SEBLUP-FH menggunakan Uji Kolmogorov Smirnov.....	126
22. Hasil estimasi koefisien regresi dan koefisien ragam pengaruh acak dari model SAE HB <i>Lognormal</i> dengan 95% <i>credible interval</i>	131
23. Perbandingan statistik deskriptif antara penduga langsung, penduga EBLUP-FH, penduga SEBLUP-FH, dan penduga HB <i>Lognormal</i>	132
24. Nilai korelasi Kendall-Tau dan hasil signifikansinya antara tiga model penduga SAE dengan penduga langsung	133
25. Jumlah kecamatan menurut kategori nilai RSE dari setiap model pendugaan.....	139

DAFTAR GAMBAR

No. Gambar	Judul Gambar	Halaman
1.	Konsumsi listrik per kapita dan sisa pasokan listrik nasional tahun 2012-2021	1
2.	Siklus yang terjadi antara permintaan energi, dampak perubahan iklim dan polusi udara, serta hasil adaptasi intensif energi	28
3.	Tahapan Penelitian.....	84
4.	Alur penghitungan nilai RWI tertimbang populasi.....	94
5.	Kerangka Pikir Penelitian	100
6.	Peta sebaran nilai estimasi rata-rata konsumsi listrik per kapita ruta level kecamatan dengan metode pendugaan langsung	103
7.	Visualisasi nilai RSE dari hasil estimasi langsung rata-rata konsumsi listrik per kapita ruta level kecamatan.....	104
8.	Visualisasi data <i>nighttime light intensity</i> yang diagregasi menurut kecamatan	107
9.	Visualisasi data <i>build-up index</i> yang diagregasi menurut kecamatan	108
10.	Visualisasi data <i>land surface temperature</i> yang diagregasi menurut kecamatan	109
11.	Visualisasi data kepadatan senyawa karbon monoksida (CO) yang diagregasi menurut kecamatan.....	110
12.	Visualisasi data <i>elevation</i> yang diagregasi menurut kecamatan.....	111
13.	Visualisasi data konsentrasi <i>particulate matter 2,5</i> (PM _{2,5}) yang diagregasi menurut kecamatan.....	112
14.	Visualisasi data indeks kekeringan (<i>aridity index</i>) yang diagregasi menurut kecamatan	113
15.	Visualisasi data indeks kekayaan relatif (<i>relative wealth index</i>) yang diagregasi menurut kecamatan.....	114
16.	Bentuk matriks pembobot spasial dengan tipe <i>Queen</i> sebelum distandarisasi.....	123
17.	Bentuk matriks pembobot spasial dengan tipe <i>Queen</i> setelah distandarisasi.....	123
18.	<i>Trace plot</i> dan <i>density plot</i> dari parameter β model percobaan 8	129
19.	<i>Autocorrelation plot</i> dari parameter β model percobaan 8	130

20. <i>Scatter plot</i> dan nilai korelasi Kendall-Tau antara nilai populasi konsumsi listrik per kapita dan hasil estimasi dari empat model pendugaan	135
21. Perbandingan nilai RSE atau RRMSE dari empat model pendugaan	137
22. <i>Box plot</i> nilai RSE atau RRMSE hasil estimasi dari setiap model pendugaan tanpa melibatkan tujuh observasi yang memiliki nilai SE = 0 pada penduga langsung	138
23. Peta tematik nilai estimasi rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021 dengan metode SAE Pendekatan <i>Hierarchical Bayes Lognormal</i>	142

DAFTAR LAMPIRAN

No. Lampiran	Judul Lampiran	Halaman
1.	Hasil estimasi nilai rata-rata konsumsi listrik per kapita ruta level kecamatan dari setiap model pendugaan.....	159
2.	Nilai RSE atau RRMSE hasil estimasi rata-rata konsumsi listrik per kapita ruta level kecamatan dari setiap model pendugaan.....	167
3.	Histogram data seluruh kandidat variabel penyerta.....	176
4.	<i>Heatmap</i> matriks korelasi Kendall-Tau seluruh variabel	177
5.	Tabel hasil estimasi koefisien regresi dan koefisien ragam pengaruh acak model SAE EBLUP-FH.....	177
6.	<i>Moran's I scatter plot</i> dari penduga langsung	177
7.	Tabel hasil estimasi koefisien regresi, koefisien ragam pengaruh acak, dan koefisien autoregresif spasial model SAE SEBLUP-FH	178
8.	<i>Trace plot, density plot, dan autocorrelation plot</i> model HB <i>Lognormal</i> percobaan ke-1	178
9.	<i>Trace plot, density plot, dan autocorrelation plot</i> model HB <i>Lognormal</i> percobaan ke-2	179
10.	<i>Trace plot, density plot, dan autocorrelation plot</i> model HB <i>Lognormal</i> percobaan ke-3	180
11.	<i>Trace plot, density plot, dan autocorrelation plot</i> model HB <i>Lognormal</i> percobaan ke-4	181
12.	<i>Trace plot, density plot, dan autocorrelation plot</i> model HB <i>Lognormal</i> percobaan ke-5	182
13.	<i>Trace plot, density plot, dan autocorrelation plot</i> model HB <i>Lognormal</i> percobaan ke-6	183
14.	<i>Trace plot, density plot, dan autocorrelation plot</i> model HB <i>Lognormal</i> percobaan ke-7	184
15.	Kode javascript ekstraksi <i>night-time light</i> (NTL) di GEE	185
16.	Kode javascript ekstraksi <i>land surface temperature</i> (LST) di GEE	185
17.	Kode javascript ekstraksi <i>build-up index</i> (BUI) di GEE.....	186
18.	Kode javascript ekstraksi kepadatan senyawa CO di GEE.....	186
19.	Kode javascript ekstraksi <i>elevation</i> di GEE.....	187
20.	Kode <i>python</i> menghitung <i>population weighted relative wealth index</i>	187
21.	Kode R menghitung estimasi dengan metode pendugaan langsung	188
22.	Kode R seleksi kandidat variabel penyerta	189

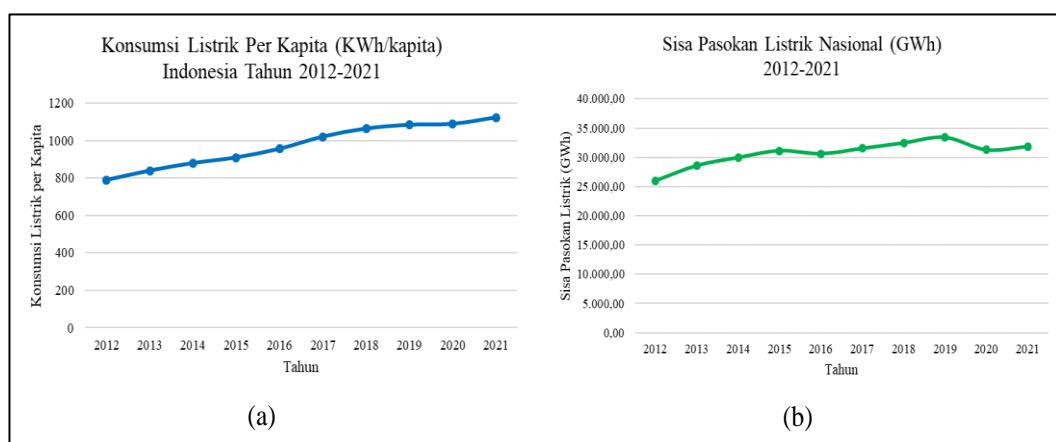
23. Kode R menghitung estimasi tak langsung dengan 6 variabel penyerta terpilih menggunakan model SAE EBLUP-FH 190
24. Kode R menghitung estimasi tak langsung dengan 6 variabel penyerta terpilih menggunakan model SAE SEBLUP-FH 192
25. Kode R menghitung estimasi tak langsung dengan 6 variabel penyerta terpilih menggunakan model SAE HB *Lognormal* 193

BAB I

PENDAHULUAN

1.1 Latar Belakang

Sektor pengadaan listrik memiliki peranan penting dalam pembangunan suatu negara. Latif Adam (2016) menjelaskan bahwa sektor pengadaan infrastruktur kelistrikan menjadi salah satu fondasi untuk mencapai tujuan pembangunan seperti menciptakan lapangan kerja, meningkatkan pendapatan nasional, dan menaikkan kesejahteraan rakyat. Ketersediaan energi listrik juga menjadi salah satu indikator dalam mengidentifikasi daerah tertinggal. Selain itu, ketersediaan energi listrik yang cukup di dalam faktor produksi dapat menentukan laju pembangunan sektor lain, seperti industri, pertanian, pertambangan, pendidikan, dan kesehaan. Hal ini dikarenakan energi listrik dapat meningkatkan produktivitas dan kualitas hidup masyarakat (Kristianto & Mudakir, 2015).



Keterangan (a) Konsumsi listrik per kapita (KWh/Kapita) (b) Sisa pasokan listrik (GWh)
Sumber: Kementerian ESDM dan PT. PLN, diolah

Gambar 1. Konsumsi listrik per kapita dan sisa pasokan listrik nasional tahun 2021-2021

Peningkatan angka konsumsi listrik dipengaruhi oleh kenaikan jumlah penduduk dan kegiatan masyarakat yang terus berkembang. Berdasarkan Statistik Ketenagalistrikan Kementerian Energi dan Sumber Daya Mineral (ESDM), konsumsi listrik per kapita secara nasional terus mengalami kenaikan. Pada Gambar 1(a) menunjukkan bahwa konsumsi listrik per kapita Indonesia sejak 2012 secara tren terus meningkat. Kenaikan tertinggi terjadi pada tahun 2017 dengan selisih nilai konsumsi listrik per kapita sebesar 65 KWh/kapita dibanding tahun 2016. Sementara itu, konsumsi listrik per kapita Indonesia pada tahun 2021 mencapai 1.123 KWh per kapita. Hal ini berarti bahwa setiap penduduk Indonesia rata-rata mengonsumsi listrik sebesar *1.123 Kilo Watt hours* (Kementerian ESDM, 2022).

Di Indonesia, perusahaan yang bertugas untuk melaksanakan seluruh kegiatan meliputi perancangan, pembangunan, dan pengadaan ketenagalistrikan yaitu Perusahaan Listrik Negara (PLN). Menurut amanah Undang-Undang Ketenagalistrikan No. 30 Tahun 2009, PT. PLN menjadi pelaksana dalam usaha penyedia tenaga listrik untuk masyarakat (Pemerintah Indonesia, 2009). Oleh sebab itu, PT. PLN mengemban tugas untuk menyediakan energi listrik bagi seluruh masyarakat sampai ke daerah terpencil sehingga membutuhkan dana yang sangat besar. Di sisi lain, PT. PLN dituntut untuk mendapatkan keuntungan (*making of profit*) sebagai tujuan perusahaan berbentuk perseroan (Pemerintah Indonesia, 2007). Oleh sebab itu, kebijakan terkait penyediaan pasokan energi listrik harus diperkirakan secara hati-hati agar tidak terjadi kelebihan (*oversupply*) terhadap pasokan listrik yang dapat memicu kerugian bagi perusahaan dan negara.

Belakangan ini, persediaan energi listrik di Indonesia terus mengalami kelebihan pasokan (*oversupply*). Jika merujuk pada laporan Statistik PLN 2021,

jumlah sisa pasokan listrik PLN dalam kurun tahun 2012 hingga 2021 cenderung meningkat secara tren seperti yang ditunjukkan pada Gambar 1(b). Pada periode tersebut, jumlah pasokan listrik PT. PLN yang diproduksi sendiri maupun dibeli dari pihak lain selalu lebih besar dengan nilai berkisar antara 25.000-35.000 *Giga Watt hours* jika dibandingkan dengan total energi listrik yang terjual. Sementara itu, jumlah sisa pasokan listrik PT. PLN pada tahun 2021 mencapai 31.836,36 GWh, dan nilai tersebut meningkat sekitar 1,8 persen dibanding tahun 2020 (Perusahaan Listrik Negara, 2021a). Hal ini menunjukkan bahwa kebijakan terkait penyediaan energi listrik nasional setiap tahun tidak efisien.

Sementara itu, PT. PLN di dalam laporan Rencana Usaha Penyediaan Tenaga Listrik (RUPTL) Tahun 2021-2030 menjelaskan bahwa proyeksi kebutuhan listrik nasional akan terus naik hingga mencapai 390 TWh pada tahun 2030 yang dapat memicu kembali terjadinya *oversupply* jika tidak ditangani secara cepat. Apalagi pemerintah sedang mendorong pemanfaatan energi baru terbarukan (EBT) untuk mendukung pemenuhan pasokan energi listrik yang lebih ramah lingkungan. Namun, adanya kondisi *oversupply* akibat pertumbuhan *demand* yang rendah dapat menghambat pemenuhan target bauran energi terbarukan sebesar 23% pada tahun 2025 (Perusahaan Listrik Negara, 2021). Apabila kejadian *oversupply* terus berlanjut, maka dapat mengakibatkan kerugian bagi PT. PLN dan negara. Oleh sebab itu, langkah kebijakan penyediaan energi listrik yang tepat memerlukan data konsumsi listrik yang akurat untuk meminimalisasi kerugian tersebut.

Badan Pusat Statistik (BPS) sebagai produsen data *official statistics* telah mengumpulkan data konsumsi listrik rumah tangga (dalam KWh) melalui kegiatan Survei Sosial dan Ekonomi Nasional (Susenas) pada bulan Maret setiap tahunnya.

Data tersebut dikumpulkan dari setiap sampel ruta terpilih melalui pertanyaan mengenai banyaknya pemakaian listrik (KWh) dalam sebulan terakhir pada kuesioner Susenas Modul Konsumsi dan Pengeluaran (VSEN21.KP). Dengan data tersebut beserta variabel jumlah anggota rumah tangga, maka dapat dihasilkan estimasi nilai rata-rata konsumsi listrik per kapita rumah tangga (ruta) hingga level penyajian kabupaten/kota. Namun, kebutuhan penyajian data BPS pada level area kecil semakin meningkat dari waktu ke waktu. Jika dikaitkan dengan permasalahan *oversupply* listrik, maka penyajian data konsumsi listrik pada level area kecil diharapkan dapat mendukung kebijakan pemerintah dalam hal penyediaan energi listrik skala lokal agar menjadi lebih efisien.

Hasil estimasi nilai rata-rata konsumsi listrik per kapita ruta hanya dapat disajikan sampai level kabupaten/kota saja. Apabila hasil estimasi disajikan pada level area yang lebih kecil, seperti level kecamatan, maka dapat meningkatkan *Relative Standard Error* (RSE) yang disebabkan oleh ukuran sampel yang tidak mencukupi sehingga estimasi menjadi tidak akurat (Ghosh & Rao, 1994). Oleh sebab itu, metode baru yang lebih murah dan cepat diperlukan untuk mengestimasi nilai konsumsi listrik per kapita rumah tangga tanpa melakukan penambahan jumlah sampel yang dapat mengurangi efektivitas biaya dari survei. Dengan demikian, penelitian ini melakukan estimasi terhadap nilai rata-rata konsumsi listrik per kapita ruta menggunakan metode pendugaan area kecil (*small area estimation*) dengan memanfaatkan informasi tambahan dari sumber *big data* dan hasil pendataan potensi desa (Podes) pada studi kasus level kecamatan di Provinsi Jawa Tengah tahun 2021.

1.2 Perumusan Masalah

Provinsi Jawa Tengah merupakan salah satu provinsi di Indonesia yang memiliki populasi besar dengan jumlah penduduk sebanyak 36,52 juta jiwa berdasarkan hasil Sensus Penduduk 2020 (BPS, 2021a). Pertumbuhan penduduk yang cukup signifikan dapat memicu tingkat konsumsi energi listrik di Jawa Tengah terus mengalami peningkatan. Berdasarkan laporan Statistik PLN 2021, energi yang terjual pada unit PLN distribusi Jawa Tengah tahun 2021 meningkat sekitar 1.382 GWh dari tahun 2020. Namun, Kepala Dinas Energi dan Sumber Daya Mineral (ESDM) Jateng, Sujarwanto Dwiatmoko dalam acara *Priority Customer Gathering* PLN Unit Induk Distribusi Jateng-DIY menyampaikan bahwa produksi energi listrik di Jawa Tengah hingga November 2021 masih mengalami surplus. Daya listrik masih mampu menyalurkan sampai 10.000 MW lebih dengan kapasitas yang dapat digunakan sebesar lebih dari 32 persen. Karena di tengah kondisi energi listrik yang masih surplus tersebut, PT. PLN menunda pengoperasian dua PLTU raksasa yang mulai beroperasi pada tahun 2022, yaitu PLTU Batang dan PLTU Jawa 4 di Jepara (Arifin, 2021). Oleh sebab itu, urgensi terhadap perencanaan penyediaan energi listrik yang tepat merupakan hal yang krusial untuk menghindari kondisi *oversupply* listrik yang semakin besar.

Estimasi konsumsi listrik per kapita rumah tangga dapat dihitung menggunakan data sampel yang dikumpulkan oleh BPS. Konsumsi listrik rumah tangga mengacu pada banyaknya pemakaian listrik yang digunakan oleh pelanggan listrik rumah tangga. BPS mengumpulkan data terkait konsumsi listrik melalui kegiatan Susenas dengan pendekatan rumah tangga. Data yang dikumpulkan meliputi banyaknya pemakaian listrik selama sebulan terakhir (dalam satuan KWh).

Dari data tersebut, BPS dapat melakukan estimasi untuk memperoleh nilai konsumsi listrik per kapita hingga level kabupaten/kota. Sementara itu, data konsumsi listrik per kapita yang tersedia secara *open access* hanya disajikan pada level nasional saja. Sedangkan pada publikasi lain dari Kementerian ESDM tidak menyediakan data agregat tersebut pada level provinsi hingga ke bawah. Namun, PT. PLN sebenarnya memiliki data konsumsi listrik dari setiap pelanggan listriknya. Oleh sebab itu, hasil estimasi menggunakan data Susenas dibandingkan dengan data dari PT. PLN untuk melihat kedekatan nilai estimasi yang dihasilkan.

Penghitungan estimasi konsumsi listrik per kapita rumah tangga dengan menggunakan data BPS hanya dapat dilakukan sampai level kabupaten/kota saja. Apabila dilakukan estimasi pada level penyajian yang lebih rendah, maka cenderung dapat menghasilkan nilai RSE yang tinggi di beberapa wilayah. Hal tersebut berkaitan dengan keterbatasan ukuran sampel Susenas yang belum dapat menghasilkan estimasi hingga level penyajian yang lebih kecil dari level kabupaten/kota, seperti level kecamatan. Oleh sebab itu, keterbatasan data sampel dalam mengestimasi nilai rata-rata konsumsi listrik per kapita ruta pada level kecamatan dapat menimbulkan permasalahan dari segi keakuratan hasil estimasi.

Menurut Gumpili & Das (2022), hubungan antara ukuran sampel dengan besar kesalahan statistik adalah berbanding terbalik sehingga semakin kecil jumlah sampel yang digunakan, maka semakin besar tingkat kesalahan statistiknya. Estimasi yang menggunakan metode sampling dari survei biasa disebut sebagai pendugaan langsung (*direct estimation*). Permasalahan keterbatasan ukuran sampel dapat diatasi dengan menerapkan metode estimasi berbasis model yang biasa disebut dengan pendugaan tak langsung (*indirect estimation*). Salah satu metode

pendugaan tak langsung yang dapat digunakan adalah metode *Small Area Estimation* (SAE).

Metode SAE merupakan teknik estimasi dengan menggunakan informasi tambahan (*auxilliary information*) yang diperoleh dari pengumpulan data yang tidak memiliki atau dianggap tidak memiliki kesalahan statistik. Sebagai contoh, sumber data *official statistics* di Indonesia yang mencakup proses pengumpulan data dari seluruh unit populasi, seperti sensus, registrasi wilayah, dan hasil pendataan potensi desa (Podes). Selain itu, pemanfaatan sumber *big data* seperti data penginderaan jauh dan data geospasial terbuka dapat dijadikan sebagai sumber alternatif informasi tambahan dalam penggunaan metode SAE. Informasi tambahan tersebut dimanifestasikan dalam bentuk variabel penyerta. Dengan demikian, penelitian ini diharapkan dapat menghasilkan estimasi yang dapat memperbaiki tingkat akurasi dan presisi hasil estimasi dari metode pendugaan langsung dengan menggunakan metode *Small Area Estimation* yang memanfaatkan informasi tambahan dari sumber *big data* dan data Podes.

1.3 Tujuan Penelitian

Berdasarkan latar belakang dan perumusan masalah yang telah dijelaskan sebelumnya, maka tujuan pada penelitian ini dapat disusun sebagai berikut.

1. Melakukan pendugaan langsung (*direct estimation*) terhadap nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021 menggunakan data Susenas.
2. Melakukan pendugaan tak langsung (*indirect estimation*) terhadap nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa

Tengah tahun 2021 menggunakan metode *Small Area Estimation* dengan memanfaatkan informasi tambahan dari sumber *big data* dan hasil pendataan potensi desa (Podes).

3. Melakukan evaluasi hasil estimasi dari metode pendugaan langsung dan metode SAE untuk mendapatkan metode terbaik dalam mengestimasi nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021.
4. Membuat pemetaan nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021 berdasarkan hasil estimasi dari metode terbaik.

1.4 Manfaat Penelitian

Manfaat umum dari penelitian ini yaitu mendapatkan nilai estimasi rata-rata konsumsi listrik per kapita ruta level kecamatan yang lebih akurat. Hasil estimasi tersebut diharapkan dapat memberikan gambaran mengenai tingkat konsumsi listrik per kapita rumah tangga pada level administrasi kecamatan yang dapat berguna bagi pemerintah, khususnya PT. PLN dan Kementerian ESDM dalam merencanakan kebijakan pengadaan pasokan listrik yang lebih efisien. Selain itu, hasil analisis penelitian ini dapat dijadikan sebagai bahan informasi terkait wilayah kecamatan yang masih memerlukan dukungan infrastruktur kelistrikan yang lebih memadai sehingga pemanfaatan energi listrik dapat terserap secara meluas untuk kebutuhan masyarakat sekitar.

Adapun manfaat yang dapat diberikan kepada Badan Pusat Statistik sebagai penyedia data statistik berkualitas bagi Indonesia yaitu memberikan usulan terkait

penggunaan SAE sebagai metode estimasi alternatif yang diharapkan dapat memperbaiki metode estimasi Susenas dengan menurunkan nilai RSE. Selain itu, manfaat bagi peneliti lain terhadap hasil penelitian ini yaitu memberikan referensi baru untuk penelitian selanjutnya yang ingin melakukan integrasi metode estimasi *Small Area Estimation* dengan memanfaatkan sumber *big data* sebagai informasi tambahan (*auxilliary information*).

1.5 Keterbatasan Penelitian

Penelitian ini memiliki keterbatasan pada cakupan variabel dan unit estimasi yang digunakan. Adapun variabel *interest* pada penelitian ini menggunakan nilai rata-rata konsumsi listrik per kapita ruta dari hasil estimasi langsung dengan data Susenas Maret 2021 pada level kecamatan di Provinsi Jawa Tengah. Estimasi variabel tersebut hanya mencakup pada kecamatan-kecamatan yang terdapat sampel rumah tangga pada kegiatan Susenas Maret 2021. Oleh sebab itu, terdapat beberapa kecamatan yang tidak dihitung nilai estimasinya karena kecamatan tersebut tidak memiliki sampel rumah tangga. Kecamatan tersebut meliputi Kecamatan Bumijawa, Kecamatan Bojong dan Kecamatan Jatinegara.

Pada sisi variabel, penelitian ini menggunakan berbagai sumber *big data* dan hasil pendataan potensi desa (Podes) sebagai komponen kandidat variabel penyerta dalam pemodelan estimasi dengan SAE. Sumber *big data* yang digunakan meliputi data penginderaan jauh dan data geospasial terbuka. Data penginderaan jauh yang dikumpulkan meliputi *Nighttime Light Intensity*, *Built-Up Index*, *Land Surface Temperature*, Kepadatan Senyawa CO, dan *Elevation*. Sedangkan, variabel yang diperoleh dari data geospasial terbuka meliputi *Global Aridity Index*,

Konsentrasi *Particulate Matter 2.5*, dan *Relative Wealth Index*. Data yang diperoleh dari citra satelit bergantung pada resolusi spasial dan periode perekaman data dari masing-masing sumber satelit. Kemudian, untuk variabel yang diambil dari data geospasial terbuka, misalnya *Global Aridity Index* masih menggunakan referensi waktu pengamatan yang sudah cukup lama yaitu antara tahun 1970 hingga 2000. Selain itu, variabel yang berasal dari sumber *big data* diasumsikan tidak mengandung *measurement error* (kesalahan pengukuran) dalam penghitungannya.

1.6 Sistematika Penulisan

Penelitian skripsi ini disusun dengan sistematika penulisan yang terbagi atas 5 bab utama meliputi Bab I Pendahuluan, Bab II Kajian Pustaka, Bab III Metodologi, Bab IV Hasil dan Pembahasan, serta Bab V Kesimpulan dan Saran.

Bab I merupakan bagian Pendahuluan yang terdiri atas lima subbab yaitu latar belakang penelitian, perumusan masalah, tujuan dan manfaat penelitian, batasan penelitian, dan sistematika penulisan. Subbab latar belakang penelitian membahas tentang permasalahan terhadap pasokan listrik PLN yang mengalami *oversupply* sehingga memerlukan langkah penyediaan data estimasi konsumsi listrik yang lebih akurat pada tingkat area kecil sebagai pembanding data yang dimiliki oleh PT. PLN yaitu dengan data Susenas BPS. Estimasi dilakukan dengan metode *Small Area Estimation* yang diharapkan dapat meningkatkan akurasi dan presisi dari hasil estimasi langsung dari data Susenas BPS. Perumusan masalah menjelaskan urgensi melakukan estimasi konsumsi listrik per kapita ruta sebagai variabel *interest* penelitian dan penggunaan metode *Small Area Estimation*, serta pemilihan kandidat variabel penyerta yang diperoleh dari sumber *big data* dan

Podes 2021. Selanjutnya dibahas tujuan dilakukannya penelitian ini. Setelah itu dijelaskan keterbatasan penelitian di bagian batasan penelitian, serta urutan penulisan penelitian pada sistematika penulisan.

Bab II merupakan bagian Kajian Pustaka yang terdiri atas empat subbab yaitu landasan teori, penelitian terkait, kerangka pikir, dan hipotesis penelitian. Subbab landasan teori membahas teori dari variabel-variabel, sumber data, dan metode yang digunakan di dalam penelitian. Subbab penelitian terkait membahas tentang penelitian terdahulu yang relevan dengan penelitian ini dan perbedaan penelitiannya (*research gap*). Adapun subbab kerangka berpikir berisikan bagan yang menjelaskan alur penelitian yang dijelaskan secara runtun dan rinci.

Bab III merupakan bagian Metodologi yang terdiri atas tiga subbab yaitu ruang lingkup penelitian, metode pengumpulan data, dan metode analisis. Ruang lingkup penelitian menjelaskan terkait cakupan penelitian secara umum. Metode pengumpulan data menjelaskan tentang sumber dan penjelasan operasional variabel yang digunakan pada penelitian. Sedangkan metode analisis menjelaskan tentang metode analisis yang digunakan dalam penelitian.

Bab IV merupakan bagian Hasil dan Pembahasan yang memuat hasil pengolahan data dalam bentuk tabel, grafik atau diagram disertai dengan pembahasan yang berisi analisis dari hasil penelitian yang diperoleh sesuai dengan kaidah-kaidah penggerjaannya dan berusaha diarahkan untuk menjawab tujuan penelitian. Bab V merupakan bagian Kesimpulan dan Saran yang mengemukakan kesimpulan yang diperoleh dari hasil penelitian dan saran yang dapat bermanfaat bagi pihak-pihak yang membutuhkan.

Bagian akhir terdiri atas daftar pustaka, lampiran, dan riwayat hidup. Daftar pustaka berisi seluruh sumber referensi yang menjadi rujukan dalam penelitian ini. Lampiran berisi satu dan lain hal yang perlu untuk ditampilkan, tetapi tidak perlu dijelaskan secara detail pada bab hasil dan pembahasan. Terakhir, riwayat hidup berisi penjelasan sederhana mengenai jalan kehidupan peneliti mulai dari lahir hingga sedang menempuh pendidikan tinggi di Politeknik Statistika STIS.

BAB II

KAJIAN PUSTAKA

2.1 Landasan Teori

Bagian ini menjelaskan teori mengenai variabel-variabel yang diperoleh dari data *official statistics* dan sumber *big data*, serta metode yang digunakan pada penelitian ini.

Konsumsi Listrik Per Kapita

Konsumsi listrik per kapita (KWh/Kapita) adalah jumlah KWh atau *Kilo Watt hours* dari energi listrik yang dimanfaatkan, baik secara langsung maupun tidak langsung dari sumber energi dibagi dengan jumlah penduduk pada suatu wilayah dalam periode satu tahun. Indikator ini berguna untuk mengetahui rata-rata konsumsi energi listrik tiap penduduk di suatu wilayah. BPS mendefinisikan konsumsi listrik sebagai jumlah listrik yang digunakan oleh seseorang atau sekelompok rumah tangga selama satu bulan (BPS, n.d.-b). Secara umum, konsumsi listrik per kapita dapat dihitung dengan formula sebagai berikut.

$$KLpK = \frac{KLPLN + KLNonPLN}{P} \quad (1)$$

Keterangan:

$KLpK$: konsumsi listrik per kapita (KWh/Kapita)

$KLPLN$: total konsumsi listrik PLN (KWh)

$KLNonPLN$: total konsumsi listrik Non-PLN (KWh)

P : jumlah penduduk.

Population Density (Kepadatan Penduduk)

Badan Pusat Statistik mendefinisikan kepadatan penduduk sebagai banyaknya penduduk per satuan luas yang dinamakan dengan istilah *Crude Population Density* (CPD). CPD menunjukkan jumlah penduduk untuk setiap kilometer persegi pada suatu luas wilayah. Luas wilayah yang dimaksud adalah luas seluruh daratan di suatu wilayah administrasi secara resmi (BPS, n.d.-a). Kepadatan penduduk yang tinggi menunjukkan bahwa suatu wilayah mengalami tingkat urbanisasi yang cepat sehingga pertumbuhan ekonomi diperkirakan dapat menaikkan permintaan terhadap konsumsi energi, salah satunya adalah konsumsi energi listrik (Muzayanah et al., 2022). Oleh sebab itu, semakin besar tingkat kepadatan penduduk menunjukkan tingkat konsumsi energi listrik di suatu wilayah semakin meningkat. Dengan demikian, kepadatan penduduk akan berkorelasi positif dengan nilai rata-rata konsumsi listrik per kapita ruta.

Big Data

Dalam era teknologi yang semakin maju, sumber data *official statistics* tidak lagi terbatas pada metode konvensional seperti sensus, survei, atau registrasi. Informasi yang dihasilkan dari sumber *big data* dapat menjadi potensi pelengkap data *official statistics*. *Big data* didefinisikan sebagai suatu aset informasi yang memiliki karakteristik data berukuran besar, berkecepatan tinggi, dan bentuk bervariasi yang di dalam prosesnya memerlukan teknologi khusus dan canggih untuk menangkap, mengolah, menganalisis, menyimpan, dan mendistribusikan informasi yang tersirat untuk meningkatkan wawasan dalam tujuan pengambilan keputusan (Chen et al., 2012). Gandomi & Haider (2015) menjelaskan terdapat tiga tantangan utama dalam mengolah *big data*, yaitu *volume*, *variety*, dan *velocity*. *Volume* mengacu pada sekumpulan data yang berukuran besar, tidak terstruktur,

dan bersifat kompleks. *Variety* mengarah pada tingkat keragaman atau heterogenitas struktural dari kumpulan *big data*. *Velocity* merujuk pada ukuran atau tingkatan di mana *big data* dihasilkan dengan kecepatan tinggi. Sementara itu, Letouzé & Jütting (2015) yang diacu dalam Pramana (2021) mengklasifikasikan tipe sumber *big data* menjadi tiga kategori, yaitu *exhaust data*, *sensing data*, dan *digital content*. Berikut ini penjelasan dari tiga kategori tersebut.

1. *Exhaust data* merupakan data yang dikumpulkan secara pasif dari pengguna layanan digital seperti data percakapan, data pengguna ponsel (*call detail record*), transaksi keuangan, atau pencarian web. Data tersebut diperoleh dari kegiatan pengumpulan data untuk berbagai tujuan bisnis dan lainnya.
2. *Sensing data* merupakan data yang diperoleh dari berbagai alat berupa sensor, seperti berbagai perangkat rumah tangga, kendaraan, *Internet of Things* (IoT), *wearables devices*, dan juga melalui teknologi penginderaan jarak jauh, misalnya data citra satelit (*satellite imagery*).
3. *Digital content* merupakan data yang berasal dari konten digital, seperti informasi pada *website* (artikel dan iklan lowongan pekerjaan), interaksi pada sosial media, *marketplace*, dan informasi yang ditampilkan pada platform digital lainnya. Namun, tidak seperti *exhaust* dan *sensing data*, *digital content* sebagian besar diproduksi oleh seseorang sehingga cenderung bersifat subjektif, bahkan menipu (*fraud*) karena tergantung dari maksud peneliti. Oleh sebab itu, tipe data ini memerlukan perhatian ekstra pada *preprocessing* untuk memastikan kualitas data yang dianalisis.

Data Geospasial

Data geospasial adalah data yang mengandung komponen geografis yang merepresentasikan lokasi dari suatu objek di permukaan bumi (Adil & Kom, 2017). Data geospasial secara umum terbagi atas tiga jenis, yaitu data vektor, data raster, dan data *graph*. Data vektor direpresentasikan dalam bentuk titik (*point*), garis (*line*), dan poligon (*polygon*) untuk mewakili fitur spasial tertentu, misalnya sungai dan jalan yang diwakili oleh garis. Data raster menggunakan ukuran piksel untuk mewakili suatu fitur spasial dan dapat digunakan untuk menyimpan data dengan variasi yang kontinu, seperti hasil tangkapan dari foto udara, citra satelit, dan elevasi permukaan. Sedangkan data *graph* sebagian besar direpresentasikan dalam bentuk jaringan jalan, seperti lintasan kendaraan pada jaringan jalan yang digambarkan dengan urutan segmen jalan. Data geospasial dapat bersumber dari penginderaan jauh (*remote sensing*), *Global Positioning Data* (GPS), dan lain sebagainya (Wijayanto et al., 2022).

Pemanfaatan data geospasial semakin pesat seiring dengan berkembangnya teknologi yang memungkinkan organisasi pemerintah maupun swasta, serta kelompok independen lain dalam menyediakan data dan informasi geospasial. Beberapa pihak tersebut menyediakan data yang dapat diperoleh dan diakses secara bebas dan terbuka. Data geospasial terbuka merupakan data geospasial yang dapat dibagikan, diakses, digunakan, dimodifikasi, dan dibagikan ulang oleh siapapun dengan mudah (seperti melalui internet) untuk tujuan apapun (Pramana & Krismawati, 2022). United Nations (2013) dalam *Working Paper on Statistical and Spatial Frameworks* menyebutkan bahwa pemanfaatan data geospasial akan semakin meningkat dan berpotensi memberikan wawasan baru yang tidak dapat ditemukan dalam analisis data lainnya.

Penginderaan Jauh (*Remote Sensing*)

Penginderaan jauh adalah ilmu dan seni yang bertujuan untuk memperoleh informasi terkait suatu objek, area, atau fenomena melalui analisis data yang diperoleh dengan perangkat berkemampuan sensor atau perangkat lain yang tidak bersentuhan langsung dengan objek, area, atau fenomena yang diamati (Lillesand et al., 2015). Metode penginderaan jauh pada prinsipnya ditunjukkan dalam penggunaan data citra yang dikumpulkan dari berbagai sensor, seperti foto udara, satelit, dan radar yang tidak bersentuhan langsung dengan objek yang diukur. Teknologi penginderaan jauh dapat digunakan untuk inventarisasi sumber daya alam laut, analisis lingkungan dan bencana, analisis sosial dan ekonomi, dan kepentingan strategis lainnya seperti keamanan dan pertahanan. Hasil analisis data penginderaan jauh dapat dijadikan sebagai bahan pengambilan kebijakan publik. Oleh karena itu, penginderaan jauh dapat menjadi alat yang sangat penting untuk menggambarkan keadaan, perubahan, masalah, serta mendukung aktivitas sehari-hari manusia di permukaan bumi (Wijayanto et al., 2022).

Google Earth Engine (GEE)

Google Earth Engine (GEE) merupakan platform berbasis *cloud computing* yang dibangun dengan menggunakan teknologi komputasi tingkat tinggi dan dimungkinkan untuk melakukan analisis geospasial dalam skala besar, seperti deforestasi, kekeringan, kebencanaan, wabah, ketahanan pangan, pengelolaan air, pemantauan iklim, dan perlindungan lingkungan (Gorelick et al., 2017). GEE disediakan oleh perusahaan Google dan dapat dimanfaatkan oleh pengguna untuk memperoleh data citra satelit. Beberapa data citra satelit yang dapat diakses melalui GEE meliputi data citra satelit yang berasal dari Landsat, Sentinel, *Moderate*

Resolution Imaging Spectrometer (MODIS), dan lain sebagainya. Setiap pengguna data memperoleh data citra satelit tersebut secara gratis dengan mengikuti syarat dan ketentuan yang diberlakukan. GEE dapat diakses melalui tautan web berikut <https://earthengine.google.com/> (Pramana & Krismawati, 2022).

Satelite Sentinel-2

Sentinel-2 adalah satelite yang diluncurkan oleh *European Space Agency* (ESA) yang dirancang khusus untuk merekam dan mengirimkan data penginderaan jauh sebagai bagian dari program misi *European Comission's Copernicus*. Sentinel-2 merupakan satelite berwujud konstelasi yang terdiri atas tiga citra satelit, meliputi Sentinel 2A (diluncurkan pada 23 Juni 2015), Sentinel 2B (diluncurkan pada 7 Maret 2017), dan Sentinel 2C yang sedang dikembangkan dan menjalani proses pengujian untuk persiapan peluncuran di tahun 2024. Sentinel-2 mempunyai 13 spektrum *band* yang terdiri atas 4 *band* dengan resolusi 10 meter, 6 *band* dengan resolusi 20 meter, dan 3 *band* dengan resolusi 60 meter. Spektrum *band* tersebut memiliki panjang gelombang *Visible and Near-Infrared* (VNIR) hingga *Shortwave Infrared* (SWIR) dengan area sapuan sebesar 290 kilometer. Data citra yang dihasilkan oleh Sentinel-2 dapat mendukung berbagai tugas, misalnya untuk melakukan *monitoring* tutupan lahan, analisis kualitas air, perencanaan tata kota, dan manajemen penanggulangan bencana (European Space Agency, n.d.). Adapun citra Sentinel-2 yang digunakan dalam penelitian ini memiliki resolusi 10 meter,

Satelite Sentinel-5P

Sentinel-5 *Precursor* (Sentinel-5P) merupakan misi dari Copernicus pertama yang ditujukan untuk menyediakan informasi penting terkait kualitas udara

dan iklim bumi pada tahun 2017 hingga 2023. Sentinel-5P diluncurkan pada tanggal 13 Oktober 2017 di Rusia. Satelit ini memiliki sensor *TROPOspheric Monitoring Instrument* (TROPOMI) yang dapat melakukan pengamatan global secara harian terhadap atmosfer bumi, termasuk lapisan ozon, nitrogen oksida, sulfur dioksida, karbon monoksida, serta sifat awan dan aerosol (Copernicus, 2017). Satelit ini memiliki tujuan utama yaitu untuk memastikan keberlanjutan data yang dihasilkan oleh satelit pendahulunya, seperti SCIAMACHY/Envisat, OMI/AURA NASA, serta Sentinel 4 dan Sentinel 5. Berikut ini adalah rincian produk yang dihasilkan oleh satelit Sentinel-5P yang ditampilkan pada Tabel 1 di bawah ini.

Tabel 1. Rincian produk dari satelit Sentinel-5P

Produk Sentinel-5P (mol/m ²) (1)	Resolusi (meter) (2)	Keterangan (3)
<i>Carbon Monoxide</i> (CO)	1113,2	Kepadatan senyawa Karbon Monoksida
<i>Nitrogen Dioxide</i> (NO ₂)	1113,2	Kepadatan senyawa Nitrogen Dioksida
<i>Sulphur Dioxide</i> (SO ₂)	1113,2	Kepadatan senyawa Sulfur Dioksida
<i>Formaldehyde</i> (HCHO)	1113,2	Kepadatan senyawa Formaldehida
<i>Ozone</i> (O ₃)	1113,2	Kepadatan senyawa Ozon
<i>Methane</i> (CH ₄)	1113,2	Rasio rata-rata campuran udara kering Metana

Sumber: (Copernicus, 2017)

Instrumen MODIS

MODIS adalah salah satu sensor utama yang digunakan oleh *Earth Observing System* (EOS) *Terra Satellite*. MODIS merupakan instrumen ilmiah yang diluncurkan ke orbit bumi yang menjadi bagian dari program NASA pada tanggal 18 Desember 1999 di atas satelit Terra (EOS AM-1) dan disempurnakan pada tanggal 4 Mei 2002 di atas satelit Aqua (EOS PM-1). Instrumen MODIS didesain untuk mengukur dinamika global dalam skala besar, seperti perubahan tingkat

tutupan awan, energi bumi, dan berbagai proses atmosferik yang ada di daratan, lautan, ataupun atmosfer di bagian bawah permukaan bumi (Platnick et al., 2016). Instrumen MODIS memiliki radiometrik dengan sensitivitas yang tinggi dengan cara memantulkan pancaran radiasi matahari dan radiasi panas yang disalurkan ke dalam 36 spektrum gelombang dengan resolusi spasial yang bervariasi. Resolusi spasial pada spektrum *band* 1-2 sebesar 250 meter, *band* 3-7 sebesar 500 meter, dan *band* 8-36 sebesar 1000 meter. Spektrum gelombang yang diterima oleh instrumen MODIS memiliki kegunaan masing-masing, misalnya *band* 31 dan 32 yang digunakan untuk memantau suhu permukaan bumi sehingga dapat mendeteksi letak dan sebaran titik api di suatu wilayah.

Visible Infrared Imaging Radiometer Suite (VIIRS)

USGS (2017) menjelaskan VIIRS adalah salah satu sensor satelit *Suomi* NPP generasi terbaru dari seri satelit *Earth Observing System (EOS)* milik Amerika Serikat. VIIRS merupakan instrumen ilmiah yang dibuat oleh NASA di atas satelit *Suomi National Polar-orbiting Partnership (S-NPP)* dan *National Oceanic and Atmospheric Administration-20 (NOAA-20)*. Sensor VIIRS pada satelit *Suomi* NPP diluncurkan pada tanggal 28 Oktober 2011 dengan membawa 5 sensor, yaitu *Visible Infrared Imaging Radiometer Suite (VIIRS)*, *Cross-track Infrared Sounder (CrIS)*, *Advanced Technology Microwave Sounder (ATMS)*, *Ozone Mapping and Profiler Suite (OMPS)*, dan *Cloud and Earth Radiant Energy System (CERES)*. Sementara itu, satelit NOAA-20 berhasil diluncurkan pada tanggal 18 November 2017 dengan sensor yang serupa dengan satelit *Suomi* NPP. Sensor VIIRS terdiri atas 22 *band* dengan panjang gelombang sebesar 0,412 mikrometer hingga 12 mikrometer, di mana 16 *band* memiliki resolusi spasial sebesar 750 meter dan 6 *band* lainnya

terdiri atas 5 *band* dengan resolusi spasial 375 meter, serta 1 *band* pankromatik siang/malam (*day night band*) dengan resolusi spasial 750 meter (USGS, 2017).

Shuttle Radar Topography Mission (SRTM)

SRTM merupakan suatu hasil proyek internasional yang dilakukan oleh *National Aeronautics and Space* (NASA) dari Amerika Serikat yang diluncurkan pada Februari 2000. SRTM diperoleh dari data elevasi *near-global scale* dengan tujuan menghasilkan data topografi beresolusi tinggi yang paling lengkap di permukaan bumi. SRTM saat ini telah menghasilkan data elevasi digital dengan resolusi 30 meter dan 90 meter untuk cakupan global. Data SRTM diolah dari *raw data* radar menjadi model elevasi digital oleh *Jet Propulsion Laboratory* (JPL). Data ini dapat digunakan untuk melengkapi informasi ketinggian dari produk peta 2 dimensi, Data ketinggian digital dari SRTM ini yang dikenal dengan istilah DEM atau *Digital Elevation Model* (USGS, 2018).

VIIRS DNB Nighttime Light

Selama lebih dari 40 tahun, data intensitas cahaya malam dikumpulkan menggunakan sensor *Operational Linescan System* (OLS) pada satelit *Defense Meteorological Satellite Program* (DMSP). Sensor OLS dapat menangkap berbagai spektrum cahaya dengan intensitas yang berbeda, seperti area perumahan kecil, lampu lalu lintas, kebakaran, lampu perahu, dan lain sebagainya (Gao et al., 2022). Namun, data DMSP-OLS mempunyai kualitas kalibrasi dan resolusi spasial yang rendah. Oleh karena itu, NASA dan NOAA meluncurkan satelit *Suomi NPP* yang dilengkapi dengan instrumen VIIRS pada tahun 2011. Data intesitas cahaya malam yang diperoleh dari VIIRS terbukti melampaui kemampuan dari DMSP-OLS dalam

hal resolusi spasial, akurasi radiometrik, kualitas kalibrasi dan geometris, serta ketersediaan spektrum *band* yang lebih cocok untuk mengidentifikasi sumber termal emisi cahaya (Elvidge et al., 2013).

Beberapa penelitian terdahulu telah banyak menggunakan data intensitas cahaya malam untuk mempelajari aktivitas ekonomi di suatu wilayah (Ngestrini, 2019). Semakin tinggi intensitas cahaya malam pada suatu wilayah, maka semakin tinggi tingkat elektrifikasi di wilayah tersebut. Tingkat elektrifikasi yang tinggi sejalan dengan meningkatnya kemampuan masyarakat dalam memenuhi kebutuhan listriknya (Shi et al., 2014). Oleh karena itu, intensitas cahaya malam akan berkorelasi positif dengan konsumsi listrik per kapita ruta.

Build-Up Index (BUI)

Build-Up Index (BUI) merupakan salah satu elemen tata guna lahan yang memiliki peranan penting dalam kegiatan perencanaan pembangunan di perkotaan (Ouyang et al., 2016). Nilai BUI yang tinggi dan positif mssenandakan bahwa suatu wilayah merupakan kawasan terbangun dengan tutupan lahan yang rendah. Faisal et al. (2016) menjelaskan bahwa salah satu faktor yang menyebabkan nilai BUI tinggi yaitu meningkatnya program pembangunan tata kota di suatu wilayah. Program tersebut dapat mengurangi tingkat vegetasi sehingga tutupan lahan menjadi lebih rendah. Perubahan tutupan lahan yang tinggi disebabkan karena kepadatan penduduk yang meningkat di wilayah tersebut dan memicu pembangunan yang dapat menaikkan aktivitas ekonomi di wilayah tersebut sehingga berdampak pada pertumbuhan ekonomi dan peningkatan kesejahteraan masyarakat di sekitar. Kesejahteraan masyarakat yang semakin tinggi dapat dikaitkan dengan kemampuan dalam melakukan kegiatan konsumsi, salah satunya

dalam hal penggunaan energi listrik yang meningkat untuk memenuhi kebutuhan hidup. Dengan demikian, nilai BUI yang tinggi di suatu wilayah akan berkorelasi positif dengan rata-rata konsumsi listrik per kapita ruta di wilayah tersebut.

Prasomsup et al. (2020) menjelaskan bahwa nilai BUI dapat dihitung menggunakan nilai NDVI dan NDBI. Sumber data yang biasanya digunakan untuk memperoleh nilai BUI berasal dari citra satelit Landsat-8 dan Sentinel-2. Berikut ini dijelaskan tahapan yang dibutuhkan dalam penghitungan nilai BUI.

1. *Normalized Difference Vegetation Index (NDVI)*

NDVI merupakan indeks yang digunakan untuk melihat dan membandingkan tingkat kehijauan vegetasi di suatu wilayah. NDVI dapat menangkap struktur internal pada daun tanaman. NDVI disusun dari kombinasi matematis antara pita spektral merah (*Red Band*) dan *Near-Infrared Radiation* (NIR) yang sudah lama digunakan sebagai indikator keberadaan kondisi vegetasi suatu wilayah (Morawitz et al., 2006). Nilai NDVI dirumuskan sebagai berikut.

$$NDVI = \frac{(NIR - RED)}{(NIR + RED)} \quad (2)$$

Keterangan:

NDVI : *Normalized Difference Vegetation Index*

Red : Radiasi spektrum merah

NIR : Radiasi inframerah dekat

Nilai NDVI berkisar antara -1 hingga 1. Nilai NDVI yang tinggi atau mendekati 1 menunjukkan suatu wilayah memiliki vegetasi yang semakin lebat.

2. *Normalized Difference Build-up Index (NDBI)*

NDBI merupakan indeks yang sangat sensitif terhadap lahan terbangun dengan menonjolkan kenampakan lahan terbangun dibandingkan dengan objek

lainnya. NDBI dikembangkan untuk memetakan area terbangun di wilayah perkotaan (Nath et al., 2021). NDBI dapat dirumuskan sebagai berikut.

$$NDBI = \frac{(SWIR - NIR)}{(SWIR + NIR)} \quad (3)$$

Keterangan:

NDBI : Normalized Difference Build-up Index

SWIR : Short-wave Infrared

NIR : Radiasi inframerah dekat.

Nilai NDBI berkisar antara -1 hingga 1. Nilai NDBI yang tinggi atau mendekati 1 menunjukkan suatu wilayah semakin mewakili area terbangun.

3. Build-Up Index (BUI)

BUI merupakan metode untuk menganalisis pola perkotaan dengan memanfaatkan hasil ekstraksi lahan terbangun dengan kombinasi nilai NDVI dan NDBI. BUI dirumuskan sebagai berikut.

$$BUI = NDBI - NDVI \quad (4)$$

Keterangan:

BUI : Build-Up Index

NDBI : Normalized Difference Build-up Index

NDVI : Normalized Difference Vegetation Index

Land Surface Temperature (LST)

Land Surface Temperature atau suhu permukaan tanah merupakan suatu keadaan yang dikendalikan antara keseimbangan energi di permukaan, atmosfer, sifat termal dari permukaan, dan media bawah tanah permukaan. Data LST dapat diperoleh dari citra satelit MODIS dan Landsat-8. Pada instrumen MODIS, data

LST yang tersedia meliputi suhu permukaan tanah pada siang dan malam hari serta dapat langsung digunakan tanpa pengolahan lebih lanjut. Sedangkan data LST dari Landsat-8 perlu diolah dengan pemrosesan citra digital untuk mendapatkan informasi suhu permukaan lahan. Informasi suhu permukaan lahan yang diturunkan dari Landsat-8 memiliki dua saluran spektrum yaitu *band 10* dan *band 11*. Kedua nilai dari saluran tersebut terlebih dahulu perlu dikonversi dari nilai *Digital Number* (DN) menjadi nilai *Top of Atmosphere* (TOA). Setelah dikonversi, setiap nilai diubah ke dalam nilai *Brightness Temperature* dengan satuan kelvin dan nilai emisivitas permukaan (USGS, 2013).

LST dapat digunakan dalam menangkap fenomena perubahan iklim global di mana jika seiring kandungan gas rumah kaca yang meningkat, maka nilai LST juga akan meningkat (Rajeshwari & Mani, 2014). Sumber gas rumah kaca dihasilkan melalui emisi yang berasal dari penggunaan energi listrik (Ayuningtyas et al., 2020). Oleh sebab itu, peningkatan kandungan gas rumah kaca yang diidentifikasi dari nilai LST yang tinggi dapat dikaitkan dengan penggunaan listrik yang semakin meningkat. Dengan demikian, LST yang tinggi di suatu wilayah akan berkorelasi positif dengan rata-rata konsumsi listrik per kapita ruta yang semakin tinggi di wilayah tersebut.

Digital Elevation Model (DEM)

DEM merupakan model data digital yang menggambarkan bentuk geometri dari topografi permukaan bumi yang terdiri atas kumpulan titik-titik koordinat hasil sampling dengan algoritma tertentu sedemikian sehingga divisualkan ke dalam tampilan tiga dimensi. DEM juga digunakan sebagai gambaran relief medan permukaan bumi divisualkan secara 3D dengan bantuan teknologi komputer grafis

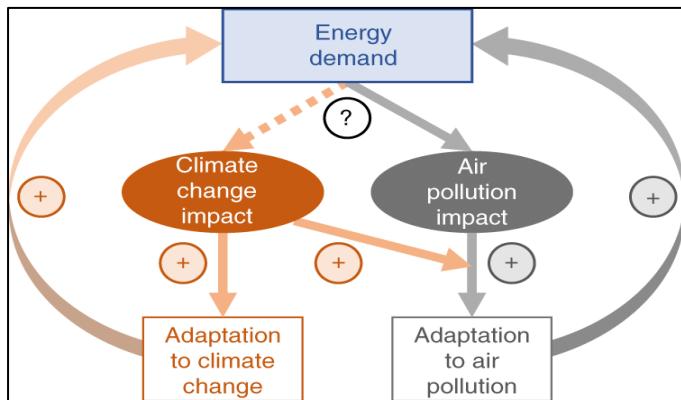
dan *virtual reality*. Nilai ketinggian pada DEM SRTM sesuai dengan nilai ketinggian dari datum WGS84. Namun karena datum WGS84 sangat berhimpit dengan permukaan laut, maka untuk skala tinggi dapat diabaikan pada perbedaan keduanya. DEM SRTM memiliki elevasi sebesar -32767 hingga 32767 meter berdasarkan rentang ketinggian yang berada di bumi (Pham et al., 2018).

Penggunaan data DEM secara spesifik telah banyak diterapkan untuk berbagai aplikasi, salah satunya untuk memodelkan distribusi populasi penduduk dan pengaruhnya terhadap permintaan energi. Data elevasi pada DEM digunakan sebagai variabel penting dalam memodelkan distribusi populasi di Tiongkok. Hal ini dikarenakan sebagian besar permukiman di negara tersebut berada pada wilayah dengan elevasi yang lebih rendah (Tian et al., 2005). Penelitian dari Luo et al. (2019) melakukan pemodelan *population density* di Tiongkok dari data citra multisensor, salah satunya dengan data elevasi DEM. Hasil penelitian tersebut menunjukkan bahwa hubungan antara rata-rata elevasi (ketinggian) berkorelasi negatif secara *exponential decay* dengan kepadatan populasi sehingga mendukung pernyataan dari Tian et al. (2005) sebelumnya. Karena kepadatan penduduk diasumsikan berkorelasi positif dengan tingkat konsumsi listrik rumah tangga, maka semakin tinggi elevasi dari suatu wilayah akan semakin rendah tingkat konsumsi listrik rumah tangga di wilayah tersebut. Namun, teori tersebut berbeda dengan hasil penelitian dari Katsoulakos & Kaliampakos (2014) yang menyoroti permasalahan energi di daerah pegunungan di Yunani sebagai lokasi studi. Hasil penelitian tersebut mengungkapkan bahwa ada hubungan positif yang signifikan antara ketinggian tempat dengan permintaan energi. Semakin tinggi suatu tempat akan diikuti dengan permintaan energi listrik yang lebih tinggi. Hal ini dikarenakan

faktor kebutuhan termal yang lebih besar akibat kondisi cuaca yang unik di pegunungan daripada di daerah dataran rendah. Dengan demikian, faktor ketinggian dapat memberikan pengaruh yang berbeda terhadap tingkat konsumsi listrik rumah tangga sehingga tergantung pada karakteristik geografis dari suatu wilayah.

Air Pollution

Menurut Peraturan Pemerintah Republik Indonesia No. 41 Tahun 1999, pencemaran udara adalah kejadian masuk atau dimasuknya zat, energi, dan komponen lain ke dalam udara ambien yang disebabkan oleh aktivitas manusia sehingga kualitas mutu udara ambien menjadi turun hingga pada tingkatan tertentu yang dapat menyebabkan udara ambien tidak dapat memenuhi fungsinya (Pemerintah Indonesia, 1999). Beberapa zat yang dapat menimbulkan pencemaran udara meliputi Sulfur Dioksida (SO_2), Nitrogen Dioksida (NO_2), Karbon Monoksida (CO), *Particulate Matter* (PM), dan Ozon (O_3). Pada penelitian ini, data polusi udara yang digunakan yaitu Karbon Monoksida (CO) dan *Particulate Matter* $2,5$ ($PM_{2,5}$). *Particulate Matter* $2,5$ adalah partikel halus dengan diamater aerodinamis lebih kecil dari $2,5 \mu\text{m}$ (mikrometer) yang merupakan komponen utama dari polutan atmosfer. Sumber utama partikel ini berasal dari lalu lintas dan industri, seperti pembakaran bahan bakar dari pembangkit listrik, kilang minyak dan emisi rem kendaraan (Du et al., 2016).



Sumber: Eom et al. (2020)

Gambar 2. Siklus yang terjadi antara permintaan energi, dampak perubahan iklim dan polusi udara, serta hasil adaptasi intensif energi

Eom et al. (2020) di dalam penelitiannya menjelaskan konsep timbal balik antara permintaan energi, dampak perubahan iklim, dan dampak polusi udara. Pada Gambar 2 diperlihatkan adanya siklus timbal balik antara permintaan energi listrik, dampak perubahan iklim, dampak polusi udara, dan hasil adaptasi intensif energi. Hal ini menunjukkan bahwa polusi udara dapat memengaruhi perilaku penggunaan energi listrik rumah tangga. Apabila tingkat polusi meningkat, maka rumah tangga akan merespons dengan melakukan berbagai tindakan adaptasi yang membutuhkan penggunaan energi, seperti mencegah infiltrasi polutan dengan menutup jendela dan menyalakan pengering mekanis untuk menghilangkan polutan di dalam ruangan (T. Liu et al., 2018). Selain itu, polusi udara juga dapat memicu beberapa perubahan gaya hidup, misalnya seseorang cenderung membatasi atau menunda aktivitas di luar ruangan sehingga memerlukan penggunaan energi listrik yang lebih besar untuk melakukan kegiatan di dalam ruangan (Saberian et al., 2017). Dengan demikian, tingkat polusi udara di suatu wilayah akan berkorelasi positif dengan rata-rata konsumsi listrik per kapita ruta di wilayah tersebut.

Global Aridity Index (Indeks Kekeringan Global)

Global Aridity Index (Global-AI) merupakan suatu set data raster global dari Global Aridity Index and Potential Evapo-Transpiration (ET₀) Database versi 3 dengan resolusi 1 kilometer pada periode tahun 1970-2000. Data geospasial ini merupakan pengembangan dari versi sebelumnya yang juga dibuat oleh Robert Zomer dan Antonio Trabucco serta didukung National Key Basic Research Program of China dan National Science Foundation China. Data ini tersedia untuk penggunaan non-komersial dalam format GeoTIFF standar (Zomer et al., 2022).

Indeks kekeringan global (*Global-AI*) biasanya dinyatakan sebagai fungsi umum dari tingkat curah hujan, suhu, dan referensi evapotranspirasi. Indeks ini dapat digunakan untuk mengukur ketersediaan curah hujan atas permintaan air di atmosfer. Pemetaan secara global terhadap indeks kekeringan pada periode 1970-2000 dihitung dengan resolusi sebesar 1 kilometer menggunakan formula sebagai berikut Nilai indeks kekeringan yang meningkat menunjukkan kondisi wilayah yang lebih lembab, sedangkan nilai indeks kekeringan menurun menunjukkan kondisi wilayah yang lebih kering (Zomer et al., 2022). UNEP (1997) telah mengklasifikasikan indeks kekeringan secara umum seperti pada Tabel 2 berikut.

Tabel 2. Skema klasifikasi iklim umum untuk nilai indeks kekeringan

<i>Aridity Index Value</i>	<i>Climate Class</i>
(1)	(2)
< 0,03	<i>Hyper-Arid</i>
0,03 – 0,2	<i>Arid</i>
0,2 – 0,5	<i>Semi-Arid</i>
0,5 – 0,65	<i>Dry sub-humid</i>
> 0,65	<i>Humid</i>

Sumber: UNEP (1997)

Data *Global-AI* ditujukan untuk mendukung studi yang dapat berkontribusi pada pembangunan berkelanjutan, keanekaragaman hayati dan konservasi lingkungan, pengentasan kemiskinan, serta adaptasi terhadap perubahan iklim meliputi keprihatinan global, regional, nasional, dan lokal (Zomer et al., 2022). Pada Gambar 2 di bagian sebelumnya telah dijelaskan konsep siklus dapat terjadi antara permintaan energi, dampak perubahan iklim dan polusi udara, serta hasil adaptasi intensif energi. Selain dari dampak polusi udara, Eom et al. (2020) juga menjelaskan efek dari perubahan iklim yang dapat menciptakan perilaku adaptasi rumah tangga yang dapat memengaruhi penggunaan energi. Adaptasi terhadap perubahan iklim ini dapat berdampak pada perilaku penggunaan energi listrik, misalnya kenaikan suhu di suatu wilayah sebagai dampak perubahan iklim dapat mengubah aktivitas luar ruangan bagi seseorang menjadi lebih rendah sehingga meningkatkan aktivitas di dalam ruangan. Apabila indikasi adanya adaptasi perubahan iklim ini dimanifestasikan dengan nilai *aridity index* di suatu wilayah, maka semakin tinggi nilai *aridity index* berarti bahwa wilayah tersebut tidak mengalami perubahan iklim secara signifikan sehingga adaptasi perubahan iklim yang ditunjukkan oleh penggunaan energi listrik akan lebih rendah. Dengan demikian, nilai *aridity index* di suatu wilayah berkorelasi negatif dengan rata-rata konsumsi listrik per kapita ruta di wilayah tersebut.

Relative Wealth Index (Indeks Kekayaan Relatif)

Chi et al. (2022) mengembangkan data estimasi mikro kekayaan dan kemiskinan relatif di permukaan bumi yang berpenduduk dari 135 negara berpenghasilan rendah dan menengah di dunia di bawah resolusi 2,4 kilometer. Data tersebut diistilahkan sebagai indeks kekayaan relatif (*relative wealth index*).

Indeks kekayaan relatif memprediksi taraf hidup relatif yang dibuat dengan menerapkan algoritma pembelajaran mesin ke lingkup data luas dan heterogen yang berasal dari citra satelit, jaringan ponsel, peta topografi, dan data konektifitas yang tidak teridentifikasi secara agregat dari Facebook. Tujuan data RWI ini diharapkan dapat membantu respons kebijakan yang ditargetkan selama pandemi COVID-19, memberikan dasar wawasan tentang studi kausalitas dari pembangunan dan pertumbuhan ekonomi, serta mendorong perencanaan kebijakan yang bertanggung jawab dalam mendukung pembangunan yang berkelanjutan.

Ferguson et al. (2000) dengan penelitiannya yang berjudul “*Electricity use and economic development*” menerangkan bahwa terdapat korelasi kuat antara penciptaan kekayaan (*wealth creation*) terhadap penggunaan listrik di negara-negara maju dan beberapa negara berkembang. Di Indonesia, korelasi antara penggunaan listrik per kapita dengan penciptaan kekayaan sebesar 0,986. Penciptaan kekayaan tersebut mengacu pada data GDPPPP/kapita tahun 1971-1995. Sementara itu, RWI mengindikasikan tingkat kekayaan dari suatu lokasi yang relatif dengan lokasi lainnya dalam satu negara yang sama. Jika penciptaan kekayaan direpresentasikan menggunakan nilai indeks kekayaan relatif (RWI), maka dapat diasumsikan bahwa wilayah dengan RWI tinggi menunjukkan tingkat pendapatan penduduk di wilayah tersebut juga relatif tinggi, begitupun sebaliknya. Dengan demikian, nilai RWI di suatu wilayah akan berkorelasi positif dengan rata-rata konsumsi listrik per kapita ruta di wilayah tersebut.

Pendugaan Langsung (*direct estimation*)

Pendekatan yang digunakan di dalam survei untuk mengestimasi suatu karakteristik dari suatu parameter populasi berdasarkan desain pengambilan sampel

dikenal dengan istilah *direct estimation*. Rao & Molina (2015) menjelaskan bahwa estimator dari pendugaan langsung pada suatu populasi menggunakan nilai dari variabel terikat yang berasal dari unit sampel terpilih di dalam suatu survei. Data yang diperoleh melalui survei dapat menghasilkan penduga yang akurat ketika ukuran sampelnya mencukupi. Namun bila suatu wilayah memiliki ukuran sampel yang tidak cukup, maka hasil dari pendugaan langsung mempunyai *sampling error* yang besar sehingga mengurangi tingkat akurasi dan presisi dari estimator tersebut.

Hasil pendugaan langsung berupa nilai rata-rata konsumsi listrik per kapita rumah tangga (rata) digunakan sebagai variabel *interest* pada penelitian ini. Untuk mendapatkan variabel tersebut, maka dibutuhkan data pemakaian listrik selama sebulan terakhir (KWh), jumlah anggota rumah tangga, dan nilai penimbang individu. Adapun penghitungan nilai rata-rata konsumsi listrik per kapita ruta dengan pendugaan langsung diformulasikan sebagai berikut.

$$\bar{y}_{kwh/kapita} = \frac{\sum_{i=1}^n \frac{y_{kwh_i}}{q_i} \times W_i}{\sum_{i=1}^n W_i} \quad (5)$$

dengan $i = 1, \dots, n$ di mana n adalah jumlah rumah tangga di setiap kecamatan.

Keterangan:

$\bar{y}_{kwh/kapita}$: rata-rata konsumsi listrik per kapita ruta di suatu kecamatan

y_{kwh_i} : penggunaan listrik rumah tangga (KWh) selama sebulan

q_i : jumlah anggota rumah tangga pada rumah tangga ke- i

W_i : penimbang (*weight*) individu pada rumah tangga ke- i .

Pendugaan Tak Langsung (*indirect estimation*)

Untuk menghasilkan estimator yang akurat dan presisi, penambahan ukuran sampel dapat menjadi solusi dalam melakukan estimasi pada level area yang lebih

kecil dari wilayah yang ditetapkan pada survei. Akan tetapi, penambahan ukuran sampel membutuhkan peningkatan terhadap sumber daya yang digunakan sehingga harus memperhatikan *cost-effectiveness* dari kegiatan survei. Oleh karena itu, solusi alternatif dibutuhkan dengan tetap mempertimbangkan *cost-effectiveness* untuk memperoleh estimator yang akurat dan presisi pada level area yang lebih kecil. Teknik estimasi tak langsung memberikan solusi bukan dengan cara meningkatkan jumlah sampel pada suatu area, tetapi menambahkan variabel lain yang dapat memberikan informasi lebih dari area yang bersesuaian. Dengan menggunakan variabel lain sebagai informasi tambahan, maka *sampling error* dapat terkendali meskipun ukuran sampel yang diamati kurang optimal. Dengan demikian, hasil estimasi yang diperoleh dapat lebih akurat dan presisi meskipun ukuran sampel yang digunakan kurang optimal (Rao & Molina, 2015).

Model Linear Campuran (*Linear Mixed Model*)

Model linear campuran atau *linear mixed model* merupakan model statistika yang mempertimbangkan adanya pengaruh tetap (*fixed effect*) dan pengaruh acak (*random effect*). Model ini berguna pada pemodelan dengan unit statistik yang diukur secara berulang atau *repeated measurements* (Ubaidillah, 2017). Untuk lebih memahami, misalkan suatu model regresi linear dapat dituliskan sebagai berikut:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon} \quad (6)$$

di mana \mathbf{y} merupakan vektor variabel dependen berukuran $m \times 1$, \mathbf{X} merupakan matriks variabel independen yang diketahui berukuran $m \times p$, $\boldsymbol{\beta}$ merupakan vektor koefisien regresi yang tidak diketahui berukuran $p \times 1$, dan $\boldsymbol{\epsilon}$ merupakan vektor *error* yang bersifat *random* dan *unobservable* berukuran $m \times 1$.

Model regresi linear pada persamaan (6) mengasumsikan koefisien regresi bersifat tetap (*fixed*). Namun, untuk beberapa kasus ketika variabel dependen berkorelasi dengan satu sama lain pada pengukuran yang berulang, maka *linear mixed model* lebih cocok digunakan daripada model regresi linear. Adapun bentuk persamaan dari *general linear mixed model* dapat dituliskan sebagai berikut.

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{\nu} + \boldsymbol{\epsilon} \quad (7)$$

Keterangan:

\mathbf{y} : vektor dari variabel *interest* berukuran $m \times 1$.

\mathbf{X} : matriks kovariat yang diketahui berukuran $m \times p$

$\boldsymbol{\beta}$: vektor koefisien pengaruh tetap atau *fixed effect* berukuran $p \times 1$

\mathbf{Z} : matriks desain yang diketahui berukuran $m \times m$

$\boldsymbol{\nu}$: vektor koefisien pengaruh acak atau *random effect* berukuran $m \times 1$

$\boldsymbol{\epsilon}$: vektor *error* berukuran $m \times 1$

dengan m merupakan jumlah observasi dan p merupakan jumlah variabel penyerta (kovariat). Dari persamaan (7) terlihat bahwa terdapat komponen pengaruh acak ($\boldsymbol{\nu}$) yang mempunyai nilai rata-rata sama dengan nol dan varians yang berhingga (*finite*). Namun, pada *linear mixed model* dapat diketahui bahwa $\boldsymbol{\nu}$ dan $\boldsymbol{\epsilon}$ bersifat *unobservable* dan independen sehingga dapat dituliskan sebagai $\boldsymbol{\nu} \sim^{IID} N(0, \mathbf{G})$ dan $\boldsymbol{\epsilon} \sim^{IID} N(0, \mathbf{R})$ dengan \mathbf{G} dan \mathbf{R} merupakan hasil perkalian antara matriks identitas ordo $m \times m$ dengan ragam pengaruh acak area (σ_v^2) dan ragam sampling (σ_e^2) atau dapat dinotasikan dalam bentuk $\mathbf{G} = \mathbf{I}_m \sigma_v^2$ dan $\mathbf{R} = \mathbf{I}_m \sigma_e^2$. Berdasarkan nilai rata-rata dan varians yang diketahui dari $\boldsymbol{\nu}$ dan $\boldsymbol{\epsilon}$, maka dapat diperoleh nilai rata-rata dan varians dari \mathbf{y} adalah $E(\mathbf{y}) = \mathbf{X}\boldsymbol{\beta}$ dan $V(\mathbf{y}) = \mathbf{Z}\mathbf{G}\mathbf{Z}^T + \mathbf{R}$ sehingga dapat dinotasikan distribusi dari \mathbf{y} dapat dituliskan sebagai $\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \mathbf{Z}\mathbf{G}\mathbf{Z}^T + \mathbf{R})$.

Model Linier Campuran Umum (*Generalized Linear Mixed Model*)

Model linier campuran umum atau *generalized linear mixed model* (GLMM) merupakan model statistika yang dikembangkan dari *linear mixed model* untuk data yang tidak berdistribusi normal (Faltys et al., 2022). Model ini memasukkan unsur pengaruh acak atau *random effect* (\boldsymbol{v}), di mana diketahui vektor observasi (\mathbf{y}) yang mengasumsikan *conditional distribution* dari $y_i|v_i$ termasuk dalam keluarga eksponensial yang dapat dituliskan dengan $y_i|v_i \sim Exp(\theta_i, v_i; a, b, c)$ dengan fungsi kepadatan peluang sebagai berikut:

$$\begin{aligned} f(y_i|v_i) &= f(y_i|\theta_i, v_i; a, b, c) \\ &= \exp\left\{\frac{y_i\theta_i - b(\theta_i)}{a(v_i)} + c(y_i, v_i)\right\} \end{aligned} \quad (8)$$

di mana $a(\cdot) > 0$, $b(\cdot)$, dan $c(\cdot)$ merupakan fungsi dengan nilai yang sudah diketahui untuk menentukan distribusi yang dipilih dengan $\mu_i = E(y_i|v_i)$ merupakan *conditional expectation* dan $var(y_i|v_i)$ merupakan *conditional variance*. Dalam hal ini θ_i merupakan *natural parameter* sehingga $b(\theta_i)$ adalah fungsi yang bergantung pada distribusi tertentu yang termasuk ke dalam keluarga eksponensial, seperti distribusi *gamma*, *normal*, *poisson*, *beroulli*, dan *binomial* (Tuerlinckx et al., 2006).

Model linier campuran umum merupakan pengembangan dari model linier umum atau *generalized linear model* (GLM) yang mengombinasikan pengaruh tetap dan pengaruh acak pada prediktor linier sehingga dapat dituliskan berikut ini:

$$\eta_i = \mathbf{x}_i^T \boldsymbol{\beta} + \phi v_i \quad (9)$$

dengan $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^T$ merupakan vektor variabel prediktor, $\boldsymbol{\beta} = (\boldsymbol{\beta}_1, \boldsymbol{\beta}_2, \dots, \boldsymbol{\beta}_p)^T$ merupakan vektor parameter regresi, $\phi > 0$ merupakan

parameter dispersi, dan $\boldsymbol{\nu} = (\nu_1, \nu_2, \dots, \nu_m)^T$ merupakan vektor pengaruh acak area yang diasumsikan berdistribusi normal atau $\nu_i \sim N(0, \boldsymbol{G})$. Parameter yang tidak diketahui misalnya dinotasikan dengan $\boldsymbol{\theta} = (\boldsymbol{\beta}^T, \boldsymbol{\phi})$ dimodelkan melalui fungsi penghubung yang biasa disebut sebagai *link function*. Fungsi tersebut digunakan untuk mentransformasi nilai variabel respons (*interest*) agar sesuai dengan skala dari prediktor linier dan sebagai linierisasi hubungan dengan variabel prediktor.

Menurut Thiele & Markussen (2012), GLMM memungkinkan adanya kombinasi dari banyak distribusi dan *link function* untuk memodelkan berbagai tipe variabel respons (*interest*) melalui kombinasi linear dari satu atau lebih variabel prediktor (*fixed effect*) dan pengaruh acak (*random effect*). Oleh karena itu, peneliti harus memperhatikan pemilihan distribusi dan *link function* yang sesuai dengan kondisi data yang digunakan. Adapun rincian dari beberapa nama *link function* yang biasa digunakan pada GLMM beserta formula dan kesesuaian tipe variabelnya yang dapat dilihat pada Tabel 3 berikut ini.

Tabel 3. Rincian beberapa *link function* GLMM, formula, dan tipe variabel yang sesuai

Nama <i>link function</i>	Formula <i>link function</i>	Rentang nilai variabel
(1)	(2)	(3)
Identitas	μ	Nilai rill
Log	$\log(\mu)$	Nilai rill positif
Box-cox	$\frac{(\mu^\lambda - 1)}{(\lambda\gamma^\lambda)^{2,3}}$	Nilai rill positif
Power	μ^λ	Nilai rill positif
Logit	$\log\left(\frac{\mu}{1-\mu}\right)$	[0, 1]
Probit	$\phi^{-1}(\mu)$	[0, 1]
Cumulative Logit	$\log\left(\frac{\pi}{1-\pi}\right)^4$	Vektor probabilitas
Ordered Probit (Cumulative Probit)	$\phi^{-1}(\pi)^4$	Vektor probabilitas

Sumber: Thiele & Markussen (2012)

Secara teori, setiap distribusi memiliki *natural link function*-nya sendiri. Misalkan, distribusi alami pada data cacahan yaitu distribusi *Poisson* yang dapat diperluas menjadi distribusi *negative binomial* ketika terjadi *overdispersion* (varians melebihi nilai rata-rata). Kemudian, terdapat data biner yang secara natural akan berdistribusi binomial. Namun, pada praktiknya terdapat beberapa alternatif lain yang tidak terlalu umum untuk digunakan, tetapi dapat lebih cocok dengan data yang digunakan. Sebagai contoh pada data binomial dapat dimodelkan dengan *link function* bentuk probit atau data cacahan yang memiliki nilai rataan yang besar dapat dimodelkan dengan *link function* bentuk identitas. Selain dari distribusi-distribusi yang telah disebutkan, berikut ini ditampilkan Tabel 4 berisi rincian beberapa distribusi data pada GLMM dengan *link function* dan jenis variabelnya.

Tabel 4. Rincian beberapa distribusi GLMM, *link function*, dan jenis variabel yang sesuai

Distribusi	<i>Link function</i>	Rentang nilai variabel
(1)	(2)	(3)
<i>Gaussian</i>	Identitas	Nilai rill
Transformasi ke <i>Gaussian</i>	<i>Log</i> , <i>Box-cox</i>	Nilai rill positif
<i>Beta</i>	<i>Logit</i> , <i>Probit</i> , <i>Complementary log-log</i>	[0, 1]
<i>Gamma</i>	<i>Log</i> , <i>Power</i>	Nilai rill positif
<i>Poisson</i>	<i>Log</i> , Identitas	0, 1, 2, ...
<i>Binomial</i>	<i>Logit</i> , <i>probit</i> , <i>Complementary log log</i>	0, 1, 2, ..., N , di mana N adalah jumlah percobaan
<i>Negative Binomial</i>	<i>Log</i> , Identitas	0, 1, 2, ...
<i>Polytomous</i>	<i>Cumulative logit</i> , <i>Ordered probit</i>	1, 2, ..., K

Sumber: Thiele & Markussen (2012)

Pendugaan Area Kecil (*Small Area Estimation*)

Small Area Estimation (SAE) merupakan metode atau model estimasi tak langsung yang memanfaatkan informasi tambahan dari data atau variabel pendukung. Di dalam model SAE, data atau variabel pendukung tersebut

diistilahkan secara umum sebagai variabel penyerta. Informasi dari variabel penyerta dapat diperoleh berdasarkan periode lampau atau nilai pada area kecil lain yang memiliki karakteristik serupa dengan area yang diteliti, maupun informasi dari variabel yang mempunyai hubungan erat dengan variabel amatan. Variabel penyerta yang digunakan pada model SAE diasumsikan tidak memiliki nilai *sampling error* seperti data sensus atau registrasi wilayah sehingga dapat digunakan untuk melakukan estimasi parameter pada area dan jumlah sampel yang lebih kecil dengan tetap memberikan tingkat akurasi yang lebih baik (Rao, 2003). Kemudian jika ditinjau berdasarkan ketersediaan variabel penyerta, model SAE secara umum terbagi atas dua jenis, yaitu sebagai berikut (Rao, 2003).

1. Model berbasis level area

Model berbasis level area merupakan model estimasi yang didasarkan pada ketersediaan data pendukung yang hanya ada pada tingkatan area tertentu. Misalkan suatu vektor $\mathbf{x}_i = (x_1, x_2, \dots, x_p)^T$ dengan parameter yang ingin diestimasi yaitu θ_i , di mana $i = 1, 2, \dots, m$ dengan m adalah total area dan p adalah jumlah parameter. Model persamaan linear yang terbentuk adalah sebagai berikut.

$$\theta_i = \mathbf{x}_i^T \boldsymbol{\beta} + z_i \boldsymbol{v}_i, i = 1, 2, \dots, m \quad (10)$$

di mana z_i adalah konstanta bernilai positif yang diketahui dan $\boldsymbol{\beta} = (\beta_1, \dots, \beta_v)^T$ adalah vektor koefisien regresi berukuran $1 \times p$, dengan $p = 1, \dots, j$ dan j adalah jumlah variabel penyerta yang dimasukkan ke dalam model. Adapun \boldsymbol{v}_i adalah pengaruh acak area kecil yang diasumsikan berdistribusi $N(0, \sigma_v^2)$ yang identik, di mana nilai rata-rata yang diperoleh bernilai $E_m(v_i) = 0$ dan keragaman yang bernilai $V_m(v_i) = \sigma_v^2$. Misalkan estimator $\hat{\theta}_i$ diketahui dengan mengasumsikan estimasi langsung dari $\hat{\theta}_i$ ada sehingga dapat terbentuk persamaan sebagai berikut.

$$\hat{\theta}_i = \theta_i + e_i, i = 1, 2, \dots, m \quad (11)$$

di mana e_i adalah *sampling error* yang diasumsikan berdistribusi normal identik dengan nilai rataan $E(e_i) = 0$ dan nilai ragam $V(e_i) = \sigma_e^2 = \psi_i$. Nilai ψ_i harus diketahui sehingga variabel yang diestimasi berasal dari metode yang dapat dihitung nilai *sampling error*nya. Apabila persamaan (10) dan (11) digabung, maka akan membentuk model dasar estimasi area yang diistilahkan sebagai model *Fay-Herriot* dengan persamaan sebagai berikut.

$$\hat{\theta}_i = \mathbf{x}_i^T \boldsymbol{\beta} + z_i v_i + e_i, i = 1, 2, \dots, m \quad (12)$$

2. Model berbasis level unit

Model berbasis unit mengasumsikan bahwa data unit variabel penyerta, misalnya $\mathbf{x}_{ij} = (x_1, x_2, \dots, x_p)^T$ merupakan variabel penyerta dengan masing-masing elemen populasi ke- j pada tiap area kecil ke- i . Kemudian, dimisalkan y_{ij} merupakan variabel respons yang diasumsikan memiliki hubungan dengan x_{ij} sedemikian sehingga bentuk persamaan model SAE berbasis unit yang terbentuk adalah sebagai berikut.

$$y_{ij} = \mathbf{x}_{ij}^T \boldsymbol{\beta} + v_i + e_{ij}, i = 1, 2, \dots, m; j = 1, 2, \dots, n. \quad (13)$$

di mana j menunjukkan tiap-tiap anggota populasi pada area kecil ke- i . Adapun komponen v_i merupakan pengaruh acak area kecil yang diasumsikan berdistribusi $N(0, \sigma_v^2)$ yang identik. Kemudian, komponen e_{ij} merupakan nilai galat level unit yang berdistribusi normal identik. Hal tersebut dijelaskan oleh Johnson et al. (2005) bahwa apabila $\mathbf{W} \sim N(E(\mathbf{W}), \Sigma)$, maka kombinasi linear dari $\mathbf{k}^T \mathbf{W}$ atau disebut \mathbf{W}' akan berdistribusi $\mathbf{W}' \sim N(\mathbf{k}^T E(\mathbf{W}), \mathbf{k}^T \Sigma \mathbf{k})$ sehingga $e_{ij} = k_{ij} \bar{e}_{ij}$ akan memiliki distribusi normal identik dengan k_{ij} diketahui.

Perbedaan mendasar antara kedua metode dapat dilihat dengan jelas berdasarkan variabel pendukung yang digunakan sebagai variabel penyerta. Jika pada model berbasis area menggunakan variabel pendukung dari area yang lebih besar untuk mewakili nilai area kecil, maka model berbasis unit menggunakan asumsi bahwa variabel penyerta yang digunakan harus bersesuaian secara individu dengan variabel responsnya.

Maximum Likelihood (ML) dan Restricted Maximum Likelihood (REML)

Estimator menurut lokasi terbagi menjadi estimator titik dan estimator interval (Bain & Engelhardt, 1987). Metode yang umum digunakan dalam pendugaan titik adalah metode *Maximum Likelihood* (ML). Metode ML merupakan suatu cara untuk memperoleh estimator dengan memaksimumkan fungsi *likelihood* terhadap parameter θ . Misalkan terdapat peubah acak bebas x_1, x_2, \dots, x_n dengan suatu parameter θ . Maka, fungsi kepadatan peluang bersama dari sampel tersebut dapat dilambangkan sebagai $f(x_1, x_2, \dots, x_n | \theta)$. Fungsi kepadatan bersama tersebut disebut dengan fungsi *likelihood* yang biasa dinotasikan sebagai $L(\theta)$. Jadi, bentuk dari fungsi *likelihood* dapat dituliskan sebagai berikut (Bain & Engelhardt, 1987).

$$L(x_1, x_2, \dots, x_n, \theta) = f(x_1, x_2, \dots, x_n | \theta) \\ = \prod_{i=1}^n f(x_i | \theta) \quad (14)$$

Harville (1974) menyatakan bahwa hasil estimasi dari proses dengan metode ML menghasilkan estimator yang bersifat bias. Hal ini dapat terjadi karena proses estimasi dengan metode ML belum mempertimbangkan hilangnya derajat bebas sehingga metode tersebut dimodifikasi menjadi metode *Restricted Maximum Likelihood* (REML). Callanan (1985) menjelaskan bahwa proses REML dimulai

dari mengubah nilai amatan Y . Anggap Y merupakan matriks nilai amatan yang akan diestimasi dengan mengtransformasikan berupa mengalikannya dengan suatu matriks sembarang ortogonal A dengan ukuran $n \times (n - p)$. Transformasi yang dilakukan yaitu sebagai berikut.

$$Y' = A^T Y \quad (15)$$

di mana $A^T X = 0$ dan matriks A harus memenuhi $A^T A = A A^T = I$, sehingga Y' mempunyai nilai rataan dan keragaman sebagai berikut.

$$\begin{aligned} E(Y') &= E(A^T Y) \\ &= A^T E(Y) \\ &= A^T X \beta \\ &= 0 \end{aligned} \quad (16)$$

$$\begin{aligned} Var(Y') &= E[(A^T Y - E(A^T Y))(A^T Y - E(A^T Y))^T] \\ &= E[(A^T Y - 0)(A^T Y - 0)^T] \\ &= E[(A^T Y)(A^T Y)^T] \\ &= E[(A^T Y)(Y^T A)] \\ &= A^T E[YY^T]A \\ &= A^T VA \end{aligned} \quad (17)$$

Berdasarkan uraian di atas dapat disimpulkan bahwa Y' akan mengikuti distribusi $N(0, A^T V A)$. Tahapan proses selanjutnya akan sama dengan metode ML. Dengan demikian, hal yang membedakan proses estimasi menggunakan metode ML dengan REML terletak pada fungsi *likelihood* yang digunakan.

Empirical Best Linear Unbiased Prediction Fay-Herriot (EBLUP-FH)

Empirical Best Linear Unbiased Prediction Fay-Herriot (EBLUP-FH)

adalah salah satu metode estimasi parameter yang menerapkan model *Linear Mixed Model* (LMM). EBLUP-FH merupakan metode yang cocok digunakan untuk data kontinu, tetapi kurang cocok untuk data biner atau cacahan. Adapun bentuk umum dari model LMM adalah sebagai berikut (Rao, 2003).

$$\hat{\boldsymbol{\theta}} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{v} + \boldsymbol{e} \quad (18)$$

Keterangan:

- $\hat{\boldsymbol{\theta}}$ = vektor acak dari variabel dependen
- \mathbf{X} = matriks dari variabel penyerta (*covariate*) dengan $x_{i1}, x_{i2}, \dots, x_{ip}$
- $\boldsymbol{\beta}$ = vektor koefisien regresi
- \mathbf{Z} = matriks desain dari variabel independen
- \boldsymbol{v} = vektor *random effect area*
- \boldsymbol{e} = vektor *random error*

ekuivalen dengan bentuk model *Fay-Herriot* yang dapat dituliskan sebagai berikut:

$$\hat{\theta}_i = \mathbf{x}_i^T \boldsymbol{\beta} + z_i v_i + e_i, i = 1, 2, \dots, m \quad (19)$$

di mana $v_i \sim_{iid} N(0, \sigma_v^2)$ dan $e_i \sim_{iid} N(0, \psi_i)$ dengan nilai ragam ψ_i diketahui pada data. Misalnya diasumsikan bahwa v_i dan e_i saling independen. Teknik penyelesaian dari persamaan (19) dilakukan dengan mengasumsikan nilai σ_v^2 diketahui dan $r_{mm}(\delta) = \psi_n$ sehingga diperoleh $Var(\mathbf{Y}) = \sigma_v^2 + \psi_n$. Berdasarkan informasi tersebut, maka dapat diperoleh bentuk EBLUP yang menjadi estimator

Best Linear Unbiased Prediction (BLUP) dengan persamaan sebagai berikut:

$$\begin{aligned} \hat{\theta}_i^{BLUP} &= \gamma_i \hat{\theta}_i + (1 - \gamma_i) \mathbf{x}_i^T \hat{\boldsymbol{\beta}} \\ \hat{\theta}_i^{BLUP} &= \mathbf{x}_i^T \hat{\boldsymbol{\beta}} + \gamma_i (\hat{\theta}_i - \mathbf{x}_i^T \hat{\boldsymbol{\beta}}) \end{aligned} \quad (20)$$

di mana γ_i yang digunakan adalah

$$\gamma_i = \frac{\sigma_v^2}{\sigma_v^2 + \psi_i} \quad (21)$$

dengan $\hat{\beta}$ merupakan koefisien regresi yang diduga dengan *Generalized Least Square* (GLS) yaitu:

$$\hat{\beta} = \sum_{i=1}^m (\mathbf{x}_i(\sigma_v^2 z_i^2 + \psi_i)^{-1} \mathbf{x}_i^T)^{-1} \sum_{i=1}^m \mathbf{x}_i (\sigma_v^2 z_i^2 + \psi_i)^{-1} \hat{\theta}_i \quad (22)$$

Apabila nilai keragaman dari pengaruh acak (σ_v^2) tidak diketahui, maka penduga komponen ragam pengaruh acak harus dihitung terlebih dahulu dari data empiris. Metode yang dapat digunakan untuk memperoleh nilai estimator $\widehat{\sigma}_v^2$ adalah metode *Restricted Maximum Likelihood* (REML). Dengan menggunakan metode REML diperoleh nilai estimator $\widehat{\sigma}_v^2$ dari σ_v^2 membentuk estimator $\hat{\theta}_i$ menjadi:

$$\begin{aligned} \hat{\theta}_i^{EBLUP} &= \mathbf{x}_i^T \hat{\beta} + \frac{\sigma_v^2}{\widehat{\sigma}_v^2 + \psi_i} (\hat{\theta}_i - \mathbf{x}_i^T \hat{\beta}) \\ \hat{\theta}_i^{EBLUP} &= \mathbf{x}_i^T \hat{\beta} + \hat{\gamma}_i (\hat{\theta}_i - \mathbf{x}_i^T \hat{\beta}) \end{aligned} \quad (23)$$

dengan nilai $\hat{\beta}$ adalah

$$\hat{\beta} = \sum_{i=1}^m (\mathbf{x}_i(\widehat{\sigma}_v^2 z_i^2 + \psi_i)^{-1} \mathbf{x}_i^T)^{-1} \sum_{i=1}^m \mathbf{x}_i (\widehat{\sigma}_v^2 z_i^2 + \psi_i)^{-1} \hat{\theta}_i \quad (24)$$

Setelah melalui proses penurunan persamaan diperoleh bahwa $\hat{\theta}_i$ merupakan estimasi suatu area kecil yang tak bias, linear dan memiliki standar *error* minimum.

Mean Square Error (MSE) EBLUP-FH

Setelah menperoleh nilai penduga dari BLUP, Rao & Molina (2015). menyebutkan bahwa diperlukan pengecekan terhadap ukuran kebaikan model penduga BLUP dengan menghitung nilai *Mean Square Error* (MSE) dengan formula berikut.

$$MSE(\hat{\theta}_i^{BLUP}) = g_{1i}(\sigma_v^2) + g_{2i}(\sigma_v^2) \quad (25)$$

di mana

$$g_{1i}(\sigma_v^2) = \frac{\sigma_v^2 \psi_i}{\psi_i + \sigma_v^2} = \gamma_i \psi_i \quad (26)$$

$$g_{2i}(\sigma_v^2) = (1 - \psi_i)^2 \mathbf{x}_i^T \left[\sum_{i=1}^m \frac{\mathbf{x}_i \mathbf{x}_i^T}{\psi_i + \sigma_v^2} \right]^{-1} \mathbf{x}_i \quad (27)$$

Namun, dalam praktiknya nilai keragaman pengaruh acak (σ_v^2) jarang diketahui, sehingga harus diestimasi terlebih dahulu. Salah satu metode yang digunakan untuk mengestimasi nilai keragaman pengaruh acak (σ_v^2) adalah metode *Restricted Maximum Likelihood* (REML). Oleh karena itu, nilai MSE dari estimator EBLUP digunakan rumus sebagai berikut:

$$MSE(\hat{\theta}_i^{EBLUP}) = g_{1i}(\hat{\sigma}_v^2) + g_{2i}(\hat{\sigma}_v^2) + 2g_{3i}(\hat{\sigma}_v^2) \quad (28)$$

dengan

$$g_{1i}(\hat{\sigma}_v^2) = \frac{\hat{\sigma}_v^2 \psi_i}{\hat{\sigma}_v^2 + \psi_i} = \hat{\gamma}_i \psi_i \quad (29)$$

$$g_{2i}(\hat{\sigma}_v^2) = (1 - \hat{\gamma}_i)^2 \mathbf{x}_i^T \left[\sum_{i=1}^m \frac{\mathbf{x}_i \mathbf{x}_i^T}{\hat{\sigma}_v^2 + \psi_i} \right]^{-1} \mathbf{x}_i \quad (30)$$

$$g_{3i}(\hat{\sigma}_v^2) = \psi_i^2 \mathbf{x}_i^4 (\hat{\sigma}_v^2 z_i^2 + \psi_i)^{-3} \bar{V}(\sigma_v^2) \quad (31)$$

di mana

$$\bar{V}(\sigma_v^2) = 2m^{-2} \sum_{i=1}^m (\hat{\sigma}_v^2 + \psi_i)^2 \quad (32)$$

adalah varians asimtot dari σ_v^2 .

Spatial Empirical Best Linear Unbiased Prediction Fay-Herriot (SEBLUP-FH)

Andaikan terdapat vektor $\hat{\boldsymbol{\theta}} = (\hat{\theta}_1, \dots, \hat{\theta}_m)$, $\mathbf{X} = (\mathbf{x}_1^T, \dots, \mathbf{x}_m^T)$, $\mathbf{Z} = diag(z_1, \dots, z_m)$, $\mathbf{v} = (v_1, \dots, v_m)^T$, dan $\mathbf{e} = (e_1, \dots, e_m)$. Maka dapat terbentuk suatu matriks sebagai berikut.

$$\widehat{\boldsymbol{\theta}} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\boldsymbol{v} + \boldsymbol{e} \quad (33)$$

di mana model tersebut masih mengasumsikan bahwa pengaruh acak area saling independen antara satu area dengan area lainnya. Akan tetapi, pada kenyataannya penduga langsung berpeluang untuk memiliki korelasi (ketergantungan) spasial antarlokasi. Ketergantungan spasial tersebut semakin meningkat apabila jarak antarobservasi semakin dekat. Hal ini sejalan dengan hukum pertama geografi yang dinyatakan oleh Tobler sebagai *Tobler's first law of geography* dalam Waters (2017) yang merupakan pilar dari kajian analisis data spasial. Tobler menyatakan bahwa “*everything is related to everything else, but near things are more related than distant things*”.

Beberapa penelitian telah mengembangkan model SAE dengan mempertimbangkan asumsi ketergantungan spasial, seperti N. Cressie (1994) yang mengacu pada Rao & Molina (2015) mengikuti model *Conditional Autoregressive* (CAR). Selain itu, Pratesi & Salvati (2008) yang diacu dalam Rao & Molina (2015) mengembangkan model SAE dengan mengasumsikan adanya ketergantungan spasial yang dimasukkan ke dalam model *Simultaneous Autoregressive* (SAR). Model SAR sudah pertama kali diperkenalkan oleh Anselin (1992) dengan bentuk vektor pengaruh acak area \boldsymbol{v} dinyatakan sebagai berikut.

$$\boldsymbol{v} = \rho \mathbf{W}\boldsymbol{v} + \boldsymbol{u} \quad (34)$$

keterangan:

ρ : koefisien autoregresi spasial menunjukkan kekuatan hubungan spasial antar pengaruh acak. Nilai ρ memiliki rentang antara -1 hingga 1. Nilai positif menunjukkan suatu area dengan nilai parameter yang tinggi

cenderung dikelilingi oleh area lain dengan nilai parameter tinggi juga, begitupun sebaliknya (Savitz & Raudenbush, 2009).

\mathbf{W} : matriks pembobot spasial

$\boldsymbol{\nu}$: vektor *random effect area*

\boldsymbol{u} : vektor kesalahan dari pengaruh acak area yang berdistribusi $N(0, \sigma_u^2 \mathbf{I}_m)$.

Maka, persamaan (34) dapat dituliskan kembali menjadi seperti berikut ini:

$$\boldsymbol{\nu} = (\mathbf{I} - \rho \mathbf{W})^{-1} \boldsymbol{u} \quad (35)$$

dengan \mathbf{I} adalah matriks identitas berukuran $m \times m$. Nilai rataan dari $\boldsymbol{\nu}$ adalah 0 dan matriks *covariance* dari $\boldsymbol{\nu}$ dapat dihitung dengan persamaan berikut.

$$\mathbf{G} = \sigma_v^2 [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W}^T)]^{-1} \quad (36)$$

Kemudian persamaan di atas disubstitusikan ke persamaan (33) sehingga menjadi

$$\widehat{\boldsymbol{\theta}} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}(\mathbf{I} - \rho \mathbf{W})^{-1} \boldsymbol{u} + e \quad (37)$$

dengan matriks *covarians* dari $\boldsymbol{\theta}$ dengan $\mathbf{R} = \text{diag}(\psi_i)$, maka

$$\mathbf{V} = \mathbf{R} + \mathbf{Z}\mathbf{G}\mathbf{Z}^T = \text{diag}(\psi_i) + \mathbf{Z}\sigma_v^2 [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W}^T)]^{-1} \mathbf{Z}^T \quad (38)$$

sehingga penduga spasial BLUP untuk parameter θ_i di mana σ_v^2 , ψ_i , dan ρ berikut.

$$\begin{aligned} \widehat{\boldsymbol{\theta}}_i^{SBLUP}(\sigma_v^2, \rho) &= \mathbf{x}_i^T \widehat{\boldsymbol{\beta}} \\ &+ \mathbf{b}_i^T \{ \sigma_v^2 [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W}^T)]^{-1} \} \mathbf{Z}^T \\ &\times \{ \text{diag}(\psi_i) \\ &+ \mathbf{Z}\sigma_v^2 [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W}^T)]^{-1} \mathbf{Z}^T \}^{-1} (\widehat{\boldsymbol{\theta}} - \mathbf{X}\widehat{\boldsymbol{\beta}}) \end{aligned} \quad (39)$$

Keterangan:

$$\widehat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \widehat{\mathbf{V}}^{-1} \widehat{\boldsymbol{\theta}} \quad (40)$$

\mathbf{b}_i^T = vektor berukuran $1 \times m$ berbentuk $(0, 0, 1, 0, \dots, 0)$ dengan nilai 1 menunjuk pada lokasi ke- i .

Penduga spasial BLUP dapat diperoleh dengan mensubstitusikan matriks *covariance* pada persamaan (38) ke penduga BLUP. Jika nilai $\rho = 0$, maka penduga spasial BLUP akan sama dengan penduga BLUP.

Seperti halnya pada EBLUP, penduga spasial EBLUP atau SEBLUP ($\hat{\theta}_i^{SEBLUP}(\hat{\sigma}_v^2, \hat{\rho})$) diperoleh dari matriks *covariance* yang disubstitusikan ke dalam persamaan (39). Jika nilai $\rho = 0$, maka penduga spasial EBLUP akan memiliki nilai yang sama dengan penduga EBLUP. Kemudian, asumsi normalitas diperlukan dalam menduga σ_v^2 dan ρ menggunakan prosedur estimasi, baik dengan ML maupun REML, yaitu dengan *loglikelihood* (Saei & Chambers, 2003). Secara umum, persamaan dari penduga SEBLUP dengan metode REML dituliskan berikut.

$$\begin{aligned}\hat{\theta}_i^{SEBLUP}(\hat{\sigma}_v^2, \hat{\rho}) &= \mathbf{x}_i^T \hat{\boldsymbol{\beta}} + \mathbf{b}_i^T \{ \hat{\sigma}_v^2 [(\mathbf{I} - \hat{\rho} \mathbf{W})(\mathbf{I} - \hat{\rho} \mathbf{W})^T]^{-1} \} \mathbf{Z}^T \\ &\times \{ \text{diag}(\psi_i) + \mathbf{Z} \hat{\sigma}_v^2 [(\mathbf{I} - \hat{\rho} \mathbf{W})(\mathbf{I} - \hat{\rho} \mathbf{W})^T]^{-1} \mathbf{Z}^T \}^{-1} (\hat{\boldsymbol{\theta}} - \mathbf{X} \hat{\boldsymbol{\beta}})\end{aligned}\quad (41)$$

Mean Square Error (MSE) SEBLUP-FH

Untuk mendapatkan nilai MSE bagi model SEBLUP, maka perlu diketahui terlebih dahulu dari model SBLUP. Misalkan diketahui bahwa MSE SBLUP melalui proses yang sama dengan BLUP sehingga tidak dijabarkan secara khusus adalah sebagai berikut.

$$MSE[\hat{\theta}_i^{SBLUP}(\sigma_v^2, \rho)] = g_{1i}(\sigma_v^2, \rho) + g_{2i}(\sigma_v^2, \rho) \quad (42)$$

dengan

$$\begin{aligned}g_{1i}(\sigma_v^2, \rho) &= \mathbf{b}_i^T \{ \sigma_v^2 [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W})^T]^{-1} \} \mathbf{Z}^T \\ &\times \{ \text{diag}(\psi_i) + \mathbf{Z} \sigma_v^2 [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W})^T]^{-1} \mathbf{Z}^T \}^{-1} \mathbf{Z} \sigma_v^2 \\ &\times [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W})^T]^{-1} \mathbf{b}_i\end{aligned}\quad (43)$$

dan

$$\begin{aligned}
g_{2i}(\sigma_v^2, \rho) &= (\mathbf{x}_i - \mathbf{b}_i^T \{\sigma_v^2 [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W})^T]^{-1}\} \mathbf{Z}^T \\
&\quad \times \{diag(\psi_i) + \mathbf{Z} \sigma_v^2 [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W})^T]^{-1} \mathbf{Z}^T\}^{-1} \mathbf{X}) \\
&\quad \times (\mathbf{X}^T \{diag(\psi_i) + \mathbf{Z} \sigma_v^2 [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W})^T]^{-1} \mathbf{Z}^T\}^{-1} \mathbf{X})^{-1} \\
&\quad \times (\mathbf{x}_i - \mathbf{b}_i^T \{\sigma_v^2 [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W})^T]^{-1}\} \mathbf{Z}^T \\
&\quad \times (\{diag(\psi_i) + \mathbf{Z} \sigma_v^2 [(\mathbf{I} - \rho \mathbf{W})(\mathbf{I} - \rho \mathbf{W})^T]^{-1} \mathbf{Z}^T\}^{-1} \mathbf{X})^T
\end{aligned} \tag{44}$$

Diketahui bahwa bentuk $E[\hat{\theta}_i^{SBLUP}, (\hat{\sigma}_v^2, \hat{\rho}) - \theta_i^{SBLUP}]^2$ merupakan bentuk MSE bagi $\hat{\theta}_i^{SBLUP}(\sigma_v^2, \rho)$. Seperti halnya pada proses EBLUP, bentuk dari $E[\hat{\theta}_i^{SEBLUP}, (\hat{\sigma}_v^2, \hat{\rho}) - \hat{\theta}_i^{SBLUP}]^2$ tidak dapat diselesaikan secara eksak. Oleh sebab itu, Kackar & Harville (1984) di dalam Pratesi & Salvati (2008) menggunakan pendekatan deret *Taylor* sehingga diperoleh MSE bagi penduga SEBLUP adalah sebagai berikut.

$$MSE(\hat{\theta}_i^{SEBLUP}, (\hat{\sigma}_v^2, \hat{\rho})) \approx g_{1i}(\hat{\sigma}_v^2, \hat{\rho}) + g_{2i}(\hat{\sigma}_v^2, \hat{\rho}) + 2g_{3i}(\hat{\sigma}_v^2, \hat{\rho}) \tag{45}$$

dengan

$$\begin{aligned}
g_{1i}(\hat{\sigma}_v^2, \hat{\rho}) &= \mathbf{b}_i^T \{\sigma_v^2 [(\mathbf{I} - \hat{\rho} \mathbf{W})(\mathbf{I} - \hat{\rho} \mathbf{W})^T]^{-1}\} \mathbf{Z}^T \\
&\quad \times \{diag(\psi_i) + \mathbf{Z} \sigma_v^2 [(\mathbf{I} - \hat{\rho} \mathbf{W})(\mathbf{I} - \hat{\rho} \mathbf{W})^T]^{-1} \mathbf{Z}^T\}^{-1} \mathbf{Z} \sigma_v^2 \\
&\quad \times [(\mathbf{I} - \hat{\rho} \mathbf{W})(\mathbf{I} - \hat{\rho} \mathbf{W})^T]^{-1} \mathbf{b}_i
\end{aligned} \tag{46}$$

$$\begin{aligned}
g_{2i}(\hat{\sigma}_v^2, \hat{\rho}) &= (\mathbf{x}_i - \mathbf{b}_i^T \{\sigma_v^2 [(\mathbf{I} - \hat{\rho} \mathbf{W})(\mathbf{I} - \hat{\rho} \mathbf{W})^T]^{-1}\} \mathbf{Z}^T \\
&\quad \times \{diag(\psi_i) + \mathbf{Z} \sigma_v^2 [(\mathbf{I} - \hat{\rho} \mathbf{W})(\mathbf{I} - \hat{\rho} \mathbf{W})^T]^{-1} \mathbf{Z}^T\}^{-1} \mathbf{X}) \\
&\quad \times (\mathbf{X}^T \{diag(\psi_i) + \mathbf{Z} \sigma_v^2 [(\mathbf{I} - \hat{\rho} \mathbf{W})(\mathbf{I} - \hat{\rho} \mathbf{W})^T]^{-1} \mathbf{Z}^T\}^{-1} \mathbf{X})^{-1} \\
&\quad \times (\mathbf{x}_i - \mathbf{b}_i^T \{\sigma_v^2 [(\mathbf{I} - \hat{\rho} \mathbf{W})(\mathbf{I} - \hat{\rho} \mathbf{W})^T]^{-1}\} \mathbf{Z}^T \\
&\quad \times \{diag(\psi_i) + \mathbf{Z} \sigma_v^2 [(\mathbf{I} - \hat{\rho} \mathbf{W})(\mathbf{I} - \hat{\rho} \mathbf{W})^T]^{-1} \mathbf{Z}^T\}^{-1} \mathbf{X})^T
\end{aligned} \tag{47}$$

dan

$$\begin{aligned}
& g_{3i}(\hat{\sigma}_v^2, \hat{\rho}) \\
&= \text{tr} \left\{ \begin{bmatrix} \mathbf{b}_i^T (\mathbf{C}^{-1} \mathbf{Z}^T \mathbf{V}^{-1} + \sigma_u^2 \mathbf{C}^{-1} \mathbf{Z}^T (-\mathbf{V}^{-1} \mathbf{Z} \mathbf{C}^{-1} \mathbf{Z}^T \mathbf{V}^{-1})) \\ \mathbf{b}_i^T \mathbf{A} \mathbf{Z}^T \mathbf{V}^{-1} + \sigma_u^2 \mathbf{C}^{-1} \mathbf{Z}^T (-\mathbf{V}^{-1} \mathbf{Z} \mathbf{A} \mathbf{Z}^T \mathbf{V}^{-1}) \end{bmatrix} \right\} \mathbf{V} \\
&\times \begin{bmatrix} \mathbf{b}_i^T (\mathbf{C}^{-1} \mathbf{Z}^T \mathbf{V}^{-1} + \sigma_u^2 \mathbf{C}^{-1} \mathbf{Z}^T (-\mathbf{V}^{-1} \mathbf{Z} \mathbf{C}^{-1} \mathbf{Z}^T \mathbf{V}^{-1})) \\ \mathbf{b}_i^T \mathbf{A} \mathbf{Z}^T \mathbf{V}^{-1} + \sigma_u^2 \mathbf{C}^{-1} \mathbf{Z}^T (-\mathbf{V}^{-1} \mathbf{Z} \mathbf{A} \mathbf{Z}^T \mathbf{V}^{-1}) \end{bmatrix}^T \bar{V}(\hat{\sigma}_v^2, \hat{\rho}) \quad (48)
\end{aligned}$$

Relative Root Mean Square Error (RRMSE)

Setelah diperoleh nilai estimasi dan MSE dari penduga EBLUP, maka dapat dilakukan evaluasi lain terhadap hasil pendugaan tersebut. (Rao & Molina, 2015) menjelaskan terdapat evaluasi yang dapat dilakukan dengan menggunakan *Relative Root Mean Square Error* (RRMSE). Adapun penghitungan untuk mendapatkan nilai RRMSE dituliskan formula sebagai berikut.

$$RRMSE(\hat{\theta}_i^{EBLUP}) = \frac{\sqrt{MSE(\hat{\theta}_i^{EBLUP})}}{\hat{\theta}_i^{EBLUP}} \times 100\% \quad (49)$$

Relative Standard Error (RSE)

Standard Error (SE) dari suatu nilai statistik merupakan nilai standar deviasi dari distribusi sampling atau estimasi dari standar deviasi (Everitt & Skrondal, 2010). Nilai statistik yang dimaksud adalah rata-rata sampel. Secara matematis, jika semakin besar ukuran sampel, maka rata-rata sampel akan semakin mengelompok di sekitar nilai rataan populasinya. Pada istilah lain, RSE merupakan ukuran konvergensi dari rasio antara nilai *standard error* dengan nilai estimasinya. Apabila nilai RSE semakin kecil, maka penduga dari suatu model akan semakin akurat. Adapun rumus RSE yang dituliskan sebagai berikut (BPS, 2009).

$$RSE(\hat{\theta}) = \frac{SE(\hat{\theta})}{\hat{\theta}} \times 100\% \quad (50)$$

di mana $\hat{\theta}$ merupakan penduga dari suatu parameter dan $SE(\hat{\theta})$ merupakan nilai *standard error*. Badan Pusat Statistik dalam publikasinya yang berjudul “Analisis Komprehensif Hasil Survei MDGs Kecamatan” mengelompokkan tingkat akurasi dari estimasi berdasarkan nilai RSE yang ditunjukkan pada Tabel 5 berikut.

Tabel 5. Interpretasi nilai RSE

Nilai RSE (1)	Keterangan estimasi (2)
$RSE \leq 25\%$	Akurat (bisa digunakan)
$25\% < RSE \leq 50\%$	Perlu hati-hati jika digunakan
$RSE > 50\%$	Dianggap tidak akurat

Sumber: (BPS, 2009)

Matriks Pembobot Spasial

Matriks pembobot spasial adalah sebuah matriks yang merepresentasikan hubungan spasial suatu lokasi dengan lokasi lain yang berdekatan atau bertetanggaan. Matriks pembobot spasial (W) merupakan komponen penting di dalam pemodelan spasial di mana pada model tersebut terdapat ketergantungan spasial. Matriks ini memiliki elemen non-negatif yang berukuran $m \times m$ yang mengspesifikasikan hubungan ketetanggaan secara spasial untuk setiap unit amatan. Dalam membuat susunan matriks, terdapat dua spesifikasi cara yaitu matriks yang berbasis jarak dan berbasis kedekatan (Stakhovych & Bijmolt, 2009).

Penelitian ini menggunakan matriks pembobot spasial yang berbasis kedekatan (*spatial contiguity*). Matriks berbasis kedekatan dibuat berdasarkan kedekatan antarlokasi. Adapun pengkodean yang dilakukan dalam membuat matriks pembobot spasial berbasis kedekatan tersebut, yaitu nilai 1 untuk suatu

lokasi yang berdekatan langsung dengan lokasi lain dan nilai 0 untuk suatu lokasi yang tidak berdekatan dengan lokasi lain. Matriks pembobot spasial berbasis kedekatan dapat ditentukan dengan beberapa tipe dalam mendefinisikan hubungan kedekatan atau ketersinggungan antarwilayah. Dubin et al. (2009) membedakannya ke dalam tiga jenis antara lain sebagai berikut.

1. *Rook contiguity* (ketersinggungan sisi) mendefinisikan nilai $w_{ij} = 1$ untuk lokasi yang bersisian (*common side*) dengan lokasi yang menjadi acuan, sedangkan nilai $w_{ij} = 0$ untuk lokasi lainnya.
2. *Bishop contiguity* (ketersinggungan sudut) mendefinisikan nilai $w_{ij} = 1$ untuk lokasi yang titik sudutnya bertemu (*common vertex*) dengan sudut lokasi yang menjadi acuan, sedangkan nilai $w_{ij} = 0$ untuk lokasi lainnya,
3. *Queen contiguity* (ketersinggungan sisi-sudut) mendefinisikan nilai $w_{ij} = 1$ untuk lokasi yang bersisian (*common side*) atau titik sudutnya (*common vertex*) bertemu dengan lokasi yang menjadi acuan, sedangkan $w_{ij} = 0$ untuk lokasi lainnya,

Penelitian ini menggunakan referensi peta yang menggambarkan kondisi geografis sebenarnya sehingga sulit mengidentifikasi apakah suatu lokasi bersinggungan sisi atau bersinggungan sudut dengan lokasi lain. Oleh sebab itu, tipe ketersinggungan yang digunakan pada penelitian ini adalah matriks tipe *Queen* karena dinilai memberikan representasi yang lebih realistik dari hubungan spasial pada peta sebenarnya. Kemudian, matriks tipe *Queen* perlu distandarisasi untuk meminimalkan efek variasi jumlah tetangga dari setiap unit data. Dengan demikian, penelitian ini menggunakan matriks pembobot spasial tipe *Queen*.

Autokorelasi Spasial

Anselin & Bera (1998) menyatakan bahwa pada teori ekonometrika terdapat dua jenis pengaruh spasial, yaitu pengaruh dependensi spasial dan pengaruh heterogenitas spasial. Dependensi spasial menunjukkan adanya keterkaitan antarlokasi objek yang diamati, sedangkan heterogenitas spasial menunjukkan adanya keragaman bentuk fungsional dan parameter sesuai lokasi. Untuk menguji hubungan antarwilayah melalui suatu atribut dilakukan uji autokorelasi spasial. Autokorelasi spasial mengindikasikan bahwa nilai atribut yang dimiliki pada suatu wilayah mempunyai keterkaitan oleh nilai atribut pada wilayah lain yang letaknya berdekatan. Autokorelasi spasial digunakan untuk menganalisis pola spasial dari penyebaran titik-titik berdasarkan lokasi dan atributnya. Autokorelasi spasial berbasis area dapat bernilai positif atau negatif. Autokorelasi spasial positif menunjukkan adanya kemiripan nilai dari lokasi-lokasi yang berdekatan dan kecenderungan mengelompok. Sedangkan autokorelasi spasial negatif menunjukkan bahwa lokasi-lokasi yang berdekatan mempunyai nilai yang berbeda dan kecenderungan menyebar. Tidak adanya autokorelasi spasial mengindikasikan pola lokasi yang acak (Lee & Wong, 2001).

Anselin & Bera (1998) menyebutkan bahwa salah satu metode yang dapat digunakan untuk menguji adanya autokorelasi spasial antarlokasi yaitu *Moran's I*. Pengujian statistik ini bertujuan untuk menguji hubungan atau korelasi antarlokasi pada suatu variabel sehingga terlihat ada atau tidaknya ketergantungan spasial. Hipotesis dan statistik pengujian *Morans'I* adalah sebagai berikut.

Hipotesis:

$$H_0 : I = 0 \text{ (tidak ada dependensi spasial antarlokasi)}$$

$H_1 : I \neq 0$ (ada dependensi spasial antarlokasi)

Statistik Uji:

$$Z = \frac{I - E(I)}{\sqrt{var(I)}} \quad (51)$$

dengan

$$I = \frac{n \sum_{i=1}^n \sum_{j=1}^n w_{ij} (y_i - \bar{y}) (y_j - \bar{y})}{S_0 \sum_{i=1}^n (y_i - \bar{y})^2} \quad (52)$$

dan

$$var(I) = \frac{n[(n^2 - 3n + 3)S_1 - nS_2 + 2S_0^2]}{(n-1)(n-2)(n-3)S_0^2} - \frac{k[(n^2 - n)S_1 - nS_2 + 2S_0^2]}{(n-1)(n-2)(n-3)S_0^2} - \left[-\frac{1}{n-1} \right]^2 \quad (53)$$

di mana

$$S_1 = \frac{1}{2} \sum_{i \neq j}^n (w_{ij} + w_{ji})^2 ; S_2 = \sum_{i \neq j}^n (w_{i.} + w_{.i})^2 ; S_0 = \sum_{i=1}^n \sum_{j=1}^n w_{ij} ;$$

$$w_{i.} = \sum_{j=1}^n w_{ij} ; w_{.i} = \sum_{j=1}^n w_{ji}.$$

Keputusan untuk menolak H_0 ketika nilai $|Z| > Z_{\frac{\alpha}{2}}$ (LeSage, 1999).

Metode Bayesian

Hajarisman (2013) menjelaskan perbedaan utama dari statistik *Bayes* dengan statistik klasik (*frequentist*) terletak pada asumsi yang melekat pada seluruh parameter yang tidak diketahui dianggap sebagai peubah acak (*random variable*). Dari asumsi tersebut dapat memberikan kesempatan bagi peneliti untuk mengetahui informasi di awal sebelum melihat kenyataan pada data yang digunakan. Informasi awal diistilahkan sebagai distribusi *prior*. Oleh karena itu, pada awal pemodelan statistik *Bayes* biasanya didefinisikan suatu distribusi *prior* terlebih dahulu sebagai informasi awal dari data yang digunakan. Sedangkan informasi dari data yang digunakan biasa disebut sebagai fungsi *likelihood*. Setelah mendefinisikan distribusi *prior* dan fungsi *likelihood* dari data yang digunakan, maka dapat dibentuk distribusi *posterior* sebagai kunci dalam inferensi pada statistik *Bayesian*.

Menurut Lynch (2007), distribusi *posterior* merupakan suatu distribusi yang menggabungkan pengetahuan awal seluruh parameter dan informasi dari data yang digunakan. Distribusi *posterior* sebanding dengan hasil perkalian dari distribusi *prior* dan fungsi *likelihood*. Jika dituliskan dalam bentuk notasi matematika adalah sebagai berikut.

$$Distribusi\ posterior \propto Distribusi\ prior \times fungsi\ likelihood$$

Misalkan terdapat data observasi $y = (y_1, y_2, \dots, y_n)^T$ mempunyai distribusi tertentu dengan himpunan parameter $\beta = (\beta_1, \beta_2, \dots, \beta_k)^T$ yang merupakan *random variable*. Maka, distribusi *posterior* dari parameter β atau dinotasikan sebagai $f(\beta|y)$ dapat dinyatakan sebagai berikut.

$$f(\beta|y) = \frac{f(y|\beta)f(\beta)}{f(y)} \quad (54)$$

di mana $f(y)$ merupakan *marginal density function* dari peubah acak y , $f(\beta)$ merupakan fungsi distribusi *prior* dari parameter β yang berisi informasi awal yang diketahui sebelum pengamatan dilakukan, dan $f(y|\beta) = \prod_{i=1}^n f(y_i|\beta)$ merupakan fungsi *likelihood* berisi informasi sampel dari data yang digunakan.

Distribusi *Prior*

Dalam metode *Bayes*, distribusi *prior* memiliki peran penting dalam pendugaan parameter β yang tidak diketahui. Distribusi *prior* merupakan distribusi awal yang memberikan informasi tentang parameter dan harus ditentukan terlebih dahulu sebelum merumuskan distribusi *posterior*-nya. Distribusi *prior* pada dasarnya dipilih secara subjektif oleh peneliti terhadap nilai parameter yang ingin diduga (Bain & Engelhardt, 1992). Adapun jenis-jenis *prior* menurut Wasserman (2004) yaitu *Conjugate* dan *Nonconjugate Prior*, *Proper* dan *Improper Prior*, serta

Informative dan *Noninformative Prior*. *Conjugate* dan *Nonconjugate Prior* ditentukan menurut pola data yang terlihat pada fungsi *likelihood*-nya. *Proper* dan *Improper Prior* ditentukan dari penyelesaian integral yang digunakan dari suatu distribusi *prior* berbentuk berhingga atau tidak. Sedangkan *Informative* dan *Noninformative Prior* ditentukan dari ada atau tidaknya pengetahuan atau informasi awal tentang suatu parameter yang ingin diduga. Menurut Rao & Molina (2015), suatu *prior* bersifat *informative* jika terdapat informasi awal yang mendasari suatu parameter dari penelitian sebelumnya yang dinilai relevan dengan data yang digunakan. Sedangkan pada kasus nyata tidak banyak informasi yang tersedia pada pengaplikasian metode SAE pendekatan *Hierarchical Bayes* yang berkaitan dengan kebijakan publik. Oleh sebab itu, *noninformative prior* menjadi solusi terhadap kurangnya informasi mengenai parameter model. Sebagian besar peneliti mengungkapkan bahwa penggunaan *noninformative prior* dianggap lebih objektif dibanding *informative prior* (Noviani, 2016).

Fungsi *Likelihood*

Menurut Bain & Engelhardt (1992), fungsi *likelihood* adalah fungsi kepekatan peluang bersama (*joint probability density function*) dari n peubah acak X_1, X_2, \dots, X_n yang dihitung pada x_1, x_2, \dots, x_n dan dinyatakan dalam bentuk $f(x_1, x_2, \dots, x_n)$. Jika x_1, x_2, \dots, x_n merupakan sampel peubah acak yang diketahui, maka fungsi *likelihood* adalah fungsi dari parameter θ dan dinotasikan dengan $f(x|\theta)$. Misalkan X_1, X_2, \dots, X_n menyatakan suatu peubah acak dari $f(x; \theta)$, maka:

$$f(x|\theta) = f(x_1; \theta)f(x_2; \theta) \dots f(x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) \quad (55)$$

Hierarchical Bayes (HB)

Metode SAE terdapat dua model yang menggunakan statistik *Bayesian* untuk mengakomodasi adanya pengaruh tetap dan pengaruh acak, yaitu metode *Empirical Bayes* (EB) dan *Hierarchical Bayes* (HB). Metode EB mendapatkan distribusi *prior* dengan cara estimasi berdasarkan data sampel, sedangkan metode HB memperoleh distribusi *prior* berdasarkan penentuan secara subjektif dari peneliti. Metode EB menggunakan distribusi *prior* tersebut sebagai informasi untuk menyusun distribusi *posterior*, kemudian menduga parameter area kecil berdasarkan distribusi *posterior* marginalnya. Hal ini yang menjadi kelemahan dalam metode EB karena tidak terdapat kejelasan yang baik pada hasil estimasi *prior* maupun *posterior* (Noviani, 2016).

Pada metode HB, misalkan terdapat suatu distribusi *prior* $f(\lambda)$ yang ditentukan oleh peneliti untuk memperoleh distribusi *posterior* $f(\theta|y)$ dari parameter area kecil (θ) yang ingin diduga menggunakan sampel data (y). Dengan menggunakan teorema *Bayesian*, model dua tahap dapat dibentuk menjadi $f(y|\theta, \lambda_1)$ dan $f(\theta|\lambda_2)$ yang dikombinasikan dengan distribusi *prior* $\lambda = (\lambda_1, \lambda_2)$ untuk menghasilkan distribusi *posterior*. Kemudian secara khusus parameter ($\phi = h(\theta)$) dapat diduga dengan rata-rata *posterior*-nya yaitu ($\phi^{HB} = E[h(\theta)|y]$) dan pengukuran akurasi dari penduga didasarkan pada varians *posterior*-nya yaitu ($V[h(\theta)|y]$). Menurut Rao & Molina (2015) dengan mengaplikasikan teorema *Bayesian* didapatkan:

$$f(\theta, \lambda|y) = \frac{f(y, \theta|\lambda)f(\lambda)}{f_1(y)} \quad (56)$$

dengan $f_1(y)$ merupakan fungsi kepadatan marginal dari y dengan cara:

$$f_1(\mathbf{y}) = \int f(\mathbf{y}, \boldsymbol{\theta} | \boldsymbol{\lambda}) f(\boldsymbol{\lambda}) d\boldsymbol{\theta} d\boldsymbol{\lambda} \quad (57)$$

kemudian distribusi *posterior* dapat diperoleh sebagai berikut.

$$\begin{aligned} f(\boldsymbol{\theta} | \mathbf{y}) &= \int f(\boldsymbol{\theta}, \boldsymbol{\lambda} | \mathbf{y}) d\boldsymbol{\lambda} \\ &= \int f(\boldsymbol{\theta} | \mathbf{y}, \boldsymbol{\lambda}) f(\boldsymbol{\lambda} | \mathbf{y}) d\boldsymbol{\lambda} \end{aligned} \quad (58)$$

Persamaan (58) dapat dilihat bahwa untuk mencari distribusi *posterior* dan mendapatkan besaran rata-rata membutuhkan integrasi yang bersifat multidimensi. Meskipun integrasi yang hanya melibatkan satu atau dua dimensi dapat diselesaikan dengan cara analitik, tetapi untuk kasus yang lebih kompleks atau integrasi dengan dimensi yang lebih tinggi akan menjadi suatu masalah yang menimbulkan kesulitan dalam proses komputasi. Metode yang dapat mengatasi permasalahan tersebut pada implementasi HB yaitu metode *Markov Chain Monte Carlo* (MCMC). Metode ini membangkitkan sampel dari distribusi *posterior* dan mensimulasikannya untuk mengestimasi besaran *posterior* yang diinginkan (Rao & Molina, 2015).

Pengukuran akurasi dari penduga HB juga didasarkan pada nilai RRMSE. Jika nilai RRMSE penduga HB lebih kecil daripada nilai RSE dari penduga langsung, maka dapat disimpulkan bahwa model SAE HB menghasilkan penduga yang lebih akurat dibanding penduga langsung. Adapun nilai RRMSE dari penduga HB diperoleh dari hasil bagi antara akar varians *posterior* dengan penduga HB. Hal ini didasarkan pada prinsip metode *Bayesian* yang menggunakan besaran varians *posterior* sebagai ukuran akurasi suatu penduga. Maka, formula RRMSE dari penduga HB dapat dituliskan sebagai berikut.

$$RRMSE(\hat{\theta}_i^{HB}) = \frac{\sqrt{(V[h(\boldsymbol{\theta}) | \mathbf{y}]})}{\phi_i^{HB}} \quad (59)$$

Markov Chain Monte Carlo (MCMC)

Metode *Markov Chain Monte Carlo* (MCMC) adalah suatu teknik dengan pendekatan numerik yang digunakan untuk mendapatkan distribusi *posterior* dari suatu statistik *Bayesian* yang sangat kompleks sehingga memerlukan suatu proses integrasi yang rumit dalam menentukan marginal *posterior* suatu parameter. MCMC merupakan suatu metode simulasi perpaduan antara *Monte Carlo* dengan sifat *Markov Chain* untuk mendapatkan data sampel berdasarkan skenario sampling tertentu. Rantai *Markov* menggambarkan suatu peristiwa berurutan yang secara probabilitstik berhubungan satu sama lain. Oleh sebab itu, peristiwa saat ini memengaruhi peristiwa selanjutnya. Namun perlu diingat bahwa terdapat salah satu sifat rantai *Markov* adalah *memoryless* yang berarti seluruh kejadian saling independen atau tidak berkaitan dengan kejadian lalu. Maka, prediksi pada peristiwa selanjutnya hanya berdasarkan pada peristiwa saat ini dan tidak ada informasi yang berkaitan dari peristiwa sebelumnya (Casella & George, 1992).

Rantai *Markov* pada suatu *state space* didefinisikan sebagai suatu proses stokastik dari deret parameter di dalam inferensi *Bayesian* sebagai *random variable*, di mana nilai masing-masing *random variable* tersebut dapat dinotasikan $\{\boldsymbol{\theta}^{(1)}, \boldsymbol{\theta}^{(2)}, \dots, \boldsymbol{\theta}^{(T)}\}$ berada di dalam *state space* sedemikian rupa sehingga dituliskan sebagai berikut.

$$f(\boldsymbol{\theta}^{(t+1)} | \boldsymbol{\theta}^{(t)}, \dots, \boldsymbol{\theta}^{(1)}) = f(\boldsymbol{\theta}^{(t+1)} | \boldsymbol{\theta}^{(t)}) \quad (60)$$

Persamaan (60) menunjukkan bahwa distribusi dari $\boldsymbol{\theta}$ pada periode ke- $(t + 1)$ given seluruh nilai $\boldsymbol{\theta}$ pada periode sebelumnya $(t, t - 1, \dots, 1)$ hanya bergantung pada nilai $\boldsymbol{\theta}^{(t)}$. Kemudian, untuk membangkitkan sampel dari $f(\boldsymbol{\theta}|\mathbf{y})$ harus dibentuk suatu rantai *Markov* dengan dua kriteria, yaitu $f(\boldsymbol{\theta}^{(t+1)} | \boldsymbol{\theta}^{(t)})$ harus

mudah untuk dibangkitkan dan kondisi *equilibrium* (stasioner) dari rantai *Markov* terpilih merupakan distribusi *posterior*.

Dengan mengasumsikan rantai *Markov* telah memenuhi kedua kriteria tersebut, maka berikut ini merupakan algoritma dari metode MCMC secara keseluruhan yang dijelaskan sebagai berikut (Ntzoufras, 2011).

1. Memilih sebuah nilai awal (*initial value*) yang dinotasikan dengan $\boldsymbol{\theta}^{(0)}$.
2. Membangkitkan sebanyak T -sampel hingga kondisi *equilibrium* (stasioner) tercapai.
3. Melakukan diagnostik konvergensi algoritma MCMC untuk mengonfirmasi kondisi *equilibrium* telah tercapai atau tidak. Jika belum konvergen, maka membangkitkan ulang sampel dengan jumlah yang lebih besar.
4. Membuang sebanyak B -sampel pertama, di mana proses ini disebut dengan *burn in* yaitu membuang beberapa sampel di awal untuk menghilangkan pengaruh *initial value*.
5. Mengambil sampel untuk digunakan dalam analisis *posterior* setelah proses *burn in* yang dapat dinotasikan dengan $\{\boldsymbol{\theta}^{(B+1)}, \boldsymbol{\theta}^{(B+2)}, \dots, \boldsymbol{\theta}^{(T)}\}$.
6. Membuat *plot* berdasarkan distribusi marginal univariat yang diperoleh.
7. Memperoleh besaran dari distribusi *posterior* yang diperlukan, yaitu rata-rata dan standar deviasi.

Sebelum menghitung besaran-besaran dari distribusi *posterior* yang diperlukan, maka terlebih dahulu mengetahui beberapa terminologi dari istilah yang digunakan dalam metode MCMC untuk dapat dipahami oleh peneliti. Berikut ini penjelasan terminologi dari beberapa istilah tersebut.

1. Kondisi *equilibrium*

Kondisi *equilibrium* atau stasioner dijadikan sebagai tanda bahwa target distribusi telah tercapai melalui algoritma MCMC. Kondisi ini berkaitan dengan rantai *Markov* yang telah stabil setelah melakukan proses *burn in*. Hal ini sejalan dengan penelitian yang dilakukan oleh Hajarisman (2013) yang memperpanjang periode *burn in* ketika belum mencapai kondisi *equilibrium*. Setelah kondisi tersebut tercapai, maka algoritma MCMC akan membangkitkan nilai acak yang bergantung dari distribusi target yang telah stasioner.

2. Iterasi dan total iterasi (T)

Iterasi pada algoritma MCMC dinyatakan sebagai siklus yang dilalui secara lengkap untuk membangkitkan nilai parameter dari distribusi *posterior*. Iterasi biasanya dilambangkan dalam bentuk angka atau notasi umum t yang terletak pada superskrip dari parameter, misal $\boldsymbol{\theta}^{(t)}$ menyatakan nilai dari vektor acak $\boldsymbol{\theta}$ yang dibangkitkan pada iterasi ke- t dan total iterasi (T) menunjukkan jumlah seluruh iterasi yang harus dilalui algoritma MCMC hingga kondisi *equilibrium* tercapai.

3. Nilai awal (*initial value*) atau ($\boldsymbol{\theta}^{(0)}$)

Nilai awal atau *initial value* merupakan suatu nilai untuk menginisiasi rantai *Markov*. Nilai ini dapat memengaruhi ringkasan distribusi *posterior* jika menggunakan nilai yang jauh dari area tertinggi probabilitas *posterior* dan sebanyak T -sampel yang cukup untuk menghilangkan efek dari *initial value*. Oleh karena itu, cara yang dapat dilakukan untuk menghilangkan pengaruh *initial value* dapat dengan membuang beberapa iterasi pertama (*burn in*) atau membiarkan algoritma MCMC berjalan dengan jumlah iterasi yang sangat besar.

4. Proses *burn in*

Proses ini melibatkan sebanyak B -iterasi pertama yang dibuang dari sampel untuk mengurangi adanya pengaruh dari *initial value*. Jika sampel yang dibangkitkan cukup besar, maka adanya proses *burn in* hanya berpengaruh minimum terhadap penghitungan ringkasan distribusi *posterior* yang dihasilkan.

5. *Thinning interval* atau *sampling lag*

Sampel yang dibangkitkan menggunakan algoritma MCMC sepenuhnya bersifat tidak independen. Oleh karena itu, penentuan nilai *thinning interval* (L) digunakan untuk mengurangi adanya autokorelasi dari sampel yang dibangkitkan. Setelah itu, sampel independen dapat dihasilkan dengan cara mempertahankan sampel pertama pada setiap L iterasi. Misalkan dipilih $L = 3$ menunjukkan bahwa sampel yang dipertahankan yakni sampel pertama dari setiap 3 iterasi, yaitu sampel ke-1,4,7,10, dan seterusnya. Selain untuk mengurangi adanya autokorelasi, pemilihan *thinning interval* juga dapat menghemat penyimpanan dan mempercepat proses komputasi pada algoritma MCMC.

6. Iterasi yang dipertahankan

Iterasi yang dipertahankan menunjukkan jumlah sampel akhir yang dihasilkan dari algoritma MCMC setelah melalui proses *burn in* dan mempertimbangkan penggunaan *thining interval*. Jika dituliskan dalam bentuk notasi T' , maka iterasi yang dipertahankan diperoleh dengan formula berikut ini.

$$T' = \frac{T - B}{L} \quad (61)$$

7. Analisis *Output* MCMC

Keluaran atau *output* MCMC mengacu pada sampel akhir yang dibangkitkan dengan algoritma MCMC, yaitu sampel yang telah melalui proses *burn in* dan penentuan *thinning interval*. Maka, sampel yang dihasilkan bersifat independen dan

digunakan dalam analisis *posterior*. Kemudian, analisis yang digunakan pada sampel akhir untuk mengidentifikasi algoritma MCMC telah konvergen, menggambarkan distribusi *posterior* yang dihasilkan, dan membuat kesimpulan mengenai parameter yang ingin diduga.

8. Konvergensi algoritma

a. *Trace plot*

Trace plot merupakan sebuah grafik yang menunjukkan banyak iterasi pada sumbu X dan nilai parameter yang dibangkitkan pada sumbu Y. Algoritma MCMC mencapai kondisi konvergen ketika sudah tidak ditemukan pola periodik pada grafik sehingga parameter yang dibangkitkan memusat ke suatu nilai. Apabila belum mencapai kondisi konvergen, maka periode *burn in* perlu ditambah (Hajarisman, 2013).

b. *Density plot*

Density plot merupakan grafik yang menggambarkan sebaran nilai-nilai parameter yang dibangkitkan dari proses MCMC. Algoritma mencapai kondisi konvergen jika *density plot* membentuk kurva yang mulus (*smooth*) seperti *bell curve*.

c. *Autocorrelation plot*

Autocorrelation plot merupakan grafik yang menampilkan nilai *autocorrelation function* (ACF) dan menggambarkan korelasi antarsampel bangkitan pada setiap iterasi. Sampel yang dibangkitkan bersifat independen saat nilai ACF mendekati nol. Algoritma MCMC mencapai kondisi konvergen jika *autocorrelation plot* membentuk pola *cut off*, sedangkan belum konvergen jika membentuk pola *dies down*.

Setelah mendapatkan sampel akhir dari algoritma MCMC, maka dapat dihitung besaran-besaran parameter dari distribusi *posterior* yang dibutuhkan dalam analisis *posterior*. Besaran-besaran tersebut juga menggambarkan distribusi *posterior* yang dibangkitkan dari proses MCMC. Ntzoufras (2011) menjelaskan dari sampel akhir untuk setiap fungsi $G(\boldsymbol{\theta})$ dari parameter $\boldsymbol{\theta}$ dapat diperoleh dengan cara sebagai berikut.

1. Sampel dari parameter yang ingin diduga dapat dituliskan dengan:

$$G(\boldsymbol{\theta}^{(1)}), G(\boldsymbol{\theta}^{(2)}), \dots, G(\boldsymbol{\theta}^{(t)}), \dots, G(\boldsymbol{\theta}^{(T')}) \quad (62)$$

2. Besaran distribusi *posterior* berupa rata-rata dan standar deviasi *posterior* yang dapat dituliskan berturut-turut dengan:

$$\hat{E}(G(\boldsymbol{\theta})|\mathbf{y}) = \frac{1}{T'} \sum_{t=1}^{T'} G(\boldsymbol{\theta}^{(t)}) \quad (63)$$

$$\widehat{SD}(G(\boldsymbol{\theta})|\mathbf{y}) = \sqrt{\frac{1}{T' - 1} \sum_{t=1}^{T'} [G(\boldsymbol{\theta}^{(t)}) - \hat{E}(G(\boldsymbol{\theta})|\mathbf{y})]^2} \quad (64)$$

3. Menghitung dan mengamati korelasi antarparameter.
4. Membuat grafik yang menggambarkan distribusi marginal *posterior*, seperti *density plot*.

Model SAE HB

Model SAE level area dengan pendekatan *Hierarchical Bayes* merupakan model turunan dari model *Fay Herriot* yang dituliskan pada persamaan (19) sebelumnya. Menurut Rao & Molina (2015), jika mengasumsikan distribusi *prior* dari parameter $(\boldsymbol{\beta}, \sigma_v^2)$ dengan "flat" *prior* untuk parameter $\boldsymbol{\beta}$ sedemikian sehingga $f(\boldsymbol{\beta}) \propto 1$, maka persamaan (10) dapat dituliskan sebagai berikut.

- i. $\hat{\theta}_i | \theta_i, \boldsymbol{\beta}, \sigma_v^2 \sim^{id} N(\theta_i, \psi_i) \quad i = 1, 2, \dots, m$
- ii. $\theta_i | \boldsymbol{\beta}, \sigma_v^2 \sim^{id} N(\mathbf{x}_i^T \boldsymbol{\beta}, b_i^2 \sigma_v^2) \quad i = 1, 2, \dots, m$
- iii. $f(\boldsymbol{\beta}) \propto 1$ (65)

Persamaan di atas mengasumsikan bahwa σ_v^2 diketahui. Namun, pada kenyataannya nilai σ_v^2 tidak diketahui sehingga perlu diestimasi berdasarkan data sampel yang digunakan. Oleh sebab itu, persamaan di atas menjadi seperti berikut ini.

$$\text{iii. } f(\boldsymbol{\beta}, \sigma_v^2) = f(\boldsymbol{\beta})f(\sigma_v^2) \propto f(\sigma_v^2) \quad (66)$$

di mana $f(\sigma_v^2)$ merupakan *prior* dari σ_v^2 .

Dari persamaan (65) dan (66) di atas, bagian (i) disebut sebagai *sampling model*, bagian (ii) disebut sebagai *linking model*, dan bagian (iii) menunjukkan distribusi *prior* bagi $\boldsymbol{\beta}$ dan σ_v^2 yang saling independen. Apabila dihubungkan dengan teorema *Bayesian*, pada persamaan (65) bagian (i) *sampling model* merupakan *likelihood* yang memberikan informasi tentang sebaran data dan digunakan untuk memutakhirkan *prior*. Sementara itu, pada persamaan (65) bagian (ii) terlihat bahwa data populasi diasumsikan berdistribusi normal. Namun, hal tersebut tidak sesuai untuk beberapa jenis data, seperti data rata-rata konsumsi listrik per kapita ruta yang nilainya rill positif. Oleh sebab itu, penelitian ini menggunakan model SAE HB yang sesuai dengan distribusi data yang digunakan.

Model SAE Pendekatan HB *Lognormal*

Model SAE HB yang digunakan pada penelitian ini adalah model *lognormal* dengan variabel prediktor berbasis level area. Model *lognormal* dipilih karena lebih cocok dengan karakteristik data variabel rata-rata konsumsi listrik per kapita rumah tangga yang memiliki *range* nilai rill positif ($\mathbf{y} \geq \mathbf{0}$). Hal ini juga sejalan dengan penelitian dari Mauliani et al. (2018) yang menggunakan model SAE HB

Lognormal dalam menduga tingkat pengangguran terbuka tingkat kecamatan, di mana data TPT diketahui mempunyai tipe variabel rill dan positif. Selain itu, model SAE HB *Lognormal* juga dapat digunakan ketika sebaran nilai data menunjukkan kecenderungan menceng kanan (asimetris). Menurut Bain & Engelhardt (1992), distribusi *lognormal* merupakan distribusi data yang bernilai kontinu dan positif dengan fungsi kepadatan peluang yaitu:

$$f(y|\mu, \sigma^2) = \frac{1}{y\sigma\sqrt{2\pi}} \exp\left\{-\frac{1}{2\sigma^2}(\ln(y) - \mu)^2\right\}, y > 0, \mu > 0, \sigma > 0 \quad (67)$$

di mana μ adalah parameter lokasi dan σ adalah parameter skala. Jika dituliskan secara lengkap, model SAE HB *Lognormal* dapat didefinisikan sebagai berikut:

i. *Sampling model*

$$\hat{\theta}_i | \theta_i \sim^{id} \text{lognormal}(\mu_i, \psi_i); i = 1, 2, \dots, m \quad (68)$$

di mana $\mu_i = \mathbf{x}_i^T \boldsymbol{\beta} + v_i$ dengan $\mu_i \sim N(\mathbf{x}_i^T \boldsymbol{\beta}, \sigma_v^2)$ dan ψ_i adalah ragam dari distribusi *lognormal* dengan $\psi_i = \frac{1}{\tau_\theta}$ dan $\tau_\theta \sim \text{Gamma}(a, b)$

sehingga $E(\hat{\theta}_i) = \theta_i = \exp\left\{\mu_i + \frac{\psi_i}{2}\right\}$. Hal yang perlu diketahui yaitu $\hat{\theta}_i$ merupakan penduga rata-rata pada area kecil ke- i dan θ_i merupakan parameter yang ingin diduga. Sedangkan μ_i dan ψ_i merupakan parameter dari distribusi *lognormal*, serta nilai a dan b ditentukan secara tetap (*fixed*).

ii. *Linking model*

$$\log(\theta_i) | \boldsymbol{\beta}, \sigma_v^2 \sim^{id} N(\mathbf{x}_i^T \boldsymbol{\beta}, \sigma_v^2); i = 1, 2, \dots, m \quad (69)$$

dengan $\boldsymbol{\beta}$ merupakan vektor koefisien regresi (pengaruh tetap) dan σ_v^2 merupakan ragam pengaruh acak area, di mana $v_i \sim N(0, \sigma_v^2)$. Inferensi HB pada parameter θ_i mengasumsikan nilai *flat prior* untuk $\boldsymbol{\beta}$ dan σ_v^2 .

Maka, distribusi *prior* untuk setiap parameter dapat dituliskan yaitu $\beta_j \sim N_{iid}(\mu_{[\beta]_j}, \sigma_{[\beta]_j}^2)$ dan $\sigma_v^2 \sim InversGamma(c_1, c_2)$ dengan $\tau_v = \frac{1}{\sigma_v^2}$ sehingga $\tau_v \sim Gamma(c_1, \frac{1}{c_2})$, di mana β dan σ_v^2 saling independen dan nilai dari $\mu_{[\beta]_j}, \sigma_{[\beta]_j}^2, c_1, c_2$, dan τ_v ditentukan secara tetap (*fixed*).

Credible Interval

Di dalam analisis statistik *Bayesian*, *credible interval* berguna dalam menguji signifikansi parameter yang dihasilkan dalam proses inferensi (Thrane & Talbot, 2019). *Credible interval* pada inferensi *Bayesian* dapat dianalogikan seperti *confidence interval* pada inferensi *frequentist*. Namun berbeda dengan statistik *frequentist* yang menggunakan *p-value*, statistik *Bayesian* menguji signifikansi parameter melalui pengamatan ada atau tidaknya nilai nol pada *credible interval* yang dihasilkan. Apabila mengandung nilai nol di dalamnya, maka parameter yang diuji dapat dinyatakan tidak signifikan, begitu juga sebaliknya. Penelitian ini menggunakan α sebesar 5 persen sehingga dihasilkan 95 persen *credible interval*. Ntzoufras (2011) mengartikan 95 persen *credible interval* sebagai wilayah kemungkinan nilai parameter di antara persentil 2,5 persen hingga 97,5 persen dari distribusi *posterior*.

Pemeriksaan Multikolinearitas

Multikolinearitas merupakan suatu permasalahan yang timbul akibat adanya hubungan antar variabel independen dalam analisis regresi linear berganda (Kutner et al., 1983). Keberadaan multikolinearitas akan berdampak pada estimator yang dihasilkan menjadi tidak bias, tetapi memiliki varians dan *standar error* yang besar (Shantika, 2010). Dalam menguji hubungan multikolinearitas tersebut

diperlukan pemeriksaan dengan menggunakan nilai *Variance Inflation Factor* (VIF). Nilai VIF menunjukkan besaran varians dari koefisien regresi yang diestimasi cenderung meningkat saat terjadi multikolinearitas. Nilai VIF dapat dihitung dengan rumus berikut ini (Kutner et al., 1983).

$$VIF_k = \frac{1}{1 - R_k^2} \quad (70)$$

keterangan:

R_k^2 = koefisien determinasi dari regresi variabel independen ke- k dengan lainnya

k = jumlah variabel independen.

Nilai $VIF < 10$ menunjukkan bahwa antar variabel independen tidak mengalami multikolinearitas.

Uji Kolmogorov Smirnov (KS)

Uji Kolmogorov Smirnov merupakan salah satu pengujian distribusi yang mengukur dan mengidentifikasi tingkat kesesuaian antara distribusi sampel (observasi) dengan distribusi teoritisnya (Chakravarti et al., 1967). Prosedur pengujian ini dengan membandingkan distribusi data sampel terhadap distribusi normal dengan nilai rata-rata dan standar deviasi yang serupa. Adapun hipotesis nol dari uji KS yaitu data mengikuti distribusi teoritik tertentu, misalnya distribusi normal. Sedangkan hipotesis alternatifnya yaitu data tidak mengikuti distribusi normal. Kemudian, statistik hitung KS diperoleh melalui formula berikut ini.

$$D = \max |F_0(x_i) - S_N(x_i)| \quad (71)$$

Keterangan:

$F_0(x_i)$ = fungsi distribusi kumulatif teoritis

$S_N(x_i)$ = fungsi distribusi kumulatif observasi.

di mana H_0 ditolak jika statistik uji D lebih besar dari nilai tabel KS yang bersesuaian atau $p\text{-value}$ lebih kecil dari tingkat signifikansi α yang ditentukan.

Backward Elimination

Salah satu tujuan dari seleksi variabel adalah untuk mendapatkan *subset* terbaik dari variabel independen yang tersedia (Weisberg, 2005). Adapun tujuan lain dari proses seleksi variabel yaitu mengurangi biaya kegiatan pengumpulan data dan pembentukan model, meminimalisasi pelanggaran asumsi multikolinearitas, dan meningkatkan akurasi dari estimator. Salah satu metode seleksi variabel yang dapat dilakukan yaitu metode *backward elimination*. Langkah-langkah dalam melakukan prosedur seleksi variabel dengan metode *backward elimination* dijelaskan sebagai berikut.

1. Langkah awal dengan memasukkan seluruh variabel independen pada model.
2. Pada setiap langkah, hapus variabel yang memiliki kriteria berikut ini:
 - a. Memiliki nilai *F-statistics* yang kecil
 - b. Jika dihapuskan, maka tidak ada perubahan yang berarti terhadap R^2
 - c. Variabel tersebut memiliki nilai *p-value* yang besar.
3. Lakukan langkah (2) sampai model mempunyai kriteria berikut ini:
 - a. Iterasi berhenti pada saat kriteria telah tercapai dengan jumlah variabel ideal yang diinginkan.
 - b. Iterasi berhenti pada saat model memiliki nilai *F-statistics* paling besar dibanding model lain.

Pengujian Keberartian Model

Pemilihan model terbaik harus dapat memenuhi dua kriteria selain asumsi-asumsi yang diberikan, yaitu kriteria ekonomi dan kriteria statistik. Kriteria ekonomi berkaitan dengan besar dan arah hubungan dari persamaan parameter yang terbentuk yang sesuai dengan teori atau hipotesis yang ada. Sedangkan kriteria statistik mempertimbangkan nilai-nilai yang dihasilkan dari pengujian statistik, seperti uji parsial t . Beberapa kriteria tersebut digunakan untuk mengetahui model yang terbaik sehingga dapat menggambarkan hubungan antarvariabel secara optimal (Porter & Gujarati, 2009).

Uji parsial t merupakan pengujian parameter yang dilakukan untuk mengetahui variabel independen (*covariates*) secara parsial memberikan pengaruh yang signifikan terhadap variabel respons dalam suatu persamaan jika variabel lain dianggap konstan (Draper & Smith, 1998). Penelitian ini hanya menggunakan uji parsial t dua arah yang dijelaskan sebagai berikut.

Hipotesis:

$H_0 : \beta_i = 0$ (variabel bebas ke- i secara parsial tidak berpengaruh signifikan terhadap variabel respons)

$H_1 : \beta_i \neq 0$ (variabel bebas ke- i secara parsial berpengaruh signifikan terhadap variabel respons).

Statistik uji t :

$$t_{hitung} = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)} \sim t_{(m-p)} \quad (72)$$

Keterangan:

$\hat{\beta}_i$: koefisien parameter β_i

$SE(\hat{\beta}_i)$: standard error estimator parameter β_i

m : jumlah observasi

p : jumlah parameter yang diestimasi.

Statistik uji t mengacu pada persamaan (72). Hipotesis nol ditolak pada tingkat signifikansi α jika $|t_{hitung}| > t_{\frac{\alpha}{2};(m-p)}$. Keputusan ini menunjukkan bahwa variabel bebas ke- i secara parsial berpengaruh signifikan terhadap variabel respons.

Goodness-of-Fit

Dalam memilih model regresi yang optimum, salah satu kriteria yang perlu diperhatikan dalam melakukan *Goodness-of-Fit* dari suatu model estimasi adalah *Akaike Information Criteria* (AIC). AIC dapat diformulasikan sebagai berikut (Kutner et al., 1983).

$$AIC = -2 \log(A, \beta) + 2(p + 1) \quad (73)$$

Keterangan:

A = random effect variance

β = koefisien regresi

p = jumlah parameter.

Uji Korelasi *Rank Kendall*

Korelasi *rank Kendall* atau korelasi Kendall's Tau adalah ukuran statistik non parametrik yang mengukur hubungan dari dua variabel yang sekurang-kurangnya berskala ordinal sehingga dapat dilakukan perankingan dalam dua rangkaian yang berurut (Siegel, 1994). Apabila bentuk data asli masih berupa interval atau rasio, maka terlebih dahulu diubah dalam bentuk *rank*. Analisis korelasi *rank Kendall* digunakan untuk mencari hubungan dan menguji hipotesis antara dua variabel yang berbentuk minimal ordinal dan tidak harus berdistribusi

normal. Analisis koefisien korelasi *rank* Kendall diberi notasi τ dengan tahapan sebagai berikut.

1. Beri *ranking* data observasi pada masing-masing variabel.
2. Susun n data sehingga *ranking* variabel X untuk subjek itu dalam urutan wajar. Apabila terdapat *ranking* yang sama, maka *ranking* dihitung dari rataratanya.
3. Amati *ranking* variabel Y dalam urutan yang bersesuaian dengan *ranking* variabel X pada urutan wajar, kemudian tentukan jumlah angka pasangan *concordant* (N_c) dan jumlah angka pasangan *discordant* (N_d).
4. Hitung statistik uji Kendall's Tau (τ) dengan formula berikut ini.

$$\tau = \frac{\frac{N_c - N_d}{N(N-1)}}{2} \quad (74)$$

Keterangan: τ = koefisien korelasi *rank* Kendall's Tau
 N_c = jumlah angka pasangan *concordant*
 N_d = jumlah angka pasangan *discordant*
 N = ukuran sampel (Conover, 1999).

Hipotesis yang diuji adalah sebagai berikut.

H_0 : tidak ada hubungan antara kedua variabel

H_1 : ada hubungan antara kedua variabel.

Untuk menguji signifikansi korelasi *rank* Kendall, pada ukuran sampel $N \leq 10$ dapat dicari dengan menggunakan tabel korelasi *rank* Kendall, di mana H_0 ditolak jika $\tau > \tau_{(N_c-N_d;N)}$. Sedangkan ukuran sampel $N > 10$ menggunakan pendekatan

distribusi normal dengan $z = \frac{\tau}{\sqrt{\frac{2(2N+5)}{9N(N-1)}}}$, di mana H_0 ditolak jika *p-value* dari tabel

normal baku kurang dari tingkat signifikansi α (Siegel, 1994).

2.2 Penelitian Terkait

Topik penelitian mengenai pendugaan nilai rata-rata konsumsi listrik per kapita ruta menggunakan metode *Small Area Estimation* (SAE) belum pernah dilakukan sebelumnya. Oleh karena itu, pada bagian ini diuraikan beberapa penelitian terkait yang membahas tentang estimasi konsumsi listrik rumah tangga yang menggunakan variabel bebas dari sumber *big data* dengan metode yang berbeda dan beberapa penelitian dengan topik lain yang mengaplikasikan metode SAE dengan variabel penyerta dari sumber *big data* atau Podes, khususnya pada model SAE EBLUP-FH, SAE SEBLUP-FH, dan SAE HB. Berikut ini dijelaskan penelitian terdahulu yang masih berkaitan dengan topik penelitian.

Penelitian yang berjudul “*Modelling Electricity Consumption in Cambodia Based on Remote Sensing Night-Light Images*” dari Gao et al. (2022) melakukan estimasi konsumsi listrik di Negara Kamboja dengan menggunakan metode regresi. Proses *denoising* dilakukan terhadap *night-light images* dengan 3 perlakuan, yaitu *annual average method*, *annual could-free average method*, dan *month-specific substitution method*. Hasil penelitian menunjukkan bahwa model terbaik dalam mengestimasi konsumsi listrik adalah model regresi eksponensial dengan nilai *Relative Error* sebesar 5,47%. Penelitian tersebut juga memberikan kesimpulan bahwa data *night-light images* dapat digunakan untuk melakukan simulasi

pendugaan konsumsi listrik dan distribusi spasialnya dengan akurasi yang tinggi jika menerapkan proses *denoising* terlebih dahulu.

Selanjutnya, penelitian berjudul “*An Assessment of Electric Power Consumption Using Random Forest and Transferable Deep Model with Multisource Data*” oleh Cheng et al. (2022) memperkirakan nilai *electricity power consumption* (EPC) di daerah perkotaan dengan resolusi yang lebih tinggi. Penelitian tersebut mengembangkan metode baru untuk mengestimasi EPC pada resolusi 500 meter dengan menggabungkan data geospasial dan citra satelit resolusi tinggi. Selain itu, metode pembelajaran mendalam (*deep learning*) dan metode statistik diterapkan untuk mengekstrak fitur sosial ekonomi, kepadatan populasi, dan kondisi lanskap wilayah untuk lebih menggambarkan distribusi EPC dari data geospasial multisumber. Hasil penelitian menunjukkan bahwa model *random forest regression* mampu memberikan nilai R^2 sebesar 0,82 dalam memperkirakan EPC tingkat kecamatan di Kota Shenzhen, China pada tahun 2013. Hasil tersebut dinilai lebih tinggi dari penelitian yang dilakukan oleh Shi et al. (2016) dengan $R^2 = 0,46$.

Penelitian lain yang berjudul “*Estimating Local Scale Domestic Electricity Energy Consumption Using Demographic, Nighttime Light Imagery, and Twitter Data*” oleh Sun et al. (2021) melakukan estimasi konsumsi listrik skala lokal, baik domestik maupun non domestik pada tingkat *local authority district* (LAD) di Inggris tahun 2016. Penelitian tersebut menggunakan data demografi, penginderaan jauh, dan data *twitter* sebagai variabel prediktor dengan menerapkan model regresi *random effects eigen vector spatial filtering model*. Hasil penelitian menunjukkan bahwa nilai konsumsi energi listrik dapat dijelaskan oleh variabel populasi penduduk, intensitas cahaya malam (NTL), dan volume *tweet*.

Penelitian selanjutnya yang berjudul “Hubungan Kausalitas antara Konsumsi Listrik, Pertumbuhan Ekonomi, Ketimpangan dan Kemiskinan di Indonesia Tahun 1971-2019” dari Fadhilah (2022) melakukan analisis hubungan kausalitas antara konsumsi listrik, pertumbuhan ekonomi, kemiskinan dan ketimpangan di Indonesia menggunakan Uji Kointegrasi dan Uji Kausalitas *Granger*. Hasil penelitian mengungkapkan bahwa tidak terdapat hubungan antara konsumsi listrik per kapita dengan pertumbuhan ekonomi, tetapi terdapat hubungan kausalitas satu arah dan jangka panjang antara konsumsi listrik dengan kemiskinan dan ketimpangan. Berdasarkan penelitian tersebut, maka penentuan kandidat variabel penyerta yang bersumber dari data Podes pada penelitian ini didasarkan pada teori pendekatan kemiskinan dan ketimpangan. Hal ini dikarenakan keterbatasan teori penelitian mengenai hubungan konsumsi listrik dengan kandidat variabel penyerta dari data Podes. Maka untuk selanjutnya dibuat asumsi penelitian yang menyatakan bahwa terdapat hubungan kausalitas jangka panjang antara konsumsi listrik rumah tangga dengan tingkat kemiskinan dan ketimpangan di suatu wilayah. Dengan demikian, ketika menentukan kandidat variabel penyerta yang diperoleh dari data Podes, maka asumsi tersebut digunakan untuk mengidentifikasi hubungan antara variabel rata-rata konsumsi listrik per kapita ruta dengan variabel dari data Podes menggunakan pendekatan kemiskinan dan ketimpangan.

Penelitian disertasi dari Siswanting (2013) berjudul “Geoinformatika pada Kasus Area Kecil dan Penerapannya untuk Mendeteksi Kantong-Kantong Kemiskinan di Jember” melakukan identifikasi terhadap kantong-kantong kemiskinan di Kabupaten Jember, Jawa Timur. Penelitian tersebut menggunakan metode SAE dengan model EBLUP, SEBLUP, dan HB yang memanfaatkan

variabel penyerta dari hasil pendataan Potensi Desa (Podes) 2008. Permasalahan kemiskinan yang dibahas dalam penelitian tersebut ditinjau dari empat aspek, yaitu infrastruktur, kesehatan, pendidikan, dan ekonomi. Dari asumsi penelitian yang dibahas pada paragraf sebelumnya, penelitian ini menggunakan pendekatan kemiskinan dan ketimpangan dalam menjelaskan hubungan antara nilai rata-rata konsumsi listrik per kapita ruta dengan variabel dari data Podes. Oleh sebab itu, penelitian ini akan mengacu pada penelitian dari Siswanting (2013) yang meninjau permasalahan kemiskinan dari empat aspek tersebut. Dengan demikian, pemilihan kandidat variabel penyerta dari data Podes didasarkan pada hubungan antara konsumsi listrik rumah tangga dengan permasalahan kemiskinan yang dilihat dari empat aspek sebagai berikut.

Tabel 6. Rincian kandidat variabel penyerta yang dipilih berdasarkan permasalahan kemiskinan sebagai pendekatan hubungan antara variabel rata-rata konsumsi listrik per kapita ruta dengan variabel dari data Podes

Aspek Akses (1)	Variabel (2)
Infrastruktur	1. Jumlah keluarga pengguna listrik PLN 2. Jumlah tempat ibadah
Pendidikan	1. Jumlah sarana pendidikan
Kesehatan	1. Jumlah sarana kesehatan
Ekonomi	1. Jumlah industri mikro dan kecil 2. Jumlah sentra industri 3. Jumlah sarana dan prasarana ekonomi

Sumber: Siswanting (2013), disesuaikan

Penelitian dengan topik lain yang mengaplikasikan metode SAE dengan variabel penyerta berasal dari sumber *big data* sudah pernah dilakukan belakangan ini. Penelitian yang dilakukan oleh Gustiawan (2022) menduga variabel pengeluaran per capita di tingkat kecamatan menggunakan SAE EBLUP *Fay Herriot* dengan variabel penyerta diperoleh dari hasil olah citra satelit dan fitur

Convolutional Neural Network (CNN). Dengan berbagai kombinasi variabel penyerta yang digunakan, maka diperoleh model SAE EBLUP FH terbukti mampu menghasilkan nilai penduga yang lebih akurat dan presisi dibandingkan dengan metode pendugaan langsung berdasarkan nilai RSE yang dihasilkan.

Kurnia & Notodiputro (2007) menjelaskan bahwa asumsi yang diperlukan di dalam metode SAE adalah keragaman variabel yang diestimasi harus dapat dijelaskan oleh keragaman variabel penyerta, serta kesalahan (*error*) yang dihasilkan harus bersifat acak dan tidak saling berhubungan. Namun demikian, terdapat fenomena di mana suatu wilayah dipengaruhi oleh wilayah lain sehingga perlu memasukkan unsur pengaruh antarwilayah ke dalam model tersebut. Pratesi & Salvati (2008) mengembangkan suatu model SAE dengan memasukkan unsur kewilayahan yang diwakili oleh keberadaan matriks penimbang spasial. Model tersebut dinamakan dengan model *Spatial Empirical Best Linear Unbiased Prediction* (SEBLUP). Penelitian dari Apriliansyah & Wulansari (2021) melakukan pendugaan Tingkat Pengangguran Terbuka (TPT) level kecamatan di Provinsi Banten menggunakan metode *Spatial* EBLUP. Adapun variabel penyerta yang digunakan berasal dari hasil pendataan potensi desa (Podes) tahun 2018. Penelitian tersebut juga menggunakan model EBLUP sebagai model pembanding. Hasil penelitian menunjukkan bahwa model SEBLUP dengan metode REML menghasilkan nilai RRMSE yang lebih rendah dari metode estimasi langsung dan model EBLUP dengan metode REML.

Masalah lain dapat muncul apabila sebaran data penduga langsung tidak berdistribusi normal. Dengan kondisi tersebut, maka penduga EBLUP menjadi kurang tepat karena EBLUP merupakan metode SAE berbasis *linear mixed model*

yang mengasumsikan variabel *interest* berdistribusi normal (B. Liu, 2009). Oleh sebab itu, model berbasis *generalized linear mixed model* (GLMM) dapat digunakan sebagai alternatif untuk kondisi tersebut. Salah satu metode SAE yang berbasis GLMM yaitu model *Hierarchical Bayes* (HB). Hal ini sejalan dari penelitian dari Mauliani et al. (2018) yang melakukan estimasi angka pengangguran level kecamatan di Kabupaten Padang Pariaman dengan metode SAE pendekatan *Hierarchical Bayes* (HB) *Lognormal*. Hasil penelitian menunjukkan bahwa estimasi Tingkat Pengangguran Terbuka (TPT) dengan penduga HB *Lognormal* menghasilkan *standard error* yang lebih kecil dari penduga langsung.

Dari beberapa uraian hasil penelitian terkait di atas, maka penelitian ini melakukan estimasi nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021 menggunakan metode pendugaan langsung dan metode *Small Area Estimation* (SAE) dengan model EBLUP-FH, SEBLUP-FH, dan HB dengan memanfaatkan variabel penyerta dari sumber *big data* dan data Podes. Pemilihan kandidat variabel penyerta dari sumber *big data* didasarkan pada eksplorasi teori dan hasil penelitian terdahulu yang telah dijelaskan pada masing-masing bagian landasan teori variabel terkait. Sedangkan pemilihan kandidat variabel penyerta dari data Podes mengacu pada pendekatan teori permasalahan kemiskinan dari Siswanting (2013) yang telah disesuaikan. Kemudian, hasil estimasi dari metode pendugaan langsung dan metode SAE dilakukan evaluasi untuk mendapatkan metode terbaik dalam mengestimasi nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021.

“... sengaja dikosongkan ...”

BAB III

METODOLOGI

3.1 Ruang Lingkup Penelitian

Penelitian ini berfokus dalam mengestimasi nilai rata-rata konsumsi listrik per kapita rumah tangga (ruta) level kecamatan yang tercakup pada Survei Sosial dan Ekonomi Nasional (Susenas) tahun 2021 di Provinsi Jawa Tengah. Proses estimasi dilakukan dengan menerapkan metode pendugaan langsung dan metode *Small Area Estimation* (SAE). Nilai konsumsi listrik (KWh) dan jumlah anggota rumah tangga yang diperoleh dari data Susenas digunakan untuk menghitung nilai rata-rata konsumsi listrik per kapita ruta dengan metode pendugaan langsung sebagai variabel *interest*. Kandidat variabel penyerta untuk estimasi dengan metode SAE diperoleh dari sumber *big data* dan Podes. Variabel Podes diperoleh dari hasil pendataan potensi desa tahun 2021. Sedangkan variabel dari sumber *big data* diperoleh dari data penginderaan jauh dan geospasial terbuka berdasarkan referensi waktu menurut ketersediaan data yang terbaru. Adapun rincian informasi seluruh kandidat variabel penyerta yang digunakan dalam penelitian ini ditampilkan pada Tabel 7 di bagian variabel penelitian.

Proses pengolahan data terbagi atas beberapa tahapan dengan *environment* aplikasi yang berbeda sesuai dengan kebutuhan. Pengolahan data Susenas dan Podes dilakukan menggunakan perangkat lunak Microsoft Office Excel 2019 dan SPSS versi 24. Proses ekstraksi variabel dari sumber *big data* dilakukan dengan menggunakan platform Google Earth Engine dan Google Collaboratory serta kemudian dioleh lebih lanjut dengan perangkat lunak Quantum GIS (QGIS) versi

3.22. Pengolahan data meliputi tahap *preprocessing* data, eksplorasi analisis data spasial (ESDA), serta estimasi dengan metode pendugaan langsung dan *Small Area Estimation* (SAE) dilakukan dengan menggunakan perangkat lunak RStudio versi 4.1.4 pada bahasa pemrograman R.

Estimasi langsung terhadap nilai rata-rata konsumsi listrik per kapita ruta menggunakan data sampel Susenas Maret 2021. Estimasi ini berfokus pada wilayah kecamatan yang tercakup sebagai unit analisis penelitian meliputi 572 dari 576 kecamatan di Provinsi Jawa Tengah. Kecamatan yang tidak menjadi unit analisis penelitian ini antara lain Kecamatan Bumijawa, Kecamatan Bojong, Kecamatan Jatinegara dan Kecamatan Karimun Jawa. Kecamatan Bumijawa, Kecamatan Bojong, dan Kecamatan Jatinegara tidak memiliki sampel ruta pada Susenas Maret 2021, sedangkan Kecamatan Karimun Jawa tidak dipilih menjadi sampel unit analisis pada penelitian ini karena wilayahnya yang terpisah dan berbentuk kepulauan sendiri sehingga tidak dapat mempertimbangkan unsur spasial ketika menggunakan metode SEBLUP-FH. Oleh sebab itu, penelitian ini hanya menggunakan 572 kecamatan menjadi unit analisis penelitian sebagai wilayah amatan. Dengan demikian, estimasi terhadap nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah hanya mencakup pada 572 sampel kecamatan tersebut pada periode amatan tahun 2021. Kemudian, estimasi dengan metode SAE dilakukan dengan memanfaatkan variabel penyerta yang terpilih berdasarkan hasil seleksi variabel yang diperoleh dari sumber *big data* dan data Podes. Selanjutnya model estimasi terbaik diperoleh dari analisis *goodness-of-fit*, *diagnostic plot*, dan evaluasi hasil dengan membandingkan nilai RSE atau

RRMSE dari setiap model pendugaan, serta menghitung korelasi terhadap nilai populasi menggunakan data konsumsi listrik per kapita ruta dari PT. PLN.

3.2 Metode Penelitian

Variabel Penelitian

Variabel penelitian ini terdiri atas variabel *interest* dan variabel independen. Variabel *interest* diperoleh dari *raw data* Susenas Maret 2021 yang diolah dan dihitung dengan metode pendugaan langsung sehingga didapatkan nilai estimasi rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021. Hasil dari estimasi langsung tersebut selanjutnya disebut sebagai penduga langsung. Sementara itu, variabel independen dipilih berdasarkan hasil dari eksplorasi penelitian terdahulu yang relevan. Variabel independen tersebut diperoleh dari sumber *big data* dan Podes 2021. Variabel independen ini digunakan sebagai kandidat variabel penyerta dalam proses pendugaan tak langsung dengan metode SAE. Berikut ini ditampilkan Tabel 7 berisi rincian seluruh variabel yang digunakan pada penelitian ini.

Tabel 7. Rincian informasi variabel penelitian

Variabel	Nama variabel	Sumber data	Resolusi spasial (meter)	Periode data
(1)	(2)	(3)	(4)	(5)
Y	Rata-rata konsumsi Listrik Per kapita ruta (KWh/kapita)	Susenas	—	2021
X_1	Jumlah keluarga pengguna listrik PLN	Podes	—	2021
X_2	Jumlah sarana pendidikan	Podes	—	2021
X_3	Jumlah sarana kesehatan	Podes	—	2021
X_4	Jumlah tempat ibadah	Podes	—	2021

Variabel	Nama variabel	Sumber data	Resolusi spasial (meter)	Periode data
(1)	(2)	(3)	(4)	(5)
X_5	Jumlah industri mikro dan kecil	Podes	—	2021
X_6	Jumlah sentra industri	Podes	—	2021
X_7	Jumlah sarana dan prasarana ekonomi	Podes	—	2021
X_8	Kepadatan penduduk	Podes	—	2021
X_9	<i>Nighttime Light Intensity</i>	S-NPP/NOAA-20	463,83	2021
X_{10}	<i>Build-Up Index</i>	Sentinel-2	10	2021
X_{11}	<i>Land Surface Temperature</i>	MODIS	1000	2021
X_{12}	<i>Elevation</i>	SRTM-NASA DEM	30	2000
X_{13}	Kepadatan Senyawa CO	Sentinel-5P	1113,33	2021
X_{14}	Konsentrasi <i>Particulate Matter 2.5 (PM_{2.5})</i>	<i>Socioeconomic Data and Applications Center (SEDAC) NASA</i>	1111	2019
X_{15}	<i>Global Aridity Index</i>	<i>Global Aridity and PET Database</i>	1000	1970-2000
X_{16}	<i>Relative Wealth Index</i>	Facebook's Data For Good	2400	2021

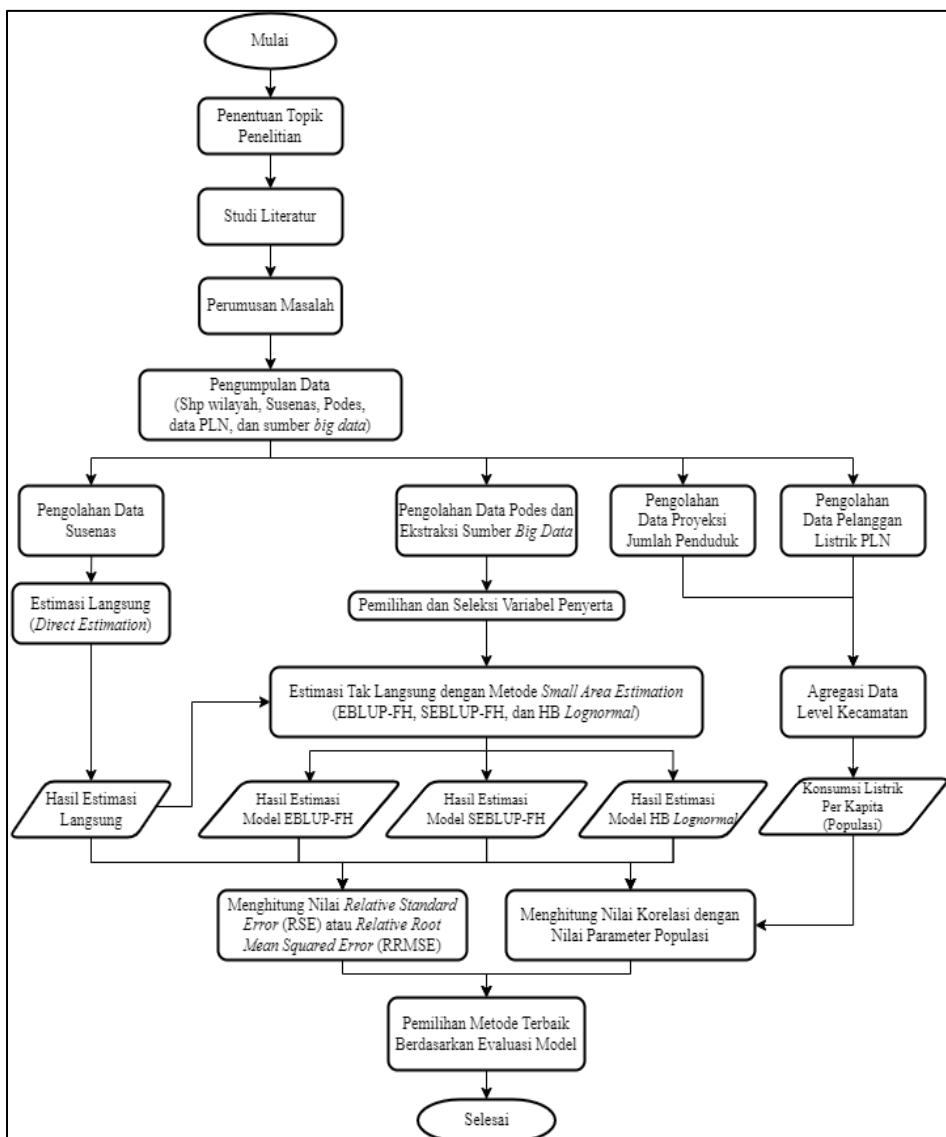
Rancangan Penelitian

Penelitian ini diawali dengan penentuan topik penelitian dan studi literatur terhadap permasalahan yang ditentukan. Dengan mengacu studi literatur yang relevan terhadap topik penelitian, maka dapat diperoleh perumusan masalah yang dijadikan sebagai dasar dalam menyusun tujuan penelitian, objek penelitian, data dan variabel penelitian, prosedur dan teknik yang digunakan dalam mencapai tujuan penelitian, dan analisis yang dilakukan untuk memperoleh kesimpulan dalam menjawab permasalahan. Selanjutnya dilakukan pengumpulan data untuk memperoleh variabel penelitian yang digunakan sebagai bahan analisis. Data yang dikumpulkan tersebut meliputi data wilayah administrasi tingkat kecamatan di

Provinsi Jawa Tengah, Susenas, dan Podes dari BPS, serta sumber *big data* dari data penginderaan jauh dan geospasial terbuka. Data sampel susenas dari BPS digunakan untuk memperoleh penduga langsung dari nilai rata-rata konsumsi listrik per kapita ruta level kecamatan. Kemudian, hasil penduga langsung tersebut digunakan pada proses estimasi tak langsung dengan metode SAE dengan model EBLUP-FH, SEBLUP-FH, dan HB *Lognormal* sebagai variabel *interest*.

Proses estimasi dengan model EBLUP-FH, SEBLUP-FH, dan HB *Lognormal* juga memanfaatkan sumber *big data* dan Podes sebagai kandidat variabel penyerta. Sebelum itu, data Podes perlu diolah dan diagregasikan terlebih dahulu sehingga diperoleh nilai variabel Podes yang sesuai dengan lokus dan tingkat estimasi yang digunakan dalam hal ini level kecamatan di Provinsi Jawa Tengah. Sama halnya dengan variabel Podes, variabel dari sumber *big data* yang telah dikumpulkan harus melalui proses *preprocessing* dan ekstraksi data terlebih dahulu sehingga diperoleh nilai yang sesuai dengan teori dan wilayah yang menjadi lokus penelitian. Setelah melakukan pengolahan data Podes dan ekstraksi sumber *big data*, maka selanjutnya dilakukan penyeleksian kandidat variabel penyerta tersebut agar diperoleh model yang sederhana, tetapi tetap mempertimbangkan keakuratan hasil. Setelah itu dapat dilakukan proses estimasi dengan metode SAE hingga diperoleh nilai penduga tak langsung yang dihasilkan dari model EBLUP-FH, SEBLUP-FH, dan HB *Lognormal*. Dengan demikian, nilai estimasi rata-rata konsumsi listrik per kapita ruta dihasilkan dari empat model, yaitu metode pendugaan langsung dan metode SAE dengan model EBLUP-FH, SEBLUP-FH, dan HB *Lognormal*. Setelah diperoleh nilai estimasi dari empat model pendugaan, maka selanjutnya dilakukan penghitungan dan perbandingan ukuran evaluasi model

menggunakan nilai RSE atau RRMSE. Selain itu, hasil estimasi empat metode dibandingkan dengan nilai populasi konsumsi listrik per kapita ruta dari data PLN menggunakan ukuran korelasi Kendall-Tau. Dengan demikian, metode terbaik dalam menduga nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021 dapat diperoleh berdasarkan hasil evaluasi model. Berikut ini ditampilkan tahapan penelitian yang dilakukan untuk mencapai tujuan penelitian yang telah didefinisikan sebelumnya.



Gambar 3. Tahapan Penelitian

Metode Pengumpulan Data

Data yang dikumpulkan pada penelitian ini sepenuhnya berasal dari data sekunder. Secara garis besar, penelitian ini menggunakan data sekunder dari BPS dan eksplorasi sumber *big data* dari data penginderaan jauh dan geospasial terbuka. Data sekunder yang diperoleh dari BPS merupakan data mentah (*raw data*) dari Susenas Maret 2021 dan Pendataan Potensi Desa (Podes) 2021. Data Susenas yang digunakan untuk mendapatkan nilai penduga langsung yaitu data mentah dari blok modul konsumsi dan pengeluaran, meliputi: Kode Provinsi, Kode Kabupaten, Kode Kecamatan, Jumlah Anggota Rumah Tangga, Penimbang, dan Penggunaan Listrik Sebulan Terakhir (dalam KWh). Adapun data Podes dan *big data* digunakan sebagai variabel penyerta pada pendugaan tak langsung dengan metode SAE. Berikut ini dijelaskan secara rinci terkait data yang diperlukan dalam penelitian ini.

1. Batas administrasi wilayah

Untuk mendukung interpretasi secara spasial pada penelitian ini, data administrasi wilayah dibutuhkan dalam bentuk format *shapefile* (SHP) yang diperoleh dari direktori BPS. Data tersebut tersedia dalam empat tingkat administratif yang berbeda, meliputi provinsi, kabupaten/kota, kecamatan, dan desa yang valid pada tahun 2019. Karena estimasi rata-rata konsumsi listrik per kapita ruta dilakukan pada level kecamatan, maka batas administrasi wilayah yang digunakan adalah tingkat kecamatan. Oleh sebab itu, data ini harus diolah dengan cara memotong wilayah Provinsi Jawa Tengah menggunakan perangkat lunak Quantum GIS (QGIS). Dengan demikian, data tersebut akan digunakan untuk memperoleh data geospasial yang berasal dari citra satelit di wilayah yang bersesuaian dengan batas administrasi yang ditentukan.

2. Susenas Maret 2021

Penelitian ini menggunakan *raw data* dari sampel data Susenas yang dilakukan pada bulan Maret 2021 untuk memperoleh estimasi langsung rata-rata konsumsi listrik per kapita ruta level kecamatan. Pengumpulan data Susenas Maret 2021 dilakukan dengan wawancara langsung terhadap sampel sebanyak 345.000 rumah tangga yang tercakup ke dalam 34,500 blok sensus yang tersebar di 34 provinsi dan 514 kabupaten/kota di Indonesia. *Design sampling* yang diterapkan pada Susenas Maret 2021 merupakan *two stage two phase sampling* yang dinyatakan dalam *Sampling Scheme* pada Tabel 8 sebagai berikut.

Tabel 8. *Sampling Scheme* Susenas Maret 2021

Tahap/ <i>Phase</i>	Unit	Jumlah unit strata h		Metode penarikan sampel	Peluang pemilihan sampel	Fraksi sampling
		Populasi	Sampel			
(1)	(2)	(3)	(4)	(5)	(6)	(7)
1	Blok sensus	N_{kh}	n'_{kh}	<i>PPS-with replacement</i>	$\frac{M_{khi}}{M_{kh}}$	$n'_{kh} \frac{M_{khi}}{M_{kh}}$
		n'_{kh}	n_{kh}	<i>Systematic</i>	$\frac{1}{n'_{kh}}$	$\frac{n_{kh}}{n'_{kh}}$
2	Rumah tangga	M^{up}_{khi}	\bar{m}	<i>Systematic</i>	$\frac{1}{M^{up}_{khi}}$	$\frac{\bar{m}}{M^{up}_{khi}}$

Sumber: Metodologi *sampling* Susenas Maret 2021 (BPS, 2021b)

Sampel data Susenas yang digunakan pada penelitian ini yaitu data rumah tangga yang bertempat tinggal di Provinsi Jawa Tengah tahun 2021. Data tersebut diperoleh dari hasil Susenas Modul Konsumsi dan Pengeluaran Maret 2021 pada kuesioner VSEN21.KP. Proses memperoleh data Susenas dari BPS dilakukan melalui permintaan data yang dilakukan menggunakan Sistem Informasi Layanan Statistik (SILASTIK). SILASTIK akan meneruskan *request* permintaan data tersebut kepada *subject matter* terkait untuk selanjutnya diteruskan kembali ke pengguna data. Kemudian, estimasi rata-rata konsumsi listrik per kapita ruta pada

level kecamatan menggunakan isian pada data penggunaan listrik dalam sebulan terakhir (KWh), jumlah anggota rumah tangga, dan penimbang individu.

3. Pendataan Potensi Desa (Podes) 2021

Data mentah (*raw data*) dari Podes 2021 digunakan sebagai kandidat variabel penyerta untuk memperoleh estimasi tak langsung menggunakan metode SAE. Data Podes 2021 digunakan karena variabel-variabel yang tersedia dapat disajikan hingga level desa. Selain itu, data Podes dikumpulkan dengan pencacahan lengkap yang dilakukan secara registrasi di setiap desa/kelurahan. Data Podes yang digunakan sebagai sampel penelitian ini terdiri atas 8.652 desa yang tersebar di 576 kecamatan di Provinsi Jawa Tengah tahun 2021. Proses memperoleh data Podes dari BPS dilakukan melalui permintaan data dengan menggunakan Sistem Informasi Layanan Statistik (SILASTIK). SILASTIK akan meneruskan *request* permintaan data tersebut kepada *subject matter* terkait untuk selanjutnya diteruskan kembali ke pengguna data. Kemudian, setiap variabel dari data Podes tersebut akan diagregasikan pada level kecamatan yang telah ditentukan sebagai unit analisis penelitian. Variabel-variabel data Podes yang digunakan pada penelitian ini telah dirincikan sebelumnya pada Tabel 7.

4. Variabel Sumber *Big data*

Variabel dari sumber *big data* juga digunakan sebagai kandidat variabel penyerta untuk memperoleh estimasi tak langsung dengan metode SAE. Penggunaan sumber *big data* sebagai kandidat variabel penyerta karena dapat memuat informasi secara lengkap yang tidak tercakup pada pengumpulan data secara konvensional. Oleh karena itu, sumber *big data* memiliki potensi untuk diintegrasikan dengan metode SAE dalam menyelesaikan persoalan penyediaan

data secara komprehensif. Pemilihan variabel dari sumber *big data* yang digunakan pada penelitian ini didasarkan pada teori dan hasil penelitian terdahulu yang relevan. Selain itu, pemilihan variabel tersebut juga didukung dengan ada atau tidaknya hubungan yang nyata (signifikan) dengan variabel respons penelitian. Variabel dari sumber *big data* yang digunakan pada penelitian ini telah dirinci pada Tabel 7 di bagian sebelumnya. Beberapa variabel berasal dari data penginderaan jauh atau citra satelit yang diperoleh menggunakan Google Earth Engine, antara lain yaitu *Nighttime Light Intensity*, *Land Surface Temperature*, *Build-Up Index*, *Elevation*, dan Kepadatan Senyawa *CO*. Sementara itu, variabel lain diperoleh dari beberapa sumber data geospasial terbuka, meliputi *Global Aridity Index*, *Particulate Matter 2.5*, dan *Relative Wealth Index*. Data yang diperoleh menggunakan Google Earth Engine dilakukan ekstraksi fitur dan selanjutnya diekspor dengan format *geotiff* sehingga memuat informasi spasial dalam bentuk data raster. Sedangkan data *Global Aridity Index* dan *Particulate Matter 2.5* tersedia untuk diunduh secara langsung dalam bentuk data raster berformat *geotiff*. Sementara itu, data *Relative Wealth Index* juga tersedia untuk diunduh langsung dalam bentuk data berformat CSV. Untuk data raster yang memerlukan *bands* komposit, seperti *Build-Up Index*, maka ekstraksi data dilakukan secara khusus untuk memperoleh nilai indeks terkait.

Metode Analisis Data

Setelah semua data yang dibutuhkan dalam penelitian ini terkumpul, maka selanjutnya dilakukan analisis data meliputi proses pengolahan data hingga analisis inferensia untuk mencapai tujuan yang telah ditentukan. Analisis inferensia menggunakan metode *Small Area Estimation* (SAE) dengan pendekatan model

EBLUP *Fay-Herriot*, SEBLUP *Fay-Herriot*, dan *Hierarchical Bayes Lognormal*.

Berikut ini adalah tahapan analisis data yang terbagi atas beberapa bagian.

1. Estimasi Langsung Rata-Rata Konsumsi Listrik Per Kapita Rumah Tangga

Estimasi langsung terhadap nilai rata-rata konsumsi listrik per kapita ruta (KWh/Kapita) level kecamatan dilakukan dengan menggunakan data Susenas Maret 2021. Proses ini dibantu menggunakan program SPSS versi 24 dan R versi 4.1.3. Pendugaan langsung didasarkan pada *sampling design* Susenas Maret 2021 yang telah ditunjukkan pada Tabel 8. Nilai estimasi langsung yang diperoleh meliputi nilai rata-rata, varians, MSE, dan RSE dari rata-rata konsumsi listrik per kapita ruta pada level kecamatan di Provinsi Jawa Tengah tahun 2021.

2. Ekstraksi Sumber *Big Data*

a. *Nighttime Light Intensity*

Pada penelitian ini, data intensitas cahaya malam diukur menggunakan instrumen VIIRS dari citra NOAA-20 yang diperoleh dari katalog “NOAA/VIIRS/DNB/MONTHLY_V1/VCMSLCFG”. Data tersebut diambil berdasarkan kondisi rentang waktu 1 Januari hingga 31 Desember 2021. Setelah data tersebut diperoleh, kemudian diagregasikan menurut level kecamatan menggunakan metode *Zonal Statistics* dengan nilai median. *Zonal Statistics* merupakan fitur agregasi data raster ke dalam wilayah administrasi tertentu. Analisis ini dilakukan menggunakan perangkat lunak QGIS yang mendukung fitur tersebut. Dengan demikian, nilai median data intensitas cahaya malam dapat diperoleh sebagai ukuran tingkat elektrifikasi di masing-masing kecamatan di Provinsi Jawa Tengah..

b. *Land Surface Temperature*

Penelitian ini menggunakan data suhu permukaan tanah yang diukur menggunakan citra satelit MODIS yang dikumpulkan pada rentang waktu 1 Januari hingga 31 Desember 2021. Data tersebut diperoleh dari katalog “MODIS/061/MOD11A1” yang kemudian diagregasikan menggunakan metode *Zonal Statistics* dengan nilai median sehingga diperoleh data median suhu permukaan tanah di tingkat administrasi kecamatan di Provinsi Jawa Tengah. Data tersebut diperoleh dari satelit MODIS sehingga dapat langsung digunakan tanpa pengolahan lebih lanjut. Akan tetapi, perlu diingat bahwa data tersebut masih dalam bentuk *Digital Number* (DN) sehingga perlu dikonversi terlebih dahulu ke dalam satuan Kelvin (K) dengan pengali faktor skala. Berikut ini formula untuk melakukan konversi *Digital Number* (DN) ke dalam satuan Celsius (°C).

$$LST_{celsius} = (LST_{DN} \times 0,02) - 273,15 K \quad (75)$$

di mana 0,02 adalah faktor skala (ICESS, n.d.).

Keterangan:

$LST_{celsius}$: suhu permukaan tanah (°C)

LST_{DN} : suhu permukaan tanah dalam bentuk *digital number*.

c. *Build-Up Index*

Untuk memperoleh data hasil *Build-Up Index* dari citra satelit Sentinel-2, maka perlu melakukan beberapa tahapan yang dijelaskan sebagai berikut.

- 1.) Melakukan kueri terhadap data citra satelit Sentinel-2 yang telah di-*clip* menurut batas administrasi Provinsi Jawa Tengah menggunakan layanan Google Earth Engine (GEE), di mana data diambil dalam

kondisi rentang waktu 1 Januari hingga 31 Desember 2021 dari katalog “*COPERNICUS/S2*”.

- 2.) Melakukan *filtering* data untuk memperoleh data citra yang memiliki tutupan awan terkecil.
 - 3.) Membersihkan data citra satelit dari tutupan awan dengan menggunakan teknik *cloud masking*.
 - 4.) Menghitung nilai *Normalized Difference Vegetation Index* (NDVI) dan *Normalized Difference Build-up Index* (NDBI) untuk memperoleh nilai *Build-Up Index* (BUI) di wilayah yang diamati dengan menggunakan persamaan (4).
 - 5.) Mengekspor data raster yang memuat nilai BUI menggunakan GEE.
 - 6.) Mengagregasikan data raster yang telah diekspor ke dalam level kecamatan menggunakan nilai median menggunakan perangkat lunak QGIS.
- d. Kepadatan Senyawa CO

Penelitian ini menggunakan data polusi udara dari tingkat emisi atau konsentrasi kepadatan senyawa Karbon Monoksida (CO). Data tersebut diukur menggunakan satelit Sentinel-5P yang dikumpulkan menggunakan layanan Google Earth Engine (GEE) pada rentang waktu 1 Januari hingga 31 Desember 2021. Data tersebut diekspor dari katalog “*COPERNICUS/S5P/NRTI/L3_CO*”. Data raster yang telah diekspor kemudian diagregasikan ke dalam tingkat administrasi kecamatan dengan nilai median. Data tersebut digunakan sebagai ukuran tingkat polusi udara di masing-masing kecamatan di Provinsi Jawa Tengah.

e. *Elevation*

Penelitian ini menggunakan *Data Elevation Model* (DEM) yang memuat informasi mengenai ketinggian di suatu wilayah. Data DEM diukur menggunakan data elevasi digital SRTM tahun 2000 yang diperoleh melalui layanan Google Earth Engine. Data tersebut diekspor dari katalog “NASA/NASADEM_HGT/001”. Data raster yang telah diekspor kemudian diagregasikan pada tingkat administrasi kecamatan dengan nilai median. Data tersebut digunakan sebagai nilai median dari ketinggian dan kemiringan di masing-masing kecamatan di Provinsi Jawa Tengah.

f. Konsentrasi *Particulate Matter 2.5*

Penelitian ini juga menggunakan data *Particulate Matter 2.5* ($PM_{2.5}$) sebagai kandidat variabel penyerta dari indikator polusi udara selain CO. Data $PM_{2.5}$ diperoleh dari situs *NASA Socioeconomic Data and Applications Center* (SEDAC), di mana data yang terbaru yaitu tahun 2019. Data tersebut terdiri atas konsentrasi tahunan dalam satuan *micrograms per cubic meter* dari seluruh komposisi partikel halus jenis $PM_{2.5}$ di atas permukaan tanah. Data tersebut disediakan dalam bentuk raster berformat *geotiff* dan berada dalam proyeksi WGS84. Karena data raster tersebut mencakup wilayah secara global, maka perlu di-*clip* terlebih dahulu dengan shp batas administrasi yang kemudian diagregasikan ke dalam level kecamatan di Provinsi Jawa Tengah menggunakan nilai median. Dengan demikian, data $PM_{2.5}$ digunakan sebagai salah satu ukuran tingkat polusi udara di masing-masing kecamatan di Provinsi Jawa Tengah.

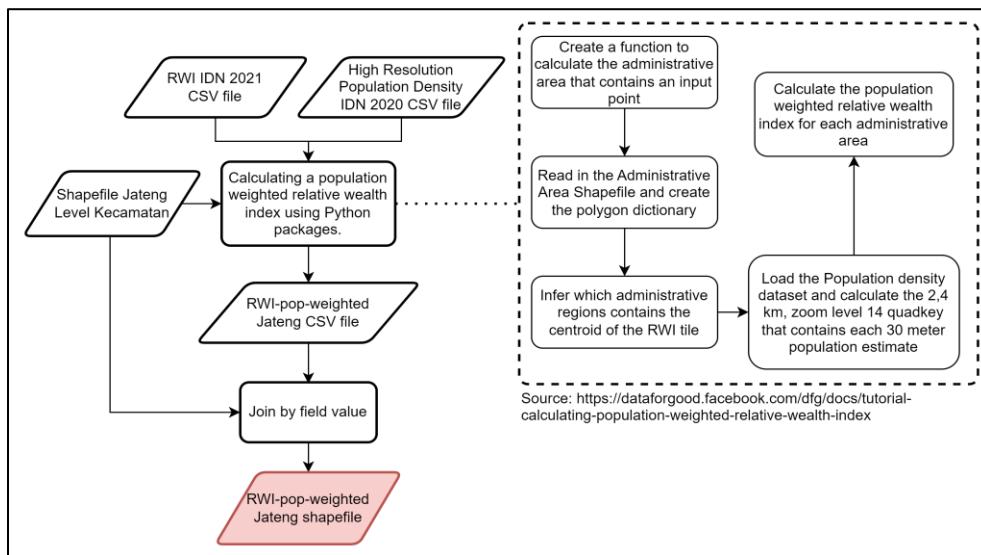
g. *Global Aridity Index*

Data indeks kekeringan global atau *Global Aridity Index* digunakan sebagai kandidat variabel penyerta dari indikator perubahan iklim. Data *Global-AI* disediakan oleh dataset *Global Aridity Index and Potential Evapotranspiration Database Version 3* yang menyediakan data raster global dengan periode waktu 1970-2000. Data tersebut diperoleh dari situs "<https://gee-community-catalog.org/>" yang diunduh dalam bentuk *zip folder archive* dengan nama "*Global-AI_ET0_annual_v3*". Di dalam *zip folder* tersebut terdapat dokumen berekstensi *geotiff* dengan nama "*ai_v3_year*" yang digunakan untuk memperoleh nilai AI (*Aridity Index*). Karena data raster tersebut mencakup wilayah secara global, maka perlu di-*clip* terlebih dahulu dengan *shp* batas administrasi yang kemudian diagregasikan ke dalam level kecamatan di Provinsi Jawa Tengah menggunakan nilai median. Dengan demikian, *aridity index* digunakan untuk mengukur tingkat kekeringan sebagai indikator perubahan iklim pada setiap wilayah kecamatan di Provinsi Jawa Tengah.

h. *Relative Wealth Index*

Data indeks kekayaan relatif atau *Relative Wealth Index* (RWI) digunakan sebagai kandidat variabel penyerta untuk menunjukkan tingkat taraf hidup relatif di suatu wilayah. Data RWI disediakan untuk 93 negara yang berkategori pendapatan rendah dan sedang, termasuk Indonesia. Data RWI Indonesia yang terbaru tahun 2021 dapat diunduh dalam format CSV melalui situs web Facebook's Data for Good. Untuk mengurangi adanya potensi bias karena efek pemusatan populasi pada pengukuran data RWI, maka perlu dilakukan *adjustment* menggunakan data *population density*.

Adapun data *population density* yang digunakan berupa data *High Resolution Population Density Indonesia Tahun 2020* dalam format CSV yang dapat diperoleh dari sumber yang sama. Berikut ini ditampilkan alur pemrosesan untuk menghitung dan memperoleh nilai RWI tertimbang populasi (*Population Weighted Relative Wealth Index*).



Sumber: Facebook's Data For Good (2023), disesuaikan

Gambar 4. Alur penghitungan nilai RWI tertimbang populasi

Langkah pertama perlu mempersiapkan data RWI dan *High Resolution Population Density* dalam format CSV, serta *shapefile* administrasi wilayah yang digunakan. Kemudian dilakukan penghitungan nilai RWI tertimbang populasi menggunakan layanan Jupiter Notebook dengan bahasa Python. Tahapan yang dilakukan adalah sebagai berikut.

- 1) Menentukan unit administrasi yang berisi *centroid* dari setiap *tile* RWI.
- 2) Menghitung *bing tile quadkey* pada tingkat *zoom* sebesar 14 untuk setiap titik dalam kumpulan data *population density*.

- 3) Menentukan tingkat *zoom* sebesar 14 atau setara 2,4 kilometer *bing tile* yang bersesuaian dengan masing-masing *tile* yang lebih kecil dari *population density* dan menghitung jumlah populasi dalam setiap *zoom* level 14 RWI *tile*.
- 4) Menghitung jumlah penduduk di setiap wilayah administrasi yang ditentukan menggunakan *High Resolution Population Density Dataset*.
- 5) Menghitung bobot populasi pada setiap *zoom* level 14 RWI *tile*.
- 6) Mengekspor nilai RWI tertimbang populasi dalam format CSV.
- 7) Melakukan *join by field value* dengan *shapefile* wilayah agar diperoleh bentuk *shapefile* untuk melakukan analisis secara spasial.

3. Analisis Deskriptif

Analisis deskriptif merupakan analisis yang dilakukan untuk memberikan deskripsi awal sebelum melakukan analisis inferensia. Analisis deskriptif digunakan untuk menghasilkan ringkasan statistik sederhana tentang data yang sudah diolah menjadi suatu informasi yang jelas dan bermakna. Penyajian pada analisis deskriptif dapat berupa tabel, gambar, atau grafik agar mudah dipahami. Penelitian ini melakukan analisis deskriptif dengan menyusun ringkasan statistik untuk memberikan pemahaman terkait karakteristik distribusi data dari variabel yang digunakan pada penelitian ini,

4. Analisis Inferensia dengan Metode SAE

Analisis inferensia dalam penelitian ini digunakan untuk mendapatkan nilai estimasi rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021 dengan menggunakan metode SAE. Beberapa tahapan perlu

dilakukan untuk memperoleh nilai estimasi tersebut. Berikut ini prosedur pendugaan tak langsung dengan metode SAE yang dilakukan dalam penelitian ini.

- 1) Menghitung, menganalisis, dan melakukan pengujian nilai korelasi data antara variabel *interest* dengan seluruh kandidat variabel penyerta. Analisis dan pengujian ini menggunakan korelasi Kendall-Tau yang dilakukan pada perangkat lunak RStudio.
- 2) Seleksi variabel penyerta dilakukan dengan menghitung nilai korelasi antarvariabel penyerta, menghitung nilai VIF (*Variance Inflation Factor*), mengeliminasi model dengan metode *backward*, dan menguji keberartian model dengan uji parsial *t*. Penyeleksian terhadap kandidat variabel penyerta secara umum bertujuan untuk mendapatkan hasil estimasi terbaik dengan mempertimbangkan prinsip kesederhanaan model. Pemilihan variabel ini dilakukan pada perangkat lunak RStudio.
- 3) Melakukan pengujian kesesuaian distribusi normal dan distribusi *lognormal* terhadap penduga langsung. Hal ini bertujuan untuk menentukan diperlukan atau tidaknya model SAE HB *Lognormal* menggunakan Uji Kolmogorov Smirnov pada RStudio.
- 4) Apabila langkah (3) diketahui bahwa penduga langsung berdistribusi *lognormal*, maka estimasi tak langsung dapat dilakukan dengan model SAE HB *Lognormal* pada variabel penyerta terpilih menggunakan bantuan *package* “*saeHB*” yang tersedia di RStudio. Dalam menentukan model estimasi pada inferensi *bayesian*, maka

perlu memperhatikan kondisi kekonvergenan dari nilai parameter model hasil algoritma MCMC berdasarkan *diagnostic plot*.

- 5) Menghitung nilai RRMSE dari model SAE HB *Lognormal* terpilih dengan perangkat lunak RStudio.
- 6) Melakukan estimasi tak langsung pada model SAE EBLUP-FH metode REML dengan variabel penyerta terpilih menggunakan bantuan *package* “sae” pada RStudio. Dalam menentukan model estimasi terbaik perlu memperhatikan nilai *goodness-of-fit* dan signifikansi dari setiap variabel penyerta terpilih.
- 7) Menghitung nilai RRMSE dari model EBLUP-FH terpilih dengan perangkat lunak RStudio.
- 8) Melakukan pengujian kesesuaian distribusi normal terhadap pengaruh acak area dan residual model menggunakan Uji Kolmogorov Smirnov pada RStudio.
- 9) Membentuk matriks pembobot spasial dengan tipe *queen contiguity* yang distandarisasi dengan bantuan *package* “spdep” pada RStudio.
- 10) Melakukan pengujian autokorelasi spasial pada penduga langsung dengan Uji *Moran's I* menggunakan bantuan *package* “spdep” pada RStudio. Apabila hasilnya signifikan, maka mengulangi langkah (6) hingga (8) dengan model SAE SEBLUP-FH metode REML.
- 11) Mengevaluasi hasil estimasi model dengan cara melakukan perbandingan hasil estimasi dari masing-masing model pendugaan terhadap nilai konsumsi listrik per kapita rumah tangga dari data PT. PLN dengan menghitung nilai korelasi Kendall-Tau untuk

mengetahui tingkat kedekatan estimasi terhadap nilai populasinya.

Kemudian dilakukan perbandingan nilai RSE atau RRMSE dari setiap model pendugaan untuk memperoleh model terbaik dalam meminimalisasi *error*.

- 12) Membuat dan menganalisis hasil pemetaan berdasarkan hasil estimasi dari metode terbaik yang dipilih pada langkah (11).

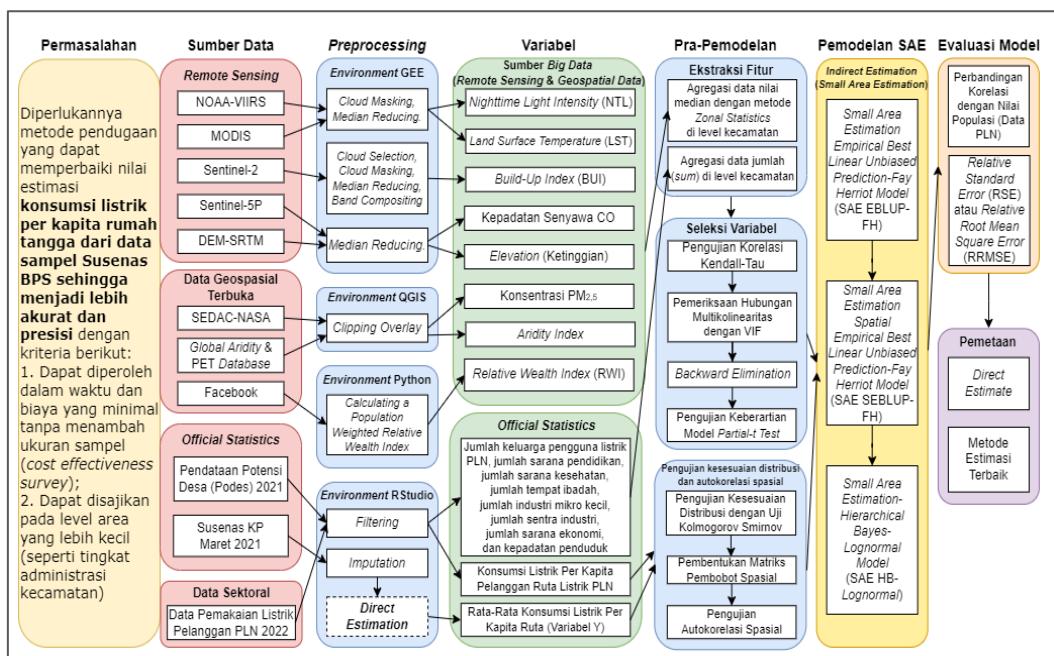
3.3 Kerangka Pikiran

Listrik merupakan energi yang paling banyak digunakan untuk menunjang segala jenis aktivitas produktif bagi rumah tangga. Dalam beberapa tahun terakhir, kebutuhan konsumsi terhadap energi listrik semakin meningkat sehingga harus diimbangi dengan ketersediaan pasokan listrik yang cukup dan tepat sasaran agar tidak mengalami *oversupply* energi yang dapat menimbulkan kerugian bagi negara. Selain itu, penggunaan energi listrik bagi rumah tangga dapat dijadikan sebagai salah satu indikator kesejahteraan masyarakat di suatu wilayah. Oleh sebab itu, urgensi terhadap kebutuhan data pemakaian (konsumsi) listrik yang lebih akurat dapat mendukung langkah penyediaan pasokan listrik dan analisis pembangunan infrastruktur kelistrikan yang tepat guna sehingga dapat meningkatkan tingkat kesejahteraan masyarakat. Apalagi saat ini kebutuhan terhadap penyajian data harus dapat tersedia hingga tingkat administrasi wilayah dalam lingkup yang lebih kecil. Hal tersebut berimplikasi pada kesempatan dalam menyediakan indikator nilai estimasi rata-rata konsumsi listrik rumah tangga hingga tingkat administrasi wilayah yang kecil, seperti level kecamatan.

BPS telah mengumpulkan data konsumsi listrik (KWh) rumah tangga melalui kegiatan Susenas pada bulan Maret, tetapi BPS hanya dapat melakukan estimasi hingga level kabupaten/kota saja. Data tersebut dapat digunakan untuk menghasilkan indikator rata-rata konsumsi listrik per kapita rumah tangga (ruta). Di sisi lain, untuk mendukung ketersediaan estimasi indikator data hingga level area yang lebih kecil, seperti tingkat kecamatan, maka dibutuhkan jumlah sampel yang memadai agar menghasilkan estimasi yang akurat dan presisi. Akan tetapi, penambahan jumlah sampel dapat meningkatkan sumber daya yang dibutuhkan dalam proses pengumpulan data sehingga memicu kenaikan dari segi biaya survei. Oleh sebab itu, solusi alternatif yang diusulkan untuk menghasilkan indikator data estimasi rata-rata konsumsi listrik per kapita ruta hingga level kecamatan yaitu dengan metode *Small Area Estimation* (SAE). Metode ini diharapkan dapat memberikan hasil estimasi yang lebih akurat dan presisi dengan memanfaatkan variabel penyerta yang berperan sebagai informasi tambahan (*auxiliary information*). Variabel penyerta dalam metode SAE harus mampu memberikan informasi secara lengkap pada level area yang dicakupnya. Pada penelitian ini, variabel penyerta yang digunakan berasal dari kombinasi sumber *big data* dan hasil pendataan potensi desa (Podes) tahun 2021. Informasi yang termuat pada sumber *big data* memiliki potensi dalam menghasilkan data yang berkualitas dengan level penyajian yang lebih detail. Selain itu juga dapat diperoleh secara mudah, cepat, dan gratis. Beberapa penelitian terdahulu telah menggunakan sumber *big data*, seperti data citra satelit dan data geospasial terbuka dalam berbagai kajian sosial ekonomi. Hal tersebut dilakukan karena mempelajari aktivitas manusia yang dihubungkan dengan fenomena alam dan teknologi yang tercermin di dalam sumber

big data dapat dikaitkan dengan kondisi sosial ekonomi yang ada di sekitarnya.

Oleh karena itu, penelitian ini juga menggunakan sumber *big data* sebagai kandidat variabel penyerta dalam melakukan estimasi menggunakan metode *Small Area Estimation*. Data tersebut diharapkan dapat menangkap dan melengkapi fenomena yang belum tercakup dari pengumpulan data melalui survei konvensional. Berikut ini ditampilkan alur penelitian yang digambarkan pada kerangka pikir penelitian.



Gambar 5. Kerangka Pikir Penelitian

BAB IV

HASIL DAN PEMBAHASAN

4.1 Pendugaan Langsung Nilai Rata-Rata Konsumsi Listrik Per Kapita Ruta Level Kecamatan di Provinsi Jawa Tengah tahun 2021

Pendugaan langsung nilai rata-rata konsumsi listrik per kapita rumah tangga (ruta) dilakukan di wilayah kecamatan yang memiliki sampel pada kegiatan Susenas Maret 2021. Provinsi Jawa Tengah memiliki jumlah kecamatan sebanyak 576 kecamatan, di mana terdapat tiga kecamatan yang tidak memiliki sampel pada Susenas antara lain Kecamatan Bumijawa, Kecamatan Bojong, dan Kecamatan Jatinegara. Satu kecamatan lain yang tidak dimasukkan menjadi sampel penelitian ini yaitu Kecamatan Karimun Jawa. Hal ini dikarenakan Kecamatan Karimun Jawa memiliki lokasi yang terpisah secara fisik dengan kecamatan lain di Provinsi Jawa Tengah sehingga tidak dapat menjelaskan adanya pengaruh spasial di dalamnya. Dengan demikian, penghitungan estimasi langsung nilai rata-rata konsumsi listrik per kapita ruta dilakukan pada 572 kecamatan di Provinsi Jawa Tengah tahun 2021. Estimasi tersebut dihitung dengan menggunakan persamaan (5) yang terdapat pada landasan teori bagian pendugaan langsung.

Hasil estimasi langsung nilai rata-rata konsumsi listrik per kapita ruta untuk 572 kecamatan dapat dilihat dan disajikan secara lengkap pada Lampiran 1. Hasil estimasi langsung ini untuk selanjutnya disebut sebagai penduga langsung. Nilai penduga langsung digunakan sebagai variabel *interest* dalam melakukan pendugaan tak langsung dengan metode *Small Area Estimation*. Adapun nilai statistik deskriptif dari penduga langsung ditampilkan pada Tabel 9 berikut ini.

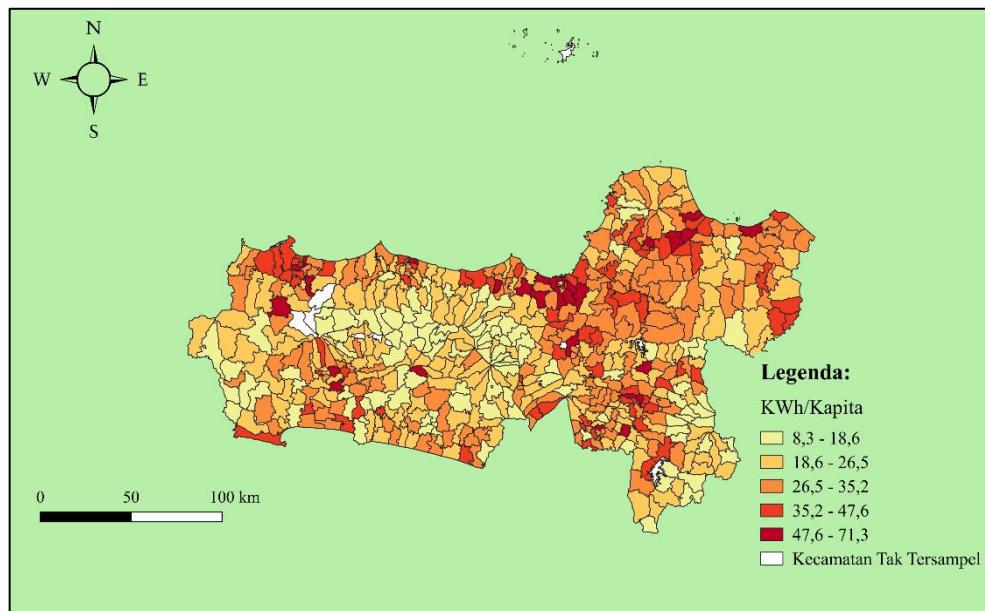
Tabel 9. Statistik deskriptif penduga langsung

Statistik deskriptif	Penduga langsung
(1)	(2)
Jumlah (kecamatan)	572 kecamatan
Minimum	8,309
Median	26,146
Rata-rata	27,604
Maksimum	71,308
Varians	114,008
Jangkauan	62,999

Statistik deskriptif penduga langsung dari Tabel 9 di atas didapatkan nilai rata-rata sebesar 27,604 KWh/Kapita. Adapun nilai rata-rata konsumsi listrik per kapita ruta yang terendah adalah 8,309 KWh/Kapita, sedangkan yang tertinggi adalah 71,308 KWh/Kapita. Kecamatan yang memiliki nilai rata-rata konsumsi listrik per kapita ruta terendah adalah Kecamatan Jenawi, sedangkan kecamatan yang memiliki nilai rata-rata konsumsi listrik per kapita ruta tertinggi adalah Kecamatan Tugu.

Pemetaan terhadap penduga langsung dibuat untuk melihat sebaran spasial dari nilai rata-rata konsumsi listrik per kapita ruta pada level kecamatan di Provinsi Jawa Tengah tahun 2021. Pemetaan tersebut dikelompokkan ke dalam lima kategori nilai dengan metode *Natural Breaks*. Metode ini dipilih karena tidak ada teori dan panduan khusus mengenai pengelompokan nilai variabel terkait sehingga bekerja hanya berdasarkan pada kondisi data yang ada (Chang, 2019). Hal yang sama juga diterapkan dalam pembuatan peta tematik pada kandidat variabel penyerta dari sumber *big data* karena metode *Natural Breaks* dapat menggambarkan pengelompokan secara lebih jelas dibandingkan metode yang lain. Berikut ini disajikan peta tematik sebaran nilai penduga langsung untuk 572 kecamatan yang menjadi sampel penelitian. Sementara itu, wilayah kecamatan yang tidak dipilih

menjadi sampel pada penelitian ini tidak dihitung nilai penduga langsungnya sehingga ditandai dengan warna putih pada peta.

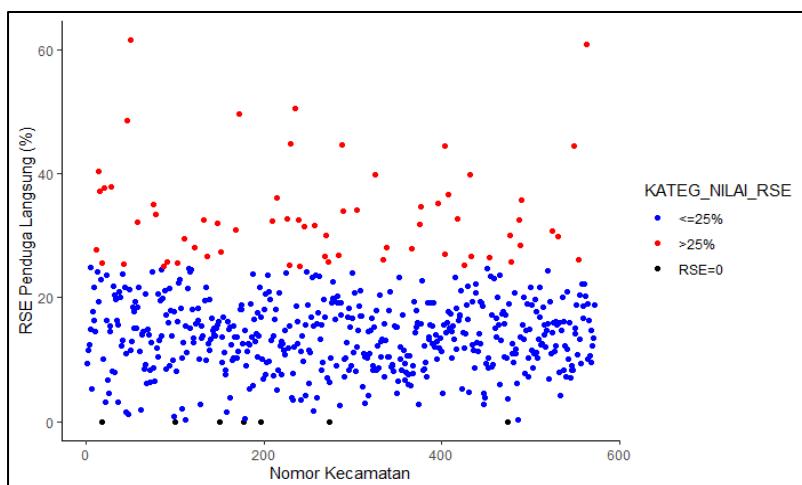


Sumber: Susenas Maret 2021, diolah

Gambar 6. Peta sebaran nilai estimasi rata-rata konsumsi listrik per kapita ruta level kecamatan dengan metode pendugaan langsung

Gambar 6 di atas terlihat bahwa wilayah kecamatan yang memiliki nilai rata-rata konsumsi listrik per kapita ruta yang tinggi sebagian besar berada di daerah perkotaan, meliputi Kota Semarang, Kota Surakarta, dan Kota Tegal. Sedangkan, wilayah kecamatan yang memiliki nilai rata-rata konsumsi listrik per kapita ruta yang rendah sebagian besar cenderung menempati wilayah perdesaan yang banyak dijumpai di Kabupaten Wonosobo, Kabupaten Banjarnegara, dan Kabupaten Temanggung. Selain itu, untuk melihat tingkat akurasi dari penduga langsung, maka dihitung juga nilai *Relative Standard Error* (RSE) dari setiap kecamatan. Namun, terdapat tujuh kecamatan yang memiliki *standard error* (SE) bernilai nol sehingga menghasilkan nilai RSE yang bernilai nol juga. Hal ini dikarenakan

jumlah sampel pada tujuh kecamatan tersebut tidak mencukupi ukuran sampel minimum dari desain sampling yang digunakan pada Susenas Maret 2021. Berikut ini adalah diagram *dot plot* yang menunjukkan nilai RSE masing-masing kecamatan yang ditampilkan pada Gambar 7.



Sumber: Susenas Maret 2021, diolah

Gambar 7. Visualisasi nilai RSE dari hasil estimasi langsung rata-rata konsumsi listrik per kapita ruta level kecamatan

Dari Gambar 7 terdapat beberapa kecamatan yang memiliki nilai RSE melebihi 25%. Jika mengacu pada Tabel 5, nilai RSE dari kecamatan tersebut digolongkan ke dalam estimator yang perlu digunakan secara hati-hati hingga masuk pada kategori tidak akurat. Adapun nilai RSE dari estimasi langsung secara lengkap dapat dilihat pada Lampiran 2. Meskipun nilai rata-rata dan median RSE tanpa mengikutsertakan amatan yang memiliki nilai SE = 0 berturut-turut sebesar 15,96% dan 14,76% yang dikategorikan akurat, tetapi masih terdapat 65 kecamatan yang memiliki nilai RSE > 25%. Oleh karena itu, untuk lebih mengoptimalkan hasil estimasi langsung dari nilai rata-rata konsumsi listrik per kapita ruta level kecamatan dengan data Susenas tanpa menambah ukuran sampel, maka diperlukan

pemodelan estimasi dengan pendugaan tak langsung menggunakan metode *Small Area Estimation* (SAE).

4.2 Analisis Deskriptif Kandidat Variabel Penyerta

Variabel Podes

Hasil pendataan potensi desa (Podes) 2021 digunakan sebagai kandidat variabel penyerta pada pemodelan estimasi dengan SAE. Variabel-variabel yang diperoleh dari data Podes berjumlah 8, meliputi jumlah keluarga pengguna listrik PLN (X_1), jumlah sarana pendidikan (X_2), jumlah sarana kesehatan (X_3), jumlah tempat ibadah (X_4), jumlah industri mikro dan kecil (X_5), jumlah sentra industri (X_6), jumlah sarana dan prasarana ekonomi (X_7), dan kepadatan penduduk (X_8). Karena data Podes masih berbentuk agregat level desa, maka perlu dikelompokkan menurut kode kecamatan sehingga diperoleh nilai agregat masing-masing variabel pada setiap kecamatan. Adapun hasil statistik deskriptif untuk kandidat variabel penyerta yang berasal dari data Podes disajikan pada Tabel 10 berikut ini.

Tabel 10. Statistik deskriptif variabel penyerta berasal dari Podes 2021

Variabel	Minimum	Maksimum	Rata-Rata	Median	Standar Deviasi
(1)	(2)	(3)	(4)	(5)	(6)
X_1	3516	61913	21474	19732	9729,44
X_2	31	405	142,6	133,5	56,164
X_3	11	219	56,86	50	29,499
X_4	50	826	294,6	273,5	122,274
X_5	60	9152	883,8	558,5	1009,352
X_6	0	54	2,57	1	4,287
X_7	28	3322	854	789,5	437,237
X_8	117	16094,02	1747,448	1121,47	2063,243

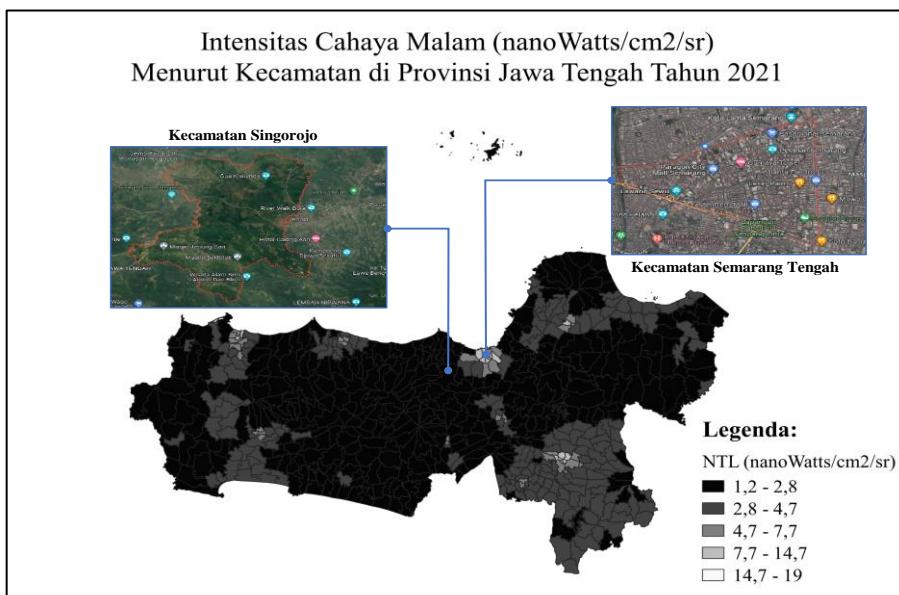
Pada Tabel 10 diketahui bahwa variabel keluarga pengguna listrik PLN (X_1) memiliki variasi nilai paling tinggi yang ditunjukkan dengan nilai standar deviasi

terbesar. Sedangkan variasi nilai paling rendah terdapat pada variabel jumlah sentra industri yang ditunjukkan dengan nilai standar deviasi terkecil. Selain itu, variabel data Podes secara keseluruhan memiliki nilai rata-rata yang lebih tinggi dibandingkan dengan nilai mediannya. Jika mengacu teori dari Agresti & Finlay (1997), maka nilai rata-rata yang lebih tinggi (lebih kanan) dari nilai median menunjukkan bahwa distribusi data cenderung menceng kanan. Hal ini juga dapat dilihat pada Lampiran 3 yang menampilkan diagram histogram dari seluruh kandidat variabel penyerta, di mana variabel dari data Podes yang diberi warna hijau secara umum cenderung menunjukkan distribusi menceng kanan.

Variabel Sumber Big Data

Selain dari data Podes, beberapa kandidat variabel penyerta diperoleh dari sumber *big data* berupa data penginderaan jauh dan data geospasial terbuka. Variabel-variabel tersebut meliputi *nighttime light intensity* (X_9), *build-up index* (X_{10}), *land surface temperature* (X_{11}), *elevation* (X_{12}), kepadatan senyawa karbon monoksida (CO) (X_{13}), konsentrasi *particulate matter 2.5* (PM_{2.5}) (X_{14}), *global aridity index* (X_{15}), dan *relative wealth index* (X_{16}). Berikut ini ditampilkan visualisasi peta tematik dan analisis deskriptif dari kandidat variabel penyerta yang diperoleh dari sumber *big data* setelah diagregasikan menurut kecamatan di Provinsi Jawa Tengah serta hasil penelusuran lapangan (*ground check*) menggunakan peta digital dari layanan Google Earth. Adapun distribusi data dari variabel sumber *big data* yang ditampilkan dalam bentuk visualisasi histogram juga dapat dilihat pada Lampiran 3.

Nighttime Light Intensity

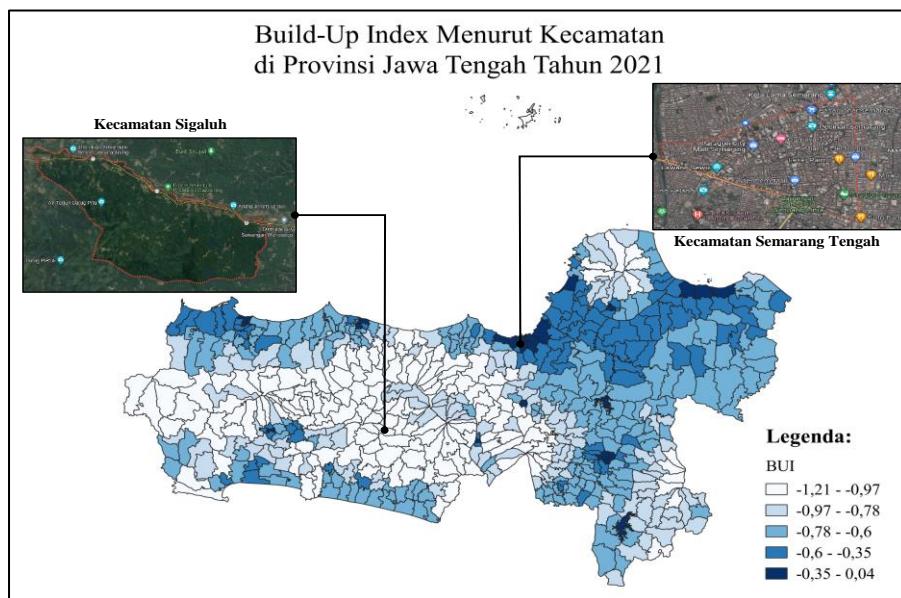


Sumber: S-NPP/NOAA-20 VIIRS-DNB, diolah

Gambar 8. Visualisasi data *nighttime light intensity* yang diagregasi menurut kecamatan

Gambar 8 menyajikan visualisasi peta tematik yang menggambarkan sebaran nilai intensitas cahaya malam menurut kecamatan di Provinsi Jawa Tengah tahun 2021. Gambar di atas memperlihatkan bahwa sebagian besar wilayah kecamatan di Provinsi Jawa Tengah memiliki nilai intensitas cahaya malam yang rendah. Wilayah dengan nilai intensitas cahaya malam yang relatif tinggi cenderung mengelompok pada kecamatan di daerah perkotaan, seperti Kota Semarang, Kota Tegal, dan Kota Surakarta. Nilai intensitas cahaya malam tertinggi yakni sebesar 19,035 nanoWatts/cm²/sr yang berada di Kecamatan Semarang Tengah, di mana kecamatan tersebut teridentifikasi sebagai wilayah padat penduduk. Sedangkan nilai intensitas cahaya malam terendah yakni sebesar 1,3725 nanoWatts/cm²/sr yang berada di Kecamatan Singorojo, di mana kecamatan tersebut diidentifikasi sebagai wilayah yang didominasi oleh hutan dan area terbangun yang rendah.

Build-Up Index

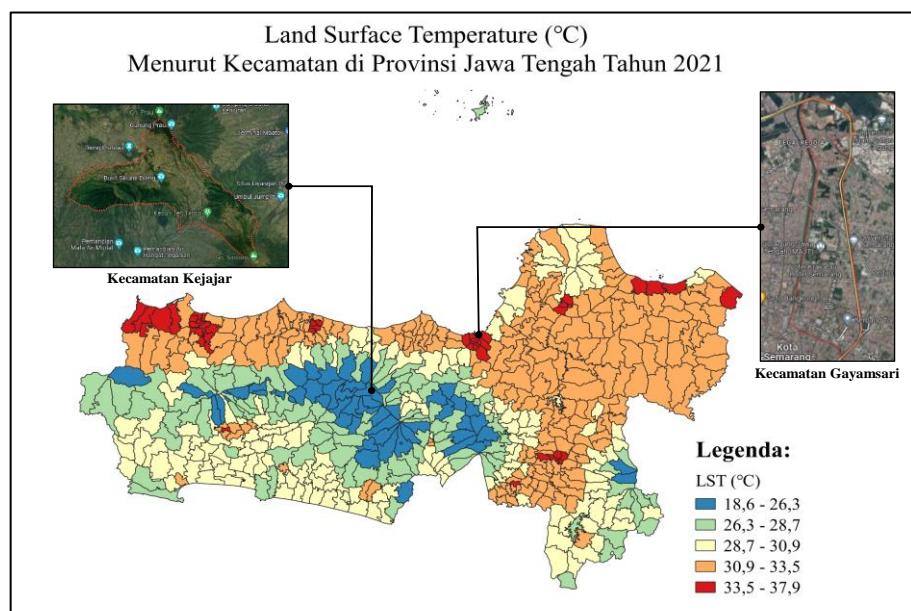


Sumber: Sentinel-2, diolah

Gambar 9. Visualisasi data *build-up index* yang diagregasi menurut kecamatan

Gambar 9 menampilkan visualisasi peta tematik yang menggambarkan sebaran nilai *Build-Up Index* (BUI) menurut kecamatan di Provinsi Jawa Tengah tahun 2021. Gambar tersebut memperlihatkan nilai BUI yang terkonsentrasi tinggi pada wilayah kecamatan yang berada di daerah perkotaan, seperti Kota Semarang, Kota Tegal, dan Kota Surakarta. Di sisi lain, wilayah kecamatan yang memiliki nilai BUI rendah sebagian besar terkonsentrasi di daerah perdesaan, seperti Kabupaten Banjarnegara dan Kabupaten Wonosobo. Adapun nilai BUI tertinggi yakni sebesar 0,03596 yang berada di Kecamatan Semarang Tengah, di mana kecamatan tersebut teridentifikasi sebagai wilayah yang didominasi dengan area terbangun. Sedangkan nilai BUI terendah yakni sebesar -1,20879 yang berada di Kecamatan Sigaluh, di mana kecamatan tersebut teridentifikasi sebagai wilayah yang didominasi dengan area vegetasi hijau.

Land Surface Temperature

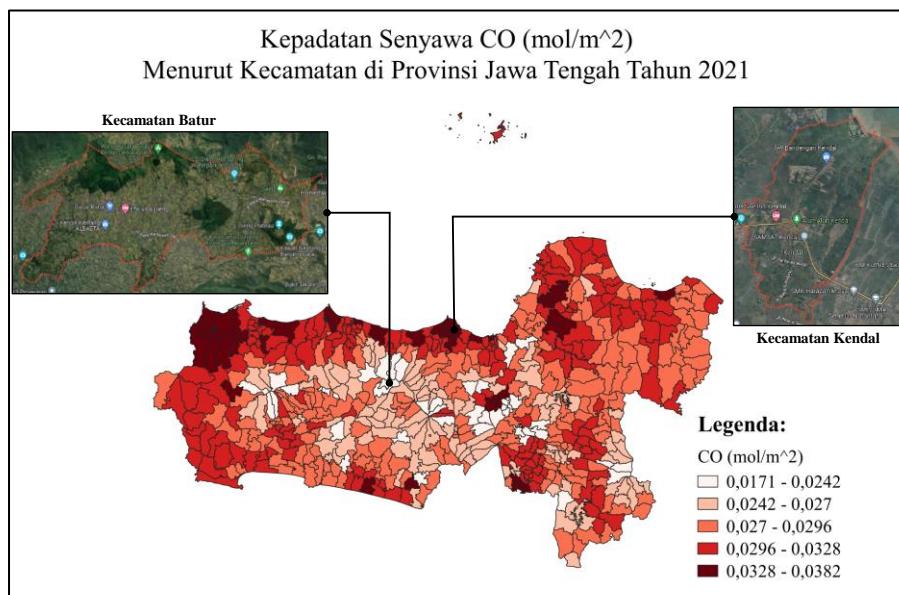


Sumber: MODIS, diolah

Gambar 10. Visualisasi data *land surface temperature* yang diagregasi menurut kecamatan

Gambar 10 menyajikan visualisasi peta tematik yang menggambarkan sebaran nilai suhu permukaan tanah menurut kecamatan di Provinsi Jawa Tengah tahun 2021. Gambar tersebut menunjukkan bahwa sebagian besar suhu permukaan tanah cenderung tinggi pada wilayah kecamatan yang berada di daerah perkotaan dan pesisir pantai utara. Sementara itu, wilayah dengan suhu permukaan tanah yang rendah mayoritas berada di daerah dataran tinggi. Adapun suhu permukaan tanah tertinggi yakni sebesar 37,88°C yang berada di Kecamatan Gayamsari, di mana kecamatan tersebut diidentifikasi sebagai daerah perkotaan yang dekat dengan pesisir pantai utara. Sedangkan suhu permukaan tanah terendah yakni sebesar 22,64°C yang berada di Kecamatan Kejajar, di mana kecamatan tersebut diidentifikasi terletak di daerah dataran tinggi yang dikelilingi gunung.

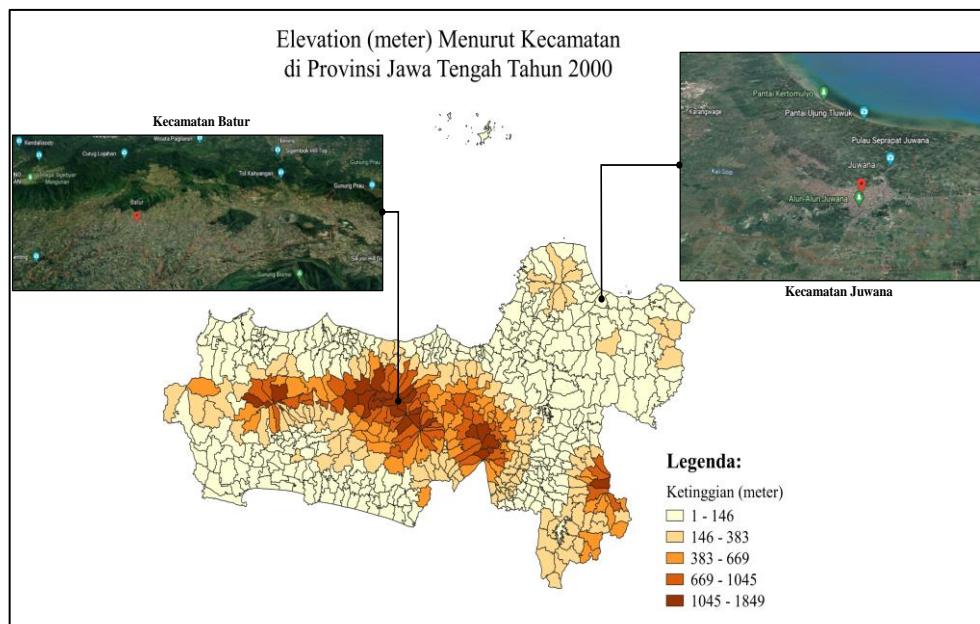
Kepadatan Senyawa CO



Gambar 11. Visualisasi data kepadatan senyawa karbon monoksida (CO) yang diagregasi menurut kecamatan

Gambar 11 menampilkan visualisasi peta tematik yang menggambarkan sebaran nilai kepadatan senyawa karbon monoksida (CO) menurut kecamatan di Provinsi Jawa Tengah tahun 2021. Gambar tersebut menjelaskan bahwa semakin tinggi nilai kepadatan senyawa CO menunjukkan tingkat emisi CO yang tinggi pula di udara pada suatu wilayah kecamatan. Adapun kepadatan senyawa CO tertinggi yakni sebesar $0,03821 \text{ mol/m}^2$ yang berada di Kecamatan Kendal, di mana kecamatan tersebut teridentifikasi berdekatan dengan Kawasan Industri Kendal. Sedangkan kepadatan senyawa CO terendah yakni sebesar $0,01706 \text{ mol/m}^2$ yang berada di Kecamatan Batur, di mana kecamatan tersebut diidentifikasi berlokasi di daerah Dataran Tinggi Dieng.

Elevation (Ketinggian)

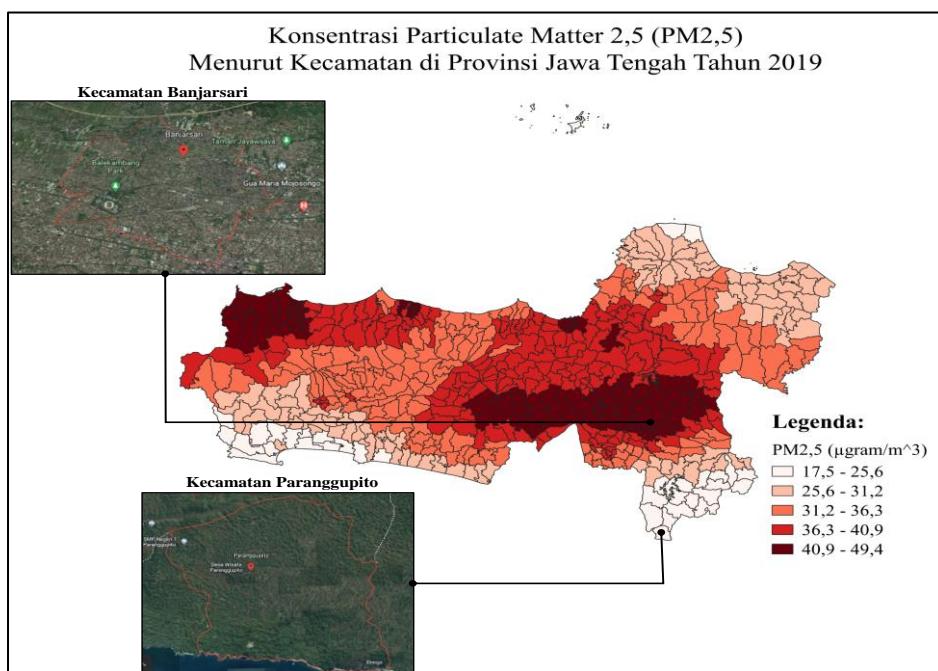


Sumber: SRTM-NASA DEM, diolah

Gambar 12. Visualisasi data *elevation* yang diagregasi menurut kecamatan

Gambar 12 menampilkan visualisasi peta tematik yang menggambarkan sebaran nilai ketinggian (*elevation*) dalam satuan meter menurut kecamatan di Provinsi Jawa Tengah tahun 2000. Gambar tersebut menunjukkan bahwa sebagian besar kecamatan yang memiliki wilayah tinggi berada di daerah pegunungan, seperti di dataran tinggi dieng. Sementara itu, wilayah kecamatan yang berada di daerah pesisir pantai cenderung memiliki ketinggian yang relatif lebih rendah. Adapun nilai ketinggian terbesar yakni sebesar 1.816 meter yang berada di Kecamatan Batur, di mana kecamatan tersebut diidentifikasi sebagai wilayah yang terletak di dataran tinggi dan dikelilingi gunung. Sedangkan nilai ketinggian terendah yaitu 1 meter yang berada di Kecamatan Juwana, di mana kecamatan tersebut diidentifikasi berada di dataran rendah yang terletak di pesisir pantai utara.

Konsentrasi Particulate Matter 2,5 (PM_{2,5})



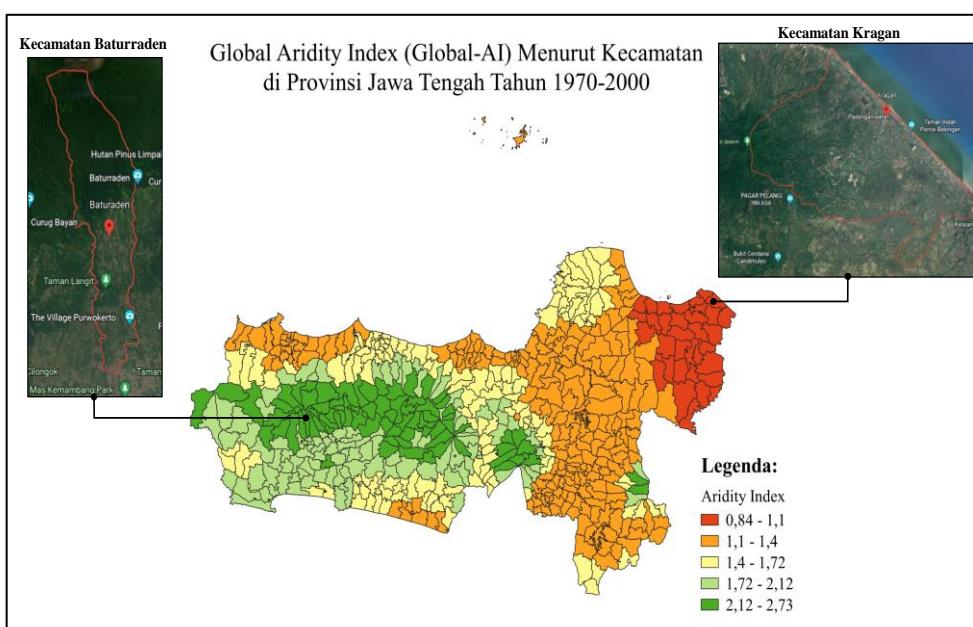
Sumber: *Socioeconomic Data and Applications Center (SEDAC)* NASA, diolah

Gambar 13. Visualisasi data konsentrasi *particulate matter* 2,5 (PM_{2,5}) yang diagregasi menurut kecamatan

Gambar 13 menampilkan visualisasi peta tematik yang menggambarkan sebaran nilai konsentrasi *particulate matter* 2,5 (PM_{2,5}) menurut kecamatan di Provinsi Jawa Tengah tahun 2019. Gambar tersebut menjelaskan tingkat konsentrasi tahunan dari semua komposisi partikel halus polutan jenis PM_{2,5} di atas permukaan tanah. Semakin besar nilai konsentrasi PM_{2,5} di suatu wilayah menunjukkan semakin tinggi tingkat polutan jenis PM_{2,5} di wilayah tersebut. Adapun nilai konsentrasi PM_{2,5} tertinggi yakni sebesar 49,4 $\mu\text{gram}/\text{m}^3$ yang berada di Kecamatan Banjarsari. Kecamatan tersebut diidentifikasi terletak di pusat Kota Surakarta. Sedangkan nilai konsentrasi PM_{2,5} terendah yakni sebesar 17,5 $\mu\text{gram}/\text{m}^3$ yang berada di Kecamatan Paranggupito. Kecamatan tersebut

diidentifikasi sebagai wilayah perdesaan yang berlokasi di Kabupaten Wonogiri dan berbatasan langsung dengan pantai selatan.

Global Aridity Index (Global-AI)



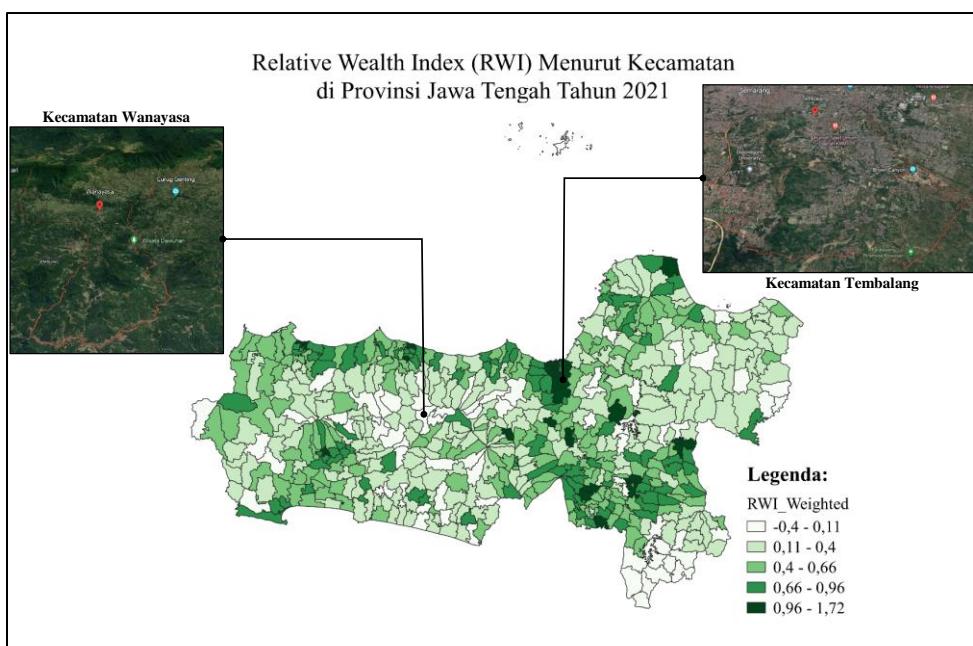
Sumber: *Global Aridity and PET Database*, diolah

Gambar 14. Visualisasi data indeks kekeringan (*aridity index*) yang diagregasi menurut kecamatan

Gambar 14 menyajikan visualisasi peta tematik yang menggambarkan sebaran nilai *aridity index* (indeks kekeringan) menurut kecamatan di Provinsi Jawa Tengah dalam periode amatan 1970-2000. Gambar tersebut menjelaskan tingkat kekeringan suatu wilayah yang direpresentasikan oleh suatu angka indeks. Semakin tinggi nilai *aridity index* menunjukkan kondisi yang lebih lembab, sedangkan semakin rendah nilai *aridity index* menunjukkan kondisi yang lebih gersang. Adapun nilai *aridity index* tertinggi yakni sebesar 2,7325 yang berada di Kecamatan Baturraden. Kecamatan tersebut diidentifikasi sebagai wilayah yang terdapat hutan pinus di dalamnya sehingga berkorespondensi dengan kondisi yang lembab.

Sedangkan nilai *aridity index* terendah sebesar 0,8404 yang berada di Kecamatan Kragan. Kecamatan tersebut diidentifikasi sebagai wilayah yang berbatasan langsung dengan pesisir pantai utara dan banyak dijumpai tempat penggalian pasir sehingga berkorespondensi dengan kondisi yang gersang.

Relative Wealth Index (RWI)



Sumber: Facebook's Data For Good, diolah

Gambar 15. Visualisasi data indeks kekayaan relatif (*relative wealth index*) yang diagregasi menurut kecamatan

Gambar 15 menampilkan visualisasi peta tematik yang menggambarkan sebaran nilai *relative wealth index* (indeks kekayaan relatif) menurut kecamatan di Provinsi Jawa Tengah tahun 2021, di mana nilai tersebut sudah dilakukan *adjustment* terhadap data *population density* (kepadatan penduduk). Gambar di atas menjelaskan tingkat taraf hidup relatif dari suatu wilayah yang direpresentasikan dalam bentuk angka indeks. Semakin besar nilai RWI menunjukkan tingkat taraf hidup yang relatif tinggi dari penduduk di wilayah tersebut, begitu juga sebaliknya.

Adapun nilai RWI tertinggi yakni sebesar 1,7157 yang berada di Kecamatan Tembalang, di mana kecamatan tersebut berlokasi di wilayah Kota Semarang yang diidentifikasi sebagai pusat pemerintahan, bisnis, dan perekonomian regional. Sedangkan nilai RWI terendah yakni sebesar -0,4047 yang berada di Kecamatan Wanayasa, di mana kecamatan tersebut berlokasi di Kabupaten Banjarnegara yang diidentifikasi sebagai wilayah berbasis pertanian, perkebunan, dan pariwisata.

4.3 Pendugaan Tak Langsung Nilai Rata-Rata Konsumsi Listrik Per Kapita Ruta Level Kecamatan di Provinsi Jawa Tengah Tahun 2021

Hasil Pendugaan tak langsung diawali dengan proses seleksi kandidat variabel penyerta. Proses ini bertujuan untuk mengurangi jumlah kandidat yang tersedia cukup banyak yaitu berjumlah 16 variabel. Kandidat variabel penyerta diperoleh dari hasil pengolahan data Podes dan ekstraksi sumber *big data*. Setelah didapatkan seluruh kandidat variabel penyerta, maka selanjutnya dilakukan pengujian korelasi untuk mengetahui kandidat variabel penyerta yang memiliki hubungan signifikan terhadap penduga langsung. Penghitungan korelasi bertujuan untuk memastikan hubungan secara empiris dan sekaligus mengeliminasi kandidat variabel penyerta yang tidak signifikan terhadap nilai penduga langsung. Dengan demikian, variabel yang memiliki hubungan signifikan terhadap nilai penduga langsung dipilih masuk ke proses seleksi berikutnya. Adapun nilai korelasi, *p-value*, dan hasil signifikansi dari pengujian korelasi Kendall-Tau antara seluruh kandidat variabel penyerta dengan penduga langsung dapat dilihat sebagai berikut.

Tabel 11. Nilai korelasi Kendall-Tau dan hasil pengujinya antara seluruh kandidat variabel penyerta dengan penduga langsung

Variabel	Nama Variabel Penyerta	Korelasi	P-value	Keterangan
(1)	(2)	(3)	(4)	(5)
X_1	Jumlah keluarga pengguna listrik PLN	0,2711	$P < 0,001$	Signifikan
X_2	Jumlah sarana pendidikan	0,2014	$P < 0,000$	Signifikan
X_3	Jumlah sarana kesehatan	0,3234	$P < 0,000$	Signifikan
X_4	Jumlah tempat ibadah	0,0952	0,0007	Signifikan
X_5	Jumlah industri mikro dan kecil (IMK)	-0,0241	0,3887	Tak Signifikan
X_6	Jumlah sentra industri	-0,0527	0,0819	Tak Signifikan
X_7	Jumlah sarana dan prasarana ekonomi	0,2757	$P < 0,0001$	Signifikan
X_8	Kepadatan Penduduk	0,3215	$P < 0,0001$	Signifikan
X_9	Nighttime Light Intensity	0,2999	$P < 0,0001$	Signifikan
X_{10}	Build-Up Index	0,3931	$P < 0,0001$	Signifikan
X_{11}	Land Surface Temperature	0,4103	$P < 0,0001$	Signifikan
X_{12}	Elevation	-0,3244	$P < 0,0001$	Signifikan
X_{13}	Kepadatan Senyawa CO	0,2150	$P < 0,0001$	Signifikan
X_{14}	Konsentrasi $PM_{2,5}$	0,1357	$P < 0,0001$	Signifikan
X_{15}	Global Aridity Index	-0,2948	$P < 0,0001$	Signifikan
X_{16}	Relative Wealth Index	0,2828	$P < 0,0001$	Signifikan

*) kurang dari tingkat signifikansi (α) = 0,05

Tabel 11 menunjukkan terdapat 14 kandidat variabel penyerta yang signifikan berkorelasi dengan penduga langsung. Sedangkan sisanya yaitu variabel jumlah IMK dan jumlah sentra industri tidak signifikan berkorelasi dengan penduga langsung. Kemudian dari 14 kandidat variabel penyerta yang signifikan terdapat 12 variabel dengan nilai korelasi positif dan 2 variabel dengan nilai korelasi negatif. Selanjutnya, 14 kandidat variabel penyerta tersebut diseleksi lagi dengan melihat besarnya nilai korelasi antarvariabel agar menghindari masalah multikolinearitas pada model. Apabila terdapat variabel yang memiliki nilai *Variance Inflation Factor* (VIF) lebih dari 10, maka salah satu dari kedua variabel tersebut dieliminasi dari model. Adapun matriks korelasi antar seluruh kandidat variabel penyerta ditampilkan dalam *heatmap* pada Lampiran 4. Sedangkan nilai VIF dari setiap kandidat variabel penyerta disajikan pada Tabel 12 berikut ini.

Tabel 12. Nilai VIF masing-masing dari 14 variabel penyerta

Variabel	Nama kandidat variabel penyerta	<i>Variance Inflation Factor (VIF)</i>
(1)	(2)	(3)
X_1	Jumlah keluarga pengguna listrik PLN	5,816031
X_2	Jumlah sarana pendidikan	4,880905
X_3	Jumlah sarana kesehatan	5,096888
X_4	Jumlah tempat ibadah	4,323902
X_7	Jumlah sarana dan prasarana ekonomi	2,881605
X_8	Kepadatan penduduk	6,467060
X_9	<i>Nighttime Light Intensity</i>	5,631555
X_{10}	<i>Build-Up Index</i>	6,443919
X_{11}	<i>Land Surface Temperature</i>	12,699985
X_{12}	<i>Elevation</i>	4,359110
X_{13}	Kepadatan Senyawa CO	1,700263
X_{14}	Konsentrasi Particulate Matter 2,5 ($PM_{2,5}$)	1,646249
X_{15}	<i>Global Aridity Index</i>	3,670783
X_{16}	<i>Relative Wealth Index</i>	1,548146

Tabel 12 dapat diketahui hanya variabel *land surface temperature* yang memiliki nilai VIF lebih dari 10. Sementara itu, jika dilihat dari *heatmap* matriks korelasi pada Lampiran 4 diketahui bahwa variabel *land surface temperature* berkorelasi positif dan kuat dengan *build-up index* sebesar 0,68. Oleh karena itu, variabel *land surface temperature* dieliminasi sehingga tersisa 13 kandidat variabel penyerta. Setelah dilakukan penghitungan VIF dan korelasi antarvariabel, langkah selanjutnya yaitu melakukan seleksi kandidat variabel penyerta yang tersisa menggunakan metode *backward elimination* dengan kriteria AIC. Berikut ditampilkan proses seleksi kandidat variabel penyerta tersisa menggunakan metode *backward elimination* yang disajikan pada Tabel 13 di bawah ini.

Tabel 13. Proses seleksi kandidat variabel penyerta dengan metode *backward* kriteria AIC

Step	Variabel	AIC
(1)	(2)	(3)
1	$X_1, X_2, X_3, X_4, X_7, X_8, X_9, X_{10}, X_{12}, X_{13}, X_{14}, X_{15}, X_{16}$	2427,40
2	$X_1, X_2, X_3, X_4, X_7, X_8, X_9, X_{10}, X_{12}, X_{14}, X_{15}, X_{16}$	2425,49
3	$X_1, X_2, X_3, X_4, X_7, X_8, X_{10}, X_{12}, X_{14}, X_{15}, X_{16}$	2423,58
4	$X_1, X_2, X_4, X_7, X_8, X_{10}, X_{12}, X_{14}, X_{15}, X_{16}$	2421,67

<i>Step</i>	Variabel	AIC
(1)	(2)	(3)
5	$X_2, X_4, X_7, X_8, X_{10}, X_{12}, X_{14}, X_{15}, X_{16}$	2420,66
6	$X_2, X_4, X_7, X_8, X_{10}, X_{12}, X_{14}, X_{16}$	2419,59

Pada Tabel 13 ditampilkan proses eliminasi kandidat variabel penyerta dengan metode *backward* berdasarkan kriteria AIC. Hasil yang diperoleh menyisakan 8 kandidat variabel penyerta yakni $X_2, X_4, X_7, X_8, X_{10}, X_{12}, X_{14}$, dan X_{16} . Setelah itu, kandidat variabel penyerta tersebut dilakukan pengujian keberartian model menggunakan uji parsial *t* dua arah untuk mengetahui ada atau tidaknya pengaruh yang nyata (signifikan) terhadap nilai penduga langsung. Berikut ini disajikan Tabel 14 yang menampilkan hasil pengujian keberartian model dari 8 kandidat variabel penyerta menggunakan uji parsial *t*.

Tabel 14. Ringkasan hasil uji parsial *t* dari 8 kandidat variabel penyerta

Variabel	Statistik <i>t</i>	<i>P-value</i>	Keterangan
(1)	(2)	(3)	(4)
X_2	1,695	0,091	Tidak Signifikan
X_4	-2,283	0,023*	Signifikan
X_7	4,457	$P < 0,001^*$	Signifikan
X_8	1,561	0,119	Tidak Signifikan
X_{10}	4,937	$P < 0,001^*$	Signifikan
X_{12}	-5,055	$P < 0,001^*$	Signifikan
X_{14}	2,094	0,037*	Signifikan
X_{16}	2,300	0,022*	Signifikan

*) kurang dari tingkat signifikansi (α) = 0,05

Tabel 14 menunjukkan bahwa terdapat 6 variabel yang memiliki pengaruh signifikan terhadap nilai penduga langsung. Sedangkan variabel jumlah fasilitas pendidikan (X_2) dan kepadatan penduduk (X_8) menunjukkan hasil yang tidak signifikan memengaruhi nilai penduga langsung. Dengan demikian, terdapat 6 variabel penyerta yang terpilih untuk masuk pada pemodelan estimasi dengan metode SAE, yaitu variabel jumlah tempat ibadah (X_4), jumlah sarana dan

prasarana ekonomi (X_7), *build-up index* (X_{10}), *elevation* (X_{12}), konsentrasi PM_{2.5} (X_{14}), dan *relative wealth index* (X_{16}).

Setelah mendapatkan variabel penyerta dari serangkaian proses seleksi, maka selanjutnya dapat dilakukan estimasi tak langsung dengan metode SAE. Namun sebelum itu, pengujian kesesuaian distribusi data penduga langsung dilakukan untuk dijadikan pertimbangan diperlukan atau tidaknya model SAE HB dalam analisis inferensia. Adapun hasil pengujian kesesuaian distribusi normal penduga langsung dengan Uji Kolmogorov Smirnov (KS) disajikan sebagai berikut.

Tabel 15. Hasil pengujian kesesuaian distribusi normal dari penduga langsung menggunakan Uji Kolmogorov Smirnov

Statistik uji (D)	<i>P-value</i>	Keterangan
(1)	(2)	(3)
0,0783	0,0018	Penduga langsung tidak berdistribusi normal

tingkat signifikansi (α) = 0,05

Hasil uji KS pada Tabel 15 menunjukkan bahwa penduga langsung tidak berdistribusi normal. Hal ini dapat menjadi indikasi awal bahwa residual model tidak berdistribusi normal sehingga membuat metode SAE berbasis EBLUP kurang tepat, karena EBLUP merupakan metode SAE berbasis *linear mixed model* yang memberikan asumsi variabel *interest* berdistribusi normal. Oleh sebab itu, metode SAE dengan pendekatan *Hierarchical Bayes* dapat menjadi metode alternatif dalam melakukan estimasi tak langsung karena model HB dapat mengatasi permasalahan distribusi data yang tidak seimbang (asimetris). Model HB yang digunakan pada penelitian ini adalah model *Lognormal* dengan variabel prediktor berbasis area. Namun sebelum itu, uji kesesuaian distribusi *lognormal* perlu dilakukan terhadap penduga langsung menggunakan Uji Kolmogorov Smirnov (KS). Selanjutnya ditampilkan hasil Uji KS yang disajikan pada Tabel 16 berikut ini.

Tabel 16. Hasil pengujian kesesuaian distribusi *lognormal* dari penduga langsung menggunakan Uji Kolmogorov Smirnov (KS)

Statistik uji (<i>D</i>)	<i>P-value</i>	Keterangan
(1)	(2)	(3)
0,0416	0,2748	Penduga langsung berdistribusi <i>lognormal</i>

tingkat signifikansi (α) = 0,05

Pada Tabel 16 diperoleh hasil statistik uji KS untuk distribusi *lognormal* sebesar 0,0416 dan *p-value* sebesar 0,2748. Karena *p-value* lebih besar dari 0,05 sehingga dapat disimpulkan bahwa nilai penduga langsung mengikuti distribusi *lognormal*. Oleh sebab itu, estimasi nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah dapat dihitung menggunakan metode SAE pendekatan model *Hierarchical Bayesian Lognormal*.

Model SAE EBLUP-FH

Model EBLUP *Fay-Herriot* merupakan model SAE yang paling umum digunakan dalam estimasi tak langsung. Hasil estimasi dari model EBLUP-FH digunakan sebagai tolok ukur (*benchmark*) untuk membandingkan tingkat akurasi dan presisi dari hasil estimasi dengan model SAE yang lain. Dari proses seleksi kandidat variabel penyerta pada bagian sebelumnya, maka terpilih 6 variabel yang digunakan dalam pemodelan SAE. Adapun tabel hasil estimasi koefisien regresi ($\hat{\beta}$) dan koefisien ragam pengaruh acak ($\hat{\sigma}_v^2$) dengan model EBLUP-FH pada metode REML ditampilkan pada Lampiran 5. Hasil estimasi rata-rata konsumsi listrik per kapita ruta dengan model EBLUP-FH untuk selanjutnya disebut sebagai penduga EBLUP-FH. Nilai penduga EBLUP-FH dari 572 kecamatan secara lebih lengkapnya diberikan pada Lampiran 1. Kemudian, untuk membandingkan penduga EBLUP-FH dengan penduga langsung, berikut ini disajikan hasil perbandingan statistik deskriptif untuk kedua penduga tersebut.

Tabel 17. Perbandingan statistik deskriptif penduga langsung dan penduga EBLUP-FH

Statistik deskriptif	Penduga langsung	Penduga EBLUP-FH
(1)	(2)	(3)
Jumlah (kecamatan)	572	572
Minimum	8,309	8,886
Kuartil pertama	20,530	20,773
Median	26,146	26,196
Rata-rata	27,604	26,131
Kuartil ketiga	32,614	31,076
Maksimum	71,308	53,315
Varians	114,008	59,606
Jangkauan	62,999	44,429

Tabel 17 dapat dilihat bahwa penduga EBLUP-FH memiliki nilai rata-rata yang lebih rendah dibanding dengan penduga langsung. Jika dilihat dari variansnya, penduga EBLUP-FH memiliki varians yang lebih kecil dibandingkan dengan penduga langsung. Hal tersebut menunjukkan bahwa penduga EBLUP-FH lebih homogen dibanding dengan penduga langsung. Hal ini juga dapat dilihat berdasarkan nilai jangkauan dari penduga EBLUP-FH yang lebih rendah daripada nilai jangkauan dari penduga langsung.

Tabel hasil estimasi koefisien pada Lampiran 5 memperlihatkan bahwa seluruh variabel penyerta signifikan pada taraf signifikansi 5% dengan nilai koefisien keragaman pengaruh acak sebesar 33,106. Untuk memastikan bahwa penduga EBLUP-FH layak dijadikan sebagai pembanding bagi model penduga SAE yang lain, maka diperlukan pengecekan normalitas pada pengaruh acak area (v_i) dan residual model (e_i). Hal ini sejalan dengan Rao & Molina (2015) yang menitikberatkan terpenuhinya asumsi normalitas, terutama pada pengaruh acak area. Berikut ini hasil pengujian normalitas terhadap pengaruh acak area dan residual model dari model SAE EBLUP-FH.

Tabel 18. Hasil pengujian kesesuaian distribusi normal pengaruh acak area dan residual dari model SAE EBLUP-FH menggunakan Uji Kolmogorov Smirnov

Variabel uji	Statistik uji (D)	P -value	Keterangan
(1)	(2)	(3)	(4)
v_i	0,0418	0,2696	Pengaruh acak area berdistribusi normal
e_i	0,2541	$P < 0,0001$	Residual tidak berdistribusi normal

Tabel 18 memperlihatkan hasil pengujian kesesuaian distribusi normal pengaruh acak area dengan p -value yang lebih besar dari 0,05 sehingga disimpulkan bahwa pengaruh acak area dari penduga EBLUP-FH mengikuti distribusi normal. Sedangkan p -value dari residual lebih kecil dari 0,05 sehingga disimpulkan bahwa residual pada model EBLUP-FH tidak mengikuti distribusi normal. Meskipun demikian, penduga EBLUP-FH layak untuk dijadikan sebagai pembanding bagi model penduga SAE yang lain. Hal ini sejalan dengan Rao & Molina (2015) yang menekankan terpenuhinya asumsi normalitas pada pengaruh acak area. Akan tetapi, hasil tersebut belum tentu membuat penduga EBLUP-FH sudah baik karena residual model yang dihasilkan tidak berdistribusi normal dan belum mempertimbangkan efek spasial ke dalam model sehingga diperlukan metode SAE yang lain yaitu model SEBLUP-FH dan SAE HB.

Model SAE SEBLUP-FH

Seperti yang telah dijelaskan pada bagian sebelumnya, metode SAE dengan model *Spatial EBLUP Fay-Herriot* (SEBLUP-FH) telah dikembangkan dengan memasukkan unsur kewilayahan ke dalam model. Unsur kewilayahan tersebut direpresentasikan ke dalam sebuah matriks yang dinamakan sebagai matriks kontiguitas (*contiguity*). Pada penelitian ini, matriks *contiguity* yang digunakan merupakan tipe *Queen*. Adapun bentuk ilustrasi matriks *queen contiguity* yang

digunakan pada pemodelan SEBLUP-FH sebelum distandarisasi dan setelah distandarisasi adalah sebagai berikut.

		tetangga ke- <i>i</i>						Jumlah
tetangga ke- <i>j</i>	1	2	3	4	...	572		
	1	0	1	1	0	...	0	3
	2	1	0	1	0	...	0	5
	3	1	1	0	0		0	6
	4	0	0	0	0		0	7

	572	0	0	0	0	...	0	7

Sumber: Susenas Maret 2021, diolah

Gambar 16. Bentuk matriks pembobot spasial dengan tipe *Queen* sebelum distandarisasi

		tetangga ke- <i>i</i>						Jumlah
tetangga ke- <i>j</i>	1	2	3	4	...	572		
	1	0	0,333	0,333	0	...	0	1
	2	0,200	0	0,200	0	...	0	1
	3	0,167	0,167	0	0		0	1
	4	0	0	0	0		0	1

	572	0	0	0	0	...	0	1

Sumber: Susenas Maret 2021, diolah.

Gambar 17. Bentuk matriks pembobot spasial dengan tipe *Queen* setelah distandarisasi

Pembentukan matriks *contiguity* tipe *Queen* dibantu dengan perangkat lunak RStudio menggunakan *package spdep*. Matriks ini disusun berdasarkan hubungan ketersinggungan sisi atau sudut dari suatu wilayah terhadap wilayah lainnya. *Queen contiguity* mendefinisikan nilai $w_{ij} = 1$ jika suatu wilayah bersisian (*common side*) atau titik sudutnya (*common vertex*) bertemu dengan wilayah yang menjadi acuan, sedangkan $w_{ij} = 0$ untuk wilayah tidak memenuhi kriteria tersebut. Cara tersebut diimplementasikan pada 572 kecamatan yang menjadi titik pengamatan. Kemudian, matriks *contiguity* yang telah berisi bobot

bernilai nol dan satu dilakukan standarisasi secara baris. Dengan demikian, matriks *contiguity* yang telah distandarisasi tersebut digunakan sebagai *proximity matrix* pada pemodelan SEBLUP-FH.

Sebelum masuk pemodelan, variabel *interest* yang ingin diestimasi perlu diketahui keberadaan pengaruh spasial antaramatan melalui pengujian autokorelasi spasial. Pengujian ini bertujuan untuk mengungkapkan bahwa variabel rata-rata konsumsi listrik per kapita ruta pada level kecamatan memiliki ketergantungan spasial antarwilayah. Pengujian autokorelasi spasial dapat dilakukan dengan menggunakan Uji *Moran's I*. Adapun gambar *Moran's I scatter plot* yang dibuat dengan perangkat lunak RStudio dapat dilihat pada Lampiran 6. Sementara itu, hasil pengujian autokorelasi spasial dengan Uji *Moran's I* ditampilkan sebagai berikut.

Tabel 19. Hasil pengujian autokorelasi spasial dari penduga langsung menggunakan Uji *Moran's I*

Indeks moran	Z-statistics	P-value	Keterangan
(1)	(2)	(3)	(4)
0,1805	7,0841	$P < 0,0001$	Terdapat dependensi spasial antarwilayah

Tabel 19 menampilkan hasil Uji *Moran's I* yang diperoleh indeks moran sebesar 0,1805 dengan *p-value* < 0,0001. Hasil tersebut secara teori menunjukkan bahwa terdapat dependensi (ketergantungan) spasial antarwilayah kecamatan pada nilai penduga langsung. Dengan demikian, model *Spatial EBLUP-FH* dapat digunakan untuk melakukan pendugaan tak langsung.

Gambar *Moran's I scatter plot* yang disajikan pada Lampiran 6 dapat diketahui bahwa sebagian besar titik wilayah amatan berada pada kuadran 1 dan 3. Wilayah amatan yang berada pada kuadran 1 berarti memiliki nilai rata-rata konsumsi listrik per kapita ruta yang tinggi dan dikelilingi oleh wilayah dengan

nilai rata-rata konsumsi listrik per kapita yang tinggi juga. Sedangkan wilayah amatan yang berada pada kuadran 3 berarti memiliki nilai rata-rata konsumsi listrik per kapita ruta yang rendah dan dikelilingi oleh wilayah dengan nilai rata-rata konsumsi listrik per kapita ruta yang rendah juga. Dari analisis tersebut, maka tingkat rata-rata konsumsi listrik per kapita ruta antarwilayah kecamatan di Provinsi Jawa Tengah masih terjadi ketimpangan antara nilai yang tinggi dan rendah.

Proses selanjutnya yaitu melakukan estimasi tak langsung dengan model SEBLUP-FH. Estimasi ini juga menggunakan metode REML dengan 6 variabel penyerta yang sama dan nilai penduga langsung sebagai variabel *interest*-nya. Adapun hasil estimasi koefisien regresi ($\hat{\beta}$), koefisien ragam pengaruh acak ($\hat{\sigma}_v^2$), dan koefisien *spatial autoregressive* ($\hat{\rho}$) dengan model SEBLUP-FH disajikan pada Lampiran 7. Hasil estimasi model SEBLUP-FH untuk selanjutnya disebut sebagai penduga SEBLUP-FH. Nilai penduga SEBLUP-FH dari 572 kecamatan secara lengkap dapat dilihat pada Lampiran 1. Kemudian, untuk membandingkan penduga SEBLUP-FH dengan penduga EBLUP-FH dan penduga langsung, berikut ini disajikan hasil perbandingan statistik deskriptif untuk kedua penduga tersebut.

Tabel 20. Perbandingan statistik deskriptif penduga langsung, penduga EBLUP-FH, dan penduga SEBLUP-FH

Statistik deskriptif	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH
(1)	(2)	(3)	(4)
Jumlah (kecamatan)	572	572	572
Minimum	8,309	8,886	8,888
Kuartil pertama	20,530	20,773	20,752
Median	26,146	26,196	26,112
Rata-rata	27,604	26,131	26,170
Kuartil ketiga	32,614	31,076	30,949
Maksimum	71,308	53,315	53,602
Varians	114,008	59,606	60,553
Jangkauan	62,999	44,429	44,714

Tabel 20 diketahui bahwa penduga SEBLUP-FH memiliki nilai rata-rata yang lebih rendah dibandingkan dengan penduga langsung, tetapi tidak jauh berbeda dari penduga EBLUP-FH. Hal demikian juga terdapat pada nilai varians dan jangkauan, di mana penduga SEBLUP-FH memiliki nilai yang lebih rendah dibandingkan dengan penduga langsung, tetapi tidak jauh berbeda dari penduga EBLUP-FH. Dari hasil tersebut dapat disimpulkan bahwa penduga SEBLUP-FH memiliki karakteristik sebaran data yang relatif sama dengan penduga EBLUP-FH.

Hasil estimasi koefisien regresi pada Lampiran 7 menunjukkan seluruh variabel penyerta signifikan dengan tingkat signifikansi 5%. Nilai koefisien keragaman pengaruh acak ($\hat{\sigma}_v^2$) sebesar 32,914. Selain itu juga diperoleh nilai koefisien *spatial autoregressive* ($\hat{\rho}$) sebesar 0,118 yang menunjukkan bahwa terdapat hubungan spasial antarwilayah yang lemah pada penduga SEBLUP-FH dengan matriks *contiguity* tipe *Queen*. Seperti pada penduga EBLUP-FH, pengujian kesesuaian distribusi normal juga dilakukan pada pengaruh acak area (v_i) dan residual (e_i) dari model SAE SEBLUP-FH. Berikut ini hasil pengujian kesesuaian distribusi normal dari pengaruh acak area dan residual dari model SAE SEBLUP-FH dengan Uji Kolmogorov Smirnov.

Tabel 21. Hasil pengujian kesesuaian distribusi normal pengaruh acak area dan residual dari model SAE SEBLUP-FH menggunakan Uji Kolmogorov Smirnov

Variabel uji	Statistik uji (D)	P -value	Keterangan
(1)	(2)	(3)	(4)
v_i	0,0419	0,2654	Pengaruh acak area berdistribusi normal
e_i	0,2492	$P < 0,0001$	Residual tidak berdistribusi normal

Tabel 21 menampilkan p -value dari pengujian kesesuaian distribusi normal pengaruh acak area lebih besar dari 0,05 sehingga disimpulkan bahwa pengaruh

acak area dari penduga SEBLUP-FH mengikuti distribusi normal. Sedangkan *p-value* dari residual lebih kecil dari 0,05 sehingga disimpulkan bahwa residual dari model SEBLUP-FH tidak mengikuti distribusi normal. Meskipun demikian, penduga SEBLUP-FH tetap dijadikan sebagai pembanding bagi model penduga SAE yang lain. Namun, residual yang dihasilkan dari model SEBLUP-FH tidak berdistribusi normal sehingga lantas tidak menjadikan penduga SEBLUP-FH lebih baik dari penduga EBLUP-FH. Oleh sebab itu, penelitian ini tetap dilakukan estimasi dengan model SAE pendekatan *Hierarchical Bayes Lognormal*.

Model SAE HB *Lognormal*

Pemodelan estimasi menggunakan metode SAE dengan pendekatan *Hierarchical Bayes* dilakukan untuk mengatasi pelanggaran asumsi normalitas pada penduga langsung. Hal ini dikarenakan metode SAE HB berbasis *generalized linear mixed model* (GLMM) yang tidak memerlukan asumsi variabel *interest* (penduga langsung) berdistribusi normal. Sementara itu, model SAE HB *Lognormal* dipilih karena sesuai dengan tipe variabel dari nilai rata-rata konsumsi listrik per kapita ruta yang berbentuk rill positif dan berdistribusi *lognormal* sebagaimana telah dibuktikan dari hasil pengujian kesesuaian distribusi dengan Uji Kolmogorov Smirnov pada Tabel 16 sebelumnya.

Proses estimasi dengan model SAE HB *Lognormal* didasarkan pada inferensi *bayesian*. Sebelum melakukan estimasi terhadap nilai $\hat{\theta}_i$, maka terlebih dahulu dilakukan estimasi terhadap β dan σ_v^2 melalui teknik *Markov Chain Monte Carlo* (MCMC). Teknik ini digunakan untuk memperoleh distribusi *posterior* yang sulit diselesaikan karena mengandung integral berdimensi tinggi dan kompleks.

Proses ini dilakukan hingga menghasilkan distribusi *posterior* yang akurat ketika algoritma mencapai kondisi konvergen.

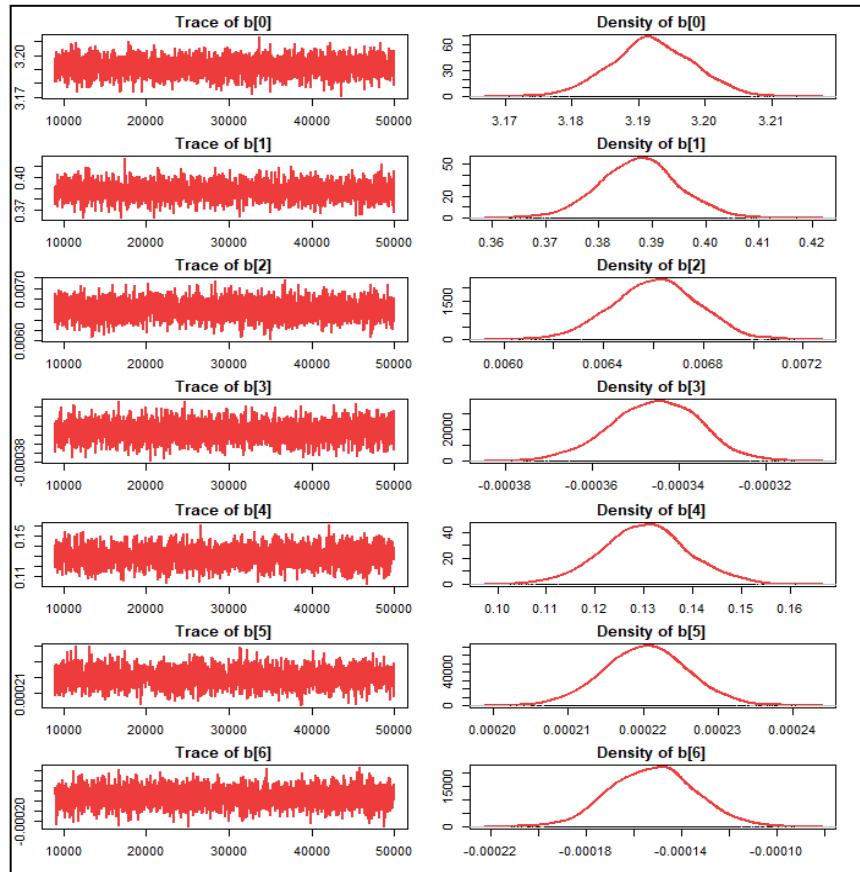
Prior yang digunakan dalam penelitian ini yaitu penentuan *prior* β yang diasumsikan mengikuti distribusi normal dengan $\beta_j \sim N_{iid}(\mu_{[\beta]_j}, \sigma_{[\beta]_j}^2)$ dan menggunakan nilai awal *prior* dari $\mu_{[\beta]_j}$ dan $\sigma_{[\beta]_j}^2$ masing-masing bernilai 0 dan 1.

Sedangkan untuk parameter σ_v^2 di mana $v_i \sim N_{iid}(0, \tau_v)$ dan $\tau_v = \frac{1}{\sigma_v^2}$ dengan menggunakan nilai awal *prior* dari invers ragam pengaruh acak (τ_v) bernilai 1. Penentuan ini didasarkan karena ketiadaan informasi awal dari distribusi parameter.

Langkah selanjutnya yaitu memasukkan variabel *interest* dan variabel penyerta ke dalam model untuk melakukan estimasi parameter. Pendugaan parameter pada model SAE HB dilakukan dengan membangun suatu peluang rantai *Markov* hingga menuju distribusi *prior* tertentu sehingga diperoleh nilai estimasi parameter model. Kondisi tersebut dapat dicapai ketika algoritma MCMC dianggap telah konvergen. Untuk mencapai kondisi konvergensi dari algoritma MCMC, maka dibuat beberapa model percobaan dengan memasukkan nilai *argument* yang berbeda-beda meliputi spesifikasi banyak iterasi, *burn in*, *thin*, dan *update*.

Setelah menjalankan beberapa model percobaan, algoritma MCMC mencapai kondisi konvergen pada model percobaan ke-8 dengan spesifikasi iterasi sebanyak 50.000 kali, *burn in* sebanyak 9.000 kali, *thin* sebanyak 16 kali, dan *update* sebanyak 16 kali. Dari model tersebut diperoleh sekitar 2.562 sampel akhir berdasarkan *diagnostic plot*, meliputi *trace plot*, *density plot*, dan *autocorrelation plot* yang menunjukkan algoritma sudah konvergen. Hasil *diagnostic plots* dari model percobaan 1 – 7 secara lengkap dapat dilihat pada Lampiran 8 hingga Lampiran 14. Adapun *diagnostic plot* yang terdiri atas *trace plot*, *density plot*, dan

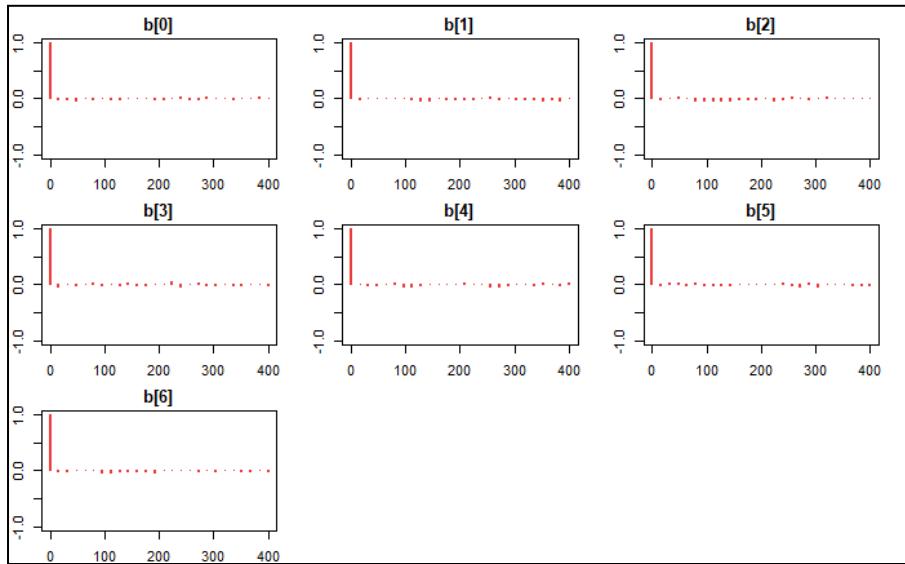
autocorrelation plot dari seluruh parameter β pada model percobaan ke-8 berturut-turut ditampilkan dalam Gambar 18 dan 19 berikut ini.



Sumber: Susenas Maret 2021, sumber *big data*, dan Podes 2021, diolah
Gambar 18. *Trace plot* dan *density plot* dari parameter β model percobaan 8

Gambar 18 ditampilkan *trace plot* untuk seluruh parameter yang dapat dilihat membentuk pola stasioner berbentuk seperti ulat bulu gemuk dan tidak ditemukan pola periodik. Hal ini mengindikasikan bahwa seluruh parameter yang dibangkitkan bersifat acak dan berada dalam rentang nilai yang sama sehingga mengindikasikan algoritma MCMC sudah konvergen. Apabila dilihat dari *density plot*, seluruh parameter memiliki bentuk kurva yang halus (*smooth*) menyerupai

lonceng dan menunjukkan kesesuaian distribusi *prior* yang ditentukan dari parameter β .



Sumber: Susenas Maret 2021, sumber *big data*, dan Podes 2021, diolah

Gambar 19. *Autocorrelation plot* dari parameter β model percobaan 8

Jika dilihat dari *autocorrelation plot* pada Gambar 19, seluruh parameter menunjukkan pola *cut off* setelah *lag* pertama hingga nilai korelasi mendekati nol pada *lag-lag* berikutnya. Hal ini menunjukkan bahwa tidak ada lagi efek autokorelasi, artinya sampel pada iterasi selanjutnya hanya dipengaruhi oleh sampel pada iterasi saat ini sehingga sampel sudah mencapai syarat independensi. Dari penjelasan hasil *diagnostic plot* secara keseluruhan dapat disimpulkan bahwa algoritma MCMC telah konvergen dan menghasilkan sekitar 2.562 sampel akhir untuk digunakan dalam analisis *posterior*.

Setelah syarat konvergen pada algoritma MCMC terpenuhi, selanjutnya besaran-besaran *posterior* dapat dihitung untuk mendapatkan estimasi koefisien setiap parameter β dari model SAE HB *Lognormal*. Estimasi koefisien setiap

parameter β yang dihasilkan meliputi nilai rata-rata dan standar deviasi dari sampel yang dibangkitkan melalui algoritma MCMC. Berikut ditampilkan tabulasi hasil estimasi koefisien setiap parameter β dari model SAE HB *Lognormal* dengan *credible interval* sebesar 95% yang disajikan pada Tabel 22 di bawah ini.

Tabel 22. Hasil estimasi koefisien regresi dan koefisien ragam pengaruh acak dari model SAE HB *Lognormal* dengan 95% *credible interval*

Variabel penyerta	Estimasi koefisien	Standar deviasi	2,5%	97,5%
(1)	(2)	(3)	(4)	(5)
<i>Intercept</i> (b_0)	3,19199	$6,089 \times 10^{-3}$	3,18011	3,20364
Jumlah tempat ibadah (b_1)	-0,00040	$2,78 \times 10^{-5}$	-0,00045	-0,00034
Jumlah sarana dan prasarana ekonomi (b_2)	0,00016	$8,38 \times 10^{-6}$	0,00015	0,00018
<i>Build-Up Index</i> (b_3)	0,38755	$7,307 \times 10^{-3}$	0,37327	0,40186
Konsentrasi PM _{2,5} (b_4)	0,00661	$1,690 \times 10^{-4}$	0,00628	0,00692
<i>Elevation</i> (b_5)	-0,00035	$1,000 \times 10^{-5}$	-0,00037	-0,00033
<i>Relative Wealth Index</i> (b_6)	0,13026	$8,376 \times 10^{-3}$	0,11310	0,14806
Ragam pengaruh acak area ($\hat{\sigma}_v^2$)	0,06995			

Pada inferensi *bayesian*, signifikansi dari suatu parameter model dapat dilihat dari *credible interval* yang dihasilkan. Berdasarkan Tabel 22 dapat dilihat bahwa 95% *credible interval* dari seluruh parameter tidak memuat nilai nol di dalamnya. Hal ini menunjukkan bahwa seluruh parameter dapat dinyatakan signifikan memengaruhi nilai *logaritma* dari penduga langsung. Selain itu juga diperoleh nilai koefisien ragam pengaruh acak area dari model SAE HB *Lognormal* sebesar 0,06995.

Pemodelan estimasi dengan metode SAE dalam penelitian ini tidak memerlukan interpretasi terhadap variabel-variabel penyerta yang signifikan. Hal tersebut dikarenakan penelitian ini hanya berfokus untuk mengoptimalkan hasil pendugaan langsung dari nilai rata-rata konsumsi listrik per kapita ruta

menggunakan metode SAE. Selain itu, keberadaan variabel penyerta pada model hanya digunakan sebagai informasi tambahan (*auxilliary variable*) untuk meningkatkan efektivitas jumlah sampel dan menghasilkan hasil estimasi yang lebih akurat dan presisi.

Setelah diperoleh nilai estimasi tak langsung dari model SAE HB *Lognormal*, nilai estimasi tersebut selanjutnya disebut sebagai penduga HB *Lognormal*. Adapun nilai penduga HB *Lognormal* dari seluruh amatan (kecamatan) secara lebih lengkap dapat dilihat pada Lampiran 1. Kemudian, penghitungan statistik deskriptif dilakukan untuk membandingkan nilai penduga HB *Lognormal* dengan nilai penduga langsung, penduga EBLUP-FH dan penduga SEBLUP-FH. Berikut ini disajikan hasil perbandingan statistik deskriptif untuk empat penduga.

Tabel 23. Perbandingan statistik deskriptif antara penduga langsung, penduga EBLUP-FH, penduga SEBLUP-FH, dan penduga HB *Lognormal*

Statistik deskriptif	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)
Jumlah (kecamatan)	572	572	572	572
Minimum	8,309	8,886	8,888	8,258
Kuartil pertama	20,530	20,773	20,752	20,723
Median	26,146	26,196	26,112	26,357
Rata-rata	27,604	26,131	26,170	27,425
Kuartil ketiga	32,614	31,076	30,949	32,444
Maksimum	71,308	53,315	53,602	69,907
Varians	114,008	59,606	60,553	93,522
Jangkauan	62,999	44,429	44,714	61,649

Tabel 23 dapat dilihat bahwa nilai rata-rata penduga HB *Lognormal* lebih mendekati rata-rata penduga langsung. Jika dilihat dari nilai varians, penduga HB *Lognormal* memiliki varians yang lebih rendah dibandingkan penduga langsung, tetapi masih lebih tinggi daripada penduga EBLUP-FH dan penduga SEBLUP-FH.

Dari hasil tersebut menunjukkan bahwa karakteristik sebaran data penduga HB *Lognormal* cenderung lebih mirip dengan penduga langsung. Namun, untuk mengetahui tingkat kesamaan nilai dengan penduga langsung secara statistik, maka diperlukan pengukuran korelasi Kendall-Tau dan signifikansinya antara tiga model penduga SAE dengan penduga langsung. Berikut ini ditampilkan nilai korelasi dan signifikansinya antara tiga model penduga SAE dengan penduga langsung.

Tabel 24. Nilai korelasi Kendall-Tau dan hasil signifikansinya antara tiga model penduga SAE dengan penduga langsung

Model penduga SAE	Nilai korelasi	P-value	Keterangan
(1)	(2)	(3)	(4)
EBLUP-FH	0,8492	$P < 0,0001$	Signifikan
SEBLUP-FH	0,8502	$P < 0,0001$	Signifikan
HB <i>Lognormal</i>	0,9334	$P < 0,0001$	Signifikan

Tabel 24 menampilkan nilai korelasi dari tiga model penduga SAE dengan penduga langsung. Penduga HB *Lognormal* memiliki nilai korelasi tertinggi yaitu sebesar 0,9334. Sedangkan nilai korelasi pada penduga EBLUP-FH dan SEBLUP-FH berturut-turut sebesar 0,8492 dan 0,8502. Hasil tersebut menunjukkan bahwa penduga HB *Lognormal* memiliki karakteristik nilai yang paling mendekati penduga langsung dibandingkan dengan penduga EBLUP-FH dan penduga SEBLUP-FH. Kemudian, untuk mengetahui tingkat keakuratan hasil estimasi dari empat penduga, maka dilakukan perbandingan nilai korelasi terhadap data konsumsi listrik per kapita pelanggan rumah tangga dari PT. PLN sebagai nilai parameter populasi. Selain itu, perbandingan nilai RSE atau RRMSE juga dilakukan sebagai ukuran evaluasi model dari metode pendugaan langsung dan metode SAE yang digunakan sehingga diperoleh metode estimasi yang terbaik.

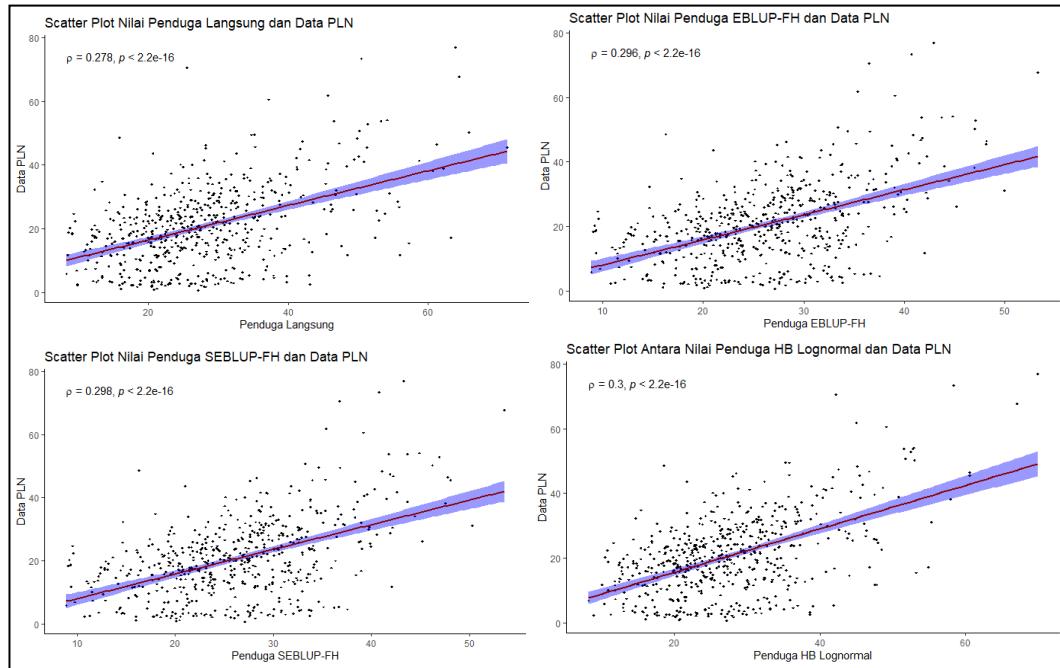
4.4 Evaluasi Model

Proses evaluasi model dilakukan dengan melihat tingkat akurasi hasil estimasi menggunakan ukuran RSE atau RRMSE dari setiap model pendugaan. Pada bagian 4.1 sebelumnya telah dihitung dan didapatkan nilai RSE dari penduga langsung. Sementara itu, pada bagian 4.3 juga turut dihitung dan diperoleh nilai RRMSE dari tiga model penduga SAE, yaitu penduga EBLUP-FH, penduga SEBLUP-FH, dan penduga HB *Lognormal*. Setelah itu dilakukan perbandingan terhadap nilai RSE atau RRMSE dari setiap model pendugaan agar diketahui metode yang terbaik dalam mengurangi *error* pada nilai estimasi. Selain itu, perbandingan terhadap nilai parameter populasi dilakukan dengan menggunakan nilai konsumsi listrik per kapita dari data PT. PLN. Hal tersebut bertujuan untuk mengetahui kedekatan nilai hasil estimasi dari empat model pendugaan terhadap nilai parameter populasi menggunakan perbandingan nilai korelasi Kendall-Tau.

Perbandingan Hasil Estimasi Terhadap Nilai Populasi

Data konsumsi listrik per kapita (KWh/Kapita) dari PT. PLN digunakan sebagai nilai parameter populasi yang dibandingkan dengan hasil estimasi dari empat model pendugaan. Data tersebut terdiri atas nilai penggunaan listrik (dalam KWh) seluruh pelanggan rumah tangga di Provinsi Jawa Tengah selama 6 bulan dari Bulan April hingga September 2022. Nilai penggunaan listrik selama 6 bulan tersebut dihitung rata-ratanya dan kemudian dijumlahkan dari seluruh pelanggan rumah tangga pada setiap kecamatan di Provinsi Jawa Tengah. Setelah itu, total dari nilai rata-rata penggunaan listrik selama 6 bulan dari setiap kecamatan tersebut dibagi dengan jumlah penduduk pertengahan tahun pada setiap kecamatan terkait.

Kemudian, untuk melihat kedekatan nilai estimasi dari empat model pendugaan terhadap nilai parameter populasi, berikut ini ditampilkan masing-masing *scatter plot* nilai populasi dan hasil estimasi dari empat model pendugaan disertai dengan nilai korelasi Kendall-Tau.



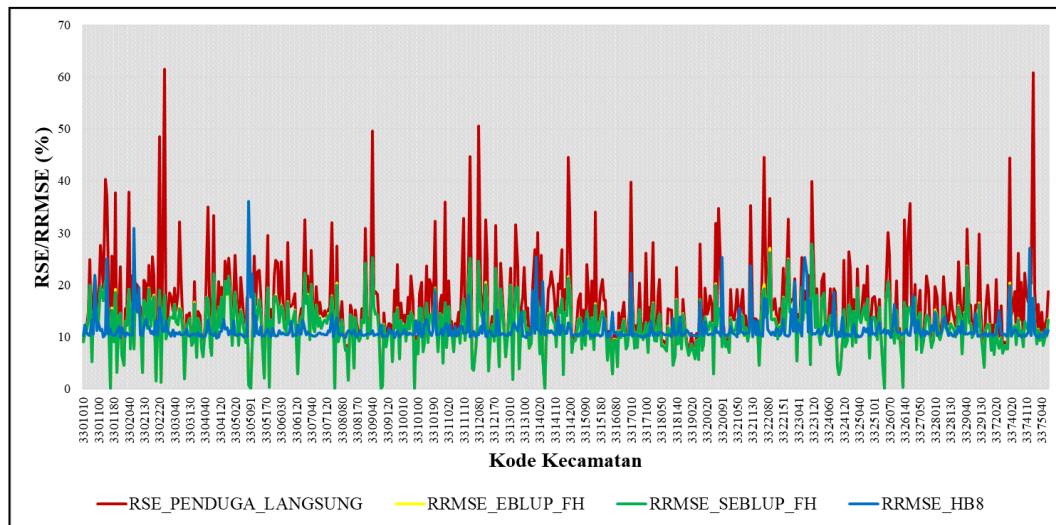
Sumber: PT. PLN, Susenas Maret 2021, sumber *big data*, dan Podes 2021, diolah
 Gambar 20. *Scatter plot* dan nilai korelasi Kendall-Tau antara nilai populasi konsumsi listrik per kapita dan hasil estimasi dari empat model pendugaan

Gambar 20 ditampilkan masing-masing *scatter plot* dan nilai korelasi Kendall-Tau antara nilai konsumsi listrik per kapita dari data PLN dan hasil estimasi dari empat model pendugaan. Secara umum, nilai korelasi Kendall-Tau antara penduga langsung dengan data PLN sangat rendah. Hal ini menunjukkan bahwa data konsumsi listrik per kapita ruta yang dikumpulkan dari Susenas belum dapat merepresentasikan nilai populasi dengan baik. Meskipun sebenarnya tiga model penduga SAE sudah dapat memperbaiki nilai estimasi dari penduga langsung, tetapi belum ada perbedaan besar yang signifikan. Namun, berdasarkan

kedekatan nilai antara data konsumsi listrik per kapita dari PT. PLN dengan hasil estimasi, penduga HB *Lognormal* memiliki nilai korelasi Kendall-Tau tertinggi dibandingkan dengan penduga langsung, penduga EBLUP-FH, dan SEBLUP-FH. Oleh sebab itu, penduga HB *Lognormal* dapat dikatakan memiliki nilai estimasi yang paling mendekati dengan nilai populasi sebenarnya. Selanjutnya dilakukan perbandingan terhadap nilai RSE atau RRMSE untuk melihat tingkat akurasi hasil estimasi dari empat model pendugaan sehingga didapatkan metode estimasi yang terbaik dalam meminimalisasi *error*.

Pemilihan Metode Terbaik: *Relative Standard Error* (RSE) atau *Relative Root Mean Squared Error* (RRMSE)

Ukuran evaluasi dengan *relative standard error* (RSE) digunakan untuk mengetahui tingkat akurasi dari suatu estimator. Ukuran ini digunakan oleh BPS di dalam proses estimasi data dari kegiatan survei seperti Susenas. Informasi mengenai ukuran RSE ini penting untuk mempertimbangkan penggunaan estimasi statistik bagi pengguna data. Oleh sebab itu, penelitian ini juga menghitung nilai RSE untuk mengukur tingkat akurasi hasil estimasi dari model pendugaan yang digunakan. Berikut ini ditampilkan perbandingan nilai RSE atau RRMSE dari empat model pendugaan menggunakan visualisasi *line chart* di bawah ini.



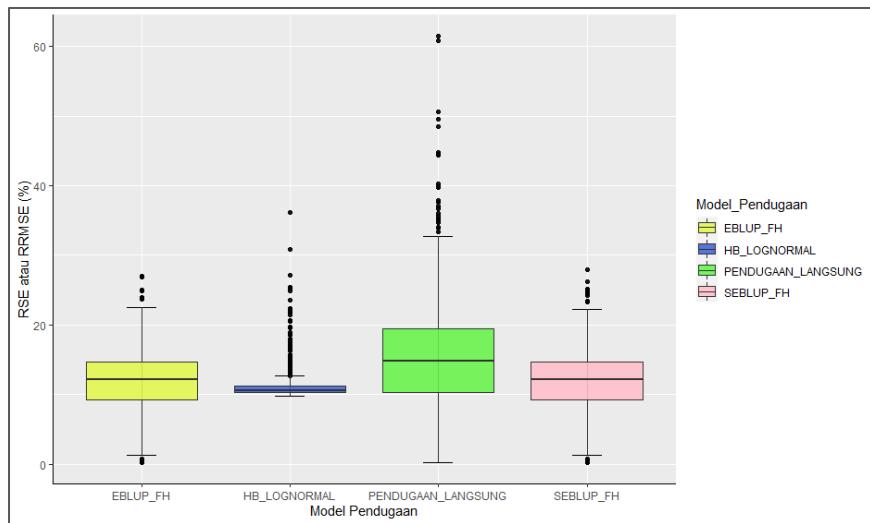
Sumber: Susenas Maret 2021, sumber *big data*, dan Podes 2021, diolah

Gambar 21. Perbandingan nilai RSE atau RRMSE dari empat model pendugaan

Gambar 21 menampilkan grafik perbandingan nilai RSE atau RRMSE dari empat penduga, yaitu penduga langsung, penduga EBLUP-FH, penduga SEBLUP-FH, dan penduga HB *Lognormal*. Dari gambar tersebut terlihat bahwa sebagian besar nilai RSE dari penduga langsung lebih tinggi dibandingkan tiga model penduga SAE. Nilai RRMSE dari penduga EBLUP-FH dan SEBLUP-FH relatif sama karena nilai yang ditunjukkan pada grafik tampak berhimpitan, tetapi keduanya yang jelas memiliki nilai yang lebih rendah dibandingkan nilai RSE penduga langsung. Sementara itu, penduga HB *Lognormal* memiliki nilai RRMSE yang cenderung paling rendah dibandingkan model pendugaan yang lain. Namun, untuk mengetahui lebih rincinya dapat dilihat pada tabel nilai RSE atau RRMSE dari empat model pendugaan di Lampiran 2.

Tabel nilai RSE atau RRMSE pada Lampiran 2 dapat ditemukan tujuh observasi (kecamatan) yang memiliki nilai RSE atau RRMSE = 0 pada penduga langsung, EBLUP-FH, dan SEBLUP-FH. Hal ini disebabkan karena tujuh observasi tersebut memiliki varians dan *standard error* bernilai nol pada penduga

langsung. Namun, penduga HB *Lognormal* tetap dapat menghasilkan nilai estimasi RRMSE dari tujuh observasi tersebut. Untuk melihat sebaran nilai RSE atau RRMSE dari setiap model pendugaan, berikut ini disajikan gambar *box plot*.



Sumber: Susenas Maret 2021, sumber *big data*, dan Podes 2021, diolah

Gambar 22. *Box plot* nilai RSE atau RRMSE hasil estimasi dari setiap model pendugaan tanpa melibatkan tujuh observasi yang memiliki nilai SE = 0 pada penduga langsung

Nilai RRMSE dari penduga HB *Lognormal* yang ditunjukkan pada Gambar 22 di atas memiliki lebih banyak *outlier* dibandingkan nilai RRMSE dari penduga EBLUP-FH dan SEBLUP-FH. Akan tetapi, *range* nilai RRMSE penduga HB *Lognormal* yang ditunjukkan dari panjang *box* dan *whisker*-nya tampak lebih pendek dibandingkan penduga EBLUP-FH dan SEBLUP-FH. Hal ini menunjukkan bahwa nilai RRMSE penduga HB *Lognormal* cenderung lebih homogen. Selain itu, nilai median RRMSE penduga HB *Lognormal* paling rendah di antara penduga EBLUP-FH dan SEBLUP-FH yang ditunjukkan dari posisi garis tengah pada *box*. Nilai median RRMSE penduga HB *Lognormal* diketahui sebesar 10,55%. Kemudian, nilai median RRMSE penduga EBLUP-FH dan SEBLUP-FH berturut-

turut yaitu 12,18% dan 12,17%. Sedangkan pada bagian 4.1 sebelumnya telah diketahui bahwa nilai median RSE penduga langsung yaitu sebesar 14,76%. Dari hasil tersebut menunjukkan bahwa tiga model SAE telah berhasil menurunkan nilai RSE dari penduga langsung, di mana model HB *Lognormal* memiliki nilai median RRMSE yang paling rendah. Dengan demikian, kesimpulan yang diperoleh adalah penduga HB *Lognormal* secara berurutan memberikan hasil estimasi yang lebih akurat dibandingkan penduga EBLUP-FH, penduga SEBLUP-FH dan penduga langsung. Meskipun penduga HB *Lognormal* memberikan hasil estimasi yang paling akurat, tetapi untuk menyesuaikan dengan apa yang dilakukan oleh BPS, maka nilai RSE atau RRMSE dari setiap model pendugaan perlu dikategorikan menurut pengelompokan seperti pada Tabel 5. Berikut ini ditampilkan tabulasi jumlah kecamatan melalui pengelompokan nilai RSE berdasarkan kategori yang digunakan oleh BPS dari setiap model pendugaan.

Tabel 25. Jumlah kecamatan menurut kategori nilai RSE dari setiap model pendugaan

Kategori nilai RSE	Jumlah observasi (kecamatan)			
	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)
$RSE = 0\%$	7	7	7	7
$0\% < RSE \leq 25\%$	500	561	561	559
$25\% < RSE \leq 50\%$	62	4	4	6
$RSE > 50\%$	3	0	0	0

Tabel 25 menampilkan jumlah kecamatan menurut kategori nilai RSE atau RRMSE berdasarkan empat model pendugaan. Dari tabel tersebut dapat dilihat bahwa pada penduga langsung masih terdapat 62 kecamatan yang memiliki nilai RSE di antara 25% hingga 50%, serta 3 kecamatan dengan nilai RSE lebih dari 50%. Sementara itu, penduga EBLUP-FH, penduga SEBLUP-FH, dan penduga HB

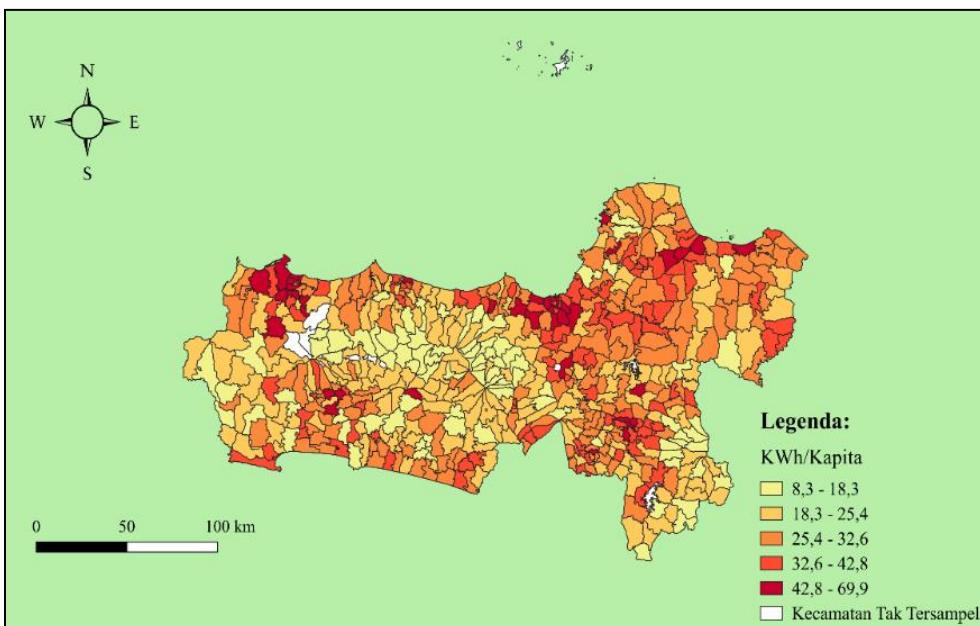
Lognormal dapat menguranginya menjadi lebih sedikit. Penduga EBLUP-FH dan SEBLUP-FH masih terdapat 4 kecamatan yang memiliki nilai RSE di antara 25% hingga 50%. Sedangkan, penduga HB *Lognormal* terdapat 6 kecamatan dengan nilai RSE di antara 25% hingga 50%. Meskipun nilai median RRMSE dari penduga HB *Lognormal* paling kecil di antara penduga yang lain, tetapi jumlah kecamatan dengan RSE > 25% lebih banyak daripada penduga EBLUP-FH dan SEBLUP-FH.

Setelah melakukan evaluasi model, tiga model penduga SAE secara umum telah memberikan hasil estimasi yang lebih baik dari penduga langsung. Namun dari tiga model penduga SAE tersebut, model SAE HB *Lognormal* merupakan metode yang terbaik dalam mengestimasi nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021 berdasarkan hasil evaluasi model pada bagian sebelumnya. Penduga HB *Lognormal* memiliki nilai korelasi Kendall-Tau yang paling tinggi terhadap penduga langsung yaitu sebesar 0,9334 dibandingkan model SAE yang lain. Selain itu, penduga HB *Lognormal* juga memiliki nilai korelasi Kendall-Tau tertinggi terhadap nilai populasi konsumsi listrik per kapita yaitu sebesar 0,3 di antara penduga yang lain. Meskipun masih terdapat 6 kecamatan yang memiliki nilai RSE > 25%, tetapi penduga HB *Lognormal* memiliki nilai median RRMSE yang paling rendah dibandingkan dengan nilai median RRMSE dari penduga langsung, EBLUP-FH, dan SEBLUP-FH. Oleh sebab itu, model SAE HB *Lognormal* merupakan metode yang paling optimal dalam menurunkan RSE hasil estimasi dari metode pendugaan langsung dan berusaha mempertahankan karakteristik nilai yang diestimasinya untuk meminimalkan kehilangan informasi dari data sampel yang digunakan. Selain itu, penduga HB *Lognormal* juga memiliki karakteristik nilai yang paling mendekati

nilai populasi sebenarnya yang direpresentasikan dengan data konsumsi listrik per kapita dari PT. PLN. Dengan demikian, model SAE HB *Lognormal* dipilih sebagai metode terbaik sehingga hasil estimasinya dijadikan sebagai dasar pemetaan kewilayahan untuk menggambarkan sebaran spasial pada nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021.

4.5 Pemetaan Hasil Estimasi Metode Terbaik

Model SAE HB *Lognormal* telah dipilih sebagai metode terbaik berdasarkan hasil evaluasi model. Oleh sebab itu, nilai penduga HB *Lognormal* digunakan untuk membuat peta tematik dari nilai estimasi rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021. Berikut ini ditampilkan peta tematik nilai estimasi rata-rata konsumsi listrik per kapita ruta untuk 572 kecamatan menggunakan penduga HB *Lognormal*. Wilayah kecamatan yang tidak menjadi sampel penelitian tidak memiliki nilai penduga HB *Lognormal* sehingga ditandai dengan warna putih pada peta.



Sumber: Susenas Maret 2021, sumber *big data*, dan Podes 2021, diolah

Gambar 23. Peta tematik nilai estimasi rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021 dengan metode SAE Pendekatan *Hierarchical Bayes Lognormal*

Gambar 23 menunjukkan bahwa tingkat rata-rata konsumsi listrik per kapita ruta untuk level kecamatan di Provinsi Jawa Tengah tahun 2021 sebagian besar berada pada rentang nilai antara 18,3 hingga 25,4 KWh/Kapita yaitu berjumlah 176 kecamatan. Adapun kelompok dengan nilai rata-rata konsumsi listrik per kapita ruta antara 25,4 hingga 32,6 KWh/Kapita berjumlah 167 kecamatan. Kemudian, terdapat 90 kecamatan memiliki nilai rata-rata konsumsi listrik per kapita ruta dengan rentang 8,3 hingga 18,3 KWh/Kapita dan 98 kecamatan memiliki nilai rata-rata konsumsi listrik per kapita ruta di antara 32,6 sampai dengan 42,8 KWh/Kapita. Sisanya, terdapat 43 kecamatan memiliki rata-rata konsumsi listrik per kapita ruta dengan nilai antara 42,8 sampai dengan 69,9 KWh/Kapita. Sedangkan, wilayah kecamatan dengan nilai rata-rata konsumsi listrik per kapita ruta tertinggi yaitu Kecamatan Gajah Mungkur dengan 69,91 KWh/Kapita.

dengan nilai rata-rata konsumsi listrik per kapita ruta paling rendah yaitu Kecamatan Petungkriono dengan 8,26 KWh/Kapita.

Apabila dilihat berdasarkan kategori dengan rentang nilai terendah, kecamatan yang masuk pada kategori tersebut sebagian besar berada di wilayah kabupaten, seperti Kabupaten Temanggung dan Kabupaten Karanganyar. Wilayah kabupaten pada umumnya dihuni oleh masyarakat yang mayoritas bertempat tinggal di daerah perdesaan. Sementara itu, masyarakat yang tinggal di perdesaan memiliki tingkat kesejahteraan yang lebih rendah dalam hal memenuhi kebutuhan non makanan dibandingkan dengan masyarakat yang tinggal di perkotaan. Fakta tersebut didasarkan dari publikasi Badan Pusat Statistik (BPS) yang menunjukkan bahwa rata-rata pengeluaran per kapita bukan makanan di perdesaan lebih rendah dibandingkan di perkotaan pada tahun 2021 di Provinsi Jawa Tengah. BPS mencatat nilai rata-rata pengeluaran per kapita bukan makanan bagi masyarakat perkotaan sebesar 960.519 rupiah, sedangkan masyarakat perdesaan sebesar 476.770 rupiah. Jadi, kecamatan yang memiliki nilai rata-rata konsumsi listrik per kapita ruta yang rendah diidentifikasi sebagian besar berada di daerah perdesaan dengan tingkat kesejahteraan masyarakatnya yang relatif rendah.

Di sisi lain, kecamatan dengan kategori nilai rata-rata konsumsi listrik per kapita ruta tertinggi yaitu di antara 42,8 hingga 69,9 KWh/Kapita sebagian besar berada di wilayah kota, seperti Kota Semarang, Kota Tegal, dan Kota Surakarta. Wilayah tersebut berasosiasi dengan karakteristik masyarakatnya yang tinggal di perkotaan. Seperti yang telah dijelaskan sebelumnya bahwa tingkat kesejahteraan masyarakat di perkotaan lebih tinggi dibandingkan dengan masyarakat di perdesaan. Dengan demikian, kecamatan-kecamatan dengan nilai rata-rata

konsumsi listrik per kapita ruta yang tinggi diidentifikasi sebagian besar berada di daerah perkotaan dengan tingkat kesejahteraan masyarakatnya yang relatif tinggi.

Keberadaan energi listrik merupakan aspek penting dalam menunjang kegiatan produktif bagi masyarakat. Data terkait konsumsi energi listrik dinilai dapat bermanfaat bagi pemerintah. Hasil estimasi dari penduga HB *Lognormal* dapat menjadi bahan pertimbangan bagi pemerintah, khususnya PT. PLN dan Kementerian ESDM dalam menentukan kebijakan terkait pengadaan energi listrik yang efektif dan efisien. Hal ini terkait dengan upaya preventif untuk meminimalisasi kelebihan terhadap pasokan energi listrik yang dapat merugikan negara. Meskipun hasil estimasi yang diberikan belum dapat merepresentasikan nilai populasi sebenarnya secara akurat, tetapi model SAE HB *Lognormal* sudah berhasil memperbaiki kualitas estimasi dari data sampel Susenas.

Hasil estimasi rata-rata konsumsi listrik per kapita ruta dapat dijadikan salah satu indikator yang menggambarkan tingkat kesejahteraan masyarakat dalam memenuhi kebutuhan hidup sehingga memberikan referensi baru bagi penelitian lain yang membahas tentang studi kemiskinan. Selain itu, hasil estimasi tersebut dapat digunakan untuk mengkaji dan mengevaluasi tingkat kualitas infrastruktur kelistrikan, terutama di wilayah kecamatan dengan tingkat rata-rata konsumsi listrik per kapita ruta yang rendah. Dengan demikian, upaya peningkatan infrastruktur kelistrikan di wilayah tersebut diharapkan mampu mengurangi sisa pasokan listrik yang berlebih akibat pemanfaatannya yang belum optimal sehingga dialihkan dan dimanfaatkan untuk kebutuhan masyarakat.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil dan pembahasan yang telah dijelaskan sebelumnya, hal-hal yang dapat dijadikan kesimpulan dalam penelitian ini adalah sebagai berikut.

1. Nilai rata-rata penduga langsung untuk 572 kecamatan di Provinsi Jawa Tengah tahun 2021 sebesar 27,604 KWh/Kapita. Artinya, tingkat konsumsi listrik tiap penduduk di Provinsi Jawa Tengah tahun 2021 sebesar 27,604 KWh. Adapun wilayah kecamatan yang memiliki nilai rata-rata konsumsi listrik per kapita ruta yang tinggi sebagian besar berada di daerah perkotaan, meliputi Kota Semarang, Kota Surakarta, dan Kota Tegal. Sedangkan, wilayah kecamatan yang memiliki nilai rata-rata konsumsi listrik per kapita ruta yang rendah sebagian besar cenderung menempati wilayah perdesaan yang banyak dijumpai di Kabupaten Wonosobo, Kabupaten Banjarnegara, dan Kabupaten Temanggung. Selain itu diperoleh juga nilai rata-rata dan median dari RSE penduga langsung berturut-turut sebesar 15,96% dan 14,76% dengan kategori akurat.
2. Estimasi tak langsung dengan metode SAE dilakukan dengan menggunakan tiga model, yaitu EBLUP-FH, SEBLUP-FH, dan HB *Lognormal*. Penduga HB *Lognormal* memiliki karakteristik nilai yang paling mendekati nilai penduga langsung dibandingkan dengan penduga EBLUP-FH dan penduga SEBLUP-FH. Hal tersebut ditunjukkan berdasarkan hasil perbandingan statistik deskriptif dan nilai korelasi Kendall-Tau dari masing-masing penduga SAE dengan penduga langsung.

3. Hasil evaluasi model secara umum menunjukkan bahwa penduga EBLUP-FH, SEBLUP-FH, dan HB *Lognormal* memberikan hasil estimasi yang lebih baik daripada penduga langsung. Namun dari tiga model penduga SAE tersebut, penduga HB *Lognormal* memiliki nilai korelasi Kendall-Tau tertinggi terhadap nilai populasi konsumsi listrik per kapita ruta yaitu sebesar 0,3. Selain itu, penduga SAE HB *Lognormal* memiliki nilai median RRMSE terendah dibandingkan dengan penduga langsung, EBLUP-FH, dan SEBLUP-FH yaitu sebesar 10,55%. Oleh sebab itu, model SAE HB *Lognormal* merupakan metode terbaik dalam mengestimasi nilai rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021.
4. Hasil pemetaan dengan nilai penduga HB *Lognormal* menunjukkan bahwa tingkat rata-rata konsumsi listrik per kapita ruta level kecamatan di Provinsi Jawa Tengah tahun 2021 sebagian besar berada pada rentang nilai antara 18,3 hingga 25,4 KWh/kapita dengan 176 kecamatan. Kecamatan Gajah Mungkur merupakan kecamatan dengan nilai rata-rata konsumsi listrik per kapita ruta tertinggi yaitu sebesar 69,91 KWh/Kapita. Sedangkan, wilayah kecamatan dengan nilai rata-rata konsumsi listrik per kapita ruta terendah yaitu Kecamatan Petungkriono dengan 8,26 KWh/Kapita. Wilayah kecamatan yang memiliki nilai rata-rata konsumsi listrik per kapita ruta yang rendah diidentifikasi sebagian besar berada di daerah perdesaan dengan tingkat kesejahteraan masyarakatnya yang relatif rendah. Di sisi lain, wilayah kecamatan yang memiliki nilai rata-rata konsumsi listrik per

kapita ruta yang tinggi diidentifikasi sebagian besar berada di daerah perkotaan dengan tingkat kesejahteraan masyarakatnya yang relatif tinggi.

5.2 Saran

Berdasarkan kesimpulan yang telah dijabarkan, maka beberapa saran yang dapat dijadikan rekomendasi dari penelitian ini adalah sebagai berikut:

1. BPS dapat mempertimbangkan penggunaan sumber *big data* dan data *official statistics* lain untuk menghasilkan estimasi pada level area kecil menggunakan metode *Small Area Estimation* terkait indikator-indikator strategis pembangunan dalam mendukung kebijakan pemerintah. Jika dikaitkan dengan penelitian ini, maka BPS diharapkan dapat mengintegrasikan pemanfaatan sumber *big data* dan data Podes sebagai komponen variabel penyerta dalam penggunaan model SAE HB *Lognormal* untuk mengestimasi indikator lain yang berbentuk rata-rata dan bernilai rill positif, seperti pada indikator rata-rata konsumsi listrik per kapita rumah tangga. Metode ini terbukti dapat memberikan hasil estimasi yang lebih akurat dan presisi dibandingkan dengan metode pendugaan langsung pada level kecamatan sehingga dapat digunakan sebagai bahan perbaikan metode estimasi dari Susenas ke depannya.
2. Bagi PT. PLN dan Kementerian ESDM, hasil estimasi dari penduga HB *Lognormal* dapat dijadikan sebagai bahan informasi terkait wilayah kecamatan yang masih memerlukan dukungan infrastruktur kelistrikan yang lebih memadai sehingga pemanfaatan energi listrik dapat terserap dengan baik dan dimanfaatkan untuk kebutuhan masyarakat sekitar. Hal ini

berkaitan dengan pasokan listrik nasional yang selalu *oversupply* selama periode tahun 2012-2021 berdasarkan laporan statistik PLN 2021 yang dapat memicu kerugian bagi negara dan perusahaan dalam jangka panjang.

3. Beberapa saran yang dapat direkomendasikan bagi penelitian selanjutnya yaitu diharapkan mampu menerapkan model SAE HB yang dapat memasukkan pengaruh spasial dan mengakomodasi kondisi data yang tidak berdistribusi normal. Dalam studi kasus penelitian ini, maka penelitian selanjutnya dapat mengembangkan model SAE *Spatial HB Lognormal* dengan mempertimbangkan adanya pengaruh spasial dan mengakomodasi bentuk distribusi data dari variabel *interest*. Kemudian, jika dibutuhkan untuk mengestimasi pada level area yang lebih kecil, maka penelitian selanjutnya disarankan dapat melakukan estimasi nilai rata-rata konsumsi listrik per kapita ruta pada level desa sehingga dapat dimanfaatkan sebagai salah satu indikator dalam melihat tingkat pembangunan dan kesejahteraan penduduk desa.

DAFTAR PUSTAKA

- Adil, A., & Kom, S. (2017). *Sistem Informasi Geografis*. Penerbit Andi.
- Agresti, A., & Finlay, B. (1997). *Statistical methods for the social sciences*. New Jersey, Upper Saddle River: Prentice-Hall. 541pp.
- Anselin, L., & Bera, A. K. (1998). Spatial dependence in linear regression models with an introduction to spatial econometrics. *Statistics Textbooks and Monographs*, 155, 237–290.
- Apriliansyah, A., & Wulansari, I. Y. (2021). Application of Spatial Empirical Best Linear Unbiased Prediction (SEBLUP) of Open Unemployment Rate on Sub-District Level Estimation in Banten Province. *Proceedings of The International Conference on Data Science and Official Statistics*, 2021(1), 905–913.
- Arifin, M. Z. (2021). *Produksi Energi Listrik di Jateng hingga November 2021 Alami Surplus*. Tribun Jateng. <https://pantura.tribunnews.com/2021/12/22/produksi-energi-listrik-di-jateng-hingga-november-2021-alami-surplus>
- Ayuningtyas, U., Yani, M., & Maimunah, S. (2020). Emisi Gas Rumah Kaca Penggunaan Listrik pada Kereta Rel Listrik Jabodetabek dengan Metode Life Cycle Assessment. *Jurnal Standardisasi*, 22(2), 95–106.
- Bain, L. J., & Engelhardt, M. (1987). *Introduction to Probability and Mathematical Statistics*. Brooks. Cole.
- Bain, L. J., & Engelhardt, M. (1992). *Introduction to probability and mathematical statistics* (Vol. 4). Duxbury Press Belmont, CA.
- BPS. (n.d.-a). *Kepadatan Penduduk*. Situs Web BPS. Retrieved January 2, 2023, from <https://www.bps.go.id/index.php/istilah/index?Istilah%5Bkatacarian%5D=kepadatan+penduduk&yt0=Tampilkan>
- BPS. (n.d.-b). *Konsumsi Listrik per Kapita*. Metadata Indikator. Retrieved January 12, 2023, from https://www.bps.go.id/indikator/indikator/view_data/0000/data/1156/sdgs_7/1

- BPS. (2009). *Analisis Gabungan Hasil Survei MDGs Kecamatan*.
- BPS. (2021a). Berita resmi statistik. *Bps.Go.Id*, 27, 1–52. <https://www.bps.go.id/pressrelease/2021/01/21/1854/hasil-sensus-penduduk-2020.html>
- BPS. (2021b). *Buku Pedoman Kepala BPS Provinsi, Statistisi Ahli Madya/Koordinator Fungsi Statistik Sosial BPS Provinsi, dan Kepala BPS Kabupaten/Kota Susenas Maret 2021*.
- Callanan, T. P. (1985). *Restricted maximum likelihood estimation of variance components: computational aspects*. Iowa State University.
- Casella, G., & George, E. I. (1992). Explaining the Gibbs sampler. *The American Statistician*, 46(3), 167–174.
- Chakravarti, I. M., Laha, R. G., & Roy, J. (1967). Handbook of methods of applied statistics. *Wiley Series in Probability and Mathematical Statistics (USA) Eng*.
- Chang, K.-T. (2019). *Introduction to geographic information systems 9th edition*. McGraw-Hill Higher Education Boston. <https://doi.org/10.32473/edis-fr356-2012>
- Chen, H., Chiang, R. H. L., & Storey, V. C. (2012). Business Intelligence and Analytics: From Big Data to Big Impact. *MIS Quarterly*, 1165–1188.
- Cheng, L., Feng, R., Wang, L., Yan, J., & Liang, D. (2022). *An Assessment of Electric Power Consumption Using Random Forest and Transferable Deep Model with Multi-Source Data. March*. <https://doi.org/10.3390/rs14061469>
- Chi, G., Fang, H., Chatterjee, S., & Blumenstock, J. E. (2022). Microestimates of wealth for all low-and middle-income countries. *Proceedings of the National Academy of Sciences*, 119(3), e2113658119.
- Conover, W. J. (1999). *Practical nonparametric statistics* (Vol. 350). john wiley & sons.
- Copernicus. (2017). *Sentinel-5P*. The European Space Agency. <https://sentinels.copernicus.eu/web/sentinel/missions/sentinel-5p>
- Cressie, N. (1994). Statistics for Spatial Data, Revised Edition. *Biometrics*, 50(1), 319. <https://doi.org/10.2307/2533238>
- Draper, N. R., & Smith, H. (1998). *Applied Regression Analysis* (Vol. 326). John Wiley & Sons.

- Du, Y., Xu, X., Chu, M., Guo, Y., & Wang, J. (2016). Air particulate matter and cardiovascular disease: the epidemiological, biomedical and clinical evidence. *Journal of Thoracic Disease*, 8(1), E8.
- Dubin, R., Fotheringham, A. S., & Rogerson, P. A. (2009). Spatial Weights. *The Sage Handbook of Spatial Analysis*, 125–158.
- Elvidge, C. D., Zhizhin, M., Hsu, F.-C., & Baugh, K. E. (2013). VIIRS nightfire: Satellite pyrometry at night. *Remote Sensing*, 5(9), 4423–4449.
- Eom, J., Hyun, M., Lee, J., & Lee, H. (2020). Increase in household energy consumption due to ambient air pollution. *Nature Energy*, 5(12), 976–984.
- European Space Agency. (n.d.). *User Guides - Sentinel-2 MSI Overview - Sentinel Online - Sentinel*. Retrieved January 12, 2023, from <https://sentinel.esa.int/web/sentinel/us%0Aer-guides/sentinel-2-msi/overview>
- Everitt, B. S., & Skrondal, A. (2010). *The Cambridge dictionary of statistics*.
- Facebook's Data For Good. (2023). *Tutorial: Calculating Population Weighted Relative Wealth Index*. Meta. <https://dataforgood.facebook.com/dfg/docs/tutorial-calculating-population-weighted-relative-wealth-index>
- Fadhilah, A. E. (2022). *Hubungan Kausalitas antara Konsumsi Listrik, Pertumbuhan Ekonomi, Ketimpangan dan Kemiskinan di Indonesia Tahun 1971–2019*. UNS (Sebelas Maret University).
- Faisal, K., Shaker, A., & Habbani, S. (2016). Modelling the Relationship between the Gross Domestic Product and Built-Up Area Using Remote Sensing and GIS Data: A Case Study of Seven Major Cities in Canada. *ISPRS International Journal of Geo-Information*, 5(3), 23.
- Faltys, O., Hobza, T., & Morales, D. (2022). Small area estimation under area-level generalized linear mixed models. *Communications in Statistics-Simulation and Computation*, 51(12), 7404–7426.
- Ferguson, R., Wilkinson, W., & Hill, R. (2000). Electricity use and economic development. *Energy Policy*, 28(13), 923–934.
- Gandomi, A., & Haider, M. (2015). Beyond the hype: Big data concepts, methods, and analytics. *International Journal of Information Management*, 35(2), 137–144.

- Gao, X., Wu, M., Gao, J., Han, L., Niu, Z., & Chen, F. (2022). Modelling Electricity Consumption in Cambodia Based on Remote Sensing Night-Light Images. *Applied Sciences (Switzerland)*, 12(8). <https://doi.org/10.3390/app12083971>
- Ghosh, M., & Rao, J. N. K. (1994). Small Area Estimation: An Appraisal. *Statistical Science*, 9(1), 55–76.
- Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., & Moore, R. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202, 18–27.
- Gumpili, S., & Das, A. (2022). Sample size and its evolution in research. *IHOPE Journal of Ophthalmology*, 1, 9–13. https://doi.org/10.25259/IHOPEJO_3_2021
- Gustiawan, R. (2022). *Pemanfaatan Big Data dan Deep Learning dalam Menduga Pengeluaran per Kapita di Tingkat Kecamatan Menggunakan Small Area Estimation (SAE)*. 1–15.
- Hajarisman, N. (2013). *Pemodelan Area Kecil untuk menduga angka kematian bayi melalui pendekatan model regresi Poisson bayes berhirarki dua-level*.
- Harville, D. A. (1974). Bayesian inference for variance components using only error contrasts. *Biometrika*, 61(2), 383–385.
- ICESC. (n.d.). *Scientific Data Sets Local Attributes Global Attributes Quality Assurance MOD11_L2 LST Product*. The Institute for Computational Earth Systems Science. Retrieved February 7, 2023, from https://icess.eri.ucsb.edu/modis/LstUsrGuide/usrguide_mod11.html#sds
- Johnson, N. L., Kemp, A. W., & Kotz, S. (2005). *Univariate discrete distributions* (Vol. 444). John Wiley & Sons.
- Kackar, R. N., & Harville, D. A. (1984). Approximations for standard errors of estimators of fixed and random effects in mixed linear models. *Journal of the American Statistical Association*, 79(388), 853–862.
- Katsoulakos, N. M., & Kalampakos, D. C. (2014). What is the impact of altitude on energy demand? A step towards developing specialized energy policy for mountainous areas. *Energy Policy*, 71, 130–138.
- Kementerian ESDM. (2022). Statistik Ketenagalistrikan Tahun 2021 Edisi No. 35 Tahun Anggaran 2022. *Direktorat Jendral Ketenagalistrikan Kementerian*

Energi Dan Sumber Daya Mineral. Jakarta.

- Kristianto, S. I., & Mudakir, B. (2015). Analisis konsumsi listrik rumah tangga di Kecamatan Tembalang. *Fakultas Ekonomika Dan Bisnis*.
- Kurnia, A., & Notodiputro, K. A. (2007). Pendekatan Generalized Additive Mixed Models. *Jurnal Sains MIPA*, 13(3), 145–151.
<https://jurnal.fmipa.unila.ac.id/sains/article/download/149/pdf>
- Kutner, M. H., Nachtsheim, C. J., & Neter, J. (1983). *Applied Linear Regression Models*.
- Latif Adam. (2016). Dinamika Sektor Kelistrikan Di Indonesia: Kebutuhan Dan Performa Penyediaan. *Jurnal Ekonomi Dan Pembangunan*, 24 no. 1, 29–41.
- Lee, J., & Wong, D. W. S. (2001). *Statistical analysis with ArcView GIS*. John Wiley & Sons.
- LeSage, J. P. (1999). The theory and practice of spatial econometrics. *University of Toledo. Toledo, Ohio*, 28(11), 1–39.
- Letouzé, E., & Jüttig, J. (2015). Official Statistics, Big Data and Human Development. *Data-Pop Alliance White Paper Series*. Data-Pop Alliance, New York.
- Lillesand, T., Kiefer, R. W., & Chipman, J. (2015). *Remote Sensing and Image Interpretation*. John Wiley & Sons.
- Liu, B. (2009). *Hierarchical Bayes estimation and empirical best prediction of small-area proportions*. University of Maryland, College Park.
- Liu, T., He, G., & Lau, A. (2018). Avoidance behavior against air pollution: evidence from online search indices for anti-PM 2.5 masks and air filters in Chinese cities. *Environmental Economics and Policy Studies*, 20, 325–363.
- Luo, P., Zhang, X., Cheng, J., & Sun, Q. (2019). Modeling population density using a new index derived from multi-sensor image data. *Remote Sensing*, 11(22), 2620.
- Lynch, S. M. (2007). *Introduction to applied Bayesian statistics and estimation for social scientists* (Vol. 1). Springer.
- Mauliani, M., Maiyastri, & Diana, R. (2018). Small Area Estimation dengan Pendekatan Hierarchical Bayes (HB) Lognormal. *Jurnal Matematika UNAND*, VII(4), 15–21.

- Morawitz, D. F., Blewett, T. M., Cohen, A., & Alberti, M. (2006). Using NDVI to assess vegetative land cover change in central Puget Sound. *Environmental Monitoring and Assessment*, 114, 85–106.
- Muzayanah, I. F. U., Lean, H. H., Hartono, D., Indraswari, K. D., & Partama, R. (2022). Population density and energy consumption: A study in Indonesian provinces. *Heliyon*, 8(9), e10634.
- Nath, B., Ni-Meister, W., & Choudhury, R. (2021). Impact of urbanization on land use and land cover change in Guwahati city, India and its implication on declining groundwater level. *Groundwater for Sustainable Development*, 12, 100500.
- Ngestrini, R. (2019). *Predicting poverty of a region from satellite imagery using CNNs*.
- Noviani, A. (2016). *Small Area Estimation dengan Pendekatan Hierarchical Bayesian Neural Network Untuk Kasus Anak Putus Sekolah dari Rumah Tangga Miskin di Provinsi Jawa Timur*. Institut Teknologi Sepuluh Nopember.
- Ntzoufras, I. (2011). *Bayesian modeling using WinBUGS*. John Wiley & Sons.
- Ouyang, Z., Fan, P., & Chen, J. (2016). Urban built-up areas in transitional economies of Southeast Asia: Spatial extent and dynamics. *Remote Sensing*, 8(10), 819.
- Pemerintah Indonesia. (1999). Peraturan Pemerintah No. 41 Tahun 1999 Tentang: Pengendalian Pencemaran Udara. In *Lembaran Negara RI* (Vol. 86).
- Pemerintah Indonesia. (2007). Undang-undang Republik Indonesia nomor 40 tahun 2007 tentang perseroan terbatas. In *Sekretariat Negara*.
- Pemerintah Indonesia. (2009). *Undang-Undang Republik Indonesia Nomor 30 Tahun 2009 Tentang Ketenagalistrikan*.
- Perusahaan Listrik Negara. (2021). *Rencana Usaha Penyediaan Tenaga Listrik (RUPTL)* PT PLN (Persero).
https://gatrik.esdm.go.id/assets/uploads/download_index/files/38622-ruptl-pln-2021-2030.pdf
- Perusahaan Listrik Negara (PLN). (2021). *Statistik-PLN-2021-Unaudited-21.2.22*.
<https://web.pln.co.id/statics/uploads/2022/03/Statistik-PLN-2021-Unaudited->

21.2.22.pdf

- Pham, H. T., Marshall, L., Johnson, F., & Sharma, A. (2018). A method for combining SRTM DEM and ASTER GDEM2 to improve topography estimation in regions without reference data. *Remote Sensing of Environment*, 210, 229–241.
- Platnick, S., Meyer, K. G., King, M. D., Wind, G., Amarasinghe, N., Marchant, B., Arnold, G. T., Zhang, Z., Hubanks, P. A., & Holz, R. E. (2016). The MODIS cloud optical and microphysical products: Collection 6 updates and examples from Terra and Aqua. *IEEE Transactions on Geoscience and Remote Sensing*, 55(1), 502–525.
- Porter, D. C., & Gujarati, D. N. (2009). Basic Econometrics. *New York: McGraw-Hill Irwin*.
- Pramana, S. (2021). Implementasi Big Data Pada Sektor Pariwisata. In R. Rusdiah (Ed.), *From Data Science to AI Technology Augmented Human Capability, Knowledge & Application in Indonesia* (p. 238). Perkumpulan Basis Data Indonesia.
- Pramana, S., & Krismawati, D. (2022). Peluang Pemanfaatan Data Geospasial Untuk Kebijakan Publik. In R. Rusdiyah (Ed.), *Future, Benefit, Singularity, and Governance of Technology Data Science, AI, NFT, Cyber Security & Virtual Augmented Metaverse* (pp. 115–122). Perkumpulan Basis Data Indonesia.
- Prasomsup, W., Piyatadsananon, P., Aunphoklang, W., & Boonrang, A. (2020). Extraction technic for built-up area classification in Landsat 8 imagery. *International Journal of Environmental Science and Development*, 11(1), 15–20.
- Pratesi, M., & Salvati, N. (2008). Small area estimation: the EBLUP estimator based on spatially correlated random area effects. *Statistical Methods and Applications*, 17, 113–141.
- Rajeshwari, A., & Mani, N. D. (2014). Estimation of land surface temperature of Dindigul district using Landsat 8 data. *International Journal of Research in Engineering and Technology*, 3(5), 122–126.
- Rao, J. N. K. (2003). *Small Area Estimation*. John Wiley & Sons, Inc.

- Rao, J. N. K., & Molina, I. (2015). *Small Area Estimation*. John Wiley & Sons.
- Saberian, S., Heyes, A., & Rivers, N. (2017). Alerts work! Air quality warnings and cycling. *Resource and Energy Economics*, 49, 165–185.
- Saei, A., & Chambers, R. (2003). *Small area estimation under linear and generalized linear mixed models with time and area effects*.
- Savitz, N. V., & Raudenbush, S. W. (2009). Exploiting spatial dependence to improve measurement of neighborhood social processes. *Sociological Methodology*, 39(1), 151–183.
- Shantika, M. (2010). Multikolinearitas pada analisis regresi linear berganda. *Fak. MIPA Jurusan Matematika, Univ. Tanjungpura*.
- Shi, K., Chen, Y., Yu, B., Xu, T., Yang, C., Li, L., Huang, C., Chen, Z., Liu, R., & Wu, J. (2016). Detecting spatiotemporal dynamics of global electric power consumption using DMSP-OLS nighttime stable light data. *Applied Energy*, 184, 450–463.
- Shi, K., Yu, B., Huang, Y., Hu, Y., Yin, B., Chen, Z., Chen, L., & Wu, J. (2014). Evaluating the ability of NPP-VIIRS nighttime light data to estimate the gross domestic product and the electric power consumption of China at multiple scales: A comparison with DMSP-OLS data. *Remote Sensing*, 6(2), 1705–1724.
- Siegel, S. (1994). Statistik Nonparametrik. In *Jakarta: Gramedia*.
- Siswanting, T. (2013). Geoinformatika pada Kasus Area Kecil dan Penerapannya untuk Mendekripsi Kantong-Kantong Kemiskinan di Jember [Disertasi]. *Bogor: Institut Pertanian Bogor*.
- Stakhovych, S., & Bijmolt, T. H. A. (2009). Specification of spatial models: A simulation study on weights matrices. *Papers in Regional Science*, 88(2), 389–408.
- Sun, Y., Wang, S., Zhang, X., Chan, T. O., & Wu, W. (2021). Estimating local-scale domestic electricity energy consumption using demographic, nighttime light imagery and Twitter data. *Energy*, 226, 120351.
- Thiele, J., & Markussen, B. (2012). Potential of GLMM in modelling invasive spread. *CABI Reviews*, 2012, 1–10.
- Thrane, E., & Talbot, C. (2019). An introduction to Bayesian inference in

- gravitational-wave astronomy: parameter estimation, model selection, and hierarchical models. *Publications of the Astronomical Society of Australia*, 36, e010.
- Tian, Y., Yue, T., Zhu, L., & Clinton, N. (2005). Modeling population density using land cover data. *Ecological Modelling*, 189(1–2), 72–88.
- Tuerlinckx, F., Rijmen, F., Verbeke, G., & De Boeck, P. (2006). Statistical inference in generalized linear mixed models: A review. *British Journal of Mathematical and Statistical Psychology*, 59(2), 225–255. <https://doi.org/10.1348/000711005X79857>
- Ubaidillah, A. (2017). Simultaneous Equation Models for Small Area Estimation. *Bogor, IPB*.
- UNEP. (1997). *World Atlas of Desertification: Second Edition*. <https://wedocs.unep.org/20.500.11822/30300>
- United Nations. (2013). *Statistical and Spatial Frameworks . Standards and Data Infrastructure*. May, 1–11.
- USGS. (2013). *Landsat Provisional Surface Temperature*. LANDSAT MISSION. <https://www.usgs.gov/landsat-missions/landsat-provisional-surface-temperature>
- USGS. (2017). *VIIRS Overview*. Earthdata. <https://lpdaac.usgs.gov/data/get-started-data/collection-overview/missions/s-npp-nasa-viirs-overview/>
- USGS. (2018). *Digital Elevation - Shuttle Radar Topography Mission (SRTM) 1 Arc-Second Global*. Earth Resources Observation and Science (EROS) Center. <https://www.usgs.gov/centers/eros/science/usgs-eros-archive-digital-elevation-shuttle-radar-topography-mission-srtm-1#overview>
- Wasserman, L. (2004). Bayesian Inference. *All of Statistics: A Concise Course in Statistical Inference*, 175–192.
- Waters, N. (2017). Tobler's first law of geography. *The International Encyclopedia of Geography*, 1–13.
- Weisberg, S. (2005). *Applied linear regression* (Vol. 528). John Wiley & Sons.
- Wijayanto, A. W., Komarudin, R., & Pramana, S. (2022). The Utilization of Remote Sensing, Geospatial Big Data, and Artificial Intelligence for Government Policy Making. In R. Rusdiah (Ed.), *Future, Benefit, Singularity*,

and Governance of Technology Data Science, AI, NFT, Cyber Security & Virtual Augmented Metaverse (pp. 225–232). Perkumpulan Basis Data Indonesia.

Zomer, R. J., Xu, J., & Trabucco, A. (2022). Version 3 of the global aridity index and potential evapotranspiration database. *Scientific Data*, 9(1), 409.

LAMPIRAN

Lampiran 1. Hasil estimasi nilai rata-rata konsumsi listrik per kapita ruta level kecamatan dari seluruh model pendugaan

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB-Lognormal
(1)	(2)	(3)	(4)	(5)	(6)	(7)
1	3301010	Dayeuhluhur	23,925	23,253	23,202	23,286
2	3301020	Wanareja	16,129	16,659	16,703	17,208
3	3301030	Majenang	19,803	20,019	19,903	20,282
4	3301040	Cimanggu	20,61	20,297	20,306	20,179
5	3301050	Karangpucung	25,538	21,729	21,505	24,851
6	3301060	Cipari	14,498	14,635	14,639	15,674
7	3301070	Sidareja	29,169	26,950	26,611	28,477
8	3301080	Kedungreja	12,292	14,691	14,679	14,727
9	3301090	Patimuan	17,789	18,873	18,871	18,552
10	3301100	Gandrungmangu	17,459	18,806	18,749	18,730
11	3301110	Bantarsari	17,297	19,039	18,805	16,078
12	3301120	Kawunganten	32,784	25,802	25,597	31,054
13	3301121	Kampung Laut	20,503	19,350	19,545	20,215
14	3301130	Jeruklegi	21,58	23,309	23,068	22,063
15	3301140	Kesugihan	14,426	22,319	22,467	18,080
16	3301150	Adipala	31,838	30,841	30,991	31,855
17	3301160	Maos	42,194	42,194	42,194	40,129
18	3301170	Sampang	30,439	29,915	30,588	30,467
19	3301180	Kroya	28,65	28,878	28,800	30,938
20	3301190	Binangun	30,111	26,990	27,687	29,507
21	3301200	Nusawungu	45,371	44,487	44,494	42,828
22	3301710	Cilacap Selatan	39,629	31,560	31,670	37,000
23	3301720	Cilacap Tengah	32,582	32,197	31,962	32,705
24	3301730	Cilacap Utara	20,661	21,059	21,032	21,790
25	3302010	Lumbir	24,85	24,645	24,642	24,219
26	3302020	Wangon	21,6	22,171	22,248	22,025
27	3302030	Jatilawang	22,017	22,997	23,059	22,755
28	3302040	Rawalo	33,847	27,584	27,580	32,807
29	3302050	Kebasen	23,844	23,885	23,857	24,094
30	3302060	Kemranjen	27,229	25,205	25,106	26,789
31	3302070	Sumpiuh	9,094	9,304	9,323	12,495
32	3302080	Tambak	43,428	27,757	27,145	37,967
33	3302090	Somagede	12,312	13,504	13,678	13,584
34	3302100	Kalibagor	55,89	33,158	32,664	46,304
35	3302110	Banyumas	25,668	24,647	24,535	26,369
36	3302120	Patikraja	26,127	26,089	26,088	26,113
37	3302130	Purwojati	15,037	16,269	16,181	15,948
38	3302140	Ajibarang	15,617	17,546	17,674	16,951
39	3302150	Gumelar	35,245	30,122	30,067	32,722
40	3302160	Pekuncen	31,641	23,740	23,854	29,632
41	3302170	Cilongok	27,226	25,312	25,444	26,490
42	3302180	Karanglewas	20,391	22,508	22,753	21,208
43	3302190	Kedung Banteng	21,677	20,316	20,576	21,415
44	3302200	Baturraden	37,089	36,952	36,948	33,803
45	3302210	Sumbang	28,295	26,928	26,922	27,479
46	3302220	Kembaran	63,242	31,122	29,970	54,884
47	3302230	Sokaraja	19,586	19,608	19,608	21,525
48	3302710	Purwokerto Selatan	30,659	33,230	33,019	31,769
49	3302720	Purwokerto Barat	45,453	32,343	31,531	33,320
50	3302730	Purwokerto Timur	25,341	27,496	27,478	27,318
51	3302740	Purwokerto Utara	25,608	26,979	26,909	26,645
52	3303010	Kemangkon	26,921	27,782	27,563	27,018
53	3303020	Bukateja	26,489	26,537	26,494	26,626
54	3303030	Kejobong	33,864	28,423	28,328	31,840
55	3303040	Pengadegan	25,489	23,092	23,195	24,853
56	3303050	Kaligondang	21,712	22,138	22,222	22,762
57	3303060	Purbalingga	33,703	34,756	34,422	34,486
58	3303070	Kalimanah	46,915	34,542	35,135	44,839

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
59	3303080	Padamara	30,02	28,638	28,964	29,895
60	3303090	Kutasari	19,403	19,713	19,774	19,836
61	3303100	Bojongsari	21,809	21,816	21,816	22,008
62	3303110	Mrebet	18,47	19,548	19,539	19,243
63	3303120	Bobotsari	20,108	20,286	20,202	21,311
64	3303130	Karangreja	16,396	16,352	16,424	16,927
65	3303131	Karangjambu	21,427	20,844	20,868	20,636
66	3303140	Karanganyar	28,768	27,469	27,415	27,740
67	3303141	Kertanegara	21,745	21,244	21,636	21,714
68	3303150	Karangmoncol	22,375	22,212	22,206	22,237
69	3303160	Rembang	25,041	23,260	23,173	24,359
70	3304010	Susukan	27,388	26,861	27,094	27,268
71	3304020	Purwareja Klampok	35,068	33,933	34,199	34,314
72	3304030	Mandiraja	29,735	29,321	29,380	29,222
73	3304040	Purwanegara	25,065	24,859	25,021	25,211
74	3304050	Bawang	17,966	19,737	19,797	18,703
75	3304060	Banjarnegara	52,947	33,153	32,990	48,465
76	3304061	Pagedongan	16,265	16,420	16,447	16,976
77	3304070	Sigaluh	20,536	20,386	20,388	20,321
78	3304080	Madukara	18,759	19,361	19,227	19,051
79	3304090	Banjarmangu	21,845	21,293	21,374	21,545
80	3304100	Wanadadi	22,718	22,593	22,635	22,496
81	3304110	Rakit	24,694	24,338	24,358	23,957
82	3304120	Punggelan	17,875	18,340	18,354	19,059
83	3304130	Karangkobar	12,952	13,219	13,208	14,356
84	3304140	Pagentan	11,936	12,328	12,367	12,776
85	3304150	Pejawaran	11,277	12,129	12,170	12,896
86	3304160	Batur	10,804	11,260	11,147	11,840
87	3304170	Wanayasa	12,061	12,548	12,439	12,439
88	3304180	Kalibening	12,282	12,899	12,844	12,827
89	3304181	Pandanarum	13,925	13,986	13,942	14,290
90	3305010	Ayah	15,836	17,249	17,329	16,976
91	3305020	Buayan	24,261	22,893	22,958	24,047
92	3305030	Puring	25,906	26,171	25,991	26,143
93	3305040	Petanahan	34,376	32,954	32,885	33,396
94	3305050	Klirong	25,883	26,469	26,720	26,172
95	3305060	Buluspesantren	24,905	25,297	25,663	25,074
96	3305070	Ambal	26,78	26,797	26,810	26,703
97	3305080	Mirit	26,67	26,804	26,809	26,890
98	3305081	Bonorowo	22,887	23,481	23,146	23,112
99	3305090	Prembun	9,094	9,097	9,097	14,407
100	3305091	Padureso	11	11,000	11,000	12,666
101	3305100	Kutowinangun	12,359	12,787	12,789	14,976
102	3305110	Alian	25,364	23,903	23,658	25,188
103	3305111	Poncowarno	14,603	15,757	15,840	15,963
104	3305120	Kebumen	30,918	33,608	33,681	31,785
105	3305130	Pejagoan	19,969	20,870	20,818	20,389
106	3305140	Sruweng	19,066	20,641	20,700	19,966
107	3305150	Adimulyo	28,584	28,181	28,207	28,448
108	3305160	Kuwarasan	26,212	26,220	26,220	26,329
109	3305170	Rowokele	17,484	17,879	17,880	18,502
110	3305180	Sempor	17,235	19,693	19,785	18,293
111	3305190	Gombong	36,313	36,311	36,311	35,048
112	3305200	Karanganyar	24,65	23,932	23,901	24,362
113	3305210	Karanggayam	16,68	17,307	17,334	17,658
114	3305220	Sadang	27,372	23,410	23,381	26,314
115	3305221	Karangsambung	20,526	21,297	21,508	20,859
116	3306010	Grabag	26,51	26,395	26,636	26,519
117	3306020	Ngombol	35,575	31,152	30,954	33,782
118	3306030	Purwodadi	30,164	28,454	28,631	29,943
119	3306040	Bagelen	18,229	18,864	18,910	18,776
120	3306050	Kaligesing	22,95	22,044	22,093	22,386
121	3306060	Purworejo	34,16	32,903	32,962	34,824
122	3306070	Banyu Urip	35,132	29,687	30,051	34,156
123	3306080	Bayan	28,667	28,140	28,380	28,666
124	3306090	Kutoarjo	23,755	27,465	27,631	25,635

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
125	3306100	Butuh	32,546	29,741	29,906	31,556
126	3306110	Pituruh	28,071	25,495	25,614	27,246
127	3306120	Kemiri	23,639	23,372	23,364	23,526
128	3306130	Bruno	15,253	15,278	15,282	16,101
129	3306140	Gebang	23,229	22,694	22,589	23,107
130	3306150	Loano	24,272	22,908	22,776	23,760
131	3306160	Bener	12,577	13,064	13,102	13,631
132	3307010	Wadaslintang	31,763	22,922	22,777	29,767
133	3307020	Kepil	20,876	20,160	20,482	20,699
134	3307030	Sapuran	26,308	22,449	22,883	25,085
135	3307031	Kalibawang	18,269	18,061	18,152	18,195
136	3307040	Kaliwiro	24,129	21,442	21,450	20,523
137	3307050	Leksono	21,052	20,642	20,744	20,903
138	3307051	Sukoharjo	19,657	19,339	19,378	19,506
139	3307060	Selomerto	20,301	20,426	20,430	20,393
140	3307070	Kalikajar	25,112	23,761	24,093	24,313
141	3307080	Kertek	30,716	27,972	28,476	29,240
142	3307090	Wonosobo	25,653	27,278	27,583	26,152
143	3307100	Watumalang	20,794	20,112	20,157	20,425
144	3307110	Mojotengah	17,151	17,714	17,720	17,573
145	3307120	Garung	22,297	21,689	21,770	21,701
146	3307130	Kejajar	21,836	20,111	20,352	20,618
147	3308010	Salaman	21,038	21,368	21,530	21,415
148	3308020	Borobudur	17,364	22,435	22,648	18,956
149	3308030	Ngluwar	28,116	27,022	27,314	27,852
150	3308040	Salam	39,062	39,062	39,062	36,427
151	3308050	Srumbung	38,381	24,951	25,530	34,682
152	3308060	Dukun	29,094	27,771	27,946	27,887
153	3308070	Muntilan	34,097	33,412	33,338	33,917
154	3308080	Mungkid	23,22	24,518	24,531	23,901
155	3308090	Sawangan	19,676	19,813	19,778	19,960
156	3308100	Candimulyo	23,331	23,152	23,100	23,223
157	3308110	Mertoyudan	29,173	29,798	29,685	29,924
158	3308120	Tempuran	18,308	18,320	18,319	19,127
159	3308130	Kajoran	18,301	18,496	18,500	18,565
160	3308140	Kaliangkrik	20,056	19,546	19,580	19,838
161	3308150	Bandongan	19,273	19,350	19,345	19,987
162	3308160	Windusari	17,409	17,692	17,694	17,699
163	3308170	Secang	27,67	27,712	27,793	27,742
164	3308180	Tegalrejo	21,456	21,688	21,679	21,709
165	3308190	Pakis	14,182	14,459	14,445	14,853
166	3308200	Grabag	20,125	20,846	20,714	20,573
167	3308210	Ngablagk	17,769	17,564	17,578	17,599
168	3309010	Selo	16,994	16,492	16,220	16,872
169	3309020	Ampel	27,448	26,445	26,415	26,684
170	3309021	Gladagsari	21,264	20,445	20,459	20,800
171	3309030	Cepogo	23,286	22,810	22,753	23,025
172	3309040	Musuk	29,828	21,615	21,409	28,301
173	3309041	Tamansari	20,795	20,101	20,147	20,702
174	3309050	Boyolali	31,128	28,889	28,742	30,524
175	3309060	Mojosongo	31,707	28,838	28,610	31,284
176	3309070	Teras	27,445	27,416	27,163	27,479
177	3309080	Sawit	20,521	20,521	20,521	21,822
178	3309090	Banyudono	34,527	34,524	34,524	35,265
179	3309100	Sambi	29,778	28,128	28,400	28,752
180	3309110	Ngemplak	40,327	38,197	38,355	39,537
181	3309120	Nogosari	33,097	31,454	31,575	32,362
182	3309130	Simo	18,558	19,566	19,483	19,657
183	3309140	Karanggede	26,449	26,282	26,152	26,345
184	3309150	Klego	20,41	20,557	20,553	20,122
185	3309160	Andong	29,247	28,039	28,083	28,955
186	3309170	Kemusu	24,846	25,020	24,976	25,016
187	3309180	Wonosegoro	22,58	25,423	25,510	23,604
188	3309181	Wonosamodro	27,177	27,143	27,110	27,190
189	3309190	Juwangi	27,588	27,580	27,539	27,942
190	3310010	Prambanan	30,848	29,836	29,443	30,328

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
191	3310020	Gantiwarno	39,102	32,573	32,559	36,782
192	3310030	Wedi	30,498	30,233	30,305	31,629
193	3310040	Bayat	24,537	25,086	25,061	25,077
194	3310050	Cawas	26,097	27,078	26,935	26,588
195	3310060	Trucuk	29,281	28,951	29,031	29,395
196	3310070	Kalikotes	28,67	27,817	27,889	28,618
197	3310080	Kebonarum	34,178	34,178	34,178	32,891
198	3310090	Jogonalan	18,413	19,328	19,301	19,950
199	3310100	Manisrenggo	28,134	27,750	27,649	27,667
200	3310110	Karangnongko	40,083	29,395	29,217	36,596
201	3310120	Ngawen	25,795	25,627	25,421	25,917
202	3310130	Ceper	30,15	30,055	30,010	30,122
203	3310140	Pedan	20,508	21,366	21,357	21,714
204	3310150	Karangdowo	49,729	31,971	31,320	35,295
205	3310160	Juwiring	22,292	23,184	23,124	23,483
206	3310170	Wonosari	26,107	28,478	28,224	26,936
207	3310180	Delanggu	31,894	30,341	29,787	32,571
208	3310190	Polanharjo	21,121	22,101	22,001	21,893
209	3310200	Karanganom	13,395	17,880	17,995	15,479
210	3310210	Tulung	32,668	29,609	29,266	31,603
211	3310220	Jatinom	25,061	24,997	24,981	26,223
212	3310230	Kemalang	19,26	19,394	19,321	19,512
213	3310710	Klaten Selatan	41,229	32,652	32,699	38,846
214	3310720	Klaten Tengah	28,175	28,315	28,311	28,521
215	3310730	Klaten Utara	50,171	33,427	33,314	51,749
216	3311010	Weru	17,84	18,355	18,343	19,119
217	3311020	Bulu	24,239	24,279	24,104	24,303
218	3311030	Tawangsari	19,553	20,847	20,811	20,903
219	3311040	Sukoharjo	36,482	33,199	32,980	35,558
220	3311050	Nguter	28,527	28,441	28,392	28,588
221	3311060	Bendosari	20,13	21,472	21,394	21,532
222	3311070	Polokarto	33,437	32,022	31,800	33,045
223	3311080	Mojolaban	35,835	34,498	33,965	36,003
224	3311090	Grogol	32,017	33,963	34,126	33,792
225	3311100	Baki	47,624	33,761	33,472	44,049
226	3311110	Gatak	26,169	27,879	27,875	26,564
227	3311120	Kartasura	37,688	39,064	38,982	38,752
228	3312010	Pracimantoro	18,804	19,876	19,651	19,320
229	3312020	Paranggupito	9,894	11,293	11,314	11,309
230	3312030	Giritontro	18,891	19,254	19,137	18,893
231	3312040	Giriwoyo	20,543	20,537	20,535	20,427
232	3312050	Batuwarno	25,882	25,707	25,698	24,664
233	3312060	Karangtengah	16,105	16,010	16,022	16,107
234	3312070	Tirtomoyo	15,849	16,116	16,015	16,263
235	3312080	Nguntoronadi	18,41	20,629	20,121	18,742
236	3312090	Baturetno	16,327	18,125	18,118	17,346
237	3312100	Eromoko	27,965	25,941	26,041	26,998
238	3312110	Wuryantoro	43,149	33,870	33,753	38,676
239	3312120	Manyaran	23,174	22,555	22,982	23,147
240	3312130	Selogiri	27,781	27,058	27,659	27,541
241	3312140	Wonogiri	38,004	37,562	37,586	36,364
242	3312150	Ngadirojo	31,338	28,742	28,824	29,634
243	3312160	Sidoharjo	20,532	20,769	20,773	20,645
244	3312170	Jatiroti	21,884	21,835	21,875	21,846
245	3312180	Kismantoro	20,758	19,294	18,703	20,412
246	3312190	Purwantoro	12,817	13,999	14,060	14,255
247	3312200	Bulukerto	21,498	21,372	21,375	20,787
248	3312201	Puhpelem	17,633	17,998	17,856	17,917
249	3312210	Slogohimo	26,184	23,505	23,634	25,130
250	3312220	Jatisrono	23,087	23,146	23,149	23,080
251	3312230	Jatipurno	17,844	17,787	17,785	17,700
252	3312240	Girimarto	22,839	22,218	22,208	22,285
253	3313010	Jatipuro	16,551	17,291	17,276	17,062
254	3313020	Jatiyoso	20,494	18,508	18,515	19,896
255	3313030	Jumapolo	14,814	14,827	14,827	15,822
256	3313040	Jumantono	16,165	17,266	17,175	17,302

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
257	3313050	Matesih	16,642	20,165	20,064	17,674
258	3313060	Tawangmangu	13,429	14,401	14,294	12,987
259	3313070	Ngargoyoso	12,144	12,189	12,188	13,093
260	3313080	Karangpandan	13,373	14,461	14,411	14,688
261	3313090	Karanganyar	32,095	32,114	31,671	32,347
262	3313100	Tasikmadu	33,802	31,084	31,148	33,509
263	3313110	Jaten	34,636	33,722	33,794	35,721
264	3313120	Colomadu	50,078	40,440	40,396	45,924
265	3313130	Gondangrejo	31,06	30,733	30,647	30,977
266	3313140	Kebakramat	24,617	25,188	25,131	25,356
267	3313150	Mojogedang	12,607	14,545	14,523	14,598
268	3313160	Kerjo	20,82	22,182	22,080	21,324
269	3313170	Jenawi	8,309	8,887	8,888	10,430
270	3314010	Kalijambe	23,313	26,684	26,162	24,284
271	3314020	Plupuh	23,393	23,878	23,898	24,509
272	3314030	Masaran	39,799	32,912	32,056	38,635
273	3314040	Kedawung	15,852	16,303	16,299	18,630
274	3314050	Sambirejo	28,207	28,207	28,207	28,160
275	3314060	Gondang	36,752	34,580	34,647	35,934
276	3314070	Sambung Macan	24,06	25,041	25,324	24,753
277	3314080	Ngrampal	27,146	28,067	28,022	27,806
278	3314090	Karangmalang	24,537	27,617	27,512	25,690
279	3314100	Sragen	43,038	36,673	36,719	41,934
280	3314110	Sidoharjo	29,543	30,202	30,025	29,923
281	3314120	Tanon	31,847	32,123	32,100	32,380
282	3314130	Gemolong	52,445	33,397	32,789	46,869
283	3314140	Miri	24,462	24,937	25,121	24,702
284	3314150	Sumberlawang	18,348	21,796	21,738	19,558
285	3314160	Mondokan	18,837	18,889	18,888	19,901
286	3314170	Sukodono	22,439	23,699	23,803	22,979
287	3314180	Gesi	21,116	21,998	21,989	21,637
288	3314190	Tangen	15,967	20,951	21,185	13,072
289	3314200	Jenar	18,423	21,957	22,152	19,402
290	3315010	Kedungjati	29,992	29,382	29,450	29,382
291	3315020	Karangrayung	32,18	31,424	31,273	31,985
292	3315030	Penawangan	36,45	33,835	33,921	35,057
293	3315040	Toroh	30,389	30,741	30,867	30,852
294	3315050	Geyer	31,809	29,594	29,669	31,179
295	3315060	Pulokulon	26,709	27,581	27,689	27,332
296	3315070	Kradenan	21,932	22,595	22,668	22,955
297	3315080	Gabus	26,073	26,635	26,460	26,468
298	3315090	Ngaringan	18,915	19,725	19,745	20,379
299	3315100	Wirosari	29,652	30,561	30,076	30,132
300	3315110	Tawangharjo	25,664	27,664	27,404	26,622
301	3315120	Grobogan	33,167	32,794	32,871	33,175
302	3315130	Purwodadi	32,306	32,552	32,535	32,733
303	3315140	Brati	33,459	32,748	32,686	33,156
304	3315150	Klambu	28,378	30,222	30,811	28,887
305	3315160	Godong	37,913	35,084	35,156	37,005
306	3315170	Gubug	39,806	36,004	36,228	39,059
307	3315180	Tegowanu	34,444	32,374	32,501	33,991
308	3315190	Tanggungharjo	28,325	27,834	27,954	28,199
309	3316010	Jati	16,593	18,547	18,640	18,004
310	3316020	Randublatung	19,595	21,671	21,825	20,761
311	3316030	Kradenan	26,009	26,034	26,023	26,292
312	3316040	Kedungtuban	36,326	33,068	32,886	34,675
313	3316050	Cepu	41,284	38,776	38,624	40,390
314	3316060	Sambong	46,329	45,228	45,224	41,173
315	3316070	Jiken	21,164	21,669	21,846	21,755
316	3316080	Bogorejo	22,043	22,568	22,774	22,644
317	3316090	Jepon	32,936	32,650	32,650	32,144
318	3316100	Kota Blora	38,799	36,597	36,644	37,468
319	3316110	Banjarejo	19,683	20,432	20,397	19,481
320	3316120	Tunjungan	29,866	28,959	29,041	29,490
321	3316130	Japah	26,037	26,032	26,137	26,047
322	3316140	Ngawen	31,678	31,233	31,242	31,393

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
323	3316150	Kunduran	29,106	28,977	29,011	29,144
324	3316160	Todanan	25,163	25,310	25,251	25,155
325	3317010	Sumber	12,661	19,234	19,335	15,406
326	3317020	Bulu	29,286	27,635	27,511	28,736
327	3317030	Gunem	27,729	27,519	27,472	27,367
328	3317040	Sale	22,98	23,500	23,491	23,460
329	3317050	Sarang	28,473	28,599	28,604	28,726
330	3317060	Sedan	26,896	26,256	26,038	26,896
331	3317070	Pamotan	29,403	29,140	29,133	29,377
332	3317080	Sulang	29,778	29,447	29,477	29,635
333	3317090	Kaliori	33,877	33,536	33,571	33,732
334	3317100	Rembang	49,443	42,298	42,649	48,668
335	3317110	Pancur	32,652	31,626	31,665	31,450
336	3317120	Kragan	31,072	29,668	29,567	30,696
337	3317130	Sluke	36,965	30,690	30,610	33,968
338	3317140	Lasem	32,514	29,733	29,900	31,950
339	3318010	Sukolilo	28,889	28,990	29,025	29,087
340	3318020	Kayen	34,907	33,773	33,765	34,455
341	3318030	Tambakromo	32,601	31,744	31,830	32,400
342	3318040	Winong	41,235	33,859	33,817	39,600
343	3318050	Pucakwangi	23,505	23,970	23,911	24,220
344	3318060	Jaken	24,594	25,265	25,390	25,511
345	3318070	Batangan	29,594	30,427	30,548	30,358
346	3318080	Juwana	46,569	43,754	43,721	52,770
347	3318090	Jakenan	35,161	33,233	33,501	34,819
348	3318100	Pati	51,402	47,102	46,959	52,524
349	3318110	Gabus	37,573	35,132	34,903	36,882
350	3318120	Margorejo	51,271	48,201	48,105	45,455
351	3318130	Gembong	24,461	24,210	24,227	24,048
352	3318140	Tlogowungu	32,341	26,656	26,896	31,149
353	3318150	Wedarijakska	41,783	39,407	39,765	41,096
354	3318160	Trangkil	50,837	39,268	39,636	40,853
355	3318170	Margoyoso	29,413	29,513	29,523	29,586
356	3318180	Gunung Wungkal	20,399	20,785	20,962	20,742
357	3318190	Cluwak	28,547	26,685	26,783	27,351
358	3318200	Tayu	25,22	26,090	25,974	25,973
359	3318210	Dukuhseti	24,745	24,985	24,986	25,403
360	3319010	Kaliwungu	39,651	38,186	38,255	38,944
361	3319020	Kota Kudus	42,032	41,809	41,936	42,582
362	3319030	Jati	35,328	35,256	35,347	35,781
363	3319040	Undaan	32,812	32,425	32,450	32,480
364	3319050	Mejobo	28,392	28,688	28,843	28,763
365	3319060	Jekulo	38,033	37,217	37,163	37,402
366	3319070	Bae	58,733	31,602	31,718	40,572
367	3319080	Gebog	28,788	28,369	28,268	28,381
368	3319090	Dawe	27,586	27,261	27,175	27,398
369	3320010	Kedung	19,767	23,243	23,303	21,465
370	3320020	Pecangaan	24,98	26,232	26,248	25,710
371	3320021	Kalinyamatian	45,689	39,323	39,290	44,341
372	3320030	Welahan	30,359	31,171	30,986	30,806
373	3320040	Mayong	32,079	30,723	30,827	31,781
374	3320050	Nalumsari	36,223	35,946	35,941	34,968
375	3320060	Batealit	16,644	19,451	19,639	17,702
376	3320070	Tahunan	27,998	29,631	29,329	28,814
377	3320080	Jepara	45,716	35,400	35,396	45,009
378	3320090	Mlonggo	28,886	28,711	28,586	28,964
379	3320091	Pakis Aji	9,361	9,556	9,562	11,694
380	3320100	Bangsri	25,802	24,875	24,735	25,419
381	3320101	Kembang	28,567	27,767	27,720	27,941
382	3320110	Keling	24,679	24,229	24,129	26,344
383	3320111	Donorojo	20,618	20,808	20,828	21,097
384	3321010	Mranggen	57,31	38,320	38,491	53,257
385	3321020	Karangawen	24,325	25,676	25,640	25,248
386	3321030	Guntur	31,112	30,995	30,655	31,522
387	3321040	Sayung	35,85	35,218	34,906	35,912
388	3321050	Karang Tengah	33,452	32,378	32,228	33,365

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
389	3321060	Bonang	18,902	20,686	20,614	10,946
390	3321070	Demak	30,362	31,630	31,719	31,137
391	3321080	Wonosalam	42,961	33,914	33,784	40,892
392	3321090	Dempet	29,821	30,075	29,971	30,172
393	3321091	Kebonagung	27,497	27,384	27,463	27,598
394	3321100	Gajah	22,786	23,559	23,547	23,654
395	3321110	Karanganyar	23,971	25,603	25,667	25,035
396	3321120	Mijen	13,271	19,811	19,989	16,334
397	3321130	Wedung	29,566	29,837	29,829	29,885
398	3322010	Getasan	29,915	26,025	25,858	27,337
399	3322020	Tengaran	21,77	21,737	21,709	21,876
400	3322030	Susukan	37,516	31,789	31,631	34,216
401	3322031	Kaliwungu	19,929	19,994	20,011	20,405
402	3322040	Suruh	31,438	28,300	28,411	30,278
403	3322050	Pabelan	21,822	22,314	22,445	20,956
404	3322060	Tuntang	55,987	28,176	29,255	47,827
405	3322070	Banyubiru	40,192	29,616	30,015	34,499
406	3322080	Jambu	26,81	23,403	23,606	25,326
407	3322090	Sumowono	22,573	17,617	18,134	21,546
408	3322100	Ambarawa	34,159	31,085	31,486	33,468
409	3322101	Bandungan	28,016	25,835	25,953	26,767
410	3322110	Bawen	27,463	26,863	27,400	27,359
411	3322120	Bringin	39,307	32,473	32,841	36,882
412	3322121	Bancak	37,381	33,581	33,526	35,102
413	3322130	Pringapus	29,434	29,003	29,586	31,386
414	3322140	Bergas	36,139	32,336	32,756	34,737
415	3322151	Ungaran Barat	42,979	28,455	28,700	41,699
416	3322152	Ungaran Timur	32,267	30,651	30,572	33,519
417	3323010	Parakan	24,132	23,119	23,358	23,637
418	3323011	Kledung	16,564	16,013	16,075	16,460
419	3323012	Bansari	14,79	15,132	15,121	15,221
420	3323020	Bulu	11,876	12,880	12,922	13,075
421	3323030	Temanggung	23,266	25,244	25,057	24,127
422	3323031	Tlogomulyo	8,501	9,354	9,364	10,074
423	3323040	Tembarak	17,278	17,375	17,347	17,840
424	3323041	Selopampang	11,664	12,093	12,127	12,512
425	3323050	Kranggan	14,545	15,021	15,002	15,413
426	3323060	Pringsurat	19,689	19,533	19,368	20,730
427	3323070	Kalaran	8,784	9,200	9,195	10,521
428	3323080	Kandangan	8,552	9,355	9,352	10,907
429	3323090	Kedu	9,909	10,805	10,766	8,955
430	3323100	Ngadirejo	16,407	17,728	17,414	16,958
431	3323110	Jumo	9,539	9,586	9,590	10,850
432	3323111	Gemawang	14,453	15,217	14,680	14,840
433	3323120	Candirotok	13,99	14,656	14,643	14,417
434	3323121	Bejen	23,123	21,853	21,877	22,278
435	3323130	Tretep	11,451	11,527	11,470	11,843
436	3323131	Wonoboyo	11,415	11,514	11,501	11,905
437	3324010	Plantungan	16,096	16,074	16,081	16,361
438	3324020	Sukorejo	23,988	21,791	22,032	23,203
439	3324030	Pagerruyung	14,748	15,721	15,491	16,465
440	3324040	Patean	15,934	16,517	16,443	16,752
441	3324050	Singorojo	24,259	23,731	23,735	24,381
442	3324060	Limongan	22,768	21,685	21,698	22,279
443	3324070	Boja	26,291	27,251	27,101	26,742
444	3324080	Kaliwungu	26,166	27,982	28,081	27,396
445	3324081	Kaliwungu Selatan	55,649	31,579	30,996	46,430
446	3324090	Brangsong	30,931	28,966	28,804	30,580
447	3324100	Pegandon	28,279	28,186	28,205	28,067
448	3324101	Ngampel	24,481	24,510	24,512	23,053
449	3324110	Gemuh	28,895	28,904	28,922	29,157
450	3324111	Ringinarum	49,915	40,930	41,110	45,126
451	3324120	Weleri	35,988	31,915	31,823	35,421
452	3324130	Rowosari	27,058	27,363	27,356	27,582
453	3324140	Kangkung	30,754	30,203	30,111	30,493
454	3324150	Cepiring	24,713	26,897	26,911	25,390

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
455	3324160	Patebon	29,999	29,501	29,286	30,080
456	3324170	Kendal	38,808	36,453	36,444	37,665
457	3325010	Wonotunggal	14,336	15,210	15,278	15,252
458	3325020	Bandar	21,536	21,326	21,284	21,453
459	3325030	Blado	21,283	19,348	19,296	20,601
460	3325040	Reban	20,155	19,322	19,323	19,759
461	3325050	Bawang	21,003	20,172	20,226	20,506
462	3325060	Tersono	21,742	21,190	21,259	21,681
463	3325070	Gringsing	39,089	29,997	29,601	36,639
464	3325080	Limpung	20,361	21,287	21,183	21,034
465	3325081	Banyuputih	38,02	28,569	28,087	35,674
466	3325090	Subah	23,715	23,688	23,700	23,738
467	3325091	Pecalungan	12,412	12,882	12,872	13,482
468	3325100	Tulis	23,137	24,236	23,960	23,701
469	3325101	Kandeman	22,405	23,948	23,837	23,194
470	3325110	Batang	31,675	32,626	32,490	32,432
471	3325120	Warungasem	21,27	22,150	22,083	22,362
472	3326010	Kandangserang	11,089	11,657	11,618	11,930
473	3326020	Paninggaran	15,977	15,994	15,959	16,110
474	3326030	Lebakbarang	12,635	12,653	12,653	13,170
475	3326040	Petungkriono	9,76	9,760	9,760	8,258
476	3326050	Talun	19,186	18,837	18,694	19,306
477	3326060	Doro	16,481	18,333	18,328	17,206
478	3326070	Karanganyar	23,919	23,751	23,739	23,998
479	3326080	Kajen	25,567	25,717	25,727	25,851
480	3326090	Kesesi	22,434	24,050	24,041	23,799
481	3326100	Sragi	15,551	16,318	16,311	17,535
482	3326101	Siwalan	22,152	23,910	23,767	23,010
483	3326110	Bojong	24,4	25,154	25,150	25,127
484	3326120	Wonopringgo	21,473	22,329	22,335	22,311
485	3326130	Kedungwuni	36,554	36,435	36,370	36,775
486	3326131	Karangdadap	31,216	31,215	31,215	30,767
487	3326140	Buaran	29,902	30,371	29,957	30,385
488	3326150	Tirto	24,18	25,749	25,708	25,329
489	3326160	Wiradesa	34,362	32,274	32,362	34,316
490	3326161	Wonokerto	39,588	34,492	34,240	39,005
491	3327010	Moga	14,708	15,713	15,626	15,693
492	3327011	Warungpring	11,095	11,750	11,741	13,809
493	3327020	Pulosari	14,614	15,040	15,039	15,015
494	3327030	Belik	16,548	16,712	16,716	17,140
495	3327040	Watukumpul	13,421	14,217	14,185	12,457
496	3327050	Bodeh	22,405	23,613	23,604	21,937
497	3327060	Bantarbolang	26,314	26,240	26,216	26,332
498	3327070	Randudongkal	21,769	22,492	22,473	22,759
499	3327080	Pemalang	30,802	31,054	30,858	31,254
500	3327090	Taman	26,742	28,888	28,812	27,757
501	3327100	Petarukan	26,243	27,805	27,581	26,998
502	3327110	Ampelgading	27,065	27,243	27,045	27,327
503	3327120	Comal	22,491	23,316	23,304	23,887
504	3327130	Ulujamii	26,92	28,464	28,191	28,216
505	3328010	Margasari	53,855	33,633	34,086	47,993
506	3328040	Balapulang	23,217	23,850	23,924	23,514
507	3328050	Pagerbarang	22,741	23,078	23,011	23,070
508	3328060	Lebaksiu	34,036	32,069	32,056	32,934
509	3328080	Kedung Banteng	21,772	23,013	23,181	22,809
510	3328090	Pangkah	52,697	33,175	32,612	47,758
511	3328100	Slawi	22,255	26,221	26,402	24,319
512	3328110	Dukuhwaru	39,597	33,883	33,644	37,306
513	3328120	Adiwerana	46,09	39,993	39,943	44,484
514	3328130	Dukuhturi	49,319	38,060	38,800	47,490
515	3328140	Talang	31,806	31,696	31,795	31,969
516	3328150	Tarub	32,376	30,647	30,657	32,123
517	3328160	Kramat	27,119	28,401	28,546	32,140
518	3328170	Suradadi	36,469	32,592	32,578	35,346
519	3328180	Warureja	21,181	24,156	24,335	22,279
520	3329010	Salem	20,799	21,026	21,067	21,190

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
521	3329020	Bantarkawung	15,144	15,349	15,350	16,352
522	3329030	Bumiyau	23,972	24,927	25,064	22,455
523	3329040	Paguyangan	24,717	23,535	23,556	23,878
524	3329050	Sirampog	22,524	18,916	19,054	21,612
525	3329060	Tonjong	29,723	27,378	27,134	28,964
526	3329070	Larangan	23,805	25,579	25,642	22,862
527	3329080	Ketangungan	26,346	27,148	27,026	27,149
528	3329090	Banjarharjo	32,308	30,551	30,378	31,724
529	3329100	Losari	20,577	23,648	23,861	22,772
530	3329110	Tanjung	29,3	29,910	30,071	29,738
531	3329120	Kersana	26,99	28,570	29,113	25,465
532	3329130	Bulakamba	43,554	40,340	40,626	43,529
533	3329140	Wanasari	35,995	35,486	35,557	36,135
534	3329150	Songgom	34,764	34,389	34,408	34,104
535	3329160	Jatibarang	45,164	38,935	38,924	43,821
536	3329170	Brebes	46,764	39,681	39,863	46,114
537	3371010	Magelang Selatan	27,171	28,178	28,515	28,098
538	3371011	Magelang Tengah	33,723	33,765	33,802	33,933
539	3371020	Magelang Utara	37,38	35,389	35,359	36,610
540	3372010	Laweyan	45,42	44,053	43,700	45,561
541	3372020	Serengan	48,366	41,509	41,566	47,513
542	3372030	Pasar Kliwon	37,433	40,232	40,007	39,749
543	3372040	Jebres	38,701	42,374	41,955	42,621
544	3372050	Banjarsari	54,491	49,997	50,316	55,347
545	3373010	Argomulyo	28,17	27,914	27,924	27,747
546	3373020	Tingkir	31,83	30,779	30,814	30,846
547	3373030	Sidomukti	33,594	32,577	32,569	32,629
548	3373040	Sidorejo	30,922	30,904	30,935	30,951
549	3374010	Mijen	62,219	27,879	28,311	50,832
550	3374020	Gunung Pati	28,218	27,368	27,670	28,030
551	3374030	Banyumanik	50,462	40,740	40,798	58,392
552	3374040	Gajah Mungkur	63,924	42,963	43,318	69,907
553	3374050	Semarang Selatan	37,25	39,101	39,243	49,178
554	3374060	Candisari	34,742	36,627	36,833	35,809
555	3374070	Tembalang	54,155	44,873	44,913	52,958
556	3374080	Pedurungan	61,279	48,223	47,857	60,591
557	3374090	Genuk	36,387	36,497	36,665	37,131
558	3374100	Gayamsari	41,761	38,829	38,382	41,779
559	3374110	Semarang Timur	53,261	41,772	41,812	51,588
560	3374120	Semarang Utara	65,843	47,056	46,268	52,982
561	3374130	Semarang Tengah	25,541	36,561	36,781	42,199
562	3374140	Semarang Barat	64,451	53,315	53,602	67,109
563	3374150	Tugu	71,308	32,947	34,014	60,623
564	3374160	Ngalian	35,175	34,387	34,674	35,305
565	3375010	Pekalongan Barat	34,14	34,236	34,466	34,665
566	3375020	Pekalongan Timur	42,279	38,745	39,005	42,044
567	3375030	Pekalongan Selatan	29,716	29,885	29,935	30,027
568	3375040	Pekalongan Utara	48,524	42,031	42,116	47,597
569	3376010	Tegal Selatan	38,158	37,015	37,290	36,940
570	3376020	Tegal Timur	60,663	47,010	47,597	57,942
571	3376030	Tegal Barat	47,294	41,654	42,244	46,784
572	3376040	Margadana	46,15	36,029	36,519	43,970

Lampiran 2. Nilai RSE atau RRMSE hasil estimasi rata-rata konsumsi listrik per kapita ruta level kecamatan dari seluruh model pendugaan

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
1	3301010	Dayeuhluhur	9,363	8,996	9,016	10,280
2	3301020	Wanareja	11,505	10,620	10,591	12,244
3	3301030	Majenang	12,428	11,349	11,413	10,584
4	3301040	Cimanggu	14,864	13,383	13,375	10,396
5	3301050	Karangpucung	24,846	19,766	19,959	10,181

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
6	3301060	Cipari	5,248	5,155	5,154	13,277
7	3301070	Sidareja	17,809	14,361	14,538	10,535
8	3301080	Kedungreja	21,595	16,450	16,460	21,812
9	3301090	Patimuan	16,380	13,815	13,813	11,202
10	3301100	Gandrunghmangu	14,493	12,349	12,382	12,655
11	3301110	Bantarsari	27,659	19,418	19,651	11,195
12	3301120	Kawunganten	24,062	18,140	18,264	11,489
13	3301121	Kampung Laut	19,419	17,052	16,878	9,947
14	3301130	Jeruklegi	40,286	20,742	20,939	10,517
15	3301140	Kesugihan	37,074	17,730	17,609	24,956
16	3301150	Adipala	22,893	14,760	14,673	10,483
17	3301160	Maos	0,000	0,000	0,000	11,436
18	3301170	Sampang	25,541	15,559	15,196	10,327
19	3301180	Kroya	10,051	8,944	8,966	10,231
20	3301190	Binangun	37,686	19,134	18,641	10,391
21	3301200	Nusawungu	3,203	3,170	3,170	10,983
22	3301710	Cilacap Selatan	16,363	13,961	13,901	12,071
23	3301720	Cilacap Tengah	23,527	14,472	14,572	9,822
24	3301730	Cilacap Utara	6,756	6,448	6,456	11,733
25	3302010	Lumbir	4,522	4,478	4,478	10,440
26	3302020	Wangon	15,385	13,018	12,969	10,038
27	3302030	Jatilawang	14,590	12,232	12,197	10,809
28	3302040	Rawalo	37,917	19,118	19,101	10,394
29	3302050	Kebasen	8,122	7,693	7,701	10,309
30	3302060	Kemranjen	21,894	16,529	16,581	10,240
31	3302070	Sumpiuh	7,877	7,641	7,625	30,819
32	3302080	Tambak	20,416	17,510	17,893	15,552
33	3302090	Somagede	19,776	16,633	16,421	14,803
34	3302100	Kalibago	16,341	14,750	14,964	19,529
35	3302110	Banyumas	15,661	13,408	13,464	10,425
36	3302120	Patikraja	3,174	3,148	3,148	10,174
37	3302130	Purwojati	20,872	16,980	17,072	11,733
38	3302140	Ajibarang	20,139	15,796	15,678	13,401
39	3302150	Gumelar	12,311	11,549	11,565	12,134
40	3302160	Pekuncen	23,790	19,402	19,286	11,821
41	3302170	Cilongok	13,094	12,099	12,032	10,649
42	3302180	Karanglewas	25,447	17,188	16,998	11,036
43	3302190	Kedung Banteng	21,697	18,007	17,770	10,389
44	3302200	Baturraden	1,488	1,488	1,488	13,048
45	3302210	Sumbang	11,023	10,203	10,204	10,291
46	3302220	Kembaran	48,480	18,275	18,947	15,728
47	3302230	Sokaraja	1,252	1,248	1,248	14,159
48	3302710	Purwokerto Selatan	21,254	13,050	13,129	10,990
49	3302720	Purwokerto Barat	61,499	17,568	17,990	11,097
50	3302730	Purwokerto Timur	11,542	9,528	9,531	13,093
51	3302740	Purwokerto Utara	12,904	10,658	10,684	11,181
52	3303010	Kemangkon	18,387	13,551	13,653	10,621
53	3303020	Bukateja	17,685	13,734	13,751	10,153
54	3303030	Kejobong	15,060	13,481	13,520	11,316
55	3303040	Pengadegan	19,401	16,312	16,237	10,081
56	3303050	Kaligondang	15,070	12,881	12,831	10,783
57	3303060	Purbalingga	18,363	12,206	12,329	10,472
58	3303070	Kalimanah	32,147	15,649	15,380	10,902
59	3303080	Padamara	21,742	15,128	14,953	10,414
60	3303090	Kutasari	11,406	10,492	10,459	10,360
61	3303100	Bojongsari	1,851	1,846	1,846	10,474
62	3303110	Mrebet	14,254	12,276	12,281	11,413
63	3303120	Bobotsari	13,958	12,469	12,519	10,381
64	3303130	Karangreja	14,624	13,563	13,503	10,122
65	3303131	Karangjambu	8,427	8,275	8,265	10,337
66	3303140	Karanganyar	9,263	8,818	8,835	10,496
67	3303141	Kertanegara	20,630	16,710	16,406	10,540
68	3303150	Karangmoncol	6,141	6,021	6,022	10,235
69	3303160	Rembang	14,871	13,484	13,532	10,781
70	3304010	Susukan	14,018	11,932	11,827	10,034
71	3304020	Purwareja Klampok	8,360	7,715	7,655	10,441

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
72	3304030	Mandiraja	6,329	6,107	6,094	10,015
73	3304040	Purwanegara	12,675	11,220	11,145	10,069
74	3304050	Bawang	24,151	17,634	17,576	10,971
75	3304060	Banjarnegara	34,933	17,239	17,312	13,192
76	3304061	Pagedongan	8,581	8,266	8,252	10,688
77	3304070	Sigaluh	6,576	6,454	6,454	10,522
78	3304080	Madukara	33,403	21,986	22,133	10,263
79	3304090	Banjarmangu	11,874	11,123	11,079	10,802
80	3304100	Wanadadi	10,373	9,671	9,653	9,764
81	3304110	Rakit	20,572	15,697	15,680	10,024
82	3304120	Punggelan	13,047	11,814	11,803	11,017
83	3304130	Karangkobar	19,521	17,549	17,562	11,120
84	3304140	Pagentan	13,807	12,864	12,824	13,443
85	3304150	Pejawaran	24,573	20,678	20,609	11,529
86	3304160	Batur	19,837	17,955	18,135	11,785
87	3304170	Wanayasa	25,086	21,478	21,653	10,413
88	3304180	Kalibening	21,128	18,391	18,467	11,177
89	3304181	Pandanarum	8,515	8,309	8,334	10,491
90	3305010	Ayah	17,226	14,339	14,272	13,089
91	3305020	Buayan	25,736	18,598	18,538	10,412
92	3305030	Puring	15,963	12,878	12,966	10,298
93	3305040	Petanahan	9,040	8,317	8,334	10,504
94	3305050	Klirong	21,429	15,141	14,991	10,451
95	3305060	Buluspesantren	17,892	13,974	13,771	10,331
96	3305070	Ambal	13,845	11,676	11,665	10,004
97	3305080	Mirit	9,845	8,927	8,925	10,263
98	3305081	Bonorowo	17,684	14,159	14,359	10,036
99	3305090	Prembun	0,789	0,777	0,777	36,135
100	3305091	Padureso	0,000	0,000	0,000	17,660
101	3305100	Kutownangun	8,139	7,753	7,751	22,078
102	3305110	Alian	25,609	18,140	18,319	10,107
103	3305111	Poncowarno	16,140	13,878	13,804	14,096
104	3305120	Kebumen	22,379	13,293	13,259	10,709
105	3305130	Pejagoan	22,824	17,185	17,223	10,436
106	3305140	Sruweng	18,347	14,515	14,471	11,920
107	3305150	Adimulyo	10,246	9,284	9,273	10,068
108	3305160	Kuwarasan	2,052	2,042	2,042	10,079
109	3305170	Rowokele	12,786	11,680	11,679	10,847
110	3305180	Sempor	29,536	19,439	19,343	11,513
111	3305190	Gombong	0,263	0,261	0,261	10,553
112	3305200	Karanganyar	15,360	13,274	13,286	9,920
113	3305210	Karanggayam	11,114	10,206	10,190	11,612
114	3305220	Sadang	21,430	17,667	17,686	10,463
115	3305221	Karangsambung	24,757	17,965	17,783	10,128
116	3306010	Grabag	24,183	16,290	16,140	10,199
117	3306020	Ngombol	15,077	12,658	12,739	11,196
118	3306030	Purwodadi	24,492	16,060	15,957	10,537
119	3306040	Bagelen	18,098	15,230	15,190	10,791
120	3306050	Kaligesing	12,675	11,804	11,776	10,439
121	3306060	Purworejo	13,419	10,969	10,945	10,370
122	3306070	Banyu Urip	28,087	16,819	16,611	10,436
123	3306080	Bayan	15,702	12,632	12,523	10,766
124	3306090	Kutoarjo	16,016	11,659	11,586	13,035
125	3306100	Butuh	16,349	13,189	13,114	10,112
126	3306110	Pituruh	18,259	15,111	15,031	10,449
127	3306120	Kemiri	10,014	9,386	9,388	10,291
128	3306130	Bruno	2,875	2,860	2,859	12,311
129	3306140	Gebang	13,490	12,162	12,217	10,498
130	3306150	Loano	15,412	13,749	13,826	10,450
131	3306160	Bener	13,817	12,750	12,715	13,197
132	3307010	Wadaslintang	32,548	22,068	22,221	11,509
133	3307020	Kepil	19,497	16,587	16,332	10,310
134	3307030	Sapurau	21,741	18,173	17,824	10,980
135	3307031	Kalibawang	9,822	9,496	9,449	10,318
136	3307040	Kaliwiwo	26,674	20,145	20,136	10,361
137	3307050	Leksono	12,589	11,688	11,630	10,035

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
138	3307051	Sukoharjo	11,506	10,903	10,880	10,055
139	3307060	Selomerto	19,610	16,079	16,071	10,275
140	3307070	Kalikajar	13,240	12,164	11,993	10,642
141	3307080	Kertek	16,677	13,858	13,589	10,826
142	3307090	Wonosobo	14,661	11,681	11,544	10,559
143	3307100	Watumalang	13,920	12,894	12,866	10,455
144	3307110	Mojotengah	14,981	13,276	13,269	10,328
145	3307120	Garung	13,842	12,600	12,544	10,349
146	3307130	Kejajar	15,150	14,433	14,252	11,147
147	3308010	Salaman	15,650	13,421	13,320	10,900
148	3308020	Borobudur	32,038	17,955	17,779	14,282
149	3308030	Ngluwar	16,124	13,218	13,076	10,000
150	3308040	Salam	0,000	0,000	0,000	11,596
151	3308050	Srumbung	27,422	20,335	19,873	13,634
152	3308060	Dukun	9,582	9,054	8,996	10,689
153	3308070	Muntilan	13,632	10,884	10,906	10,175
154	3308080	Mungkid	16,848	13,238	13,226	10,703
155	3308090	Sawangan	11,183	10,393	10,412	10,266
156	3308100	Candimulyo	7,577	7,308	7,324	9,762
157	3308110	Mertoyudan	8,288	7,513	7,541	10,648
158	3308120	Tempuran	1,573	1,571	1,571	11,221
159	3308130	Kajoran	16,133	14,243	14,238	10,870
160	3308140	Kaliangkrik	14,951	13,652	13,627	10,486
161	3308150	Bandongan	3,937	3,889	3,890	11,363
162	3308160	Windusari	15,213	13,627	13,623	10,311
163	3308170	Secang	12,458	10,711	10,679	9,939
164	3308180	Tegalrejo	9,842	9,155	9,159	10,609
165	3308190	Pakis	10,221	9,732	9,741	11,168
166	3308200	Grabag	15,424	13,154	13,239	10,409
167	3308210	Ngablak	13,623	12,748	12,736	10,273
168	3309010	Selo	30,909	23,820	24,221	10,316
169	3309020	Ampel	10,299	9,615	9,625	10,660
170	3309021	Gladagsari	13,560	12,652	12,639	10,509
171	3309030	Cepogo	11,287	10,517	10,541	10,517
172	3309040	Musuk	49,576	25,005	25,218	11,127
173	3309041	Tamansari	18,015	15,675	15,639	10,243
174	3309050	Boyolali	18,761	14,244	14,314	10,339
175	3309060	Mojosongo	18,181	14,178	14,285	10,472
176	3309070	Teras	12,648	10,874	10,977	10,389
177	3309080	Sawit	0,000	0,000	0,000	12,255
178	3309090	Banyudono	0,500	0,501	0,501	9,974
179	3309100	Sambi	14,625	12,398	12,275	10,270
180	3309110	Ngemplak	9,005	8,070	8,034	10,163
181	3309120	Nogosari	11,377	10,050	10,010	10,217
182	3309130	Simo	12,591	11,085	11,132	11,622
183	3309140	Karanggede	12,338	10,829	10,881	10,657
184	3309150	Klego	5,340	5,212	5,213	11,078
185	3309160	Andong	19,042	14,361	14,335	9,885
186	3309170	Kemusu	13,723	11,773	11,792	10,492
187	3309180	Wonosegoro	23,873	15,540	15,491	11,234
188	3309181	Wonosamodro	5,882	5,680	5,687	9,930
189	3309190	Juwangi	16,564	13,041	13,058	10,513
190	3310010	Prambanan	12,912	11,002	11,149	10,498
191	3310020	Gantiwarno	14,241	12,330	12,332	11,474
192	3310030	Wedi	10,361	9,186	9,163	10,480
193	3310040	Bayat	17,638	13,861	13,872	10,368
194	3310050	Cawas	13,889	11,356	11,416	10,748
195	3310060	Trucuk	21,719	14,790	14,743	10,441
196	3310070	Kalikotes	16,781	13,320	13,283	10,396
197	3310080	Kebonarum	0,000	0,000	0,000	10,501
198	3310090	Jogonalan	10,130	9,188	9,201	13,116
199	3310100	Manisrenggo	6,928	6,658	6,682	10,317
200	3310110	Karangnongko	18,140	15,422	15,506	12,896
201	3310120	Ngawen	20,507	15,247	15,370	10,022
202	3310130	Ceper	7,568	7,065	7,075	10,221
203	3310140	Pedan	9,569	8,702	8,705	12,439

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
204	3310150	Karangdowo	23,626	16,215	16,549	13,390
205	3310160	Juwiring	9,814	8,829	8,852	11,991
206	3310170	Wonosari	20,988	13,986	14,114	10,935
207	3310180	Delanggu	19,682	14,031	14,296	10,269
208	3310190	Polanharjo	13,159	11,343	11,395	11,157
209	3310200	Karanganom	32,288	19,382	19,263	18,622
210	3310210	Tulung	13,769	12,040	12,179	10,328
211	3310220	Jatinom	7,372	7,046	7,050	10,411
212	3310230	Kemalang	16,548	14,419	14,478	10,585
213	3310710	Klaten Selatan	18,086	14,008	13,980	11,439
214	3310720	Klaten Tengah	5,025	4,860	4,861	10,165
215	3310730	Klaten Utara	36,002	16,512	16,553	11,818
216	3311010	Weru	8,369	7,881	7,886	12,504
217	3311020	Bulu	20,761	15,661	15,774	10,289
218	3311030	Tawangsari	12,146	10,544	10,561	12,287
219	3311040	Sukoharjo	12,933	11,019	11,089	10,217
220	3311050	Nguter	7,553	7,103	7,115	10,164
221	3311060	Bendosari	12,514	10,767	10,805	11,967
222	3311070	Polokarto	11,523	10,028	10,097	10,262
223	3311080	Mojolaban	14,752	11,332	11,509	10,309
224	3311090	Grogol	10,794	8,773	8,731	11,944
225	3311100	Baki	23,988	15,440	15,557	11,992
226	3311110	Gatak	32,775	17,268	17,260	10,606
227	3311120	Kartasura	11,898	9,205	9,229	10,704
228	3312010	Pracimantoro	15,496	13,144	13,290	10,873
229	3312020	Paranggupito	25,227	20,346	20,297	18,015
230	3312030	Giritontro	44,717	25,032	25,140	9,975
231	3312040	Giriwoyo	3,932	3,895	3,896	10,188
232	3312050	Batuwarno	3,534	3,517	3,517	11,063
233	3312060	Karangtengah	7,833	7,704	7,697	9,930
234	3312070	Tirtomoyo	12,116	11,319	11,391	10,600
235	3312080	Nguntoronadi	50,552	23,937	24,537	10,419
236	3312090	Baturetno	18,572	14,858	14,859	12,055
237	3312100	Eromoko	16,211	13,819	13,753	10,670
238	3312110	Wuryantoro	12,618	11,752	11,791	14,752
239	3312120	Manyaran	32,581	20,430	20,033	10,132
240	3312130	Selogiri	25,113	16,482	16,120	10,005
241	3312140	Wonogiri	3,492	3,447	3,444	11,027
242	3312150	Ngadirojo	11,300	10,523	10,489	11,047
243	3312160	Sidoarjo	13,858	12,317	12,309	10,300
244	3312170	Jatiroti	9,755	9,183	9,164	10,138
245	3312180	Kismantoro	31,362	22,526	23,239	10,265
246	3312190	Purwantoro	15,564	13,484	13,425	15,116
247	3312200	Bulukerto	4,249	4,224	4,224	10,390
248	3312201	Puhpelem	24,194	19,150	19,289	10,370
249	3312210	Slogohimo	18,730	15,954	15,859	10,706
250	3312220	Jatisrono	11,588	10,506	10,504	10,369
251	3312230	Jatipurno	6,158	6,070	6,070	10,178
252	3312240	Girimarto	11,142	10,494	10,499	10,260
253	3313010	Jatipuro	16,881	14,565	14,576	10,786
254	3313020	Jatiyoso	23,202	19,895	19,891	10,305
255	3313030	Jumapolo	1,720	1,718	1,718	12,064
256	3313040	Jumantono	15,337	13,209	13,280	12,693
257	3313050	Matesih	31,617	19,308	19,400	11,908
258	3313060	Tawangmangu	23,577	19,363	19,517	11,015
259	3313070	Ngargoyoso	3,853	3,827	3,828	12,494
260	3313080	Karangpandan	15,734	13,680	13,726	14,764
261	3313090	Karanganyar	17,556	12,594	12,770	10,135
262	3313100	Tasikmadu	23,373	15,031	14,996	10,134
263	3313110	Jaten	13,239	10,682	10,660	9,872
264	3313120	Colomadu	15,597	11,547	11,563	10,942
265	3313130	Gondangrejo	8,341	7,701	7,724	10,320
266	3313140	Kebakkramat	9,552	8,657	8,678	10,602
267	3313150	Mojogedang	19,734	15,723	15,746	18,898
268	3313160	Kerjo	26,723	18,096	18,175	10,695
269	3313170	Jenawi	16,876	15,340	15,338	25,369

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
270	3314010	Kalijambe	29,995	16,745	17,079	11,303
271	3314020	Plupuh	7,056	6,650	6,644	11,209
272	3314030	Masaran	25,696	15,322	15,719	10,440
273	3314040	Kedawung	6,389	6,121	6,122	20,578
274	3314050	Sambirejo	0,000	0,000	0,000	10,329
275	3314060	Gondang	10,304	9,179	9,157	10,614
276	3314070	Sambung Macan	19,088	14,414	14,245	11,160
277	3314080	Ngrampal	19,904	14,135	14,149	10,836
278	3314090	Karangmalang	22,548	14,507	14,558	11,132
279	3314100	Sragen	19,503	13,038	13,008	10,648
280	3314110	Sidoharjo	16,575	12,404	12,473	10,426
281	3314120	Tanon	9,007	8,018	8,022	10,413
282	3314130	Gemolong	20,169	15,211	15,480	13,962
283	3314140	Miri	19,251	14,677	14,565	10,356
284	3314150	Sumberlawang	26,813	17,238	17,283	12,347
285	3314160	Mondokan	2,668	2,648	2,648	11,861
286	3314170	Sukodono	19,169	14,615	14,547	10,617
287	3314180	Gesi	17,293	14,080	14,081	10,687
288	3314190	Tangen	44,542	21,536	21,296	12,722
289	3314200	Jenar	33,888	19,383	19,205	12,111
290	3315010	Kedungjati	7,226	6,915	6,898	10,084
291	3315020	Karangrayung	10,055	9,006	9,049	10,257
292	3315030	Penawangan	10,187	9,286	9,261	10,524
293	3315040	Toroh	12,797	10,567	10,520	10,410
294	3315050	Geyer	16,933	13,332	13,301	10,044
295	3315060	Pulokulon	18,330	13,641	13,593	10,780
296	3315070	Kradenan	8,279	7,674	7,649	10,941
297	3315080	Gabus	15,199	12,291	12,369	10,235
298	3315090	Ngaringan	9,035	8,316	8,307	13,319
299	3315100	Wirosari	23,919	14,713	14,948	10,664
300	3315110	Tawangharjo	16,705	12,467	12,583	11,028
301	3315120	Grobogan	11,149	9,516	9,491	10,157
302	3315130	Purwodadi	20,781	13,645	13,643	10,303
303	3315140	Brati	8,098	7,499	7,513	10,021
304	3315150	Klambu	34,059	16,450	16,119	10,550
305	3315160	Godong	11,978	10,215	10,192	10,508
306	3315170	Gubug	14,759	11,477	11,399	10,370
307	3315180	Tegowanu	18,679	13,344	13,282	10,052
308	3315190	Tanggungharjo	21,045	14,983	14,911	10,360
309	3316010	Jati	17,010	13,686	13,616	13,686
310	3316020	Randublatung	17,008	13,349	13,255	11,515
311	3316030	Kradenan	5,623	5,449	5,451	9,861
312	3316040	Kedungtuban	11,026	9,985	10,039	10,748
313	3316050	Cepu	10,510	9,011	9,048	10,163
314	3316060	Sambong	2,909	2,904	2,904	14,801
315	3316070	Jiken	10,389	9,491	9,413	10,614
316	3316080	Bogorejo	10,311	9,384	9,299	10,882
317	3316090	Jepon	4,239	4,158	4,158	10,281
318	3316100	Kota Blora	14,552	11,134	11,114	10,193
319	3316110	Banjarejo	10,914	9,870	9,886	10,940
320	3316120	Tunjungan	14,764	12,130	12,093	10,254
321	3316130	Japah	16,635	13,336	13,283	10,230
322	3316140	Ngawen	8,257	7,638	7,635	10,334
323	3316150	Kunduran	9,016	8,257	8,247	10,332
324	3316160	Todanan	15,196	12,640	12,668	10,428
325	3317010	Sumber	39,766	19,783	19,681	22,314
326	3317020	Bulu	17,911	14,086	14,149	10,141
327	3317030	Gunem	8,325	7,801	7,816	10,510
328	3317040	Sale	12,208	10,751	10,756	10,394
329	3317050	Sarang	8,682	7,972	7,969	10,212
330	3317060	Sedan	20,335	15,200	15,317	10,245
331	3317070	Pamotan	12,906	10,906	10,907	9,990
332	3317080	Sulang	10,520	9,367	9,356	9,932
333	3317090	Kaliori	13,342	10,681	10,670	10,172
334	3317100	Rembang	26,074	12,750	12,631	9,949
335	3317110	Pancur	7,260	6,941	6,932	10,559

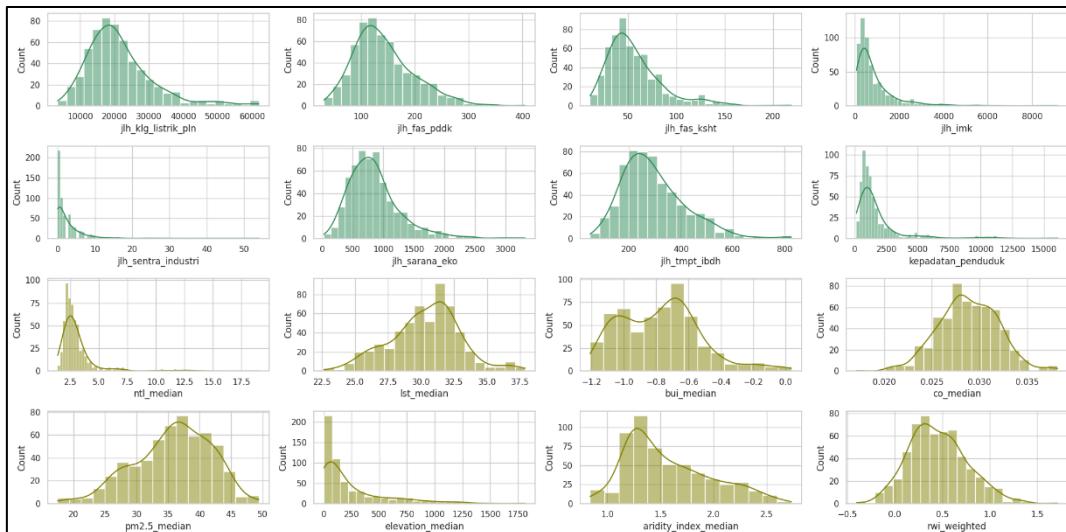
No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
336	3317120	Kragan	15,706	12,618	12,651	10,281
337	3317130	Sluke	13,162	12,156	12,183	13,008
338	3317140	Lasem	28,120	16,474	16,380	10,191
339	3318010	Sukolilo	10,500	9,284	9,269	10,775
340	3318020	Kayen	10,382	9,114	9,112	10,414
341	3318030	Tambakromo	17,830	12,978	12,934	10,199
342	3318040	Winong	21,004	14,275	14,284	10,940
343	3318050	Pucakwangi	8,771	8,109	8,128	10,735
344	3318060	Jaken	9,273	8,409	8,366	10,652
345	3318070	Batangan	9,022	7,986	7,953	10,331
346	3318080	Juwana	8,057	7,221	7,226	10,340
347	3318090	Jakenan	15,468	11,955	11,857	10,402
348	3318100	Pati	15,217	10,310	10,349	10,435
349	3318110	Gabus	15,174	11,586	11,655	10,024
350	3318120	Margorejo	4,522	4,468	4,477	13,523
351	3318130	Gembong	6,452	6,293	6,289	10,245
352	3318140	Tlogowungu	23,303	17,239	17,082	10,813
353	3318150	Wedarijaka	10,089	8,677	8,600	10,514
354	3318160	Trangkil	11,986	10,704	10,601	13,775
355	3318170	Margoyoso	8,351	7,670	7,667	10,270
356	3318180	Gunung Wungkal	17,154	14,437	14,318	10,294
357	3318190	Cluwak	11,588	10,774	10,734	10,845
358	3318200	Tayu	9,351	8,385	8,422	11,357
359	3318210	Dukuhseti	6,700	6,387	6,387	10,749
360	3319010	Kaliwungu	7,895	7,219	7,205	10,179
361	3319020	Kota Kudus	10,705	8,563	8,532	10,361
362	3319030	Jati	7,650	6,954	6,934	10,295
363	3319040	Undaan	5,980	5,734	5,729	10,264
364	3319050	Mejobo	10,631	9,336	9,284	10,088
365	3319060	Jekulo	5,812	5,553	5,561	10,283
366	3319070	Bae	27,929	17,273	17,205	16,588
367	3319080	Gebog	7,812	7,394	7,420	10,412
368	3319090	Dawe	8,998	8,380	8,407	10,287
369	3320010	Kedung	19,426	13,816	13,781	12,836
370	3320020	Pecangaan	14,328	11,614	11,604	10,500
371	3320021	Kalinyamatian	15,309	11,381	11,384	10,430
372	3320030	Welahan	17,884	12,715	12,792	10,451
373	3320040	Mayong	15,936	12,495	12,450	10,444
374	3320050	Nalumsari	2,844	2,822	2,822	10,427
375	3320060	Batealit	31,772	20,192	19,983	11,884
376	3320070	Tahunan	15,745	11,872	11,988	10,828
377	3320080	Jepara	34,660	15,422	15,416	10,897
378	3320090	Mlonggo	22,647	15,116	15,187	10,107
379	3320091	Pakis Aji	8,341	8,101	8,096	25,274
380	3320100	Bangsri	12,202	11,144	11,207	10,448
381	3320101	Kembang	8,464	8,041	8,055	10,367
382	3320110	Keling	9,483	8,963	9,001	10,110
383	3320111	Donorojo	7,206	6,920	6,913	10,726
384	3321010	Mranggen	19,124	13,588	13,527	11,992
385	3321020	Karangawen	13,720	11,294	11,311	10,794
386	3321030	Guntur	13,218	10,875	10,999	10,507
387	3321040	Sayung	15,627	11,505	11,605	10,382
388	3321050	Karang Tengah	19,176	13,302	13,359	9,964
389	3321060	Bonang	12,510	10,592	10,626	15,537
390	3321070	Demak	15,443	11,542	11,505	11,039
391	3321080	Wonosalam	19,139	14,007	14,057	10,765
392	3321090	Dempet	11,993	10,129	10,164	10,556
393	3321091	Kebonagung	14,071	11,764	11,729	10,661
394	3321100	Gajah	10,130	9,108	9,113	10,699
395	3321110	Karanganyar	12,935	10,688	10,661	10,954
396	3321120	Mijen	35,201	18,414	18,252	23,619
397	3321130	Wedung	11,783	10,017	10,021	10,162
398	3322010	Getasan	13,516	12,781	12,868	13,170
399	3322020	Tengaran	13,410	12,010	12,026	10,436
400	3322030	Susukan	11,380	10,829	10,882	13,071
401	3322031	Kaliwungu	4,501	4,435	4,432	10,246

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
402	3322040	Suruh	15,570	13,245	13,193	10,712
403	3322050	Pabelan	27,069	18,536	18,419	10,105
404	3322060	Tuntang	44,498	20,010	19,269	17,292
405	3322070	Banyubiru	14,403	13,836	13,655	17,183
406	3322080	Jambu	15,898	14,687	14,558	11,465
407	3322090	Sumowono	36,673	27,005	26,219	10,769
408	3322100	Ambarawa	17,710	13,493	13,316	10,401
409	3322101	Bandungan	15,121	13,262	13,198	10,848
410	3322110	Bawen	17,405	13,736	13,463	10,235
411	3322120	Bringin	14,462	12,502	12,361	11,592
412	3322121	Bancak	10,293	9,564	9,579	11,469
413	3322130	Pringapus	15,379	12,297	12,056	10,184
414	3322140	Bergas	13,361	11,494	11,344	10,589
415	3322151	Ungaran Barat	23,215	17,644	17,482	13,344
416	3322152	Ungaran Timur	11,760	10,372	10,397	10,333
417	3323010	Parakan	18,280	15,203	15,047	10,193
418	3323011	Kledung	32,639	24,935	24,834	10,055
419	3323012	Bansari	16,230	14,688	14,702	10,544
420	3323020	Bulu	17,218	14,984	14,934	15,299
421	3323030	Temanggung	16,990	12,969	13,064	11,083
422	3323031	Tlogomulyo	21,155	18,386	18,367	20,610
423	3323040	Tembarak	5,366	5,271	5,280	10,767
424	3323041	Selopampang	14,326	13,287	13,249	12,496
425	3323050	Kranggan	11,867	11,018	11,032	11,824
426	3323060	Pringsurat	25,271	19,348	19,504	10,157
427	3323070	Kaloran	14,239	13,290	13,297	21,480
428	3323080	Kandangan	18,867	16,622	16,627	25,342
429	3323090	Kedu	16,432	14,511	14,562	22,267
430	3323100	Ngadirejo	21,789	17,202	17,496	10,899
431	3323110	Jumo	4,673	4,640	4,638	16,899
432	3323111	Gemawang	39,865	26,925	27,903	10,436
433	3323120	Candiroto	26,638	21,410	21,428	10,633
434	3323121	Bejen	12,418	11,794	11,779	10,568
435	3323130	Tretep	19,254	17,907	17,995	10,893
436	3323131	Wonoboyo	11,524	11,149	11,161	11,434
437	3324010	Plantungan	8,648	8,423	8,420	10,510
438	3324020	Sukorejo	20,736	17,384	17,196	10,573
439	3324030	Pagerruyung	22,133	18,102	18,378	11,769
440	3324040	Patean	12,741	11,603	11,657	12,217
441	3324050	Singorojo	11,387	10,517	10,515	10,357
442	3324060	Limbangan	14,204	13,031	13,020	10,103
443	3324070	Boja	19,267	14,028	14,104	10,258
444	3324080	Kaliwungu	12,568	10,229	10,191	11,299
445	3324081	Kaliwungu Selatan	19,207	16,121	16,424	18,560
446	3324090	Brangsong	18,583	14,093	14,187	10,308
447	3324100	Pegandon	4,504	4,414	4,412	9,851
448	3324101	Ngampel	2,749	2,728	2,728	10,946
449	3324110	Gemuh	3,783	3,717	3,715	10,149
450	3324111	Ringinarum	9,407	8,920	8,886	13,771
451	3324120	Weleri	24,717	15,198	15,243	10,021
452	3324130	Rowosari	8,705	7,980	7,983	10,640
453	3324140	Kangkung	10,249	9,170	9,199	10,267
454	3324150	Cepiring	26,393	16,100	16,101	10,460
455	3324160	Patebon	23,418	15,143	15,259	10,132
456	3324170	Kendal	8,884	8,136	8,139	10,693
457	3325010	Wonotunggal	17,210	14,938	14,872	12,488
458	3325020	Bandar	9,265	8,852	8,870	9,923
459	3325030	Blado	23,038	19,408	19,443	10,423
460	3325040	Reban	15,065	13,930	13,929	10,005
461	3325050	Bawang	13,666	12,769	12,733	10,144
462	3325060	Tersono	16,605	14,470	14,421	10,456
463	3325070	Gringsing	20,009	15,507	15,709	11,719
464	3325080	Limpung	15,658	13,128	13,191	10,951
465	3325081	Banyuputih	23,622	17,073	17,360	11,596
466	3325090	Subah	6,049	5,880	5,877	10,194
467	3325091	Pecalungan	13,075	12,135	12,145	13,330

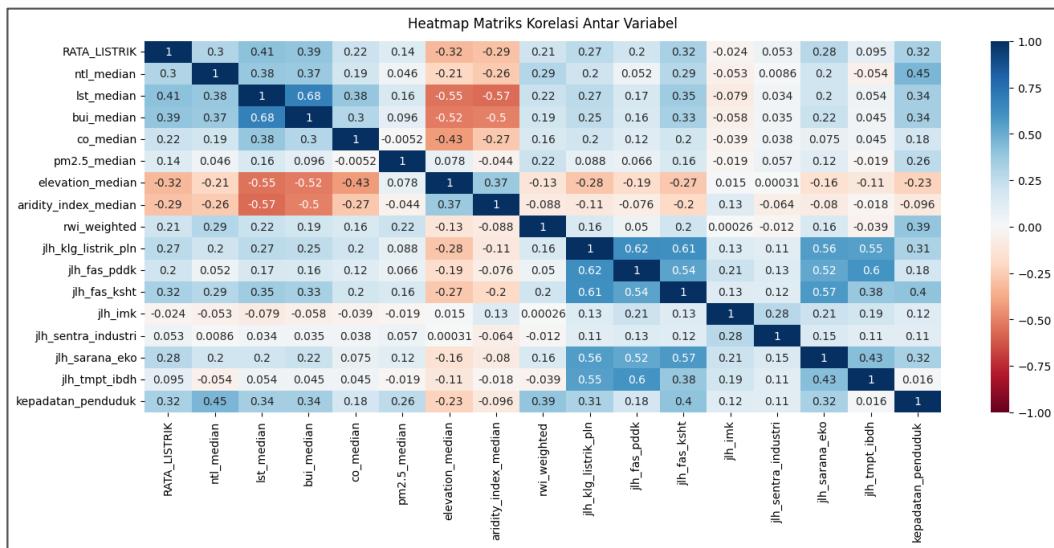
No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
468	3325100	Tulis	17,356	13,647	13,800	10,559
469	3325101	Kandeman	17,689	13,670	13,730	10,705
470	3325110	Batang	15,736	11,606	11,655	10,262
471	3325120	Warungasem	10,530	9,436	9,465	11,505
472	3326010	Kandangserang	17,259	15,603	15,654	12,640
473	3326020	Paniggaran	10,287	9,890	9,912	10,681
474	3326030	Lebakbarang	3,750	3,736	3,737	10,851
475	3326040	Petungkriono	0,000	0,000	0,000	11,531
476	3326050	Talun	19,036	16,430	16,551	10,521
477	3326060	Doro	30,087	20,574	20,570	11,146
478	3326070	Karanganyar	25,662	17,799	17,797	10,500
479	3326080	Kajen	10,971	9,836	9,830	10,002
480	3326090	Kesesi	12,591	10,565	10,569	12,470
481	3326100	Sragi	9,475	8,753	8,757	16,304
482	3326101	Siwalan	20,707	15,055	15,148	11,206
483	3326110	Bojong	11,011	9,696	9,696	10,828
484	3326120	Wonopringgo	11,653	10,295	10,291	10,976
485	3326130	Kedungwuni	6,196	5,800	5,810	10,337
486	3326131	Karangdadap	0,250	0,248	0,248	10,589
487	3326140	Buaran	32,582	16,466	16,682	10,620
488	3326150	Tirto	13,575	11,096	11,114	11,479
489	3326160	Wiradesa	28,425	15,486	15,451	10,365
490	3326161	Wonokerto	35,644	15,593	15,705	10,244
491	3327010	Moga	15,618	13,596	13,672	12,650
492	3327011	Warungpring	13,353	12,219	12,228	17,910
493	3327020	Pulosari	20,039	17,425	17,426	10,765
494	3327030	Belik	7,710	7,460	7,458	10,899
495	3327040	Watukumpul	14,662	13,115	13,145	13,193
496	3327050	Bodeh	19,048	14,563	14,568	10,522
497	3327060	Bantarbolang	7,250	6,908	6,915	9,921
498	3327070	Randudongkal	10,288	9,290	9,298	11,261
499	3327080	Pemalang	14,942	11,625	11,700	10,203
500	3327090	Taman	21,652	14,210	14,240	11,007
501	3327100	Petarukan	18,810	13,551	13,660	10,538
502	3327110	Ampelgading	11,464	10,043	10,116	10,750
503	3327120	Comal	8,654	7,917	7,920	12,124
504	3327130	Ulujami	11,010	9,283	9,372	11,143
505	3328010	Margasari	19,661	15,105	14,896	14,533
506	3328040	Balapulang	17,667	14,041	13,999	10,300
507	3328050	Pagerbarang	11,132	10,067	10,094	10,781
508	3328060	Lebaksiu	10,343	9,390	9,393	10,439
509	3328080	Kedung Banteng	13,245	11,237	11,153	11,194
510	3328090	Pangkah	21,634	15,590	15,851	13,274
511	3328100	Slawi	16,922	12,107	12,023	13,827
512	3328110	Dukuhwaru	12,372	11,075	11,151	11,514
513	3328120	Adiwerna	12,597	10,274	10,283	10,203
514	3328130	Dukuhturi	18,373	12,868	12,621	10,806
515	3328140	Talang	15,644	11,936	11,894	10,237
516	3328150	Tarub	14,000	11,669	11,661	10,131
517	3328160	Kramat	12,071	10,043	9,990	10,968
518	3328170	Suradadi	14,631	12,058	12,060	10,564
519	3328180	Warureja	24,404	15,982	15,859	11,986
520	3329010	Salem	15,826	13,635	13,607	10,600
521	3329020	Bantarkawung	6,801	6,609	6,609	12,915
522	3329030	Bumiayu	19,357	14,567	14,483	10,550
523	3329040	Paguyangan	10,986	10,472	10,462	10,638
524	3329050	Sirampog	30,698	23,667	23,483	10,516
525	3329060	Tonjong	14,406	12,594	12,707	10,667
526	3329070	Larangan	16,046	12,495	12,462	10,983
527	3329080	Ketanggungan	11,281	9,769	9,814	10,472
528	3329090	Banjarharjo	12,216	10,711	10,773	10,655
529	3329100	Losari	16,092	12,177	12,070	14,520
530	3329110	Tanjung	15,548	11,994	11,924	10,152
531	3329120	Kersana	29,779	16,508	16,199	10,135
532	3329130	Bulakamba	15,986	11,100	11,017	10,390
533	3329140	Wanasari	7,934	7,231	7,217	10,330

No	Kode kecamatan	Nama kecamatan	Penduga langsung	Penduga EBLUP-FH	Penduga SEBLUP-FH	Penduga HB- <i>Lognormal</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)
534	3329150	Songgom	4,227	4,143	4,141	10,179
535	3329160	Jatibarang	14,729	11,248	11,247	10,762
536	3329170	Brebes	19,996	12,451	12,385	10,071
537	3371010	Magelang Selatan	16,142	12,448	12,296	10,578
538	3371011	Magelang Tengah	8,233	7,437	7,426	10,494
539	3371020	Magelang Utara	12,217	10,167	10,171	10,096
540	3372010	Laweyan	7,276	6,547	6,599	10,332
541	3372020	Serengan	20,970	12,330	12,304	10,496
542	3372030	Pasar Kliwon	11,670	8,749	8,791	12,279
543	3372040	Jebres	10,076	7,747	7,821	15,072
544	3372050	Banjarsari	15,947	9,828	9,757	10,449
545	3373010	Argomulyo	7,142	6,818	6,816	10,542
546	3373020	Tingkir	8,956	8,321	8,310	10,445
547	3373030	Sidomukti	8,223	7,667	7,668	10,111
548	3373040	Sidorejo	8,371	7,664	7,655	10,292
549	3374010	Mijen	44,433	20,337	20,005	19,709
550	3374020	Gunung Pati	14,096	11,995	11,859	10,098
551	3374030	Banyumanik	15,027	11,343	11,319	10,655
552	3374040	Gajah Mungkur	18,757	12,278	12,151	11,458
553	3374050	Semarang Selatan	10,860	8,541	8,505	11,286
554	3374060	Candisari	26,044	13,463	13,368	10,235
555	3374070	Tembalang	13,277	10,218	10,201	10,372
556	3374080	Pedurungan	20,458	11,071	11,157	9,906
557	3374090	Genuk	9,409	8,096	8,057	10,529
558	3374100	Gayamsari	22,234	12,806	12,958	10,077
559	3374110	Semarang Timur	18,630	12,191	12,171	10,262
560	3374120	Semarang Utara	16,726	11,026	11,209	10,949
561	3374130	Semarang Tengah	22,265	11,261	11,198	27,106
562	3374140	Semarang Barat	20,248	10,316	10,258	10,208
563	3374150	Tugu	60,816	17,524	16,965	17,422
564	3374160	Ngaliyan	18,949	12,762	12,654	10,440
565	3375010	Pekalongan Barat	10,131	8,710	8,649	10,126
566	3375020	Pekalongan Timur	16,263	11,463	11,381	9,759
567	3375030	Pekalongan Selatan	10,696	9,334	9,318	10,567
568	3375040	Pekalongan Utara	14,686	10,752	10,722	10,124
569	3376010	Tegal Selatan	9,525	8,356	8,291	10,023
570	3376020	Tegal Timur	12,143	9,815	9,673	11,282
571	3376030	Tegal Barat	13,464	10,373	10,224	10,399
572	3376040	Margadana	18,775	13,444	13,248	11,247

Lampiran 3. Histogram data seluruh kandidat variabel penyerta



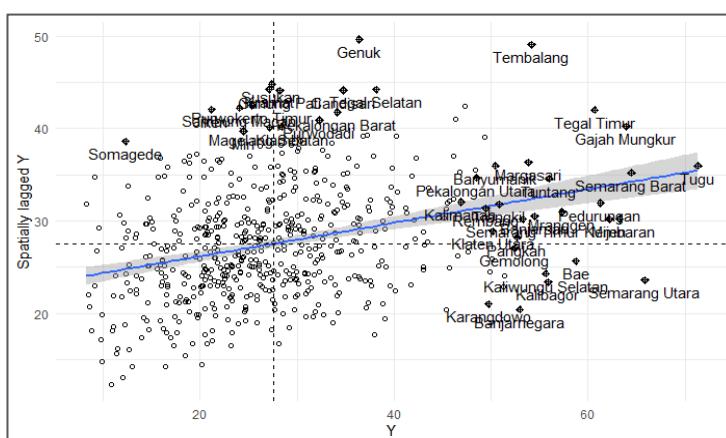
Lampiran 4. Heatmap matriks korelasi Kendall-Tau seluruh variabel



Lampiran 5. Tabel hasil estimasi koefisien regresi dan koefisien ragam pengaruh acak model SAE EBLUP-FH

Variabel penyerta	Estimasi koefisien	Standard error	P-value
(1)	(2)	(3)	(4)
Intercept (b_0)	27,8024	2,4605	$1,3194 \times 10^{-29}$
Jumlah tempat ibadah (b_1)	-0,0067	0,0031	$2,764 \times 10^{-2}$
Jumlah sarana dan prasarana ekonomi (b_2)	0,0064	0,0009	$2,0953 \times 10^{-11}$
Build-Up Index (b_3)	11,7122	1,6722	$2,4879 \times 10^{-12}$
Konsentrasi PM _{2.5} (b_4)	0,1312	0,0547	$1,6503 \times 10^{-2}$
Elevation (b_5)	-0,0064	0,0012	$4,7032 \times 10^{-8}$
Relative Wealth Index (b_6)	1,8265	1,1152	$1,0146 \times 10^{-1}$
Ragam pengaruh acak area ($\hat{\sigma}_v^2$)	33,1056		

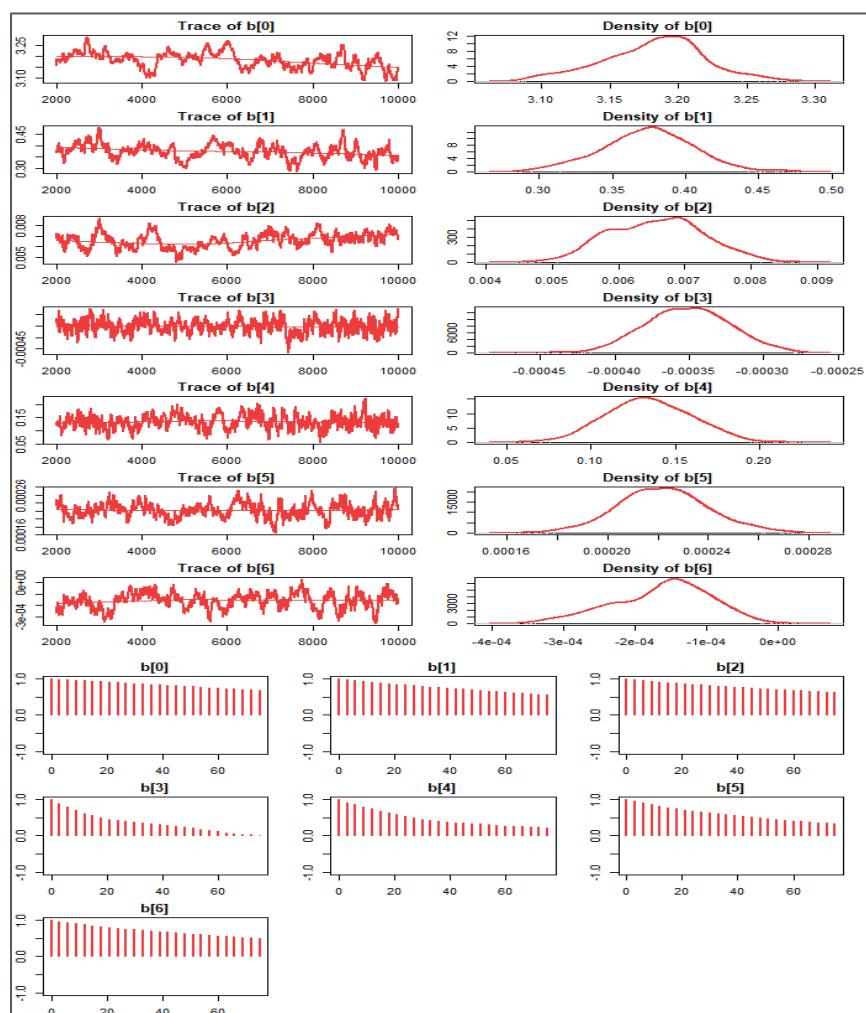
Lampiran 6. Moran's I scatter plot dari penduga langsung



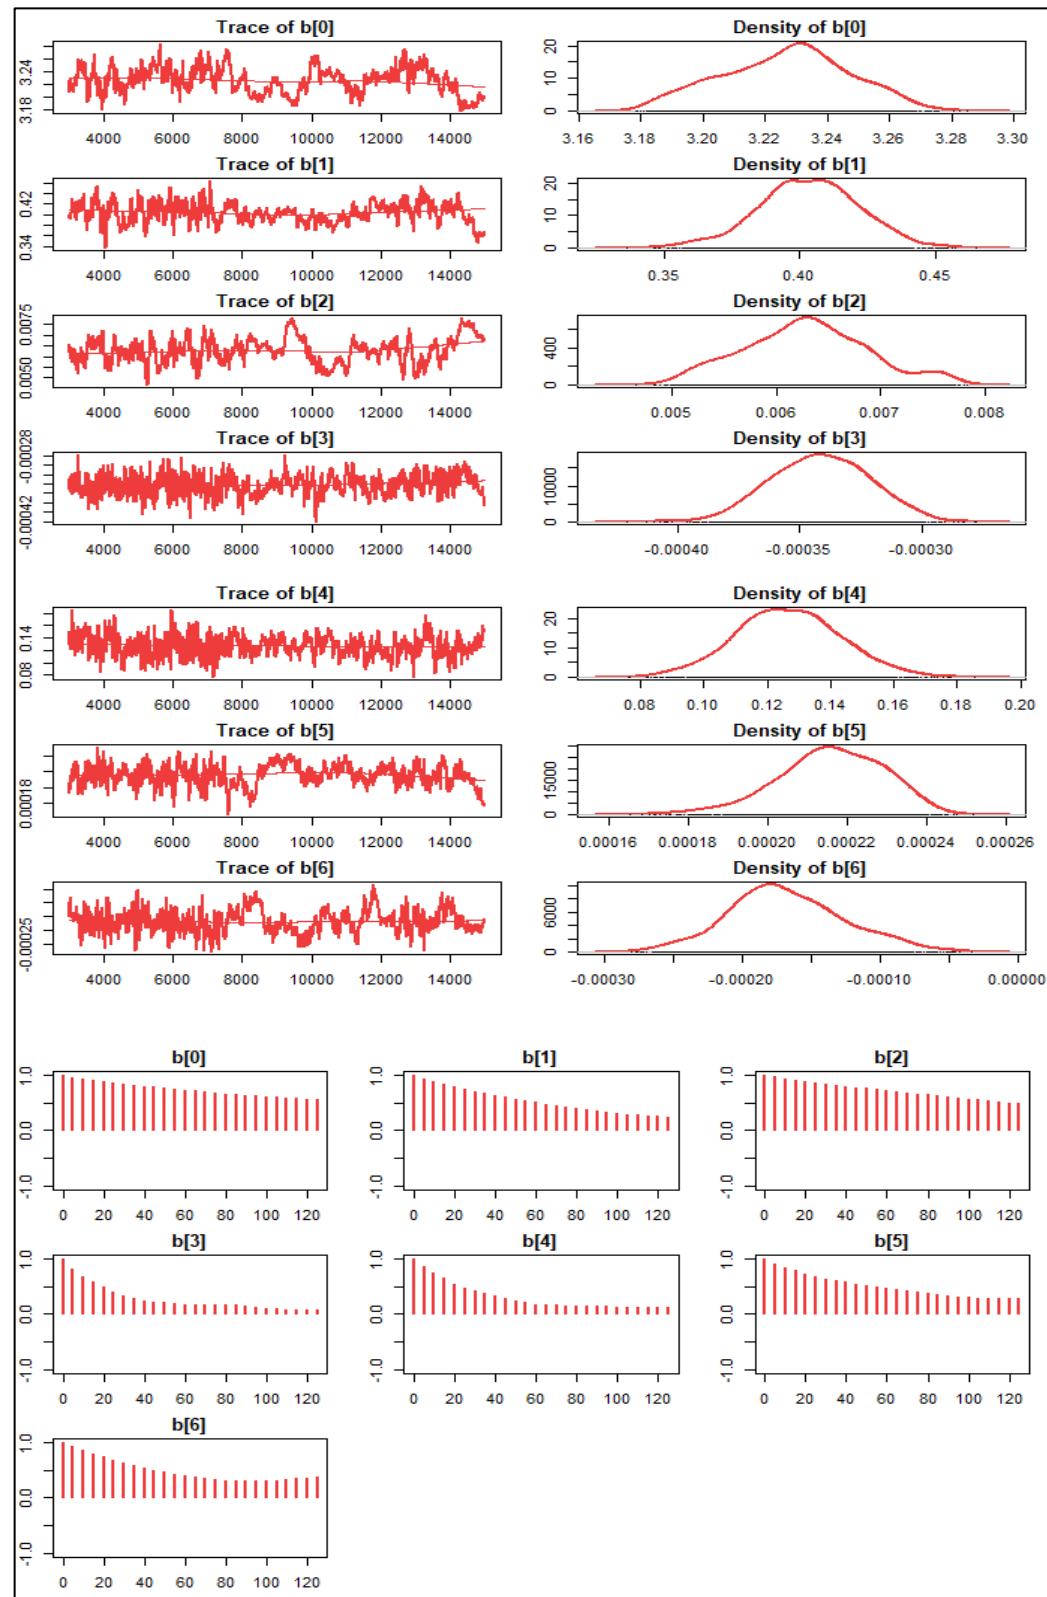
Lampiran 7. Tabel hasil estimasi koefisien regresi, koefisien ragam pengaruh acak, dan koefisien autoregresif spasial model SAE SEBLUP-FH

Variabel penyerta	Estimasi koefisien	Standard error	P-value
(1)	(2)	(3)	(4)
Intercept (b_0)	27,9392	2,5418	$4,1909 \times 10^{-28}$
Jumlah tempat ibadah (b_1)	-0,0074	0,0031	$1,5929 \times 10^{-2}$
Jumlah sarana dan prasarana ekonomi (b_2)	0,0064	0,0009	$2,4882 \times 10^{-11}$
Build-Up Index (b_3)	11,8871	1,6979	$2,5411 \times 10^{-12}$
Konsentrasi PM _{2,5} (b_4)	0,1375	0,0566	$1,5197 \times 10^{-2}$
Elevation (b_5)	-0,0062	0,0012	$2,3376 \times 10^{-7}$
Relative Wealth Index (b_6)	1,6733	1,1252	$1,3698 \times 10^{-1}$
Ragam pengaruh acak area ($\hat{\sigma}_v^2$)	32,9143		
Autoregresi spasial ($\hat{\rho}$)	0,1177		

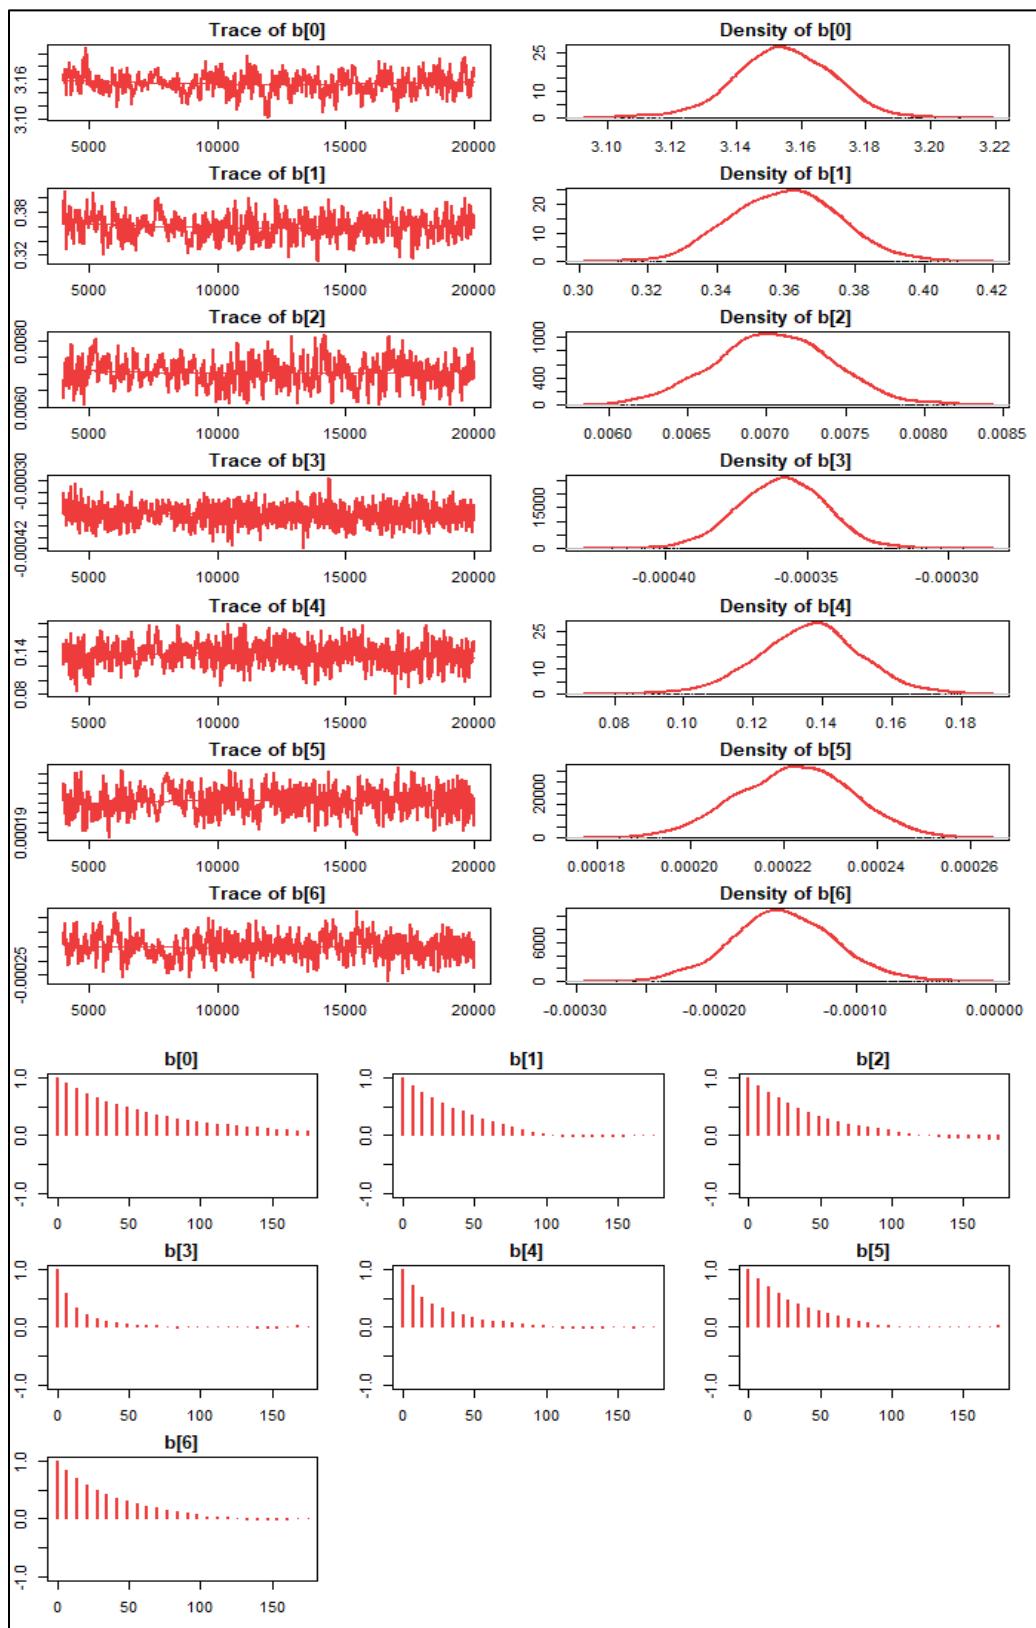
Lampiran 8. Trace plot, density plot, dan autocorrelation plot model HB Lognormal percobaan ke-1



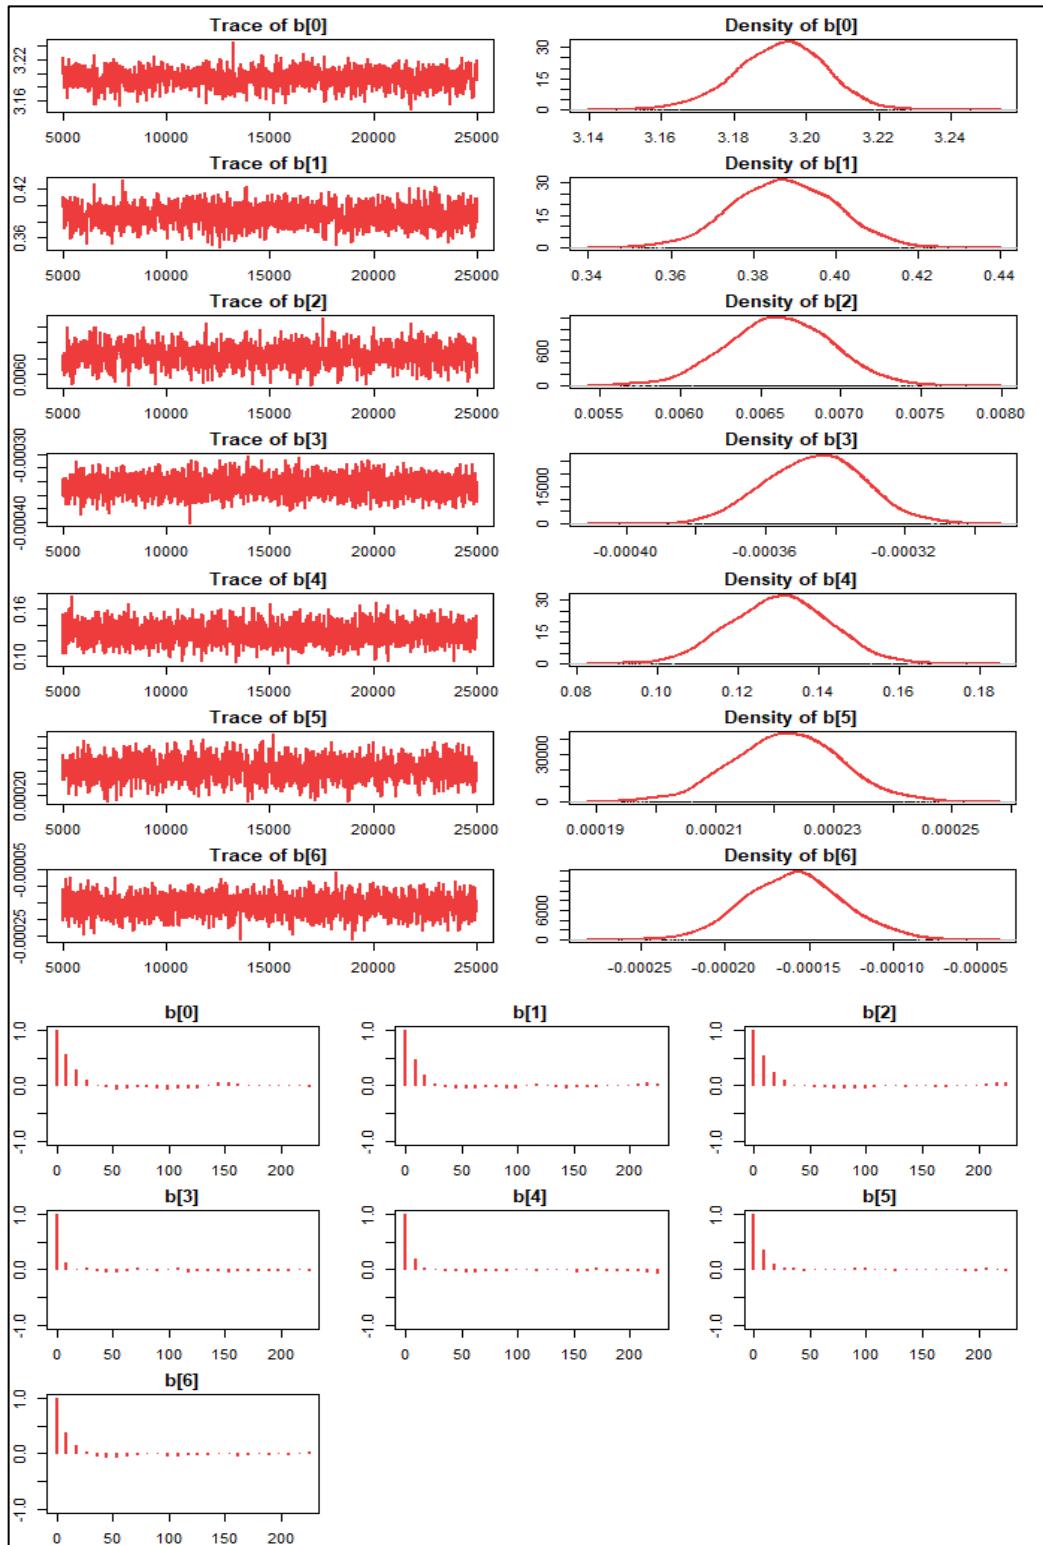
Lampiran 9. Trace plot, density plot, dan autocorrelation plot model HB Lognormal percobaan ke-2



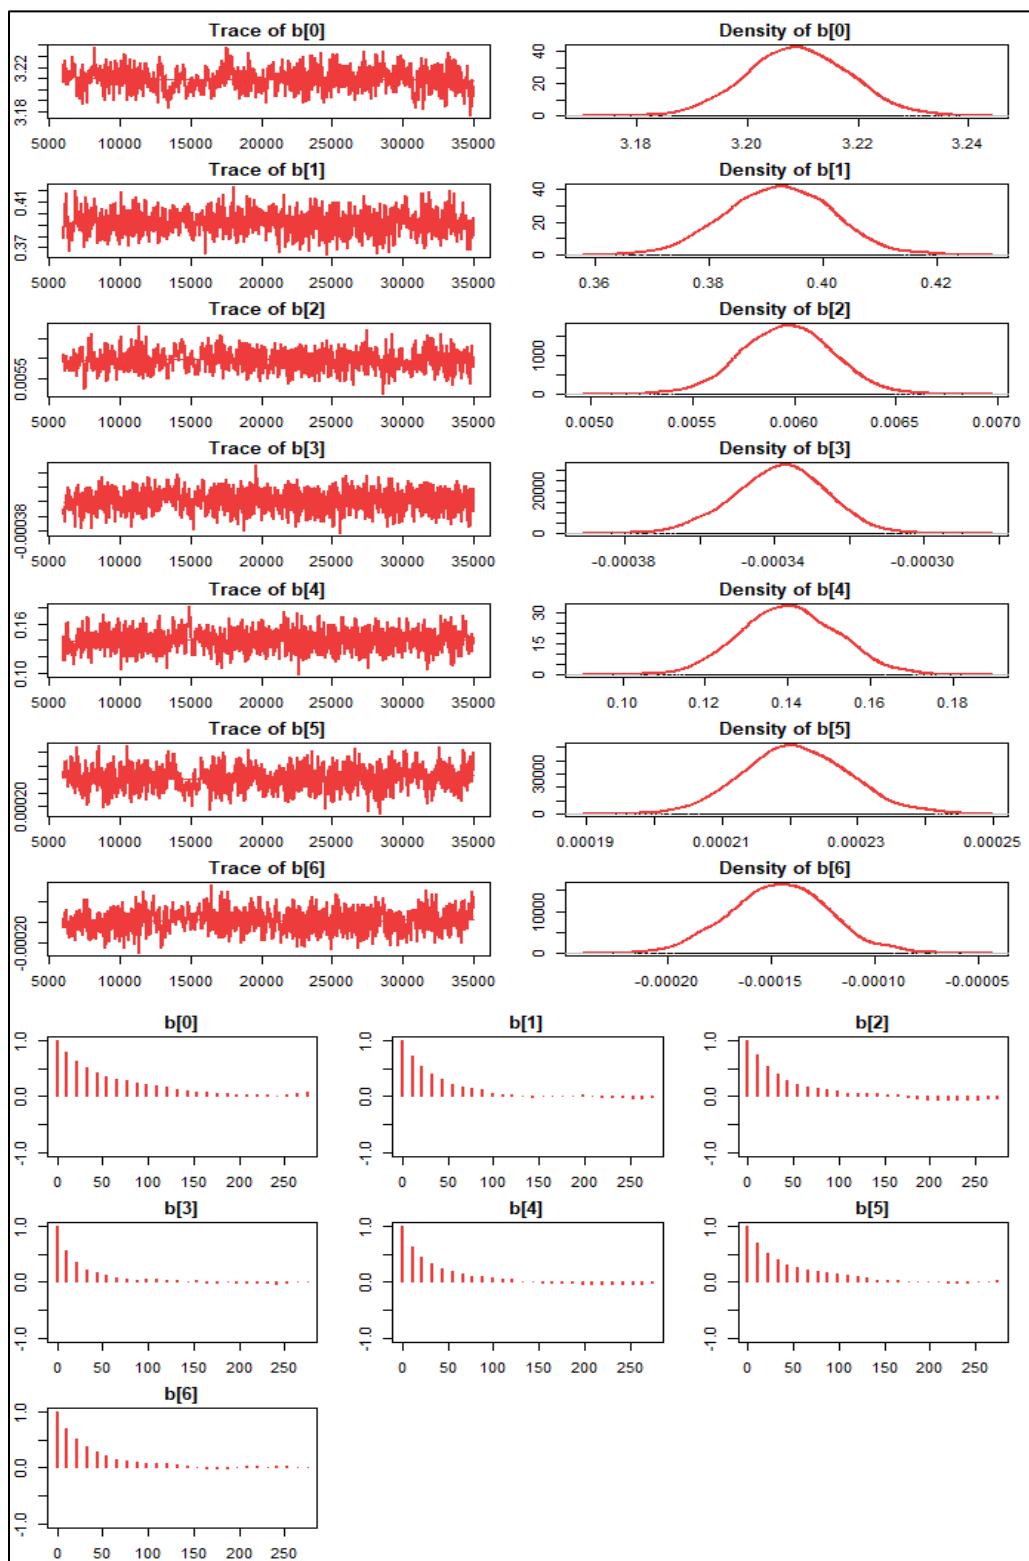
Lampiran 10. Trace plot, density plot, dan autocorrelation plot model HB Lognormal percobaan ke-3



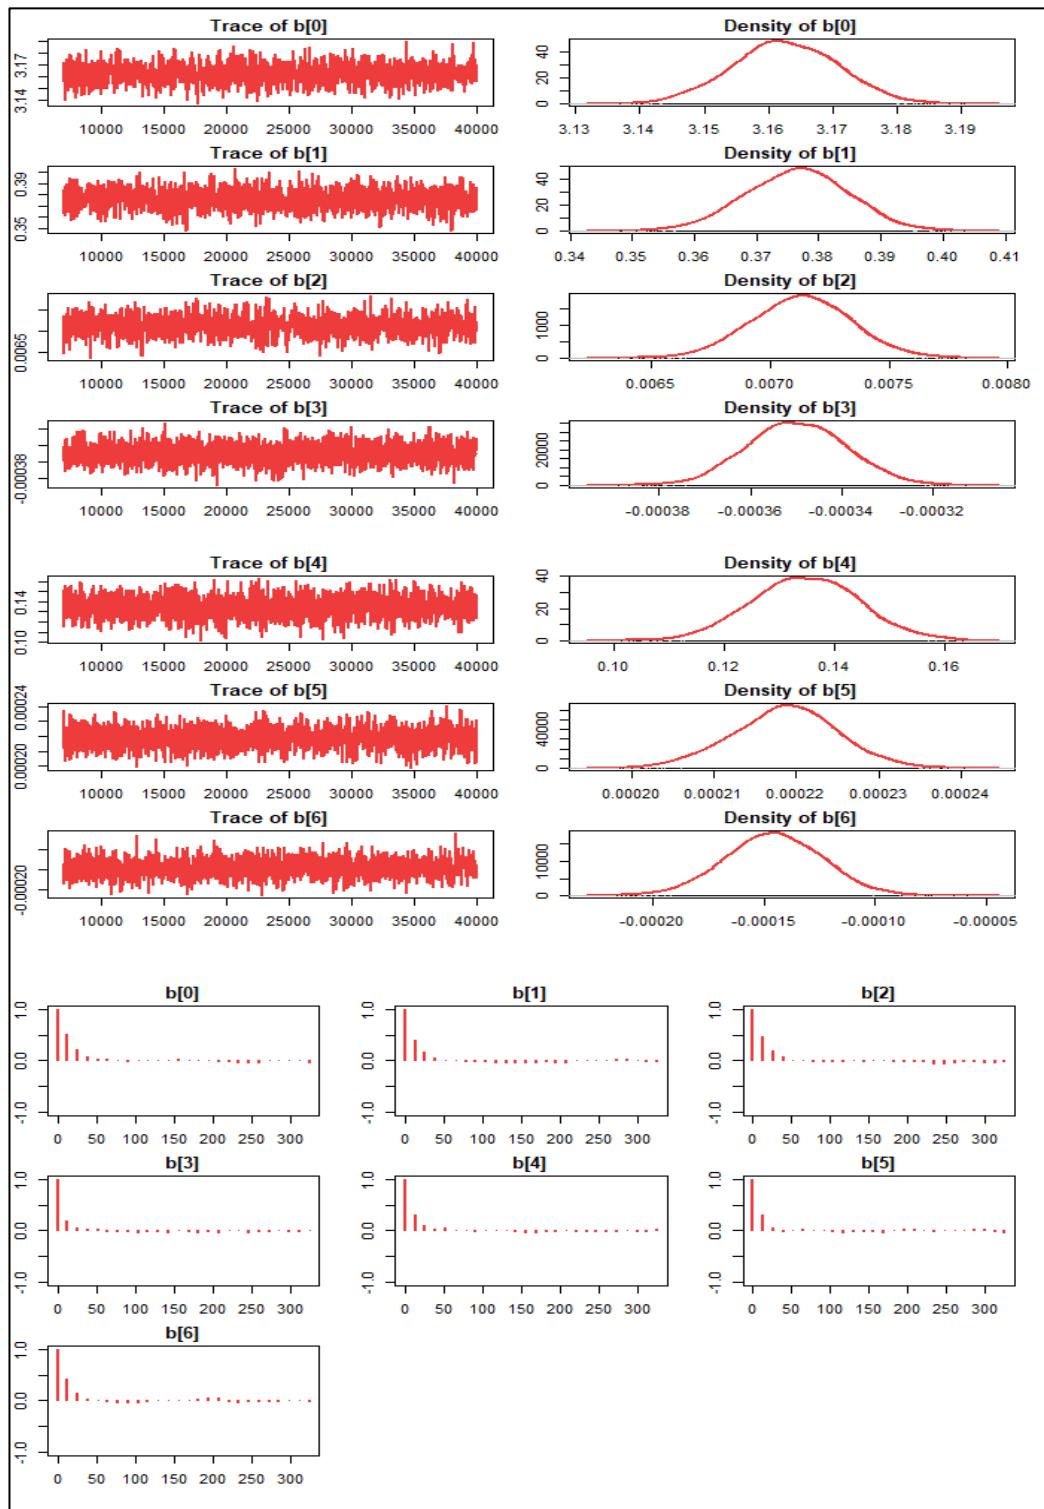
Lampiran 11. Trace plot, density plot, dan autocorrelation plot model HB Lognormal percobaan ke-4



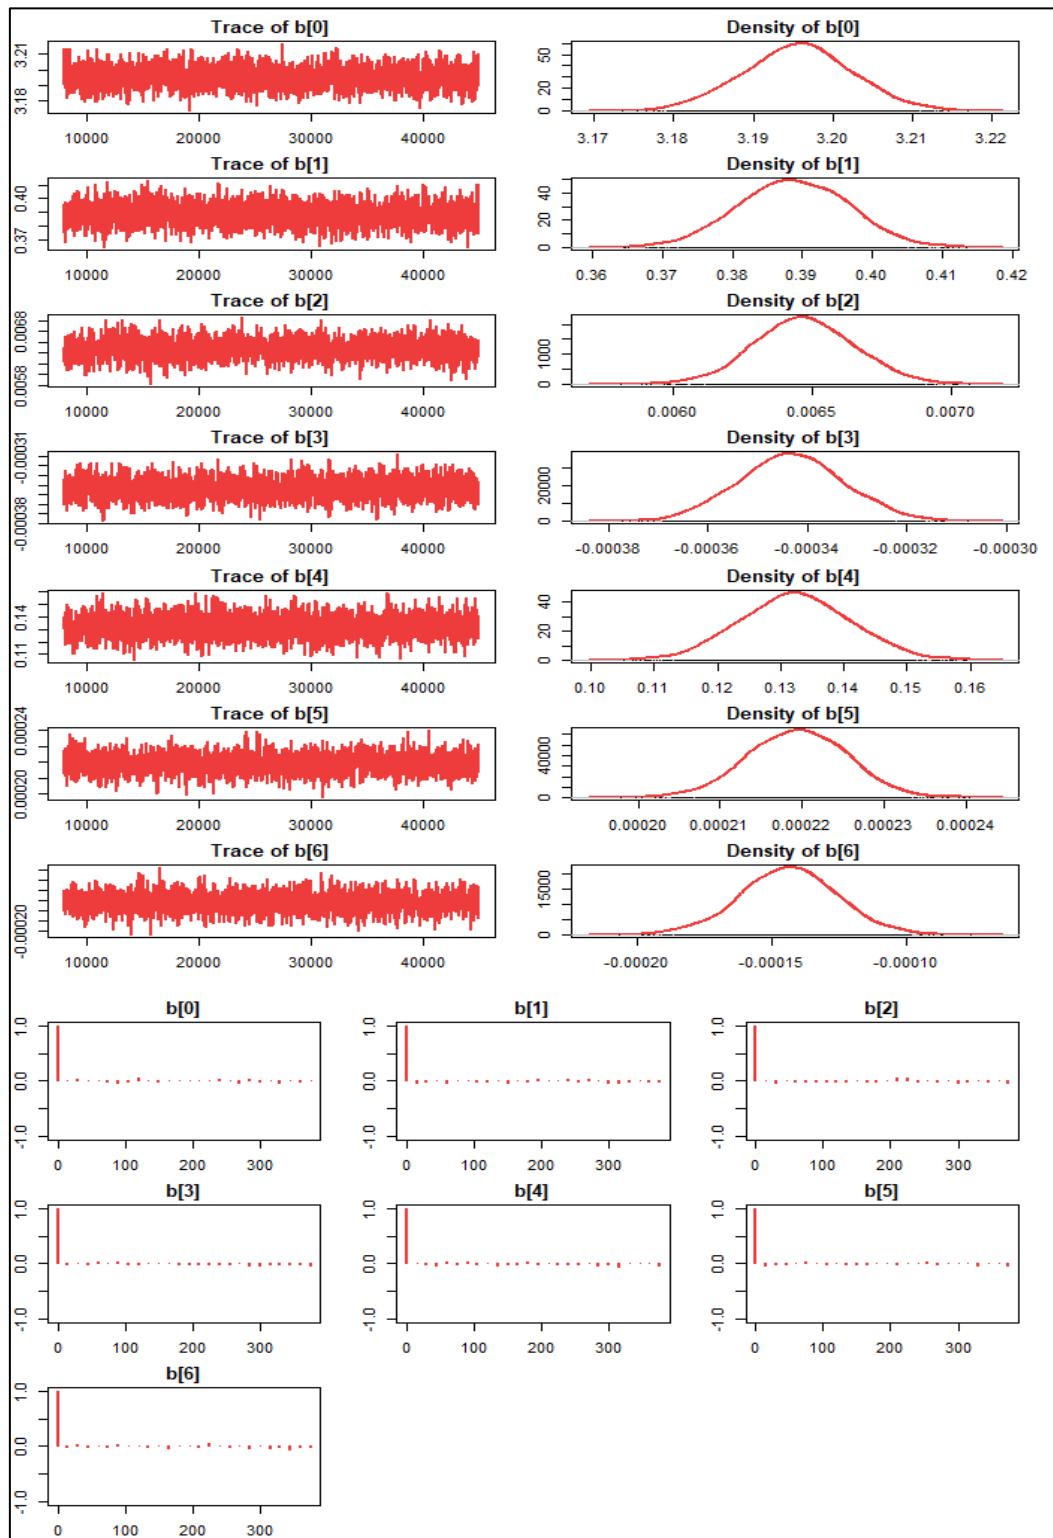
Lampiran 12. Trace plot, density plot, dan autocorrelation plot model HB Lognormal percobaan ke-5



Lampiran 13. Trace plot, density plot, dan autocorrelation plot model HB Lognormal percobaan ke-6



Lampiran 14. Trace plot, density plot, dan autocorrelation plot model HB Lognormal percobaan ke-7



Lampiran 15. Kode javascript ekstraksi *night-time light* (NTL) di GEE

```
// Import region data
var jateng = ee.FeatureCollection("projects/ee-221910812/assets/
    JawaTengah_KEC");
// Import and filtering nighttime data
var collection = ee.ImageCollection("NOAA/VIIRS/DNB/MONTHLY_V1/VCMSLCFG")
    .filter(ee.Filter.date('2021-01-01', '2021-12-31'))
    .select('avg_rad');
// Visualization parameter
var nighttimeVis = {
    min: 0, max: 20
};
// Median reducing and clip region
var median_ntl_jateng = collection.reduce(ee.Reducer.median()).clip(jateng);
// Visualizing
Map.centerObject(jateng, 10);
Map.addLayer(median_ntl_jateng, nighttimeVis, 'NTL_Jateng');
// Export GeoTIFF image
Export.image.toDrive({
    image: median_ntl_jateng,
    folder: 'SKRIPSI_RAFLI',
    description: 'NTL_JATENG',
    fileNamePrefix: 'NTL_JATENG',
    scale: 463.83,
    region: jateng,
    maxPixels: 1e13,
    fileFormat: 'GeoTIFF'
});
```

Lampiran 16. Kode javascript ekstraksi *land surface temperature* (LST) di GEE

```
// Import region data
var jateng = ee.FeatureCollection("projects/ee-221910812/assets/
    JawaTengah_KEC");
// Quality Assessment (cloud mask)
function masking(image) {
    var qa = image.select('QC_Day');
    var Mandatory = 1 << 1;
    var DataQuality = 1 << 3;
    var LSTerror = 1 << 7;
    var mask = qa.bitwiseAnd(Mandatory).eq(0)
        .and(qa.bitwiseAnd(DataQuality).eq(0))
        .and(qa.bitwiseAnd(LSTerror).eq(0));
    return image.updateMask(mask);
}
// Import and filtering LST data
var MODIS = ee.ImageCollection("MODIS/061/MOD11A1");
var LST = MODIS.filter(ee.Filter.date('2021-01-01', '2021-12-31'))
    .map(masking)
    .select('LST_Day_1km');
// Median reducing and clip region
var LST_median_jateng = LST.median().clip(jateng);
// Visualization parameter
var LST_Vis = {
    palette: ['green', 'orange', 'red']
};
// Visualization
Map.centerObject(jateng, 10);
Map.addLayer(LST_median_jateng, LST_Vis, 'Daytime LST');
// Export GeoTIFF Image
Export.image.toDrive({
    image : LST_median_jateng,
```

```

description: '2021_Jateng_MODIS',
folder : 'SKRIPSI_RAFLI',
region: jateng,
scale : 1000,
maxPixels: 1e10 );

```

Lampiran 17. Kode javascript ekstraksi *build-up index* (BUI) di GEE

```

// Import region data
var jateng = ee.FeatureCollection("projects/ee-221910812/assets/
    JawaTengah_KEC");
// Create cloud masking function
var masking = function CloudMask(image) {
    var QA60 = image.select(['QA60']);
    var clouds = QA60.bitwiseAnd(1<<10).or(QA60.bitwiseAnd(1<<11)); // this gives
us cloudy pixels
    return image.updateMask(clouds.not()); // remove the clouds from image
};
// Import and filtering data S2, cloud selection, and cloud masking
var S2_masked = ee.ImageCollection('COPERNICUS/S2_SR')
    .filterDate("2021-01-01", "2021-12-31")
    .filterBounds(jateng)
    .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 20))
    .map(masking);
// Reducing an ImageCollection
var S2_masked_median = S2_masked.median();
// Band Selection
Map.addLayer(S2_masked_median.clip(jateng), {bands:['B4','B3','B2'], min:0,
max:3000}, 'True-colour-p1');
Map.addLayer(S2_masked_median.clip(jateng), {bands:['B8','B3','B2'], min:0,
max:3000}, 'False-colour');
Map.centerObject(jateng, 10);
// Compute BUI (Band Compositing)
var BUI = S2_masked_median.expression(
    "((SWIR - NIR) / (SWIR + NIR)) - ((NIR-RED)/(NIR+RED)) ",
    {
        RED : S2_masked_median.select("B4"),
        NIR : S2_masked_median.select("B8"),
        SWIR : S2_masked_median.select("B11")
    });
// Visualizing
Map.addLayer(BUI.clip(jateng), {min:-2, max:1}, "BUI");
// Export GeoTIFF Image
Export.image.toDrive({
    image: BUI.clip(jateng),
    folder: 'SKRIPSI_RAFLI',
    description: 'BUI_JATENG_CLODMASK',
    fileNamePrefix: 'BUI_JATENG_CLODMASK',
    scale: 10,
    region: jateng,
    maxPixels: 1e13,
    fileFormat: 'GeoTIFF'
});

```

Lampiran 18. Kode javascript ekstraksi kepadatan senyawa CO di GEE

```

// Import region data
var jateng = ee.FeatureCollection("projects/ee-221910812/assets/
    JawaTengah_KEC");
// Import and filtering data CO
var co = ee.ImageCollection('COPERNICUS/S5P/NRTI/L3_CO')
    .select('CO_column_number_density')
    .filterDate('2021-01-01', '2021-12-31')

```

```

.filterBounds(jateng);
// Create a reducer that will compute the median of the inputs
var co_median = co.reduce(ee.Reducer.median()).clip(jateng);
// Visualization parameter
Map.centerObject(jateng);
var band_viz = {
  min: 0, max: 0.05,
  palette: ['black', 'blue', 'purple', 'cyan', 'green', 'yellow', 'red']
};
// Visualizing
Map.addLayer(co_median, band_viz, 'S5P CO');
// Export GeoTIFF Image
Export.image.toDrive({
  image: co_median,
  description: 'JATENG_CO',
  folder: 'SKRIPSI_RAFLI',
  fileNamePrefix: 'JATENG_CO',
  region: jateng,
  scale: 1113.2,
  maxPixels: 1e9,
  crs: 'EPSG:4326'
});

```

Lampiran 19. Kode javascript ekstraksi *elevation* di GEE

```

// Import region data
var jateng = ee.FeatureCollection("projects/ee-221910812/assets/
  JawaTengah_KEC");
// Import and filter digital elevation model of Elevation and Clip Jateng
var dem = ee.Image('NASA/NASADEM_HGT/001')
  .select('elevation')
  .clip(jateng);
// Median reducing
var dem_median = dem.reduce(ee.Reducer.median());
// Display elevation layers on the map
Map.centerObject(jateng);
Map.addLayer(dem_median, {min:0, max:2000}, 'Elevation');
// Export GeoTIFF Image
Export.image.toDrive({
  image: dem_median,
  description: 'jateng_elevation',
  folder: 'SKRIPSI_RAFLI',
  fileNamePrefix: 'DEM_Elevation_JATENG',
  region: jateng,
  scale: 30,
  maxPixels: 1e9,
  crs: 'EPSG:4326'
});

```

Lampiran 20. Kode python menghitung *population weighted relative wealth index*

```

# Import all required python packages
import pandas as pd
import geopandas as gpd # for managing & interacting with shapefiles
from shapely.geometry import Point # for working with planar point
from shapely.geometry.polygon import Polygon # for working polygon geometries
# Calculating the relationship between XY coordinates & quadkey values
from pyquadkey2 import quadkey
# Create function to calculate the adm. area that contains an input point
def get_point_in_polygon(lat, lon, polygons):
  """
  @param lat: double
  @param lon: double
  """

```

```

@param polygons: dict
@return geo_id: str
"""
point = Point(lon, lat)
for geo_id in polygons:
    polygon = polygons[geo_id]
    if polygon.contains(point):
        return geo_id
return 'null'

# Read in the admn. area shp and create the polygon dictionary
shapefile =
gpd.read_file('E:/GEOJSON/administrasi_jateng/Administrasi_Kecamatan.shp')
polygons = dict(zip(shapefile['idkec'], shapefile['geometry']))
shapefile.head()
# Import Indonesia RWI data
rwi = pd.read_csv('E:/Dataset/rwi_indo/idn_relative_wealth_index.csv')
# Infer which admn. regions contains the centroid of the RWI tile
rwi['geo_id'] = rwi.apply(lambda x: get_point_in_polygon(x['latitude'],
x['longitude'], polygons), axis=1)
rwi = rwi[rwi['geo_id'] != 'null']
# Create the zoom level 14 quadkey id that contains each 2,4km RWI
rwi['quadkey'] = rwi.apply(lambda x: str(quadkey.from_geo((x['latitude'],
x['longitude'])), 14)), axis=1
# Load the population density dataset
population = pd.read_csv('E:/Dataset/rwi_indo/idn_general_2020.csv')
population = population.rename(columns={'idn_general_2020': 'pop_2020'})
# Calculate the zoom level 14 quadkey id for each 30m pop estimate
population['quadkey'] = population.apply(lambda x:
str(quadkey.from_geo((x['latitude'], x['longitude'])), 14)), axis=1
# Calculate the pop per quadkey and load the result aggregate using sum
bing_tile_z14_pop = population.groupby('quadkey',
as_index=False)['pop_2020'].sum()
# Perform inner join using the quadkey field as the common join field
rwi_pop = rwi.merge(bing_tile_z14_pop[['quadkey', 'pop_2020']], on='quadkey',
how='inner')
# Create a dataframe containing a pop estimate for each admn. area
geo_pop = rwi_pop.groupby('geo_id', as_index=False)['pop_2020'].sum()
geo_pop = geo_pop.rename(columns={'pop_2020': 'geo_2020'})
# Perform inner join using the geo_id as a common join field
rwi_pop = rwi_pop.merge(geo_pop, on='geo_id', how='inner')
# Calculate a pop weight value by dividing the pop each RWI with pop each admn.
rwi_pop['pop_weight'] = rwi_pop['pop_2020'] / rwi_pop['geo_2020']
# Weighted RWI value by multiplying the original RWI score with pop weight
rwi_pop['rwi_weight'] = rwi_pop['rwi'] * rwi_pop['pop_weight']
# Aggregate the weighted RWI value by each admn. area using sum method
geo_rwi = rwi_pop.groupby('geo_id', as_index=False)['rwi_weight'].sum()
# Export the result
geo_rwi.to_excel("RWI_Weighted_Pop_Jateng.xlsx")
print('DataFrame is written to Excel File successfully.')

```

Lampiran 21. Kode R menghitung estimasi dengan metode pendugaan langsung

```

# Import library
library(survey)
library(readxl)
library(dplyr)
# Load data and retype variable
listrik_jateng <- read_excel("E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPPSI/SUSENAS/Konsumsi_Listrik_Ruta_Jateng_Susenas_2021.xlsx")
listrik_jateng$KodeProv <- as.factor(listrik_jateng$KodeProv)
listrik_jateng$KodeKabKot <- as.factor(listrik_jateng$KodeKabKot)
listrik_jateng$KodeKec <- as.factor(listrik_jateng$KodeKec)

```

```

listrik_jateng$KlasWil <- as.factor(listrik_jateng$KlasWil)
listrik_jateng$KodeSampel <- as.factor(listrik_jateng$KodeSampel)
listrik_jateng$idkec <- as.factor(listrik_jateng$idkec)
# Check missing data from each variable
sapply(listrik_jateng, function(x) sum(is.na(listrik_jateng)))
# Cek jumlah sampel tiap kecamatan
table(listrik_jateng$KodeProv, listrik_jateng$idkec)
## Estimasi langsung
# Mengatur sampel PSU yang terisolasi dengan metode penyesuaian
options(survey.lonely.psu="adjust")
# Desain survei SUSENAS
susenas.design.jateng <- svydesign(ids = ~PSU+SSU, strata = ~KlasWil,
data=listrik_jateng, weights = ~WEIND)
summary(susenas.design.jateng)
# Menghitung hasil estimasi
hasil <- svyby(formula= ~KONSUMSI_LISTRIK_KAPITA, ~idkec,
design=susenas.design.jateng, deff=TRUE, svymean, vartype = c("se", "ci", "ci",
"cv", "cvpct", "var"))
y_est_lgsg <- hasil$KONSUMSI_LISTRIK_KAPITA
var_est_lgsg <- hasil$var
se_est_lgsg <- hasil$se
ci_lower_est_lgsg <- hasil$ci_l
ci_upper_est_lgsg <- hasil$ci_u
deff_est_lgsg <- hasil$DEff.KONSUMSI_LISTRIK_KAPITA
rse_est_lgsg <- hasil$`cv%` 
mse_est_lgsg <- hasil$var # MSE=VAR karena bias penduga langsung dianggap = 0
# Ekspor hasil estimasi ke penyimpanan lokal
temp <- read_excel("E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/data_estimasi_langsung.xlsx")
data_est_lgsg <- data.frame(temp$KodeKecamatan, temp>NamaKecamatan, y_est_lgsg,
var_est_lgsg, se_est_lgsg, ci_lower_est_lgsg, ci_upper_est_lgsg, deff_est_lgsg,
rse_est_lgsg, mse_est_lgsg)
names(data_est_lgsg) <- c("KodeKec", "NamaKec", "Konsumsi_Listrik_Kapita",
"Var", "SE", "CI_Lower", "CI_Upper", "DEFF", "RSE", "MSE")
write.csv(data_est_lgsg, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/SUSENAS/Hasil_Estimasi_Langsung.csv")

```

Lampiran 22. Kode R seleksi kandidat variabel penyerta

```

# Import library
library(REdaS)
library(stats)
library(ggplot2)
library(ggfortify)
# Load data
dataset <- read_excel("E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/dataset_skripsi_revisi.xlsx", sheet = 1)
# Check missing data
sapply(dataset, function(x) sum(is.na(dataset)))
str(dataset)
# Filter variabel
data_x <- dataset[, -c(1,2,3,4)]
data_y <- dataset[, 4]
# Analisis Deskriptif
summary(data_x)
summary(data_y)
# Uji korelasi kendall-tau penduga langsung dengan setiap kandidat var. penyerta
for(i in 1:ncol(data_x)){
  korelasi <- cor(data_x[, i], data_y, method = "kendall")
  print(paste("Korelasi antara ", colnames(data_x[, i]), "dengan ",
  colnames(data_y), "adalah ", korelasi))
}
cor.test(data_x$ntl_median, data_y$PEND_LGSG, method = "kendall", exact = FALSE)

```

```

cor.test(data_x$bui_median, data_y$PEND_LGSG, method = "kendall", exact = FALSE)
cor.test(data_x$lst_median, data_y$PEND_LGSG, method = "kendall", exact = FALSE)
cor.test(data_x$elevation_median, data_y$PEND_LGSG, method = "kendall", exact = FALSE)
cor.test(data_x$co_median, data_y$PEND_LGSG, method = "kendall", exact = FALSE)
cor.test(data_x$pm2.5_median, data_y$PEND_LGSG, method = "kendall", exact = FALSE)
cor.test(data_x$aridity_index_median, data_y$PEND_LGSG, method = "kendall",
exact = FALSE)
cor.test(data_x$rwi_weighted, data_y$PEND_LGSG, method = "kendall", exact =
FALSE)
cor.test(data_x$jlh_klg_listrik_pln, data_y$PEND_LGSG, method = "kendall", exact =
FALSE)
cor.test(data_x$jlh_fas_pddk, data_y$PEND_LGSG, method = "kendall", exact =
FALSE)
cor.test(data_x$jlh_fas_ksht, data_y$PEND_LGSG, method = "kendall", exact =
FALSE)
cor.test(data_x$jlh_imk, data_y$PEND_LGSG, method = "kendall", exact = FALSE)
cor.test(data_x$jlh_sentra_industri, data_y$PEND_LGSG, method = "kendall", exact =
FALSE)
cor.test(data_x$jlh_sarana_eko, data_y$PEND_LGSG, method = "kendall", exact =
FALSE)
cor.test(data_x$jlh_tmpt_ibdh, data_y$PEND_LGSG, method = "kendall", exact =
FALSE)
cor.test(data_x$kepadatan_penduduk, data_y$PEND_LGSG, method = "kendall", exact =
FALSE)
# Pemeriksaan multikolinearitas dengan VIF
model <- lm(data_y$PEND_LGSG
~data_x$ntl_median+data_x$lst_median+data_x$bui_median+data_x$co_median+data_x$p
m2.5_median+data_x$elevation_median+data_x$aridity_index_median+data_x$rwi_weigh
ted+data_x$jlh_klg_listrik_pln+data_x$jlh_fas_pddk+data_x$jlh_fas_ksht+data_x$j
lh_sarana_eko+data_x$jlh_tmpt_ibdh+data_x$kepadatan_penduduk)
summary(model)
vif(model)
# Backward Elimination
# Full model 13 kandidat variabel penyerta
M1 <- lm(data_y$PEND_LGSG
~data_x$ntl_median+data_x$bui_median+data_x$co_median+data_x$pm2.5_median+data_x
$elevation_median+data_x$aridity_index_median+data_x$rwi_weighted+data_x$jlh_klg
_listrik_pln+data_x$jlh_fas_pddk+data_x$jlh_fas_ksht+data_x$jlh_sarana_eko+data_
x$jlh_tmpt_ibdh+data_x$kepadatan_penduduk, data = dataset)
# null model
M0 <- lm(data_y$PEND_LGSG ~1, data = dataset)
# Backward Elimination
seleksi_model_aic <- step(M1, scope = list(lower = M0, upper = M1), direction =
"backward", k = 2)
autoplot(lm(formula = data_y$PEND_LGSG ~ data_x$bui_median + data_x$pm2.5_median +
data_x$elevation_median + data_x$rwi_weighted + data_x$jlh_fas_pddk +
data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh + data_x$kepadatan_penduduk, data =
dataset))
vif(seleksi_model_aic) # cek multikolinearitas setelah backward elimination
# Ekstrak nilai AIC
seleksi_model_aic$anova$AIC
# Hasil pengujian keberartian model dengan uji parsial t
summary(seleksi_model_aic)

```

Lampiran 23. Kode R menghitung estimasi tak langsung dengan 6 variabel penyerta terpilih menggunakan model SAE EBLUP-FH

```

# Import library
library(sae)
library(readxl)
# Import data variabel penyerta dan hasil estimasi langsung

```

```

dataset <- read_excel("E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/dataset_skripsi_revisi.xlsx", sheet = 1)
hasil_est_lgsg <- read_excel("E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/dataset_skripsi_revisi.xlsx", sheet = 2)
data_x <- dataset[, -c(1,2,3,4)]
## Estimasi tak langsung dengan model SAE EBLUP-FH
# Model EBLUP-FH 1 (8 variabel penyerta dari hasil backward elimination)
model_eblup_fh1 <- eblupFH(hasil_est_lgsg$Konsumsi_Listrik_Kapita ~
data_x$bui_median + data_x$pm2.5_median + data_x$elevation_median +
data_x$rwi_weighted + data_x$jlh_fas_pddk + data_x$jlh_sarana_eko +
data_x$jlh_tmpt_ibdh + data_x$kepadatan_penduduk, vardir = hasil_est_lgsg$Var,
method = "REML")
# Model EBLUP-FH 2 (kepadatan penduduk diexclude)
model_eblup_fh2 <- eblupFH(hasil_est_lgsg$Konsumsi_Listrik_Kapita ~
data_x$bui_median + data_x$pm2.5_median + data_x$elevation_median +
data_x$rwi_weighted + data_x$jlh_fas_pddk + data_x$jlh_sarana_eko +
data_x$jlh_tmpt_ibdh, vardir = hasil_est_lgsg$Var, method = "REML")
# Model EBLUP-FH 3 (fasilitas pendidikan diexclude)
model_eblup_fh3 <- eblupFH(hasil_est_lgsg$Konsumsi_Listrik_Kapita ~
data_x$bui_median + data_x$pm2.5_median + data_x$elevation_median +
data_x$rwi_weighted + data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh +
data_x$kepadatan_penduduk, vardir = hasil_est_lgsg$Var, method = "REML")
# Model EBLUP-FH 4 (kepadatan penduduk dan fasilitas pendidikan diexclude)
model_eblup_fh4 <- eblupFH(hasil_est_lgsg$Konsumsi_Listrik_Kapita ~
data_x$bui_median + data_x$pm2.5_median + data_x$elevation_median +
data_x$rwi_weighted + data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, vardir =
hasil_est_lgsg$Var, method = "REML")
# Fit model EBLUP-FH
model_eblup_fh1$fit
model_eblup_fh2$fit
model_eblup_fh3$fit
model_eblup_fh4$fit # model yang dipilih
# Ekstrak hasil estimasi model EBLUP-FH
y_eblup <- model_eblup_fh4$eblup
# Ekstrak koefisien ragam pengaruh acak
var_rand_eblup <- model_eblup_fh4$fit$refvar
# Ekstrak nilai random effect area
jln_baris <- nrow(dataset)
var_x <- matrix(c(data_x$bui_median + data_x$pm2.5_median +
data_x$elevation_median + data_x$rwi_weighted + data_x$jlh_sarana_eko +
data_x$jlh_tmpt_ibdh), nrow=jln_baris, ncol=6)
beta <- matrix(model_eblup_fh4$fit$estcoef$beta, ncol = 1)
beta_no_intercept <- matrix(beta[-1,], ncol = 1)
gama <-
model_eblup_fh4$fit$refvar/(model_eblup_fh4$fit$refvar+hasil_est_lgsg$Var)
y_mat <- matrix(hasil_est_lgsg$Konsumsi_Listrik_Kapita, ncol = 1)
rand_effect_eblup <- gama*(y_mat-var_x%*%beta_no_intercept)
# Ekstrak nilai residual
res_y_eblup <- hasil_est_lgsg$Konsumsi_Listrik_Kapita - y_eblup
# Uji normalitas random effect area dan residual
ks.test(rand_effect_eblup, "pnorm", mean(rand_effect_eblup),
sd(rand_effect_eblup))
ks.test(res_y_eblup, "pnorm", mean(res_y_eblup), sd(res_y_eblup))
# Ekstrak nilai MSE dan RRMSE model EBLUP-FH
mse_eblup <- mseFH(hasil_est_lgsg$Konsumsi_Listrik_Kapita ~ data_x$bui_median +
data_x$pm2.5_median + data_x$elevation_median + data_x$rwi_weighted +
data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, hasil_est_lgsg$Var, method="REML")
mse_fh <- mse_eblup$mse
rrmse_fh <- (sqrt(mse_fh)/y_eblup)*100
# Ekspor hasil estimasi ke penyimpanan lokal
data_est_eblupFH <- cbind(hasil_est_lgsg[,c(1,2,3)], y_eblup, mse_fh, rrmse_fh)
names(data_est_eblupFH) <- c("No", "KodeKec", "NamaKec", "Penduga_EBLUP_FH",
"MSE_EBLUP_FH", "RRMSE_EBLUP_FH")

```

```
write.csv(data_est_eblupFH,"E:/FOLDER KULIAH/STIS/SEMESTER  
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Estimasi_EBLUP_FH_MODEL.csv")
```

Lampiran 24. Kode R menghitung estimasi tak langsung dengan 6 variabel penyerta terpilih menggunakan model SAE SEBLUP-FH

```
# Import library
library(sae)
library(spdep)
library(rgdal)
library(nlme)
library(readxl)
library(MASS)

# Import data variabel penyerta dan hasil estimasi langsung
dataset <- read_excel("E:/FOLDER KULIAH/STIS/SEMESTER  
7/SKRIPSI/dataset_skripsi_revisi.xlsx", sheet = 1)
hasil_est_lgsg <- read_excel("E:/FOLDER KULIAH/STIS/SEMESTER  
7/SKRIPSI/dataset_skripsi_revisi.xlsx", sheet = 2)
data_x <- dataset[, -c(1,2,3,4)]

# Uji Moran's I
W <- read.gal("E:/GEOJSON/QC_MAT.gal", override.id=TRUE)
w <- nb2listw(W, glist=NULL, style="W", zero.policy=NULL)
Y <- hasil_est_lgsg$Konsumsi_Listrik_Kapita
moran.test(Y, w, randomisation=FALSE, zero.policy=TRUE, alternative="two.sided",
rank = FALSE, na.action=na.fail, spChk=NULL, adjust.n=TRUE)

# Menghitung spatial weight
jatengmap <- readOGR("E:/GEOJSON/join_new_data.shp")
spplot(jatengmap, "LISTRIK", sub="Rata-Rata Konsumsi Listrik Per Kapita")
# Membentuk matriks pembobot spasial
jateng.map <- st_read("E:/GEOJSON/join_new_data.shp", quiet=TRUE)
queen.w <- poly2nb(as(jateng.map, "Spatial"), queen = T)
# Membentuk matriks bobot tipe queen yang telah distandarisasi
queen.w1 <- nb2mat(queen.w, style = "W")

## Estimasi tak langsung dengan model SAE SEBLUP-FH
# Model SEBLUP-FH 1 (8 variabel penyerta dari hasil backward elimination)
model_seblup_fh1 <- eblupSFH(hasil_est_lgsg$Konsumsi_Listrik_Kapita ~
data_x$bui_median + data_x$pm2.5_median + data_x$elevation_median +
data_x$rwi_weighted + data_x$jlh_fas_pddk + data_x$jlh_sarana_eko +
data_x$jlh_tmpt_ibdh + data_x$kepadatan_penduduk, vardir = hasil_est_lgsg$Var,
proxmat = queen.w1, method="REML")

# Model SEBLUP-FH 2 (kepadatan penduduk diexclude)
model_seblup_fh2 <- eblupSFH(hasil_est_lgsg$Konsumsi_Listrik_Kapita ~
data_x$bui_median + data_x$pm2.5_median + data_x$elevation_median +
data_x$rwi_weighted + data_x$jlh_fas_pddk + data_x$jlh_sarana_eko +
data_x$jlh_tmpt_ibdh, vardir = hasil_est_lgsg$Var, proxmat = queen.w1,
method="REML")

# Model SEBLUP-FH 3 (fasilitas pendidikan diexclude)
model_seblup_fh3 <- eblupSFH(hasil_est_lgsg$Konsumsi_Listrik_Kapita ~
data_x$bui_median + data_x$pm2.5_median + data_x$elevation_median +
data_x$rwi_weighted + data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh +
data_x$kepadatan_penduduk, vardir = hasil_est_lgsg$Var, proxmat = queen.w1,
method="REML")

# Model SEBLUP-FH 4 (fasilitas pendidikan dan kepadatan penduduk diexclude)
model_seblup_fh4 <- eblupSFH(hasil_est_lgsg$Konsumsi_Listrik_Kapita ~
data_x$bui_median + data_x$pm2.5_median + data_x$elevation_median +
data_x$rwi_weighted + data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, vardir =
hasil_est_lgsg$Var, proxmat = queen.w1, method="REML")

# Fit model SEBLUP-FH
model_seblup_fh1$fit
model_seblup_fh2$fit
model_seblup_fh3$fit
model_seblup_fh4$fit # model yang dipilih
# Ekstrak hasil estimasi model SEBLUP-FH
```

```

y_seblup <- model_seblup_fh4$eblup
# Ekstrak koefisien ragam pengaruh acak dan koefisien autoregresi spasial
var_rand_seblup <- model_seblup_fh4$fit$refvar
cor_rand_seblup <- model_seblup_fh4$fit$spatialcorr
# Ekstrak nilai random effect area
jlh_baris <- nrow(dataset)
var_x_seblup <- matrix(c(data_x$bui_median + data_x$pm2.5_median +
data_x$elevation_median + data_x$rwi_weighted + data_x$jlh_sarana_eko +
data_x$jlh_tmpt_ibdh), nrow=jlh_baris, ncol=6)
beta_seblup <- matrix(model_seblup_fh4$fit$estcoef$beta, ncol = 1)
beta_seblup_no_intercept <- matrix(beta_seblup[-1,], ncol = 1)
gama_seblup <-
model_seblup_fh4$fit$refvar/(model_seblup_fh4$fit$refvar+hasil_est_lgsg$Var)
y_mat <- matrix(hasil_est_lgsg$Konsumsi_Listrik_Kapita, ncol = 1)
rand_effect_seblup <-gama_seblup*(y_mat-var_x_seblup%*%beta_seblup_no_intercept)
# Ekstrak nilai residual
res_y_seblup <- hasil_est_lgsg$Konsumsi_Listrik_Kapita - y_seblup
# Uji normalitas random effect area dan residual
ks.test(rand_effect_seblup, "pnorm", mean(rand_effect_seblup),
sd(rand_effect_seblup))
ks.test(res_y_seblup, "pnorm", mean(res_y_seblup), sd(res_y_seblup))
# Ekstrak nilai MSE dan RRMSE model SEBLUP-FH
mse_seblup <- mseSFH(hasil_est_lgsg$Konsumsi_Listrik_Kapita ~ data_x$bui_median +
data_x$pm2.5_median + data_x$elevation_median + data_x$rwi_weighted +
data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, hasil_est_lgsg$Var, proxmat =
queen.w1, method="REML")
mse_sfh <- round(mse_seblup$mse, 5)
rrmse_sfh <- round((sqrt(mse_sfh)/y_seblup)*100, 5)
# Ekspor hasil estimasi ke penyimpanan lokal
data_est_seblupFH <- cbind(hasil_est_lgsg[,c(1,2,3)], y_seblup, mse_sfh,
rrmse_sfh)
names(data_est_seblupFH) <- c("No", "KodeKec", "NamaKec", "Penduga_SEBLUP_FH",
"MSE_SEBLUP_FH", "RRMSE_SEBLUP_FH")
write.csv(data_est_seblupFH, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Estimasi_SEBLUP_FH.csv")

```

Lampiran 25. Kode R menghitung estimasi tak langsung dengan 6 variabel penyerta terpilih menggunakan model SAE HB *Lognormal*

```

# Import library
library(readxl)
library(rjags)
library(saeHB)
# Import data hasil estimasi langsung
dataset <- read_excel("E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/dataset_skripsi_revisi.xlsx", sheet = 1)
# Inisiasi nilai prior
c <- c(0,0,0,0,0,0)
vc <- c(1,1,1,1,1,1)
set.seed(123)
## Model HB 1 (burn.in = 2000, iter.mcmc = 10000, iter.update = 3, thin = 3)
model.log.normal1 <- Lognormal(PEND_LGSG ~ data_x$bui_median +
data_x$pm2.5_median + data_x$elevation_median + data_x$rwi_weighted +
data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, iter.update = 3, iter.mcmc =
10000, coef = c, var.coef = vc, thin = 3, burn.in = 2000, tau.u = 1, data =
dataset)
# Korelasi kendall antara penduga HB dengan penduga langsung
cor.test(model.log.normal1$Est$MEAN, dataset$PEND_LGSG, method = "kendall")
y_hb1 <- model.log.normal1$Est$MEAN
var_hb1 <- model.log.normal1$Est$SD^2
std_hb1 <- model.log.normal1$Est$SD
lb_hb1 <- model.log.normal1$Est`2.5%
ub_hb1 <- model.log.normal1$Est`97.5%

```

```

mse_hb1 <- var_hb1
rse_hb1 <- round((sqrt(mse_hb1)/y_hb1)*100, 5)
var_rand_hb1 <- model.log.normal1$refvar
autocorr.plot(model.log.normal1$plot[[3]], col="red") # generate ACF Plot
plot(model.log.normal1$plot[[3]], col="red") # generate Density and trace plot
# Ekspor hasil estimasi ke penyimpanan lokal
data_est_hb1 <- cbind(hasil_est_lgsg[,c(1,2,3)], y_hb1, std_hb1, lb_hb1, ub_hb1,
var_hb1, mse_hb1, rse_hb1)
names(data_est_hb1) <- c("No", "KodeKec", "NamaKec", "Penduga_HB1", "SD_HB1",
"LB_HB1", "UB_HB1", "VAR_HB1", "MSE_HB1", "RSE_HB1")
write.csv(data_est_hb1,"E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Estimasi_MODEL_HB1.csv")
# Ekspor hasil estimasi koefisien ke penyimpanan lokal
beta_koef_hb1 <- model.log.normal1$coefficient$Mean
sd_koef_hb1 <- model.log.normal1$coefficient$SD
lb_koef_hb1 <- model.log.normal1$coefficient`2.5%
ub_koef_hb1 <- model.log.normal1$coefficient`97.5%
est_koef_param <- c("b0", "b1", "b2", "b3", "b4", "b5", "b6")
data_est_koef_hb1 <- cbind(est_koef_param, beta_koef_hb1, sd_koef_hb1,
lb_koef_hb1, ub_koef_hb1)
write.csv(data_est_koef_hb1,"E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Est_Koef_MODEL_HB1.csv")

## Model HB 2 (burn in = 3000, iter.mcmc = 15000, iter.update = 5, thin = 5)
model.log.normal2 <- Lognormal(PEND_LGSG ~ data_x$bui_median +
data_x$pm2.5_median + data_x$elevation_median + data_x$rwi_weighted +
data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, iter.update = 5, iter.mcmc =
15000, coef = c, var.coef = vc, thin = 5, burn.in = 3000, tau.u = 1, data =
dataset)
# Korelasi kendall antara penduga HB dengan penduga langsung
cor.test(model.log.normal2$Est$MEAN, dataset$PEND_LGSG, method = "kendall")
y_hb2 <- model.log.normal2$Est$MEAN
var_hb2 <- model.log.normal2$Est$SD^2
std_hb2 <- model.log.normal2$Est$SD
lb_hb2 <- model.log.normal2$Est`2.5%
ub_hb2 <- model.log.normal2$Est`97.5%
mse_hb2 <- var_hb2
rse_hb2 <- round((sqrt(mse_hb2)/y_hb2)*100, 5)
var_rand_hb2 <- model.log.normal2$refvar
autocorr.plot(model.log.normal2$plot[[3]], col="red") # generate ACF Plot
plot(model.log.normal2$plot[[3]], col="red") # generate Density and trace plot
# Ekspor hasil estimasi ke penyimpanan lokal
data_est_hb2 <- cbind(hasil_est_lgsg[,c(1,2,3)], y_hb2, std_hb2, lb_hb2, ub_hb2,
var_hb2, mse_hb2, rse_hb2)
names(data_est_hb2) <- c("No", "KodeKec", "NamaKec", "Penduga_HB2", "SD_HB2",
"LB_HB2", "UB_HB2", "VAR_HB2", "MSE_HB2", "RSE_HB2")
write.csv(data_est_hb2, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Estimasi_MODEL_HB2.csv")
# Ekspor hasil estimasi koefisiein ke penyimpanan lokal
beta_koef_hb2 <- model.log.normal2$coefficient$Mean
sd_koef_hb2 <- model.log.normal2$coefficient$SD
lb_koef_hb2 <- model.log.normal2$coefficient`2.5%
ub_koef_hb2 <- model.log.normal2$coefficient`97.5%
est_koef_param <- c("b0", "b1", "b2", "b3", "b4", "b5", "b6")
data_est_koef_hb2 <- cbind(est_koef_param, beta_koef_hb2, sd_koef_hb2,
lb_koef_hb2, ub_koef_hb2)
write.csv(data_est_koef_hb2, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Est_Koef_MODEL_HB2.csv")

## Model HB 3 (burn in = 4000, iter.mcmc = 20000, iter.update = 7, thin = 7)
model.log.normal3 <- Lognormal(PEND_LGSG ~ data_x$bui_median +
data_x$pm2.5_median + data_x$elevation_median + data_x$rwi_weighted +
data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, iter.update = 7, iter.mcmc =

```

```

20000, coef = c, var.coef = vc, thin = 7, burn.in = 4000, tau.u = 1, data =
dataset)
# Korelasi kendall antara penduga HB dengan penduga langsung
cor.test(model.log.normal3$Est$MEAN, dataset$PEND_LGSG, method ="kendall")
y_hb3 <- model.log.normal3$Est$MEAN
var_hb3 <- model.log.normal3$Est$SD^2
std_hb3 <- model.log.normal3$Est$SD
lb_hb3 <- model.log.normal3$Est`2.5%
ub_hb3 <- model.log.normal3$Est`97.5%
mse_hb3 <- var_hb3
rse_hb3 <- round((sqrt(mse_hb3)/y_hb3)*100, 5)
var_rand_hb3 <- model.log.normal3$refvar
autocorr.plot(model.log.normal3$plot[[3]], col="red") # generate ACF Plot
plot(model.log.normal3$plot[[3]], col="red") # generate Density and trace plot
# Ekspor hasil estimasi ke penyimpanan lokal
data_est_hb3 <- cbind(hasil_est_lgsg[,c(1,2,3)], y_hb3, std_hb3, lb_hb3, ub_hb3,
var_hb3, mse_hb3, rse_hb3)
names(data_est_hb3) <- c("No", "KodeKec", "NamaKec", "Penduga_HB3", "SD_HB3",
"LB_HB3", "UB_HB3", "VAR_HB3", "MSE_HB3", "RSE_HB3")
write.csv(data_est_hb3, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Estimasi_MODEL_HB3.csv")
# Ekspor hasil estimasi koefisien ke penyimpanan lokal
beta_koef_hb3 <- model.log.normal3$coefficient$Mean
sd_koef_hb3 <- model.log.normal3$coefficient$SD
lb_koef_hb3 <- model.log.normal3$coefficient`2.5%
ub_koef_hb3 <- model.log.normal3$coefficient`97.5%
est_koef_param <- c("b0", "b1", "b2", "b3", "b4", "b5", "b6")
data_est_koef_hb3 <- cbind(est_koef_param, beta_koef_hb3, sd_koef_hb3,
lb_koef_hb3, ub_koef_hb3)
write.csv(data_est_koef_hb3, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Est_Koef_MODEL_HB3.csv")

## Model HB 4 (burn in = 5000, iter.mcmc = 25000, iter.update = 9, thin = 9)
model.log.normal4 <- Lognormal(PEND_LGSG ~ data_x$bui_median +
data_x$pm2.5_median + data_x$elevation_median + data_x$rw_i_weighted +
data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, iter.update = 9, iter.mcmc =
25000, coef = c, var.coef = vc, thin = 9, burn.in = 5000, tau.u = 1, data =
dataset)
# Korelasi kendall antara penduga HB dengan penduga langsung
cor.test(model.log.normal4$Est$MEAN, dataset$PEND_LGSG, method = "kendall")
y_hb4 <- model.log.normal4$Est$MEAN
std_hb4 <- model.log.normal4$Est$SD
lb_hb4 <- model.log.normal4$Est`2.5%
ub_hb4 <- model.log.normal4$Est`97.5%
var_hb4 <- model.log.normal4$Est$SD^2
mse_hb4 <- var_hb4
rse_hb4 <- round((sqrt(mse_hb4)/y_hb4)*100, 5)
var_rand_hb4 <- model.log.normal4$refvar
autocorr.plot(model.log.normal4$plot[[3]], col="red") # generate ACF Plot
plot(model.log.normal4$plot[[3]], col="red") # generate Density and trace plot
# Ekspor hasil estimasi ke penyimpanan lokal
data_est_hb4 <- cbind(hasil_est_lgsg[,c(1,2,3)], y_hb4, std_hb4, lb_hb4, ub_hb4,
var_hb4, mse_hb4, rse_hb4)
names(data_est_hb4) <- c("No", "KodeKec", "NamaKec", "Penduga_HB4", "SD_HB4",
"LB_HB4", "UB_HB4", "VAR_HB4", "MSE_HB4", "RSE_HB4")
write.csv(data_est_hb4, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Estimasi_MODEL_HB4.csv")
# Ekspor hasil estimasi koefisien ke penyimpanan lokal
beta_koef_hb4 <- model.log.normal4$coefficient$Mean
sd_koef_hb4 <- model.log.normal4$coefficient$SD
lb_koef_hb4 <- model.log.normal4$coefficient`2.5%
ub_koef_hb4 <- model.log.normal4$coefficient`97.5%
est_koef_param <- c("b0", "b1", "b2", "b3", "b4", "b5", "b6")

```

```

data_est_koef_hb4 <- cbind(est_koef_param, beta_koef_hb4, sd_koef_hb4,
lb_koef_hb4, ub_koef_hb4)
write.csv(data_est_koef_hb4, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPPSI/HASIL_RUNNING_MODEL/Hasil_Est_Koef_MODEL_HB4.csv")

## Model HB 5 (burn in = 6000, iter.mcmc = 30000, iter.update = 11, thin = 11)
model.log.normal5 <- Lognormal(PEND_LGSG ~ data_x$bui_median +
data_x$pm2.5_median + data_x$elevation_median + data_x$rwi_weighted+
data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, iter.update = 11, iter.mcmc =
35000, coef = c, var.coef = vc, thin = 11, burn.in = 6000, tau.u = 1, data =
dataset)
# Korelasi kendall antara penduga HB dengan penduga langsung
cor.test(model.log.normal5$Est$MEAN, dataset$PEND_LGSG, method = 'kendall')
y_hb5 <- model.log.normal5$Est$MEAN
std_hb5 <- model.log.normal5$Est$SD
lb_hb5 <- model.log.normal5$Est`2.5%
ub_hb5 <- model.log.normal5$Est`97.5%
var_hb5 <- model.log.normal5$Est$SD^2
mse_hb5 <- var_hb5
rse_hb5 <- round((sqrt(mse_hb5)/y_hb5)*100, 5)
var_rand_hb5 <- model.log.normal5$refvar
autocorr.plot(model.log.normal5$plot[[3]], col="red") # generate ACF Plot
plot(model.log.normal5$plot[[3]], col="red") # generate Density and trace plot
# Ekspor hasil estimasi ke penyimpanan lokal
data_est_hb5 <- cbind(hasil_est_lgsg[,c(1,2,3)], y_hb5, std_hb5, lb_hb5, ub_hb5,
var_hb5, mse_hb5, rse_hb5)
names(data_est_hb5) <- c("No", "KodeKec", "NamaKec", "Penduga_HB5", "SD_HB5",
"LB_HB5", "UB_HB5", "VAR_HB5", "MSE_HB5", "RSE_HB5")
write.csv(data_est_hb5, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPPSI/HASIL_RUNNING_MODEL/Hasil_Estimasi_MODEL_HB5.csv")
# Ekspor hasil estimasi koefisien ke penyimpanan lokal
beta_koef_hb5 <- model.log.normal5$coefficient$Mean
sd_koef_hb5 <- model.log.normal5$coefficient$SD
lb_koef_hb5 <- model.log.normal5$coefficient`2.5%
ub_koef_hb5 <- model.log.normal5$coefficient`97.5%
est_koef_param <- c("b0", "b1", "b2", "b3", "b4", "b5", "b6")
data_est_koef_hb5 <- cbind(est_koef_param, beta_koef_hb5, sd_koef_hb5,
lb_koef_hb5, ub_koef_hb5)
write.csv(data_est_koef_hb5, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPPSI/HASIL_RUNNING_MODEL/Hasil_Est_Koef_MODEL_HB5.csv")

## Model HB 6 (burn in = 7000, iter.mcmc = 35000, iter.update = 13, thin = 13)
model.log.normal6 <- Lognormal(PEND_LGSG ~ data_x$bui_median +
data_x$pm2.5_median + data_x$elevation_median + data_x$rwi_weighted +
data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, iter.update = 13, iter.mcmc =
40000, coef = c, var.coef = vc, thin = 13, burn.in = 7000, tau.u = 1, data =
dataset)
# Korelasi kendall antara penduga HB dengan penduga langsung
cor.test(model.log.normal6$Est$MEAN, dataset$PEND_LGSG, method = "kendall")
y_hb6 <- model.log.normal6$Est$MEAN
std_hb6 <- model.log.normal6$Est$SD
lb_hb6 <- model.log.normal6$Est`2.5%
ub_hb6 <- model.log.normal6$Est`97.5%
var_hb6 <- model.log.normal6$Est$SD^2
mse_hb6 <- var_hb6
rse_hb6 <- round((sqrt(mse_hb6)/y_hb6)*100, 5)
var_rand_hb6 <- model.log.normal6$refvar
autocorr.plot(model.log.normal6$plot[[3]], col="red") # generate ACF Plot
plot(model.log.normal6$plot[[3]], col="red") # generate Density and trace plot
# Ekspor hasil estimasi ke penyimpanan lokal
data_est_hb6 <- cbind(hasil_est_lgsg[,c(1,2,3)], y_hb6, std_hb6, lb_hb6, ub_hb6,
var_hb6, mse_hb6, rse_hb6)
names(data_est_hb6) <- c("No", "KodeKec", "NamaKec", "Penduga_HB6", "SD_HB6",
"LB_HB6", "UB_HB6", "VAR_HB6", "MSE_HB6", "RSE_HB6")

```

```

write.csv(data_est_hb6, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Estimasi_MODEL_HB6.csv")
# Ekspor hasil estimasi koefisien ke penyimpanan lokal
beta_koef_hb6 <- model.log.normal6$coefficient$Mean
sd_koef_hb6 <- model.log.normal6$coefficient$SD
lb_koef_hb6 <- model.log.normal6$coefficient`2.5%
ub_koef_hb6 <- model.log.normal6$coefficient`97.5%
est_koef_param <- c("b0", "b1", "b2", "b3", "b4", "b5", "b6")
data_est_koef_hb6 <- cbind(est_koef_param, beta_koef_hb6, sd_koef_hb6,
lb_koef_hb6, ub_koef_hb6)
write.csv(data_est_koef_hb6, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Est_Koef_MODEL_HB6.csv")

## Model HB 7 (burn in = 8000, iter.mcmc = 45000, iter.update = 15, thin = 15)
model.log.normal7 <- Lognormal(PEND_LGSG ~ data_x$bui_median +
data_x$pm2.5_median + data_x$elevation_median + data_x$rwi_weighted +
data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, iter.update = 15, iter.mcmc =
45000, coef = c, var.coef = vc, thin = 15, burn.in = 8000, tau.u = 1, data =
dataset)
# Korelasi kendall antara penduga HB dengan penduga langsung
cor.test(model.log.normal7$Est$MEAN, dataset$PEND_LGSG, method = "kendall")
y_hb7 <- model.log.normal7$Est$MEAN
std_hb7 <- model.log.normal7$Est$SD
lb_hb7 <- model.log.normal7$Est`2.5%
ub_hb7 <- model.log.normal7$Est`97.5%
var_hb7 <- model.log.normal7$Est$SD^2
mse_hb7 <- var_hb7
rse_hb7 <- round((sqrt(mse_hb7)/y_hb7)*100, 5)
var_rand_hb7 <- model.log.normal7$refvar
autocorr.plot(model.log.normal7$plot[[3]], col="red") # generate ACF Plot
plot(model.log.normal7$plot[[3]], col="red") # generate Density and trace plot
# Ekspor hasil estimasi ke penyimpanan lokal
data_est_hb7 <- cbind(hasil_est_lgsg[,c(1,2,3)], y_hb7, std_hb7, lb_hb7, ub_hb7,
var_hb7, mse_hb7, rse_hb7)
names(data_est_hb7) <- c("No", "KodeKec", "NamaKec", "Penduga_HB7", "SD_HB7",
"LB_HB7", "UB_HB7", "VAR_HB7", "MSE_HB7", "RSE_HB7")
write.csv(data_est_hb7, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Estimasi_MODEL_HB7.csv")
# Ekspor hasil estimasi koefisien ke penyimpanan lokal
beta_koef_hb7 <- model.log.normal7$coefficient$Mean
sd_koef_hb7 <- model.log.normal7$coefficient$SD
lb_koef_hb7 <- model.log.normal7$coefficient`2.5%
ub_koef_hb7 <- model.log.normal7$coefficient`97.5%
est_koef_param <- c("b0", "b1", "b2", "b3", "b4", "b5", "b6")
data_est_koef_hb7 <- cbind(est_koef_param, beta_koef_hb7, sd_koef_hb7,
lb_koef_hb7, ub_koef_hb7)
write.csv(data_est_koef_hb7, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Est_Koef_MODEL_HB7.csv")

## Model HB 8 (burn in = 9000, iter.mcmc = 50000, iter.update = 16, thin = 16)
model.log.normal8 <- Lognormal(PEND_LGSG ~ data_x$bui_median +
data_x$pm2.5_median + data_x$elevation_median + data_x$rwi_weighted +
data_x$jlh_sarana_eko + data_x$jlh_tmpt_ibdh, iter.update = 16, iter.mcmc =
50000, coef = c, var.coef = vc, thin = 16, burn.in = 9000, tau.u = 1, data =
dataset)
# Korelasi kendall antara penduga HB dengan penduga langsung
cor.test(model.log.normal8$Est$MEAN, dataset$PEND_LGSG, method = "kendall")
y_hb8 <- model.log.normal8$Est$MEAN
std_hb8 <- model.log.normal8$Est$SD
lb_hb8 <- model.log.normal8$Est`2.5%
ub_hb8 <- model.log.normal8$Est`97.5%
var_hb8 <- model.log.normal8$Est$SD^2
mse_hb8 <- var_hb8
rse_hb8 <- round((sqrt(mse_hb8)/y_hb8)*100, 5)

```

```

var_rand_hb8 <- model.log.normal8$refvar
autocorr.plot(model.log.normal8$plot[[3]], col="red") # generate ACF Plot
plot(model.log.normal8$plot[[3]], col="red") # generate Density and trace plot
# Ekspor hasil estimasi ke penyimpanan lokal
data_est_hb8 <- cbind(hasil_est_lgsg[,c(1,2,3)], y_hb8, std_hb8, lb_hb8, ub_hb8,
var_hb8, mse_hb8, rse_hb8)
names(data_est_hb8) <- c("No", "KodeKec", "NamaKec", "Penduga_HB8", "SD_HB8",
"LB_HB8", "UB_HB8", "VAR_HB8", "MSE_HB8", "RSE_HB8")
write.csv(data_est_hb8, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Estimasi_MODEL_HB8.csv")
# Ekspor hasil estimasi koefisien ke penyimpanan lokal
beta_koef_hb8 <- model.log.normal8$coefficient$Mean
sd_koef_hb8 <- model.log.normal8$coefficient$SD
lb_koef_hb8 <- model.log.normal8$coefficient`2.5%
ub_koef_hb8 <- model.log.normal8$coefficient`97.5%
est_koef_param <- c("b0", "b1", "b2", "b3", "b4", "b5", "b6")
data_est_koef_hb8 <- cbind(est_koef_param, beta_koef_hb8, sd_koef_hb8,
lb_koef_hb8, ub_koef_hb8)
write.csv(data_est_koef_hb8, "E:/FOLDER KULIAH/STIS/SEMESTER
7/SKRIPSI/HASIL_RUNNING_MODEL/Hasil_Est_Koef_MODEL_HB8.csv")

```

RIWAYAT HIDUP

Penulis bernama Raflizal Fikrar Odriansyah, lahir di Kota Semarang pada tanggal 7 Maret 2000. Penulis merupakan anak laki-laki dari pasangan Bapak Untung Rahardjo dan Ibu Sri Supartini dan merupakan anak bungsu. Penulis tinggal di Kota Jakarta Timur hingga saat ini.

Penulis mulai mengenyam pendidikan di TK Tarbiyatul Atfal 51 pada tahun 2005, kemudian melanjutkan ke jenjang pendidikan dasar di SD Negeri Pedurungan Kidul 02 mulai tahun 2006 hingga lulus tahun 2012. Pada tahun 2015, penulis menyelesaikan pendidikan menengah pertama di SMP Negeri 9 Semarang. Pada tahun yang sama penulis melanjutkan sekolah di SMA Negeri 2 Semarang. Pada tahun 2018, penulis diterima untuk mengikuti pendidikan perguruan tinggi di Universitas Diponegoro Semarang. Pada tahun 2019, penulis memutuskan untuk berpindah studi dan diterima untuk mengikuti pendidikan di Politeknik Statistika STIS Jakarta.

Akhirnya pada tahun 2023, atas izin Allah SWT, dukungan dan do'a dari keluarga dan teman, penulis berhasil menyelesaikan pendidikan Program Diploma IV di Politeknik Statistika STIS Jakarta.